

剑指 Offer

图像算法岗 100 道真题型面试题

Computer Vision Algorithm Interview Handbook

2026 Edition · 基础原理 × 真题追问 × 工程落地 × 前沿视觉

10	知识章节
100	核心面试题
Top 30	Offer 必会
6	附录/速查

校招 / 实习 / 社招 · 面试复习手册

采用题目驱动、递进追问、方法总结的技术面试书组织方式，不复刻任何受版权保护原文。

前言：这不是“背答案”的 100 题

真正的高分回答不是记住网络有几层，而是能从公式推到直觉、从直觉推到工程后果，再从工程失败反推数据与模型。

每题固定为：考察意图 → 标准回答 → 追问链 → 常见失分点 → 工程视角 → 一句话记忆。建议把每题练成 3-8 分钟口述。

只有能在公开面经中找到明确依据的题型才标记“公开面经原题/原型”；ViT、SAM、VLM、生成视觉等内容用于校准 2026 岗位能力结构，不冒充历史原题。

面试前最重要的不是继续扩题，而是把 Top 30、三段手撕和自己的 2-3 个项目打通。

使用方法

阶段	目标
第一遍：地图	只读核心结论与一句话记忆。
第二遍：口述	遮住正文，3 分钟回答后对照修正。
第三遍：追问	连续回答 2-4 个追问并联系自己的项目。
面试前 48h	Top30 + 公式 + NMS/IoU/BN + 项目因果链。

能力地图

模块	题号	建议权重	定位
传统 CV	1-10	8%	信号/几何直觉
CNN	11-25	18%	必问基本功
检测	26-40	20%	主战场
分割	41-50	12%	Dense Prediction
OCR	51-58	7%	专项
ViT/SAM/CLIP	59-67	12%	基础模型
Diffusion	68-75	7%	生成视觉
视频/3D/多模态	76-82	6%	前沿
数据/Eval	83-89	5%	工程判断
部署/系统/手撕	90-100	15%	Offer 分水岭

目录

01 第一章 传统图像处理与视觉基础 Q01-Q10

把图像看成信号：卷积、频域、边缘、颜色、尺度与几何。

02 第二章 CNN 与深度学习基本功 Q11-Q25

把经典模块讲到“公式 - 直觉 - 优缺点 - 工程后果”。

03 第三章 目标检测 Q26-Q40

从 R-CNN 到 YOLO/DETR：检测是图像算法岗最常见主战场。

04 第四章 图像分割 Q41-Q50

语义、实例、全景分割，以及工业/医学中的边界与长尾问题。

05 第五章 OCR 与文档视觉 Q51-Q58

文本检测、识别、CTC、几何矫正与线上域偏移。

06 第六章 ViT、自监督、CLIP 与 SAM Q59-Q67

从 CNN inductive bias 走向视觉基础模型和 promptable perception。

07 第七章 Diffusion 与生成视觉 Q68-Q75

理解扩散模型的训练目标、latent、guidance、可控生成和评价。

08 第八章 视频、3D 与多模态 Q76-Q82

时间、几何、传感器融合与 VLM：面向 2026 岗位能力结构。

09 第九章 数据、训练与 Evaluation Q83-Q89

真正区分候选人的往往是数据诊断、实验设计与误差分析。

10 第十章 压缩、部署、系统设计与手撕 Q90-Q100

从 FLOPs 到真实延迟，从 PyTorch 到 TensorRT，从模型到可上线系统。

第一章 传统图像处理与视觉基础

本章目标

把图像看成信号：卷积、频域、边缘、颜色、尺度与几何。

本章速览：卷积在图像处理中到底做了什么？ / Gaussian Blur 为什么能去噪？ / Sobel、Laplacian、Canny 有什么区别？ / Histogram Equalization 为什么能提高对比度？ / ...

Q001 卷积在图像处理中到底做了什么？

难度 ★★★ 高频 ★★★★★ 标签：公开面经近似原题

面试官在考什么

卷积用共享局部核对邻域做线性组合；传统 CV 手工设计核，CNN 则让核由数据学习。

标准回答：从公式到直觉

1. 二维形式 $Y(i,j)=\sum X(i+m,j+n)K(m,n)$ ；深度学习库常实现 cross-correlation，但可学习参数使两者表达等价
2. 局部连接利用空间相关性，权重共享显著减少参数，并带来近似平移等变性
3. Gaussian/Sobel/Laplacian 分别对应低通、梯度与二阶变化；CNN 从局部纹理逐层形成语义

高频追问链

- 为什么是平移等变而不是不变？
- padding/stride/dilation 各改变什么？
- 1×1 卷积为什么有效？

常见失分点

只说“卷积提取特征”太空泛，也不要混淆 convolution 与 cross-correlation。

工程/项目视角

训练与部署的 padding/resize 必须一致，否则边界分布会漂移。

一句话记忆

卷积 = 局部 + 共享 + 等变。

Q002 Gaussian Blur 为什么能去噪？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

Gaussian blur 是低通滤波，会衰减快速变化的高频；但边缘也是高频，因此存在去噪与保边 trade-off。

标准回答：从公式到直觉

1. $G(x,y)=1/(2\pi\sigma^2)\exp(-(x^2+y^2)/(2\sigma^2))$ ， σ 越大平滑尺度越大
2. Gaussian 在频域仍是高斯，频率响应平滑，不易产生理想低通的 ringing
3. 椒盐噪声常更适合 median filter，因为中值对极端点更鲁棒

高频追问链

- σ 与 kernel size 如何配合？
- Gaussian 与 bilateral filter 的差异？

常见失分点

“高频=噪声”是错误的；纹理、边缘、细裂纹同样是高频。

工程/项目视角

微小缺陷/文字任务中，过强平滑会直接伤 recall。

一句话记忆

先分析噪声频谱，再决定是否平滑。

Q003 Sobel、Laplacian、Canny 有什么区别？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

Sobel 是一阶梯度，Laplacian 是二阶导数，Canny 是从平滑到细化再到连通判断的完整边缘 pipeline。

标准回答：从公式到直觉

1. Sobel 计算 G_x/G_y ，可得到梯度幅值与方向
2. Laplacian 对噪声更敏感，通常需先平滑
3. Canny: Gaussian→gradient→NMS→double threshold→hysteresis；NMS 把宽边缘细化，滞后阈值利用连通性保留弱边缘

高频追问链

- Canny 两个阈值分别做什么？
- 为什么二阶导数更放大噪声？

常见失分点

不要把 Canny 简化成一个 Sobel 核。

工程/项目视角

传统边缘仍可用于工业预筛、辅助标注和几何先验。

一句话记忆

Sobel 看一阶，Laplacian 看二阶，Canny 做完整边缘流程。

Q004 Histogram Equalization 为什么能提高对比度？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

利用 CDF 重映射灰度，让密集灰度区被拉开；CLAHE 则在局部做均衡并限制过度增益。

标准回答：从公式到直觉

1. $s=T(r)=CDF(r)$ ，使有限动态范围被更充分使用
2. 全局 HE 对非均匀光照和噪声可能过度增强
3. CLAHE 分块处理并用 clip limit 限制 histogram 峰值，再插值融合

高频追问链

- CLAHE 为什么要 clip？
- Gamma correction 与 HE 有何不同？

常见失分点

“直方图更均匀”不等于视觉更自然。

工程/项目视角

医学/低照度任务要做 ablation，避免预处理改变部署分布。

一句话记忆

HE 拉开灰度；CLAHE 解决局部照明并控制噪声增益。

Q005 腐蚀、膨胀、开闭运算分别做什么？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

形态学用结构元素对前景集合做几何操作，是 mask 后处理、OCR 与工业视觉常用工具。

标准回答：从公式到直觉

1. 腐蚀收缩前景、去小凸起和细连接
2. 膨胀扩大前景、补缝和连接邻近区域
3. Opening=腐蚀后膨胀，常去小噪点；Closing=膨胀后腐蚀，常填小孔

高频追问链

- 结构元素形状为什么重要？
- 如何用形态学连接文本行？

常见失分点

忽略结构元素尺度与形状，等于只会调用 API。

工程/项目视角

后处理同样要纳入完整回归测试，避免吞掉小目标。

一句话记忆

腐蚀收缩、膨胀扩张；开去噪、闭补洞。

Q006 RGB、HSV、YCbCr 为什么要存在不同颜色空间？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

不同颜色空间以不同方式解耦亮度、色度和感知属性，服务于压缩、阈值、增强与人机交互。

标准回答：从公式到直觉

1. RGB 设备友好但亮度与颜色耦合
2. HSV 更接近“色相-饱和度-明度”操作，但低饱和时 hue 不稳定
3. YCbCr 分离 Y 与色度，人眼对亮度更敏感，因此视频编码可对色度做 4:2:0 子采样

高频追问链

- 为什么 JPEG/视频偏好 YCbCr？
- HSV 在灰色附近为什么不稳定？

常见失分点

颜色空间并非只是换坐标，常伴随量化与设备假设。

工程/项目视角

相机白平衡、色彩矩阵、HDR/SDR 路径变化都会造成 domain shift。

一句话记忆

RGB 面向设备，HSV 面向感知，YCbCr 面向亮度/色度分离。

Q007 什么是图像金字塔？它和 FPN 有什么关系？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

图像金字塔通过多尺度表示解决尺度变化；FPN 则在深度特征域做可学习的多尺度语义融合。

标准回答：从公式到直觉

1. Gaussian pyramid 逐层平滑与降采样；Laplacian pyramid 表示尺度残差
2. CNN 的 C2-C5 越深语义越强但分辨率越低
3. FPN 通过 top-down + lateral connection 构造 P2-P5，使高分辨率层也获得强语义

高频追问链

- FPN 为什么不是简单 resize？
- BiFPN/PAN 改了什么？

常见失分点

FPN 的关键是跨层语义融合，不只是多几个 feature map。

工程/项目视角

小目标是否需要 P2/tiling，应按真实像素尺寸分布决定。

一句话记忆

传统金字塔做像素尺度，FPN 做特征尺度。

Q008 SIFT 为什么具有尺度和旋转不变性？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

SIFT 在尺度空间找稳定极值，并用局部主方向对齐描述子，使特征对缩放与旋转更稳。

标准回答：从公式到直觉

1. DoG 在 Gaussian scale space 中找关键点，因此关键点带有内在尺度
2. 梯度方向直方图给关键点分配 dominant orientation
3. 经典 128 维描述子来自 4×4 cells $\times$ 8 orientation bins，归一化增强光照鲁棒性

高频追问链

- 为什么用 DoG？
- SIFT 与 ORB 的权衡？

常见失分点

SIFT 不是对所有仿射变化“完全不变”。

工程/项目视角

SLAM/SfM/重定位仍大量依赖可靠局部对应。

一句话记忆

尺度空间找点，主方向对齐，梯度直方图描述。

Q009 HOG 的基本原理是什么？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

HOG 用局部梯度方向统计描述轮廓，再通过 block normalization 增强光照/对比度鲁棒性。

标准回答：从公式到直觉

1. 先求像素梯度幅值与方向，在 cell 内累积方向直方图
2. 相邻 cells 组成 block 并归一化，降低整体亮度影响
3. HOG+SVM 曾是行人检测经典方案，也能帮助理解 CNN 第一层的 edge-like filters

高频追问链

- 为什么要 block normalization？
- HOG 与 SIFT 有何共同点？

常见失分点

HOG 不是简单边缘图，而是空间分块后的方向统计向量。

工程/项目视角

可作为小数据/轻量 baseline 或解释工具。

一句话记忆

HOG = 局部方向直方图 + block 归一化。

Q010 图像缩放为什么会发生 aliasing?

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

下采样降低 Nyquist 上限，若先不低通，高频会折叠成伪低频。

标准回答：从公式到直觉

1. 缩小前通常应做 anti-alias low-pass
2. nearest/bilinear/bicubic/area 隐含不同重建假设，训练与部署实现不一致会产生输入漂移
3. 小目标对 resize 特别敏感，bbox/mask/keypoint 的几何映射也必须完全一致

高频追问链

- 为什么下采样比上采样更需要 anti-alias?
- align_corners 会带来什么差异?

常见失分点

只背插值公式而忽略采样理论和坐标一致性会失分。

工程/项目视角

上线前最好做 preprocessing 数值回归。

一句话记忆

缩小前先限频；resize 是模型分布的一部分。

第二章 CNN 与深度学习基本功

本章目标

把经典模块讲到“公式 - 直觉 - 优缺点 - 工程后果”。

本章速览：为什么 CNN 适合处理图像？ / 卷积层参数量和 FLOPs 怎么计算？ / 什么是 receptive field？怎么计算？ / 为什么深层网络会梯度消失/爆炸？ / ...

Q011 为什么 CNN 适合处理图像？

难度 ★★★ 高频 ★★★★★ 标签：公开面经高频

面试官在考什么

CNN 把局部性、权重共享和层级结构作为 inductive bias，提高参数效率与小数据样本效率。

标准回答：从公式到直觉

1. Locality 假设邻近像素先交互
2. Weight sharing 假设同类模式可出现在不同位置
3. 层级表征从边缘/纹理逐步形成部件与语义；卷积本身更接近平移等变而不是平移不变

高频追问链

- CNN 的 inductive bias 对 ViT 是优势还是限制？
- 什么时候等变性会被破坏？

常见失分点

“CNN 有平移不变性”不严谨。

工程/项目视角

小数据、边缘设备和局部纹理任务中 CNN 仍很强。

一句话记忆

CNN 的核心是局部、共享、层级。

Q012 卷积层参数量和 FLOPs 怎么计算？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

参数量由 kernel 与输入/输出通道决定；计算量还要乘输出空间位置数。

标准回答：从公式到直觉

1. 参数 $\approx K_h \cdot K_w \cdot C_{in} \cdot C_{out}$ （加 bias 则 $+C_{out}$ ）
2. MACs $\approx H_{out} \cdot W_{out} \cdot K_h \cdot K_w \cdot C_{in} \cdot C_{out}$ ；若乘加各算一次，FLOPs $\approx 2 \times \text{MACs}$
3. Group conv 再除 groups；Depthwise 约 $K_h \cdot K_w \cdot C_{in}$ ，Pointwise 为 $C_{in} \cdot C_{out}$

高频追问链

- 给定 $224 \times 224 \times 64$ ， 3×3 到 128 通道怎么算？
- 为什么 FLOPs 与 latency 不等价？

常见失分点

最常见错误是忘记输出 $H \times W$ 、groups，或混用 MAC/FLOP 口径。

工程/项目视角

部署要同时看参数、activation memory、memory access 与 kernel profile。

一句话记忆

参数看核和通道；计算再乘输出位置。

Q013 什么是 receptive field? 怎么计算?

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

感受野是某个 feature 位置在原输入上可能依赖的区域；stride/dilation 会累积扩大。

标准回答：从公式到直觉

1. 常用递推 $j_l = j_{l-1}s_l$, $r_l = r_{l-1} + (k_l - 1)d_lj_{l-1}$
2. stride 改变后续采样步长，dilation 扩大等效 kernel
3. theoretical receptive field 是最大可达区域，effective receptive field 往往更集中在中心

高频追问链

- 两个 3×3 stride1 的感受野是多少?
- dilation=2 的 3×3 等效尺寸?

常见失分点

不要把 feature map size 与 receptive field 混淆。

工程/项目视角

小目标任务中，先下采样丢掉的信息无法靠大感受野补回来。

一句话记忆

感受野是“看得到多大”，有效感受野是“真正依赖多大”。

Q014 为什么深层网络会梯度消失/爆炸?

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经高频

面试官在考什么

反向传播是多层 Jacobian 连乘，尺度长期小于/大于 1 会指数衰减/增长。

标准回答：从公式到直觉

1. Sigmoid 饱和区导数接近 0，是经典消失来源
2. Xavier/He 控制初始方差，ReLU/Norm 改善信号尺度，Residual 提供直接路径
3. gradient clipping 主要限制爆炸；mixed precision 还需关注 loss scaling/overflow

高频追问链

- ResNet identity path 为什么有帮助?
- BN 能完全解决梯度问题吗?

常见失分点

不要把所有训练困难都归因于梯度消失。

工程/项目视角

排查 NaN 应记录 activation/gradient norm、overflow 与学习率。

一句话记忆

深网络梯度是连乘；稳定训练要同时控制尺度和路径。

Q015 Xavier 和 He 初始化有什么区别？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

二者都从方差传播出发；Xavier 适合近似对称激活，He 针对 ReLU 的截断特性。

标准回答：从公式到直觉

1. Xavier 常见 $\text{Var}(W) \approx 2/(\text{fan_in} + \text{fan_out})$
2. He 对 ReLU 常用 $\text{Var}(W) = 2/\text{fan_in}$ ，补偿一半负值被截断
3. 目的不是“随机”，而是让深层网络初始时前后向信号处于可优化数值区间

高频追问链

- fan_in/fan_out 是什么？
- 预训练 backbone 需要重新初始化吗？

常见失分点

只背公式但说不出方差传播直觉会被追问。

工程/项目视角

新增 head 的初始化与 backbone 预训练状态要区别处理。

一句话记忆

Xavier 保方差，He 为 ReLU 截断做补偿。

Q016 BatchNorm 为什么有效？训练和推理有什么区别？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经原型/手撕高频

面试官在考什么

BN 用 batch statistics 归一化，再用可学习 γ/β 恢复表示能力；推理改用 running statistics。

标准回答：从公式到直觉

1. 训练： $\hat{x} = (x - \mu_B) / \sqrt{\text{var}_B + \epsilon}$ ， $y = \gamma \hat{x} + \beta$
2. γ/β 使网络可学回任意尺度，不强迫恒定零均值单位方差
3. BN 更适合理解为改善优化条件、降低尺度敏感性并带来 batch noise 正则；小 batch 可用 SyncBN/GN/FrozenBN

高频追问链

- running mean/var 怎么更新？
- 为什么 γ/β 必须可学？
- batch size=1 会怎样？

常见失分点

推理若误用当前 batch stats，或忘记 eval()，结果会明显漂移。

工程/项目视角

导出时要确认 BN folding、epsilon 与 running stats。

一句话记忆

BN = 批统计归一化 + $\gamma\beta$ ；训练看 batch，推理看 running。

Q017 BN、LN、GN 有什么区别？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

本质区别是“在哪些轴统计”；选择由结构和 batch 条件决定。

标准回答：从公式到直觉

1. BN 对同 channel 跨 batch/空间统计，依赖 batch
2. LN 对单样本 feature 维统计，不依赖其他样本，适合 Transformer
3. GN 在单样本内把 channels 分组统计，适合检测/分割小 batch；InstanceNorm 可视为更极端的通道独立归一化

高频追问链

- 为什么 Transformer 常用 LN？
- GN 的 group 数怎么选？

常见失分点

不能只背“BN 对 batch、LN 对 layer”，要说统计轴。

工程/项目视角

训练到部署还要关注 norm fusion 与数值一致性。

一句话记忆

Norm 的核心问题：统计谁、统计哪些轴、是否依赖 batch。

Q018 为什么 ResNet 可以训练很深？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

$y=x+F(x)$ 让 identity mapping 易表达，并给信息与梯度提供低阻力通道，显著改善深网络优化。

标准回答：从公式到直觉

1. 若最优映射接近 identity，普通网络需学 $H(x)=x$ ，残差网络只需让 $F(x)\approx 0$
2. 梯度含 identity term 1，但不能简单说“彻底解决梯度消失”
3. ResNet 主要解决深度增加带来的 degradation/optimization 难题

高频追问链

- projection shortcut 为什么用 1×1 ？
- bottleneck 为什么 $1\times 1-3\times 3-1\times 1$ ？

常见失分点

“残差就是特征相加”没有解释优化本质。

工程/项目视角

现代 ConvNeXt/Transformer 同样大量依赖 residual path。

一句话记忆

ResNet 的关键是 identity highway。

Q019 ReLU 为什么比 sigmoid 更适合深网络？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

ReLU 正半轴导数为 1，减少饱和导致的梯度衰减，同时计算简单并产生稀疏激活。

标准回答：从公式到直觉

1. Sigmoid 最大导数约 0.25 且两端饱和
2. ReLU $f(x)=\max(0,x)$ ，正区间梯度恒 1
3. 缺点是 dead ReLU；LeakyReLU/PReLU 保留负斜率，GELU/SiLU 提供更平滑门控

高频追问链

- dead ReLU 为什么发生？
- GELU 与 ReLU 的直觉差异？

常见失分点

不要说 ReLU “没有梯度消失”，负半轴仍为 0。

工程/项目视角

移动端激活还要考虑算子支持与硬件延迟。

一句话记忆

ReLU 用非饱和正半轴换来更易优化。

Q020 Dropout 为什么训练时要 scaling？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

inverted dropout 训练时除以 $1-p$ ，让激活期望不变，推理阶段无需再缩放。

标准回答：从公式到直觉

1. $y=m \odot x / (1-p)$ ， $m \sim \text{Bernoulli}(1-p)$ ，因此 $E[y]=x$
2. 随机丢弃降低 feature co-adaptation，可视为采样许多子网络
3. CNN 中还可使用 SpatialDropout/DropBlock；现代网络常配合 stochastic depth

高频追问链

- Dropout 与 ensemble 有何联系？
- stochastic depth 与 dropout 差在哪？

常见失分点

忘记 train/eval 状态会让推理随机。

工程/项目视角

导出部署应确认 dropout 已移除。

一句话记忆

训练时保期望，推理时用完整网络。

Q021 普通卷积、Group Conv、Depthwise Conv 有什么区别？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经高频

面试官在考什么

它们通过限制通道连接稀疏度换计算效率；Depthwise 把空间卷积和通道混合解耦。

标准回答：从公式到直觉

1. 标准卷积参数 $K^2 \text{CinCout}$
2. Group conv 参数/MAC 约除以 groups，ShuffleNet 需要 channel shuffle 促进组间通信
3. Depthwise=groups=Cin，每通道独立做空间卷积，再用 1×1 pointwise 做 channel mixing

高频追问链

- 为什么 1×1 可能占 MobileNet 大部分计算？
- Depthwise 为什么实际不一定快？

常见失分点

只看 FLOPs 不看 memory-bound 和 kernel efficiency 会失分。

工程/项目视角

目标芯片上的真实 benchmark 比纸面 FLOPs 更重要。

一句话记忆

Group 控制通道连接，Depthwise 拆开空间与通道混合。

Q022 MobileNet V1/V2/V3 分别解决了什么？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经原型

面试官在考什么

V1 用 depthwise separable；V2 用 inverted residual + linear bottleneck；V3 进一步融合 NAS、SE 与硬件友好激活。

标准回答：从公式到直觉

1. V1 将空间卷积与通道混合拆开
2. V2 采用 narrow→expand→depthwise→linear project，残差发生在窄 bottleneck；低维最后不加 ReLU 以减少信息截断
3. V3 用结构搜索/NetAdapt、SE、h-swish 等优化精度-延迟

高频追问链

- 为什么叫 inverted residual？
- linear bottleneck 为什么重要？

常见失分点

只说“V2 更快、V3 更好”不够。

工程/项目视角

轻量模型必须在真实设备而非只在 FLOPs 上比较。

一句话记忆

V1 拆卷积，V2 倒残差+线性瓶颈，V3 加搜索与硬件约束。

Q023 SE 和 CBAM Attention 怎么工作？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

SE 做 channel reweighting；CBAM 在 channel attention 后再做 spatial attention。

标准回答：从公式到直觉

1. SE: GAP→MLP→sigmoid 得到每通道权重，再乘回 feature
2. SE 有全局上下文但压掉空间位置
3. CBAM 用 avg/max pooling 做 channel attention，再沿通道聚合产生 $H \times W$ spatial attention

高频追问链

- SE 为什么要 squeeze/excitation?
- Attention 权重等于可解释性吗？

常见失分点

涨点可能来自额外参数，必须做参数/FLOPs 匹配的公平 ablation。

工程/项目视角

工业项目要在相同延迟预算下比较。

一句话记忆

SE 重标通道，CBAM 再加空间重标。

Q024 SGD 和 Adam 有什么区别？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经高频

面试官在考什么

SGD+Momentum 用全局学习率和方向累积；Adam 再维护一阶/二阶矩，为每个参数自适应缩放步长。

标准回答：从公式到直觉

1. Momentum 减少高曲率方向震荡
2. Adam 用 $m_hat / (\sqrt{v_hat} + \epsilon)$ 更新，并做 bias correction
3. Adam early optimization 快且易调；经典 CNN 中 SGD 泛化很强，现代 ViT/大模型大量用 AdamW

高频追问链

- Adam 为什么需要 bias correction?
- batch 变大为什么常调 learning rate?

常见失分点

“Adam 一定好”或“SGD 一定泛化好”都过度绝对。

工程/项目视角

公平比较要分别调学习率、warmup、schedule、weight decay。

一句话记忆

SGD 积累方向，Adam 再按历史尺度自适应。

Q025 为什么 Weight Decay 和 L2 Regularization 在 Adam 中不完全一样？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

SGD 下 L2 梯度近似等价于参数衰减；Adam 的自适应预条件会重新缩放 L2 项，因此 AdamW 显式解耦。

标准回答：从公式到直觉

1. L2 将 λW 加入梯度；在 SGD 可整理成乘性 decay
2. Adam 会把含 λW 的梯度经过二阶矩归一化，导致各参数实际 decay 不同
3. AdamW 直接 $W \leftarrow (1 - \eta \lambda)W$ ，再做 Adam 梯度步；bias/norm 常设 no_decay

高频追问链

- 为什么 norm/bias 常 no_decay？
- AdamW 的 λ 与 lr 如何互动？

常见失分点

不要默认所有框架的 weight_decay 都实现相同语义。

工程/项目视角

复现要记录 optimizer 实现与 parameter groups。

一句话记忆

AdamW 把“优化梯度”和“参数衰减”分开。

第三章 目标检测

本章目标

从 R-CNN 到 YOLO/DETR：检测是图像算法岗最常见主战场。

本章速览：Two-stage 和 One-stage Detector 的核心区别是什么？ / Faster R-CNN 完整流程是什么？ / ROI Pooling 和 ROI Align 有什么区别？ / Anchor 是什么？为什么很多方法走向 Anchor-Free？ / ...

Q026 Two-stage 和 One-stage Detector 的核心区别是什么？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经原题型

面试官在考什么

Two-stage 先生成候选再精修；One-stage 直接做 dense prediction。现代精度/速度边界已不再绝对。

标准回答：从公式到直觉

1. Faster R-CNN: RPN proposals→ROI head，候选少、精修充分但 pipeline 复杂
2. YOLO/RetinaNet 直接在 feature map 上预测 class/box，早期受前景-背景不平衡影响
3. Focal Loss、FPN、dynamic assignment、decoupled head 等让 one-stage 精度大幅提升

高频追问链

- RetinaNet 为什么是里程碑？
- DETR 还适合用 one-stage/two-stage 二分吗？

常见失分点

只说“two-stage 准、one-stage 快”太机械。

工程/项目视角

选型应结合延迟、召回、目标尺寸、类别数和硬件。

一句话记忆

Two-stage 先候选后精修；One-stage 直接 dense 预测。

Q027 Faster R-CNN 完整流程是什么？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经原题

面试官在考什么

Backbone 提特征，RPN 生成 proposals，ROIAlign/Pooling 抽取固定尺寸特征，RCNN head 分类并回归 bbox。

标准回答：从公式到直觉

1. RPN 对 anchors 预测 objectness + bbox delta，并按 IoU 分正负样本
2. proposal 经 NMS/top-k 后送 ROI head
3. 常见 loss= $L_{rpn_cls}+L_{rpn_box}+L_{roi_cls}+L_{roi_box}$ ；Mask R-CNN 再加 mask loss

高频追问链

- RPN 与 Fast R-CNN 区别？
- Faster R-CNN 有几个 loss？
- bbox delta 为什么对 w/h 取 log？

常见失分点

只复述 “R-CNN+RPN” 而不会讲 proposal/ROI 会被追问穿。

工程/项目视角

Two-stage 仍适合小数据、追求高精度的工业 baseline。

一句话记忆

Faster R-CNN = shared feature + RPN 候选 + ROI 精修。

Q028 ROI Pooling 和 ROI Align 有什么区别？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经原题

面试官在考什么

ROI Pooling 对连续坐标做量化，造成 spatial misalignment；ROI Align 保留浮点坐标并用双线性插值采样。

标准回答：从公式到直觉

1. ROI Pooling 对 ROI 边界和 bin 做 round/floor，多次量化会造成偏移
2. Mask 任务对像素对齐极敏感，因此量化误差会伤边界
3. ROI Align 在每个 bin 采样浮点位置，再 bilinear interpolate 与聚合

高频追问链

- ROIAlign 采样点怎么选？
- 为什么 detection 也能受益？

常见失分点

ROIAlign 仍会聚合，不是 “完全没有 pooling”。

工程/项目视角

部署要关注 aligned 参数和不同框架实现差异。

一句话记忆

Pool 的问题是量化；Align 用浮点采样保持对齐。

Q029 Anchor 是什么？为什么很多方法走向 Anchor-Free？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

Anchor 是预定义尺度/长宽比的参考框，Anchor-free 则减少模板先验和冗余匹配。

标准回答：从公式到直觉

1. anchor-based 在每个位置放若干 template，预测 offset；回归被局部化
2. 缺点是 anchor 多、正负不平衡、尺度/比例与 matching 规则高度工程化
3. FCOS 预测到四边距离，CenterNet 预测中心/尺寸；关键问题转向 representation 与 positive assignment

高频追问链

- Anchor 如何用 k-means 设计？
- ATSS/SimOTA 在解决什么？

常见失分点

Anchor-free 不代表没有任何先验，也不保证一定更快。

工程/项目视角

数据分布变化时动态 assignment 往往比手工 anchors 更稳。

一句话记忆

Anchor 是模板先验；Anchor-free 把更多工作交给点/距离与动态匹配。

Q030 为什么小目标检测难？如何系统提升？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经高频

面试官在考什么

小目标经下采样后信息极少、定位误差相对影响更大、正样本少且容易被背景淹没。

标准回答：从公式到直觉

1. 8×8 目标遇到 $\text{stride}=8$ 只对应约一个 cell，信息可能不可逆丢失
2. 同样 1-2 像素误差会让小框 IoU 大幅下降
3. 可从更高分辨率/P2、FPN、tiling、assignment、context、hard sampling 与数据增强优化

高频追问链

- 为什么放大输入不一定最好？
- P2 的计算代价？

常见失分点

无脑插值放大不能创造真实细节，且计算代价可能平方增长。

工程/项目视角

先按 bbox area 统计 AP_s/Recall_s，再决定结构或数据策略。

一句话记忆

小目标先问“剩多少像素”，再谈网络。

Q031 FPN 为什么有效？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

FPN 将深层强语义沿 top-down 传回高分辨率层，并用 lateral connection 融合浅层细节。

标准回答：从公式到直觉

1. C2-C5 越深语义越强但分辨率越低
2. top-down 上采样与 1×1 lateral 对齐后相加，得到 P2-P5
3. 不同 pyramid level 服务不同尺度对象；PAN/BiFPN 进一步增强双向融合

高频追问链

- 为什么常用 add 而不是 concat？
- P6/P7 从哪里来？

常见失分点

FPN 的价值不是“多几个 feature map”，而是多尺度语义对齐。

工程/项目视角

删/加 pyramid level 应基于目标尺寸分布与实际 latency。

一句话记忆

FPN 把深层语义送回高分辨率。

Q032 IoU 是什么？作为 loss 有什么问题？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

IoU 衡量预测框与 GT 的交并比；两框不相交时普通 IoU 对距离方向缺少有效信号。

标准回答：从公式到直觉

1. $\text{IoU} = |A \cap B| / |A \cup B|$ ，范围 $[0,1]$ ，与尺度较无关
2. 坐标 L1/L2 与最终评价不完全一致，IoU-based loss 更贴近任务
3. 不相交时 $\text{IoU}=0$ ，无法区分“差一点接触”和“离很远”，因此有 $\text{GIoU}/\text{DIoU}/\text{CIoU}$

高频追问链

- 为什么 IoU 对小框更敏感？
- mask IoU 与 bbox IoU 的区别？

常见失分点

代码中 xyxy/xywh 、退化框与 +1 坐标口径是高频 bug。

工程/项目视角

评价不要只看 AP50，还要看高 IoU 阈值和尺寸切片。

一句话记忆

IoU 与指标一致，但不相交时信号不足。

Q033 GIoU、DIoU、CIoU 有什么区别？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

它们逐步加入外接区域、中心距离和长宽比，让 bbox 回归在不重叠或几何不匹配时获得更丰富信号。

标准回答：从公式到直觉

1. GIoU 在 IoU 后惩罚最小外接框中的空白区域
2. DIoU 加中心距离 ρ^2/c^2 ，直接鼓励中心靠近
3. CIoU 再加 aspect ratio consistency，同时优化重叠、中心和形状

高频追问链

- GIoU 是否总 $\leq \text{IoU}$ ？
- CIoU 的形状项什么时候有帮助？

常见失分点

新 loss 不一定在所有 assignment/尺度分布上都最好。

工程/项目视角

用 AP75、AP_small 与收敛稳定性做真实消融。

一句话记忆

GIoU 补外接，DIoU 补中心，CIoU 再补形状。

Q034 为什么 Smooth L1 曾常用于 bbox regression?

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经公式题

面试官在考什么

小误差区二次、梯度连续；大误差区线性，兼顾精修与 outlier robustness。

标准回答：从公式到直觉

1. L2 对大误差梯度大，异常 proposal 容易主导
2. L1 对零点附近不平滑
3. Smooth L1 用二次小误差 + 线性大误差折中；现代 detector 更常结合 IoU-based loss

高频追问链

- Smooth L1 的 β 控制什么？
- 为什么 bbox delta 的 w/h 常取 log？

常见失分点

只背分段公式而不解释抗异常点会失分。

工程/项目视角

异常标注/极端框下 loss 曲线会明显影响稳定性。

一句话记忆

小误差精修，大误差线性抗异常。

Q035 NMS 是什么？为什么需要？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经手撕原题

面试官在考什么

同一目标常产生多个重叠预测，NMS 按 score 贪心保留代表框并抑制重复框。

标准回答：从公式到直觉

1. 按 score 降序，取最高分框；算它与剩余框 IoU；删除 $\text{IoU} > \text{threshold}$ 的框并循环
2. naive worst-case $O(N^2)$ ，实际先做 confidence/top-k 并可向量化/GPU 加速
3. class-aware 与 class-agnostic NMS 会产生不同跨类抑制行为

高频追问链

- 阈值高/低如何影响 recall/precision？
- 如何手写向量化 NMS？

常见失分点

坐标格式、退化框、面积负值是手撕高频错误。

工程/项目视角

线上 recall 下降时要检查 conf/NMS threshold，而不只怀疑 backbone。

一句话记忆

NMS = 按分数选代表，用 IoU 抑制重复。

Q036 NMS 有什么缺陷？Soft-NMS/NMS-free 在解决什么？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

硬删除会误伤真实高度重叠目标；Soft-NMS 连续降分，NMS-free 从训练的一对一预测减少重复源头。

标准回答：从公式到直觉

1. 拥挤行人/密集细胞中真实实例本身 IoU 可能很高
2. Soft-NMS 按 IoU 线性或 Gaussian 衰减 score 而非直接删除
3. DETR 通过 Hungarian one-to-one set matching 从训练目标上减少 duplicates

高频追问链

- 为什么 one-to-one 有助于 NMS-free？
- Soft-NMS 增加多少复杂度？

常见失分点

去掉 NMS 不一定自动更快，head/decoder 与候选数量也影响 latency。

工程/项目视角

密集场景需单独维护 crowd regression set。

一句话记忆

Hard NMS 从后处理抑制，NMS-free 从训练目标减少重复。

Q037 Focal Loss 为什么能解决 dense detector 类别不平衡？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

用 $(1-p_t)^\gamma$ 下调 easy example 的损失权重，把梯度集中到 hard positives/negatives。

标准回答：从公式到直觉

1. $FL = -\alpha_t (1-p_t)^\gamma \log(p_t)$
2. $p_t \rightarrow 1$ 时调制因子趋近 0；难样本保持较大权重
3. α 管类别先验， γ 管 easy sample 抑制强度；RetinaNet 用它缓解海量 easy background

高频追问链

- $\gamma=0$ 时退化为什么？
- Focal Loss 与 class weight 的关系？

常见失分点

Focal Loss 不能替代 sampling、assignment 与 label quality。

工程/项目视角

长尾类别还需看真实频率、难度与标注噪声。

一句话记忆

少学 easy background，多学难样本。

Q038 AP 和 mAP 到底怎么计算？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

按置信度排序 prediction，以 IoU 规则匹配 TP/FP，得到 PR 曲线，再对类别和/或 IoU 阈值求平均。

标准回答：从公式到直觉

1. $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$, $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$
2. COCO AP 对 IoU=0.50:0.05:0.95 平均，AP75 更强调定位
3. 还会报告 AP_s/AP_m/AP_l；不同 benchmark 的 interpolation/maxDets/crowd 规则不同

高频追问链

- 一个 GT 能匹配多个 prediction 吗？
- 为什么 accuracy 不适合检测？

常见失分点

mAP 不是“各类别 accuracy 平均”。

工程/项目视角

模型比较必须固定 evaluator、NMS/conf 和 ignore 规则。

一句话记忆

score 排序 → IoU 匹配 → PR → AP → 平均。

Q039 DETR 为什么不需要 Anchor 和传统 NMS？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

DETR 将检测表述为 set prediction，用 learned queries + Hungarian 一对一匹配直接输出对象集合。

标准回答：从公式到直觉

1. Encoder-decoder 接收图像特征与 object queries，每 query 输出 class+box
2. Hungarian algorithm 找最优 GT-prediction 一对一匹配，未匹配 query 学 no-object
3. one-to-one set loss 从源头减少 duplicate，因此无需 NMS；原始 DETR 收敛慢，Deformable DETR 用稀疏多尺度采样改善

高频追问链

- matching cost 包含什么？
- object query 是固定类别吗？

常见失分点

Query 不是固定某一类或固定空间位置。

工程/项目视角

Query-based detector 适合统一 detection/segmentation，但实时性仍需优化。

一句话记忆

DETR 用集合匹配替代 anchor matching + NMS。

Q040 线上检测 Recall 很低，如何系统定位？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

按 Data→Preprocess→Model→Threshold/Postprocess→Deployment 分层诊断，而不是直接换模型。

标准回答：从公式到直觉

1. 先核查 GT 漏标、类别口径与时间/设备 drift
2. 按 size/class/illumination/occlusion/device 分桶分析 FN
3. 检查 confidence、NMS/top-k、resize/crop；再对比 PyTorch 与 ONNX/TRT 的 logits/boxes，最终把失败样本沉淀成 regression set

高频追问链

- Recall 低但 AP 不低可能为什么？
- 如何区分模型漏检与数据漏标？

常见失分点

只调 conf threshold 是表面修复。

工程/项目视角

成熟团队会维护 failure taxonomy 与 slice dashboard。

一句话记忆

线上问题要逐层定位：数据、预处理、模型、后处理、部署。

第四章 图像分割

本章目标

语义、实例、全景分割，以及工业/医学中的边界与长尾问题。

本章速览：Semantic、Instance、Panoptic Segmentation 有什么区别？ / FCN 为什么是现代语义分割的重要起点？ / U-Net 为什么在医学/工业分割中流行？ / DeepLab 的核心思想是什么？ ASPP 为什么有效？ / ...

Q041 Semantic、Instance、Panoptic Segmentation 有什么区别？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

Semantic 给像素类别；Instance 还区分同类不同实例；Panoptic 为整图每像素给 class + instance id。

标准回答：从公式到直觉

1. Semantic 不区分两个相邻 person
2. Instance 针对 countable things 分实例
3. Panoptic 同时覆盖 things 与 stuff；对应指标 mIoU、mask AP、PQ 也不同

高频追问链

- thing/stuff 是什么？
- Panoptic Quality 怎么理解？

常见失分点

Instance segmentation 不是“检测框更精细”的简单版本。

工程/项目视角

先确定业务需要类别、实例还是完整场景解析，再选任务。

一句话记忆

Semantic 分类别，Instance 分对象，Panoptic 统一二者。

Q042 FCN 为什么是现代语义分割的重要起点？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

把分类网络的 FC 改成卷积，保留空间结构并输出 dense prediction，再上采样恢复像素级。

标准回答：从公式到直觉

1. FC 固定输入并丢空间； 1×1 conv 可做位置共享的类别预测
2. 深层 feature 低分辨率，需要 deconv/upsampling
3. skip fusion 把浅层细节与深层语义结合，为后续 encoder-decoder 范式奠基

高频追问链

- FC 如何等价转成 conv？
- 转置卷积是否等于反卷积？

常见失分点

FCN 首先是一种 fully-convolutional 思想，不是某个固定 backbone。

工程/项目视角

“高语义+高分辨率恢复”仍是现代 dense task 的核心矛盾。

一句话记忆

FCN 的革命是保留空间并直接做 dense output。

Q043 U-Net 为什么在医学/工业分割中流行？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经原题

面试官在考什么

对称 encoder-decoder + 多尺度 skip connection，同时保留上下文与精细定位，尤其适合边界重要、小数据任务。

标准回答：从公式到直觉

1. Encoder 下采样扩大上下文，Decoder 上采样恢复分辨率
2. 同尺度 skip 直接传高分辨率细节，避免所有信息都挤过 bottleneck
3. 现代 U-Net 可替换 backbone/attention/Transformer，但核心仍是 multi-scale skip

高频追问链

- U-Net concat 与 FPN add 有何区别？
- 转置卷积可能有什么 artifact？

常见失分点

skip 也可能把浅层噪声带进 decoder。

工程/项目视角

工业任务常结合 patch sampling、Dice/Boundary loss 与 hard negatives。

一句话记忆

U-Net 用 skip 让语义和细节重新会合。

Q044 DeepLab 的核心思想是什么？ASPP 为什么有效？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经高频

面试官在考什么

用 atrous convolution 扩大感受野而不继续降分辨率，ASPP 用多个 dilation rate 捕获多尺度上下文。

标准回答：从公式到直觉

1. Dilated conv 参数数不变但等效 kernel 变大
2. ASPP 并行不同 dilation + 1×1 /global context 分支
3. DeepLabv3+ 再用 decoder 融合浅层细节，提高边界

高频追问链

- output stride=8/16 是什么？
- ASPP rate 如何选？

常见失分点

“空洞卷积不增加计算”不严格，参数不增但访存和实现效率会变。

工程/项目视角

高分辨率部署要关注 dilation kernel 的硬件支持。

一句话记忆

DeepLab = atrous 高分辨率 + ASPP 多尺度 + decoder。

Q045 Dilated Convolution 为什么会有 gridding artifact?

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

固定大 dilation 使采样点落在稀疏周期网格，一些中间像素长期不参与计算。

标准回答：从公式到直觉

1. 3×3 dilation= r 等效 kernel size= $1+2r$ ，但真正采样仍只有 9 点
2. 多层相同 dilation 会形成周期覆盖空洞
3. Hybrid dilation、ASPP、多尺度或 deformable sampling 可增强覆盖

高频追问链

- dilation=2 的等效尺寸？
- 为什么 1,2,5 比 2,2,2 覆盖更好？

常见失分点

等效 kernel 大不等于密集观察整个区域。

工程/项目视角

细线/边界任务对 sampling holes 更敏感。

一句话记忆

Dilation 扩跨度不增采样数，固定稀疏网格会 gridding。

Q046 Dice Loss 为什么适合前景稀少的分割？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

Dice 直接优化集合重叠，相比逐像素 CE 对前景占比更不敏感。

标准回答：从公式到直觉

1. soft Dice= $2\sum pg / (\sum p + \sum g)$ ，Loss=1-Dice
2. 前景只占 1% 时 CE 容易被 background 主导
3. Dice 与 CE/BCE 常组合；Tversky 可分别加权 FP/FN

高频追问链

- Dice 与 IoU 如何换算？
- 空 GT mask 怎么处理？

常见失分点

空 mask、小目标与 smooth 常数处理不当会造成数值问题。

工程/项目视角

医学/缺陷任务应同时看 per-case Dice、recall 和 boundary metric。

一句话记忆

Dice 直接看重叠，所以对前景稀少友好。

Q047 mIoU 怎么计算？为什么 pixel accuracy 可能误导？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

每类 $IoU = TP / (TP + FP + FN)$ ，mIoU 对类别平均；背景占比巨大时 pixel accuracy 很容易虚高。

标准回答：从公式到直觉

1. 由 confusion matrix 统计每类 TP/FP/FN
2. mIoU 让各类权重相近，但少数类样本少时方差仍可能大
3. 评估还应明确 ignore label、resize interpolation、multi-scale inference 规则

高频追问链

- IoU 与 Dice 的关系？
- macro/micro averaging 差异？

常见失分点

不要只报 global pixel accuracy。

工程/项目视角

线上应按类别/尺寸/场景 slice 监控。

一句话记忆

mIoU 给每类算交并比再平均；背景多时 accuracy 会骗人。

Q048 如何提升细长缺陷、裂纹、道路分割？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经原型题

面试官在考什么

围绕“易被下采样切断、像素少、连通性比面积重要”设计分辨率、loss、采样与指标。

标准回答：从公式到直觉

1. 保持高分辨率、减少早期 stride、使用 tile/crop
2. Dice/Tversky 解决不平衡，boundary/skeleton/topology-aware loss 强化连通
3. 除 IoU 外看 recall、cDice、Hausdorff/boundary distance，防止“面积对了但断裂”

高频追问链

- 为什么提高分辨率仍可能断裂？
- 如何采 hard negatives？

常见失分点

只看 global IoU 可能看不到拓扑断裂。

工程/项目视角

把“是否存在、长度、连通性”等业务判定纳入 evaluation。

一句话记忆

细长结构先保像素，再保连通。

Q049 为什么 segmentation boundary 特别难？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

边界像素少、标注有不确定性，且 encoder 下采样会丢高频定位信息。

标准回答：从公式到直觉

1. 普通 CE/Dice 大部分梯度来自区域内部
2. 边界标注可能有 1-3 像素主观差异
3. 可用 edge head、distance transform、boundary loss、high-resolution skip 或 point refinement

高频追问链

- Boundary IoU 为什么有用？
- 边界标注噪声怎么处理？

常见失分点

不要把 boundary error 全归因于 decoder，GT 质量也很重要。

工程/项目视角

业务对尺寸/缺口敏感时需要专门 boundary metric。

一句话记忆

边界难 = 样本少 + 下采样 + 标注不确定。

Q050 Mask R-CNN 为什么能做 instance segmentation?

难度 ★★★★★ 高频 ★★★★★ 标签: 基础高频

面试官在考什么

在 Faster R-CNN 的每个 ROI 上加与分类解耦的 binary mask head，并用 ROIAlign 保持空间对齐。

标准回答：从公式到直觉

1. ROIAlign 后 class/box head 与 mask head 并行
2. mask head 常输出 $K \times m \times m$ ，只对 GT class 对应 channel 算 sigmoid binary loss
3. 避免对所有类别做 softmax，使 mask prediction 与分类解耦

高频追问链

- 为什么 mask head 不用 softmax?
- mask 如何映射回原图?

常见失分点

把 mask loss 理解成多类 softmax 是常见误解。

工程/项目视角

实例多时 per-ROI mask head 可能成为推理成本。

一句话记忆

Mask R-CNN = 检测实例 + 为每个实例独立预测 binary mask。

第五章 OCR 与文档视觉

本章目标

文本检测、识别、CTC、几何矫正与线上域偏移。

本章速览：一个工业 OCR 系统完整 pipeline 是什么？ / DBNet 为什么适合文本检测？ / CRNN 是怎么识别文字的？ / CTC 为什么不需要字符级对齐标注？ / ...

Q051 一个工业 OCR 系统完整 pipeline 是什么？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

经典 OCR 是 text detection→crop/rectification→recognition，再叠加方向、布局、语言模型和结构化抽取。

标准回答：从公式到直觉

1. Detection 找文字区域，可输出水平框/旋转框/多边形
2. Rectification 处理透视、旋转、弯曲；Recognition 把图像条带转成字符序列
3. 文档场景还需 layout、reading order、table/form understanding；端到端 VLM 灵活但专项 OCR 仍在小字、延迟和稳定性上有优势

高频追问链

- 为什么 detection/recognition 分开？
- 端到端 OCR 的优缺点？

常见失分点

只谈识别网络而忽略检测/矫正会显得系统经验不足。

工程/项目视角

线上误差要拆成 detect miss、crop error、recognition error、postprocess error。

一句话记忆

OCR 不是一个模型，而是一条定位→读取→结构化链。

Q052 DBNet 为什么适合文本检测？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

DBNet 用可微二值化近似硬阈值，使 probability map 与 threshold map 能一起学习。

标准回答：从公式到直觉

1. 普通 segmentation detector 的固定 threshold 不参与训练
2. DB 近似 $B=1/(1+\exp(-k(P-T)))$ ，P 是概率图，T 是自适应阈值图
3. 训练让 threshold 学习文字边界可分性，推理再用轮廓提取获得 polygon

高频追问链

- 为什么要 shrink GT polygon？
- k 变大时会怎样？

常见失分点

可微二值化是用陡峭 sigmoid 近似硬阈值，不是真正的离散阈值可微。

工程/项目视角

小字场景要检查 feature stride 和 shrink 后 GT 是否消失。

一句话记忆

DBNet 把“阈值”也学起来。

Q053 CRNN 是怎么识别文字的？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

CNN 把图像变成沿宽度展开的序列特征，BiLSTM/Transformer 建模上下文，CTC 处理无显式对齐监督。

标准回答：从公式到直觉

1. CNN 常把高度压到 1 或很小，宽度保留为 time steps
2. BiLSTM 利用左右上下文输出逐时刻字符分布
3. CTC 用 blank+collapse 规则允许多个 frame 对应一个字符，不需要字符级 bbox

高频追问链

- 为什么固定高度、可变宽度？
- CTC greedy 与 beam search 有何差异？

常见失分点

只说“CNN+RNN+CTC”而不能解释序列化和对齐会失分。

工程/项目视角

识别延迟常随输入宽度增长，工程上可做 width bucketing。

一句话记忆

CRNN = CNN 看字形，序列模型看上下文，CTC 解对齐。

Q054 CTC 为什么不需要字符级对齐标注？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

CTC 对所有能 collapse 成目标字符串的 frame-level paths 求概率和，用动态规划边际化未知对齐。

标准回答：从公式到直觉

1. 引入 blank，并允许重复字符
2. $P(y \mid x) = \sum_{\pi: B(\pi)=y} \prod_t P(\pi_t \mid x)$ ，用 forward-backward 高效计算
3. 只需整行 transcript，不需知道每个字符位于第几列

高频追问链

- 为什么 repeated letters 需要 blank？
- T 和 U 有什么约束？

常见失分点

相同字符若没有 blank 分隔，collapse 后会合并。

工程/项目视角

长序列/大字典会增加解码成本。

一句话记忆

CTC 用路径求和把未知对齐边缘化。

Q055 CTC 的核心局限是什么？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

给定 encoder feature 后 time-step 输出近似条件独立，显式语言建模和复杂 reading order 能力有限。

标准回答：从公式到直觉

1. 视觉相似字符需要上下文消歧，纯 CTC 主要依赖 encoder 隐式编码
2. autoregressive/attention decoder 建模 $P(y_t | y_{<t}, x)$ 更强但串行且可能 attention drift
3. 可用 CTC+attention hybrid 或外部 LM 融合

高频追问链

- CTC 与 autoregressive 谁更快？
- attention decoder 为什么会漏字/重复？

常见失分点

CTC 并非“完全没有上下文”，encoder 可以双向。

工程/项目视角

强词典场景可做语言约束，但要防过度纠正。

一句话记忆

CTC 对齐方便且并行快，但显式语言依赖较弱。

Q056 弯曲文字、透视文字怎么办？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

先估计文字几何，再用 homography/TPS/STN 做显式或可学习 rectification；也可直接用任意形状 recognizer。

标准回答：从公式到直觉

1. 四点透视可用 homography
2. 弯曲文本需 TPS 等更高自由度变换
3. STN 可预测变换参数并通过可微采样端到端训练，但过度矫正可能拉伸字形

高频追问链

- Homography 需要几对点？
- TPS 为什么比 affine 灵活？

常见失分点

强行把曲线文字用四边形透视会失真。

工程/项目视角

真实拍照 OCR 还需覆盖 motion blur、反光、曲面和压缩。

一句话记忆

简单透视用 H，复杂弯曲用 TPS/STN。

Q057 中文 OCR 为什么比英文更难？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

字典巨大、长尾严重、形近字多，再叠加字体/繁简/生僻字，视觉和语言空间都更复杂。

标准回答：从公式到直觉

1. 英文字符几十到上百；中文常用字数千，扩展更多
2. 许多汉字只差局部笔画，低分辨率时极易混淆
3. 可用部件/radical 表示、synthetic fonts、language model、byte/sub-character decoder；数据频率分布通常比网络结构更关键

高频追问链

→ 生僻字 OOV 怎么处理？

→ 字体合成如何减小 domain gap？

常见失分点

只扩大字典会制造大量极少样本 class。

工程/项目视角

线上应统计 rare-character recall 与 top confusion pairs。

一句话记忆

中文 OCR 难在超大、长尾、形近的字符空间。

Q058 OCR 离线 99%，上线只有 90%，怎么定位？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

先把错误拆为检测、裁剪/矫正、识别、后处理，再按设备与真实退化条件聚类。

标准回答：从公式到直觉

1. 检查 motion blur、glare、透视、小字、特殊字体、曝光、压缩等 domain shift
2. 建立原图→det→crop→rectify→logits→postprocess trace，找到误差首次出现层
3. 按 device/font/size/angle/blur 分桶，沉淀 failure mining→label→retrain→regression 闭环

高频追问链

- 如何区分 detector miss 与 recognizer error？
- 如何做低置信度拒识？

常见失分点

“domain shift”只是现象，不是足够具体的根因。

工程/项目视角

生产 OCR 的核心资产常是失败样本闭环。

一句话记忆

端到端掉点要逐级 trace。

第六章 ViT、自监督、CLIP 与 SAM

本章目标

从 CNN inductive bias 走向视觉基础模型和 promptable perception。

本章速览：ViT 如何把图像变成 Transformer 输入？ / 为什么 ViT 小数据上往往不如 CNN？ / Self-Attention 在视觉里的复杂度是多少？ / Swin Transformer 为什么适合 dense vision task？ / ...

Q059 ViT 如何把图像变成 Transformer 输入？

难度 ★★★★★ 高频 ★★★★★ 标签：2026 核心

面试官在考什么

把图像切成 patch，flatten/线性投影为 token，加位置编码后送入 Transformer encoder。

标准回答：从公式到直觉

1. $N=HW/P^2$ ，每 patch P^2C 维，经 projection 映射到 d_{model}
2. 位置编码补充空间顺序；可加 CLS token 聚合分类表示
3. patch 越小 token 越多，attention 成本迅速上升

高频追问链

- Patch embedding 是否等价于 stride=P 的 conv？
- 位置编码如何插值到新分辨率？

常见失分点

不要忽略分辨率变化时 position embedding 的处理。

工程/项目视角

高分辨率视觉通常需要 hierarchy/window/sparse attention。

一句话记忆

ViT = image patches 变 token，关系靠 self-attention。

Q060 为什么 ViT 小数据上往往不如 CNN？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经高频

面试官在考什么

CNN 的 locality/translation/hierarchy 先验在数据少时提高样本效率；ViT 自由度更大，需要预训练、增强或更多数据。

标准回答：从公式到直觉

1. CNN 把“邻近像素先交互”写进结构；原始 ViT 允许全局 token 直接交互
2. 大规模预训练后 ViT 可以从数据学出结构，scaling 很强
3. DeiT 说明蒸馏/增强能提高数据效率；Swin 又把局部窗口和 hierarchy 重新引入

高频追问链

- ViT 是否“没有 inductive bias”？
- ConvNeXt 说明什么？

常见失分点

ViT 不是完全没有先验，只是相对 CNN 更弱。

工程/项目视角

小数据工业任务通常优先用大规模预训练而非从头训 ViT。

一句话记忆

数据少时先验更值钱；数据大时自由度更值钱。

Q061 Self-Attention 在视觉里的复杂度是多少？

难度 ★★★★★ 高频 ★★★★★ 标签：2026 核心

面试官在考什么

标准 attention 的 QK^T 对 token 数 N 是 $O(N^2d)$ ，而图像 token 数随面积增长。

标准回答：从公式到直觉

1. H/W 都翻倍且 patch 不变， N 变 4 倍，attention 配对部分约变 16 倍
2. QKV/MLP 还有 $O(Nd^2)$ ，实际瓶颈随 N 和 d 变化
3. Swin/window、deformable/sparse attention 减少配对；FlashAttention 主要优化 IO/显存，不改变理论配对数

高频追问链

- FlashAttention 为什么快？
- window 如何跨窗通信？

常见失分点

只说“ $O(N^2)$ ”而不知道 N 与分辨率关系不够。

工程/项目视角

VLM serving 的瓶颈经常是 token 数、activation/KV 与 data movement。

一句话记忆

图像面积决定 token 数，token 平方决定全局 attention 的痛点。

Q062 Swin Transformer 为什么适合 dense vision task?

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

局部窗口把计算近似线性化，shifted window 建立跨窗通信，patch merging 形成层级多尺度 feature。

标准回答：从公式到直觉

1. 固定 $M \times M$ window 内做 attention，成本随全图 token 近似线性
2. 下一层 shift $M/2$ ，让上一层不同窗口中的 token 相遇
3. patch merging 逐级降分辨率、升通道，天然适配 FPN/segmentation

高频追问链

- shifted window 为什么需要 mask？
- Swin 与 ConvNeXt 有哪些相似点？

常见失分点

window attention 不等于永远局部，层叠后感受野会扩大。

工程/项目视角

dense task 中多尺度输出接口非常重要。

一句话记忆

Swin = 窗口省计算 + shift 传信息 + hierarchy 做 dense task。

Q063 MAE 为什么 mask 75% patches 仍然能学好？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

自然图像冗余高，低 mask 太容易；高 mask 迫使模型理解全局结构，同时 encoder 只计算 visible patches。

标准回答：从公式到直觉

1. encoder 只处理 visible tokens，decoder 再插 mask tokens 重建像素
2. 高 mask 降低 encoder 计算并阻止简单局部插值
3. 目标虽然是像素重建，但高遮挡与 bottleneck 会推动语义 representation 学习

高频追问链

- 为什么 decoder 可以很轻？
- mask ratio 太高会怎样？

常见失分点

不要把 MAE 误解成只学低级纹理。

工程/项目视角

标注昂贵的医学/工业视觉可用自监督预训练提升样本效率。

一句话记忆

高 mask 让任务更难，也让 encoder 更省。

Q064 CLIP 是怎么实现图文对齐的？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

双编码器把 image/text 映射到同一 embedding space，用 batch 内对比学习提升匹配对相似度、压低非匹配对。

标准回答：从公式到直觉

1. image encoder 得 v_i ，text encoder 得 t_j ，归一化后 $s_{ij} = v_i^T t_j / \tau$
2. 对 image→text 和 text→image 做对称 cross-entropy
3. 大 batch 提供大量 negatives；CLIP 形成开放语义空间，可用于 retrieval、zero-shot、VLM vision encoder

高频追问链

- 为什么要 normalize embedding？
- false negatives 会怎样？

常见失分点

CLIP 相似度高不代表复杂事实推理正确。

工程/项目视角

行业应用要关注 prompt bias、长尾概念、OCR 与局部定位能力。

一句话记忆

CLIP = 双编码器 + 对比学习，共享一个语义坐标系。

Q065 CLIP 为什么可以 zero-shot classification?

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

把类别名称/描述编码成 text prototypes，再用 image embedding 与各 prototype 的相似度作为分类分数。

标准回答：从公式到直觉

1. 例如 “a photo of a dog” 经 text encoder 得 t_{dog}
2. 图像 v 与所有类别向量算 cosine similarity, argmax 即分类
3. prompt wording 会影响性能，可用多模板 ensemble；本质是用语言动态生成 classifier weights

高频追问链

- 为什么同义 prompt 会改变结果？
- open-vocabulary detection 如何借用 CLIP？

常见失分点

zero-shot 不等于预训练时从未见过这些概念。

工程/项目视角

专业类目可加入属性描述与少量 calibration 数据。

一句话记忆

Zero-shot CLIP = 文本 embedding 当动态分类器。

Q066 SAM 的核心架构是什么？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经原题

面试官在考什么

SAM 统一为 promptable segmentation: Image Encoder 预计算图像 embedding, Prompt Encoder 编码点/框/mask, Mask Decoder 输出候选 masks 与质量。

标准回答：从公式到直觉

1. Image encoder 成本高但同图可复用 embedding
2. Prompt encoder 分 sparse prompts 与 dense mask prompt
3. Mask decoder 让 prompt tokens 与 image embedding 交互，输出多个候选以处理提示歧义，并预测 mask quality

高频追问链

- 为什么同一个点可输出多个 masks？
- 如何用 SAM 做 pseudo-label？

常见失分点

SAM 不是“万能 semantic segmentation”，不会自动给业务类别。

工程/项目视角

工业落地常需要 domain fine-tune/adapter/prompt generation。

一句话记忆

SAM = 图像一次编码，prompt+轻 decoder 多次交互。

Q067 SAM 为什么 zero-shot 强？SAM2 增加了什么？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经原题

面试官在考什么

SAM 的大规模数据引擎与统一 promptable task 带来跨任务迁移；SAM2 加 streaming memory，把能力扩展到视频。

标准回答：从公式到直觉

1. SAM 用超大 mask 数据与 data engine 学通用对象分割
2. 统一 (image,prompt)→mask 降低任务边界
3. SAM2 用 memory encoder/bank 与 temporal attention 保存对象跨帧状态，处理遮挡、外观变化和再出现

高频追问链

- SAM2 memory 存什么？
- SAM 在工业缺陷上为什么可能差？

常见失分点

“因为参数大所以 zero-shot 强”是低分回答。

工程/项目视角

细小/低对比缺陷要先验证是否符合“对象分割”假设，再定适配策略。

一句话记忆

SAM 靠大数据+统一任务泛化；SAM2 再靠 memory 获得视频一致性。

第七章 Diffusion 与生成视觉

本章目标

理解扩散模型的训练目标、latent、guidance、可控生成和评价。

本章速览：Diffusion Model 的基本思想是什么？ / 为什么 DDPM 常预测噪声 ϵ ？ / Latent Diffusion 为什么比 pixel diffusion 便宜？ / Classifier-Free Guidance 是什么？ / ...

Q068 Diffusion Model 的基本思想是什么？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

定义逐步加噪 forward process，再训练网络近似 reverse denoising，从 Gaussian noise 生成数据。

标准回答：从公式到直觉

1. $q(x_t | x_{t-1}) = N(\sqrt{1-\beta_t}x_{t-1}, \beta_t I)$
2. 闭式 $x_t = \sqrt{\alpha_t}x_0 + \sqrt{1-\alpha_t}\epsilon$ ，训练可随机采 t 一步构造
3. 推理从 $x_T \sim N(0, I)$ 多步去噪；传统 DDPM 慢主要因为 sampling steps 多

高频追问链

- 为什么训练不必真的前向 T 次？
- DDIM 为什么能少步？

常见失分点

只说“不断去噪”不够，要能写 forward closed form。

工程/项目视角

生成延迟取决于 steps、backbone、latent resolution、CFG 与 scheduler。

一句话记忆

Diffusion = 已知加噪 + 学习逆过程。

Q069 为什么 DDPM 常预测噪声 ϵ ？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

forward closed-form 直接给出噪声监督，预测 ϵ 数值稳定，并可由它恢复 x_0 与 reverse mean。

标准回答：从公式到直觉

1. $x_t = \sqrt{\alpha_t}x_0 + \sqrt{1-\alpha_t}\epsilon$ ，给定 x_0/ϵ 就有训练对
2. 经典目标 $E[\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$
3. 不同 t 的 SNR 差异很大，现代会用 v-prediction/SNR weighting 改善平衡

高频追问链

- ϵ -pred/ x_0 -pred/v-pred 有何关系？
- 为什么高 t 更难？

常见失分点

“噪声更简单所以预测噪声”只是直觉，不够完整。

工程/项目视角

parameterization 与 sampler/scheduler 必须匹配。

一句话记忆

预测 ϵ 是因为 forward 方程直接给监督且能推 reverse。

Q070 Latent Diffusion 为什么比 pixel diffusion 便宜？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

用 autoencoder 把高分辨率像素压到低分辨率 latent，在 latent 中做 diffusion，再解码回图。

标准回答：从公式到直觉

1. 1024^2 像素可压到 $128^2/64^2$ latent，conv/attention 成本大幅下降
2. Autoencoder 的压缩率与感知质量存在 trade-off；太小会丢文字/纹理
3. VAE 决定 round-trip fidelity，diffusion 负责在语义 latent 中生成

高频追问链

- VAE 为什么影响文字质量？
- 压缩率越大越好吗？

常见失分点

Latent diffusion 不只是“先压缩”，VAE 瓶颈决定生成上限。

工程/项目视角

图像编辑尤其依赖 VAE preservation，否则未编辑区域也会漂移。

一句话记忆

把昂贵生成建模搬到低分辨率语义空间。

Q071 Classifier-Free Guidance 是什么？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

同一模型同时学 conditional/unconditional denoising，推理时放大两者差向量以增强条件遵循。

标准回答：从公式到直觉

1. 训练时以一定概率 drop condition
2. 推理 $\epsilon = \epsilon_{\text{uncond}} + w(\epsilon_{\text{cond}} - \epsilon_{\text{uncond}})$
3. w 增大常提高 prompt adherence，但过大会降 diversity、产生 saturation/artifact，且通常需要 cond/uncond 两份计算

高频追问链

- $w=0/1$ 分别意味着什么？
- negative prompt 如何进入？

常见失分点

guidance scale 越大不一定越好。

工程/项目视角

实时生成要关注 CFG 近 2 倍 denoiser 计算并考虑蒸馏。

一句话记忆

CFG 用 cond-uncond 差向量把采样推向条件。

Q072 U-Net 和 DiT 做 diffusion backbone 有什么区别？

难度 ★★★★★ 高频 ★★★★★ 标签：2026 前沿

面试官在考什么

U-Net 强多尺度卷积先验，DiT 把 latent 切成 patch 用 Transformer，强调统一结构与 scaling。

标准回答：从公式到直觉

1. U-Net 的 encoder-decoder/skip 对局部和多尺度很强
2. DiT 在 latent patches 上做 Transformer blocks，通过 timestep/text 等条件调制
3. Transformer 易接入大模型工程栈与 attention 优化，但 token 成本仍需控制

高频追问链

- DiT 如何注入 timestep？
- 为什么 latent patch 比 pixel patch 更可行？

常见失分点

“Transformer 一定优于 U-Net” 不应绝对化。

工程/项目视角

结构选择取决于训练规模、硬件、分辨率和 serving 目标。

一句话记忆

U-Net 强局部多尺度，DiT 强 Transformer scaling。

Q073 ControlNet 的思想是什么？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

保持预训练 diffusion 主能力，新增 control branch 注入 edge/depth/pose 等空间条件。

标准回答：从公式到直觉

1. 复制/旁路部分网络，zero-conv 等初始化让新增分支初始近似零影响
2. 空间条件解决纯文本对几何布局控制不足
3. 多 control 可组合，但需处理权重与冲突

高频追问链

- 为什么 zero-conv 有帮助？
- ControlNet 与 adapter 的条件差异？

常见失分点 control 精准不等于语义一定正确，过强也会压制文本。	工程/项目视角 产品评价要同时看 control fidelity 与 image quality。
一句话记忆 冻结强生成先验，新增分支注入空间控制。	

Q074 Image Editing 与 Text-to-Image 最大区别是什么？

难度 ★★★★★ 高频 ★★★★★ 标签：2026 产品题

面试官在考什么 Editing 不仅要满足指令，还要保持未修改区域的身份、几何和背景，是“改对 + 保住”的双目标。
--

标准回答：从公式到直觉

- 1. T2I 主要看 alignment/quality/diversity；Editing 额外看 preservation/identity/locality
- 2. 输入可为原图+文本，也可加 mask/reference/depth
- 3. 过强重绘会 edit 成功但 preservation 失败，过保守又会修改不足

高频追问链

- identity preservation 如何评价？
- 为什么 VAE round-trip 会影响未编辑区域？

常见失分点 只用 CLIP score 评价 editing 会忽略 preservation。	工程/项目视角 真实产品还要处理局部边界、颜色一致、高分辨率与文字保持。
一句话记忆 编辑的难点不是生成，而是只改该改的。	

Q075 如何评价图像生成模型？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

需要把图像质量、文本对齐、多样性、编辑保持、文字渲染、人类偏好与安全鲁棒性拆成多维评价。

标准回答：从公式到直觉

- 1. FID 比较特征分布统计，不等于人类偏好且不能评价单张图
- 2. CLIP/VLM judge 可测 alignment 但有自身偏差
- 3. 需要 diversity/coverage、editing preservation、OCR/text rendering、slice eval 与 human preference 共同构成回归体系

高频追问链

- FID 为什么不能评单张？
- CLIP score 可能被怎样误导？

常见失分点

单一总分很容易掩盖关键 slice 退化。

工程/项目视角

维护固定 regression prompts、人评 protocol 与采样配置。

一句话记忆

生成评价要多维：好看、听话、多样、保持、文字、稳定。

第八章 视频、3D 与多模态

本章目标

时间、几何、传感器融合与 VLM：面向 2026 岗位能力结构。

本章速览：2D 图像与视频最大的建模区别是什么？ / Optical Flow 是什么？ / Camera Intrinsic 和 Extrinsic 分别是什么？ / 为什么 monocular depth 存在尺度歧义？ / ...

Q076 2D 图像与视频最大的建模区别是什么？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

视频增加时间维，需要同时建模外观、运动和跨帧身份/语义一致性。

标准回答：从公式到直觉

1. 视频张量多 T 维，3D conv 或全时空 attention 成本显著增加
2. 短期运动可用 flow/temporal conv，长期事件需要 temporal attention/memory
3. 单帧正确但帧间抖动仍是失败，采样率/clip length/camera motion 会改变分布

高频追问链

- 2+1D conv 为什么有效？
- 如何处理 variable FPS？

常见失分点

不要把视频简单理解成“多张图片独立跑”。

工程/项目视角

实时系统还要考虑 frame skipping、tracking、stream state 与尾延迟。

一句话记忆

视频 = 图像语义 + 时间运动 + 跨帧一致性。

Q077 Optical Flow 是什么？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

估计相邻帧逐像素二维位移场，经典方法建立在 brightness constancy 加额外平滑/局部一致性约束。

标准回答：从公式到直觉

1. 亮度恒常一阶展开得到 $I_x u + I_y v + I_t = 0$
2. 一个方程两个未知产生 aperture problem，因此 Lucas-Kanade 假设局部相同 flow，Horn-Schunck 加全局 smoothness
3. 深度 flow 常用 correlation/cost volume、pyramid、warping 或 Transformer

高频追问链

- aperture problem 是什么？
- 为什么 pyramid 有助大位移？

常见失分点

brightness constancy 在曝光变化/反光时并不严格成立。

工程/项目视角

Flow 可用于插帧、稳定、运动分割、辅助 tracking。

一句话记忆

Flow 是逐像素运动；欠定方程需要额外约束。

Q078 Camera Intrinsic 和 Extrinsic 分别是什么？

难度 ★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

Extrinsic 把世界坐标变到相机坐标；Intrinsic 把相机坐标投到像素坐标。

标准回答：从公式到直觉

1. $P_c = RP_w + t$ 描述 pose
2. $\lambda p = K[R | t]P_w$, K 包含 f_x, f_y, c_x, c_y 等
3. 真实相机还要标定 radial/tangential distortion；多相机系统最常见 bug 是坐标系方向和手性约定

高频追问链

→ 为什么 t 不等于简单相机世界坐标？

→ PnP 在求什么？

常见失分点

world→camera 与 camera→world 不说明清楚，公式很容易反。

工程/项目视角

机械震动/镜头更换会造成外参漂移，应版本化 calibration。

一句话记忆

外参管相机在哪，内参管怎么投到像素。

Q079 为什么 monocular depth 存在尺度歧义？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

单张 2D 投影缺少绝对尺度，多组 3D scene/scale 可以产生相同或相近图像。

标准回答：从公式到直觉

1. 小物体近与大物体远可形成相似投影，因此单目依赖 learned prior
2. 输出常是 relative depth；metric depth 需要额外尺度信息/相机参数/监督
3. Stereo 已知基线时 $Z = fB/d$ ，可恢复绝对尺度

高频追问链

→ 为什么 stereo 近距离更准？

→ disparity 小时深度误差如何放大？

常见失分点

不要把单目网络输出数字默认当米。

工程/项目视角

机器人/AR 必须明确 relative 还是 metric，并做设备标定。

一句话记忆

单目看到投影，不天然知道世界的尺子。

Q080 BEV 为什么在自动驾驶视觉中常见？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

BEV 将多相机透视视图统一到世界鸟瞰坐标，利于融合、定位、地图与规划。

标准回答：从公式到直觉

1. Perspective 中尺度随深度变化强；BEV 在地面坐标更接近 metric uniformity
2. 多 camera overlap 可在共享 BEV 融合
3. 2D→3D/BEV 的核心仍是 depth ambiguity，因此需要 depth distribution、3D query 或 geometry-aware attention

高频追问链

- Lift-Splat-Shoot 的思想？
- BEVFormer query 在做什么？

常见失分点

BEV 不是简单 homography，非地面对象需要真正 3D reasoning。

工程/项目视角

还要处理时间同步、外参漂移、遮挡和传感器延迟。

一句话记忆

BEV 把多视角统一到世界平面，换来更直接空间推理。

Q081 多模态融合有哪些常见方式？

难度 ★★★★★ 高频 ★★★★★ 标签：2026 前沿

面试官在考什么

可按融合位置分 early/late/intermediate，也可按机制分 concat、gating、cross-attention、shared token space。

标准回答：从公式到直觉

1. Early fusion 细粒度交互强但要求对齐
2. Late fusion 模块化强、缺失模态好处理，但跨模态细节交互弱
3. Cross-attention 用一模态 Q 查询另一模态 K/V；真实系统还要处理时间/空间同步、missing modality 和置信度

高频追问链

- 缺失模态如何训练鲁棒性？
- camera+audio 如何时间对齐？

常见失分点

简单 concat 不等于有效融合。

工程/项目视角

传感器失效必须作为设计输入，不能假设所有模态永远可用。

一句话记忆

融合要回答：何时融合、如何对齐、谁更可信。

Q082 VLM 相比传统 CV 模型解决了什么？专用模型还需要吗？

难度 ★★★★★ 高频 ★★★★★ 标签：当前岗位核心

面试官在考什么

VLM 将固定类别感知扩展为开放词汇、问答与跨模态推理；专用模型仍在定位、确定性、低延迟和资源约束上重要。

标准回答：从公式到直觉

1. 传统 detector/classifier 输出固定 label space；VLM 可接受自由文本指令
2. 常见结构为 vision encoder + projector/connector + LLM，或统一多模态模型
3. 真实系统常采用 specialised perception + larger multimodal model：前者做可靠低层感知，后者做语义理解和交互

高频追问链

→ VLM 为什么 hallucinate？

→ vision projector 的作用？

常见失分点

把 VLM 当“更大的图像分类器”会错过跨模态 reasoning。

工程/项目视角

当前岗位越来越要求同时懂感知、VLM、数据和 real-time deployment。

一句话记忆

VLM 扩展任务边界，专用模型守住精度、成本与实时性。

第九章 数据、训练与 Evaluation

本章目标

真正区分候选人的往往是数据诊断、实验设计与误差分析。

本章速览：训练数据类别严重不均衡怎么办？ / MixUp 和 CutMix 分别是什么？ / 为什么 Data Augmentation 不能随便加？ / 标注有大量噪声怎么办？ / ...

Q083 训练数据类别严重不均衡怎么办？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经原题

面试官在考什么

从数据采样、loss、assignment、augmentation 和评价多层处理，而不只是加 class weight。

标准回答：从公式到直觉

1. 数据层 oversample/undersample、targeted synthesis、hard negative mining
2. loss 可用 weighted CE/Focal/class-balanced；检测还需处理 foreground-background imbalance
3. 评价看 per-class recall/AP、macro F1，避免 overall accuracy 掩盖少数类

高频追问链

- oversampling 与 class weight 能同时用吗？
- 长尾与 hard sample 有何区别？

常见失分点

真实业务先验不一定要强行训练成均匀分布。

工程/项目视角

训练分布与线上概率先验可分开处理，再做 calibration。

一句话记忆

不均衡是数据、采样、目标函数和指标的联合设计。

Q084 MixUp 和 CutMix 分别是什么？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经高频

面试官在考什么

MixUp 做全图凸组合，CutMix 做局部区域替换并按面积混标签，二者都在扩展训练分布并平滑决策边界。

标准回答：从公式到直觉

1. MixUp: $x \sim \lambda x_i + (1-\lambda)x_j$, $y \sim \lambda y_i + (1-\lambda)y_j$
2. CutMix 保留真实局部纹理，label 权重按区域面积
3. 检测/分割必须同步处理 boxes/masks；OCR 等任务未必适合强混合

高频追问链

- λ 从什么分布采样？
- CutMix 对小目标有什么风险？

常见失分点

augmentation 越强不一定越好，必须保持标签语义。

工程/项目视角

按真实 failure slice 做 augmentation ablation。

一句话记忆

MixUp 混整图，CutMix 混局部。

Q085 为什么 Data Augmentation 不能随便加？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

每个增强都隐式声明“该变换不改变标签”；若声明错误，就在主动制造 label noise。

标准回答：从公式到直觉

1. 猫狗水平翻转通常不改类，但 OCR、驾驶方向、医学左右侧可能改变语义
2. color jitter 是否合理取决于颜色是否是 label 信息
3. 增强强度应尽量贴近真实 deployment shift，而不是堆技巧

高频追问链

- 如何判断增强产生了 label noise？
- TTA 什么时候值得？

常见失分点

照搬 ImageNet augmentation 到所有任务是常见错误。

工程/项目视角

优先记录真实设备/环境扰动并模拟真实噪声。

一句话记忆

Augmentation 本质是 task-specific invariance engineering。

Q086 标注有大量噪声怎么办？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

先识别 noise mechanism，再决定重标、鲁棒训练或样本过滤；系统性噪声往往比随机噪声更危险。

标准回答：从公式到直觉

1. random noise 分散，systematic noise 会让某类/某设备长期错误
2. 可用 clean subset、模型 disagreement、loss history、confident learning 找疑似样本
3. 高 loss 也可能是最有价值的 hard example，不能直接删；更根本的是 guideline、双标与复核

高频追问链

- 如何区分 hard sample 与 noisy label？
- 边界标注不一致怎么评估？

常见失分点

纯模型自动清洗会放大模型偏差，需要人工 audit。

工程/项目视角

保存 annotation provenance 和 reviewer history，便于回滚。

一句话记忆

先找噪声机制；高 loss 不等于坏数据。

Q087 半监督视觉训练怎么做？最大风险是什么？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

用 labeled supervised loss 加 unlabeled pseudo-label/consistency loss；最大风险是 confirmation bias。

标准回答：从公式到直觉

1. Teacher 在弱增强生成伪标签，Student 在强增强学习
2. EMA teacher 提高稳定性，confidence threshold 控制 precision/coverage
3. 若 teacher 对某类系统性错误，伪标签会持续自我强化，需要 class-aware threshold、uncertainty 或人工抽检

高频追问链

- threshold 太高/太低分别怎样？
- Mean Teacher 的 EMA 为什么有用？

常见失分点

无标注数据不是“免费数据”，错误伪标签同样有成本。

工程/项目视角

半监督适合大规模未标注工业数据，但必须有质量监控。

一句话记忆

真标签锚定 + 伪标签扩展；最大敌人是错误自我强化。

Q088 为什么 calibration 在真实视觉系统里重要？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

置信度常被用于阈值、拒识、人审路由和风险控制，因此概率是否可信直接影响系统决策。

标准回答：从公式到直觉

1. 理想 calibration：置信度 0.9 的样本约 90% 正确
2. ECE/reliability diagram 比较 confidence 与 empirical accuracy
3. Temperature scaling 学一个 T 调 logits，不改变 argmax，但 distribution shift 下校准仍可能失效

高频追问链

- Calibration 与 accuracy 有何区别？
- OOD 与 calibration 什么关系？

常见失分点

softmax 最大值不能直接当真实概率。

工程/项目视角

高风险业务应设计 abstention/human review 并按业务成本选阈值。

一句话记忆

模型分数不只要会排序，还要知道自己多确定。

Q089 如何判断模型真的变好，而不是偶然涨 0.5%？

难度 ★★★★★ 高频 ★★★★★ 标签：项目拷打核心

面试官在考什么

用控制变量、多随机种子、置信区间、slice analysis、failure migration 与成本指标证明稳定因果收益。

标准回答：从公式到直觉

1. 一次只改一个关键因素做 ablation
2. 重复 seeds 或 bootstrap 估计波动，若涨幅小于自然方差不能宣称稳定提升
3. 按 class/size/device/lighting 看收益来源，并同时报告 latency/memory/training cost

高频追问链

- 如何做 bootstrap CI?
- 关键类退化但总体涨怎么办？

常见失分点

只报 best checkpoint/best seed 会有 selection bias。

工程/项目视角

维护实验 registry 与固定 regression suite。

一句话记忆

涨点要能复现、能解释、落到关键 slice，还要算成本。

第十章 压缩、部署、系统设计与手撕

本章目标

从 FLOPs 到真实延迟，从 PyTorch 到 TensorRT，从模型到可上线系统。

本章速览：Pruning、Quantization、Distillation 分别解决什么？ / PTQ 和 QAT 有什么区别？ / 为什么 FLOPs 降 50%，latency 不一定降 50%？ / ONNX 自身会不会让模型自动变快？ / ...

Q090 Pruning、Quantization、Distillation 分别解决什么？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

Pruning 减连接/通道，Quantization 降数值精度，Distillation 把 teacher 能力迁移给小 student。

标准回答：从公式到直觉

1. Unstructured pruning 稀疏但普通硬件未必加速；structured pruning 更易获得真实 latency
2. Quantization 降 FP32/FP16 到 INT8/INT4，减少带宽和算力但引入量化误差
3. Distillation 可对 logits/features/relations 对齐，小模型学习 teacher 的软知识

高频追问链

- 为什么非结构化稀疏不一定快？
- 蒸馏 temperature 有什么用？

常见失分点

模型尺寸小不等于运行快，依赖硬件/编译器支持。

工程/项目视角

压缩目标应是端到端 latency/energy/size + accuracy。

一句话记忆

Prune 删结构，Quant 降精度，Distill 教小模型。

Q091 PTQ 和 QAT 有什么区别？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

PTQ 在训练后用 calibration 量化，成本低；QAT 训练时模拟量化，让模型适应离散化误差。

标准回答：从公式到直觉

1. PTQ 需代表性 calibration data 估 activation range/scale
2. QAT 插 fake quant/dequant，forward 模拟整数截断，backward 常用 STE
3. per-channel weight 常比 per-tensor 精确；敏感层可保留高精度

高频追问链

- symmetric vs asymmetric？
- 为什么 calibration 数据不用很大但要代表？

常见失分点

QAT 通常不是全程真的用 INT8 算子训练。

工程/项目视角

部署要按目标 runtime 的具体 quant scheme 做数值回归。

一句话记忆

PTQ 快速后量化，QAT 提前适应量化噪声。

Q092 为什么 FLOPs 降 50%，latency 不一定降 50%？

难度 ★★★★★ 高频 ★★★★★ 标签：当前岗位核心

面试官在考什么

真实延迟由计算、内存、算子实现、并行度、kernel launch、batch 和硬件占用共同决定；FLOPs 只是代理。

标准回答：从公式到直觉

1. 低 FLOPs 算子可能 memory-bound，例如 depthwise conv
2. 小算子过多造成 kernel launch 开销；reshape/transpose 几乎不计 FLOPs 但可能很慢
3. 小 batch/小 feature 可能无法占满 GPU；必须用 profiler 看 per-op time、utilization、bandwidth 与 fusion

高频追问链

- compute-bound vs memory-bound？
- 为什么大 batch 吞吐高但 latency 可能高？

常见失分点

用 FLOPs 直接推断“更快”是部署面试大忌。

工程/项目视角

必须在目标硬件、目标 batch、目标输入上 benchmark。

一句话记忆

FLOPs 是理论工作量，latency 是硬件执行结果。

Q093 ONNX 自身会不会让模型自动变快？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经部署题

面试官在考什么

不会。ONNX 是中间表示；真正加速来自执行后端的图优化、kernel、precision 与硬件特化。

标准回答：从公式到直觉

1. ONNX 负责把计算图标准化，供 ORT/TensorRT/OpenVINO 等执行
2. 加速来自 constant folding、operator fusion、layout、FP16/INT8 与 kernel selection
3. unsupported op 可能 fallback 或拆成低效子图；dynamic shape/custom op/NMS/ROIAlign 是常见难点

高频追问链

- opset 是什么？
- dynamic axes 如何影响 TensorRT？

常见失分点

“转 ONNX 就会快” 是错误认知。

工程/项目视角

导出后必须同时做 numerical parity 和 performance benchmark。

一句话记忆

ONNX 负责表达，快来自后端与硬件。

Q094 TensorRT 为什么快？

难度 ★★★★★ 高频 ★★★★★ 标签：基础高频

面试官在考什么

通过图融合、低精度、tactic/kernel 搜索、内存复用与 NVIDIA GPU 特化把网络编译成高效 engine。

标准回答：从公式到直觉

1. Layer fusion 减少中间 tensor 落显存和 kernel launch
2. Builder benchmark 多种 tactics，结合 Tensor Core/FP16/INT8 选快实现
3. dynamic shape 用 optimization profile；精度漂移可能来自低精度、resize/NMS 或算子实现差异

高频追问链

- Engine 为什么与 GPU/版本相关？
- 如何定位 PyTorch/TRT 输出差异？

常见失分点

TensorRT 不是无损魔法，低精度和算子替换会带来数值变化。

工程/项目视角

固定 CUDA/cuDNN/TRT 与 engine build provenance。

一句话记忆

快在编译、融合、低精度和最优 kernel。

Q095 Latency、Throughput、QPS 有什么关系？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经/系统题

面试官在考什么

Latency 是单请求响应时间，Throughput/QPS 是单位时间处理量；batch/concurrency 往往提高吞吐但增加排队与尾延迟。

标准回答：从公式到直觉

1. 端到端 $\text{latency} = \text{decode} + \text{pre} + \text{H2D} + \text{model} + \text{post} + \text{queue}$
2. batch 大通常 GPU utilization 高、throughput 高，但 P95/P99 可能变差
3. 应同时报告 P50/P95/P99、QPS、batch、并发、GPU utilization 与错误率

高频追问链

- 为什么 $\text{QPS} \neq 1/\text{latency}$ ？
- tail latency 从哪里来？

常见失分点

只报“模型 5ms”而不说设备、batch、前后处理不完整。

工程/项目视角

线上 SLA 由 tail latency 和吞吐成本共同约束。

一句话记忆

Latency 看一个请求，Throughput 看系统一秒做多少。

Q096 手写 Batch IoU：如何向量化？

难度 ★★★★★ 高频 ★★★★★ 标签：手撕必会

面试官在考什么

利用 broadcasting 把 $N \times 4$ 与 $M \times 4$ 展开成 $N \times M$ 配对，统一计算交集和 union。

标准回答：从公式到直觉

1. $lt = \max(a[:, None, :2], b[None, :, :2])$; $rb = \min(a[:, None, :2], b[None, :, :2])$
2. $wh = \text{clip}(rb - lt, 0)$, $inter = wh_x \cdot wh_y$; area 分别广播
3. $iou = inter / (area1 + area2 - inter + eps)$ ，并测试空输入、退化框、完全重合/不相交

高频追问链

- 如何分块避免 $N \times M$ 太大？
- xywh 输入怎么改？

常见失分点

xyxy/xywh 混淆、负宽高、union=0 是高频 bug。

工程/项目视角

matcher 场景 Pairwise IoU 可能占显存，要考虑 chunking。

一句话记忆

向量化关键：max 左上、min 右下、clip、union。

Q097 手写 NMS：面试时应该怎么写？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经手撕原题

面试官在考什么

先写正确贪心算法，再用向量化 IoU 优化；重点是 shape、排序和边界条件。

标准回答：从公式到直觉

1. scores 降序，循环取最高分 index 加 keep
2. 对其余框一次性算 IoU，只保留 $IoU \leq \text{threshold}$
3. class-aware 可分组或做 class offset；worst-case $O(N^2)$ ，实际常先 top-k/conf filter

高频追问链

- 如何写 Soft-NMS？
- batched NMS 怎么做？

常见失分点

边写边说明 shape 和 edge cases 比沉默手敲更稳。

工程/项目视角

NMS 参数属于业务 recall/precision 的一部分，应版本化。

一句话记忆

排序→取最高→批量 IoU→过滤→循环。

Q098 手写 BatchNorm forward：哪些维度统计？

难度 ★★★★★ 高频 ★★★★★ 标签：公开面经手撕原题

面试官在考什么

CNN BN 对每个 channel 跨 N/H/W 统计均值方差；训练更新 running stats，推理用 running stats，再做 γ/β affine。

标准回答：从公式到直觉

1. NCHW 的 reduce axes=(0,2,3)，得到 [C] 的 mean/var
2. 训练 batch stats 与 running update 要区分；不同框架 momentum 定义可能方向不同
3. eval 不再用当前 batch；Conv+BN 可融合进卷积 weight/bias

高频追问链

- 为什么 eps 在 sqrt 内？
- Conv-BN 如何 fuse？

常见失分点

统计轴写错、忘记 eval path、running update 写反最常见。

工程/项目视角

部署可通过 BN folding 减少推理算子。

一句话记忆

BN 手撕关键：统计轴、running 状态、train/eval。

Q099 系统设计：如何设计一个工业缺陷检测系统？

难度 ★★★★★ 高频 ★★★★★ 标签：高级系统题

面试官在考什么

先从业务失败成本定义指标，再设计数据、模型、阈值/拒识、部署、监控和持续学习闭环。

标准回答：从公式到直觉

1. 指标先定 Recall/FNR、False Reject、P95 latency、吞吐与设备预算
2. 数据覆盖产线/相机/材质/批次/光照/稀有缺陷，并维护 hard negatives/OOD
3. 模型可 coarse detector→fine segmenter；系统需质量检测、低置信人审、日志、A/B、回滚、drift monitor 与 FP/FN 回流

高频追问链

- Recall 要 99.9% 怎么设计测试？
- 未知缺陷怎么处理？

常见失分点

一上来只讲 YOLO/U-Net 会显得缺少落地视角。

工程/项目视角

工业系统核心往往是数据闭环与失败处理。

一句话记忆

系统题先谈业务指标和失败成本，再谈模型。

Q100 项目终极拷问：你的模型为什么提升了 3 个点？

难度 ★★★★★ 高频 ★★★★★ 标签：终极项目题

面试官在考什么

用 Failure→Hypothesis→Change→Ablation→Cost→Business Decision 的因果链证明，而不是罗列模块。

标准回答：从公式到直觉

1. 先给 baseline 和明确 failure slice，例如总体 AP43.1、AP_s21.3
2. 提出机制假设并对应改动，例如 stride 过大→加 P2/改 assignment
3. 逐项消融并报告关键 slice 与成本，例如 latency 8.1→9.5ms、memory+12%，再说明 SLA 内为何值得

高频追问链

- 如何证明不是参数量带来的？
- 如何证明不是随机种子？
- 涨点但超 SLA 怎么办？

常见失分点

“加 attention 所以涨了” 没有因果证据，只报 best run 也有 selection bias。

工程/项目视角

优秀项目陈述应展示 failure migration 和可复现实验记录。

一句话记忆

黄金链：失败模式→假设→改动→消融→成本→业务结论。

附录 A：Top 30 必须吃透

题号	主题	临场要求
Q012	卷积层参数数量和 FLOPs 怎么计算？	能口述 + 能追问 + 能联系项目
Q013	什么是 receptive field？怎么计算？	能口述 + 能追问 + 能联系项目
Q014	为什么深层网络会梯度消失/爆炸？	能口述 + 能追问 + 能联系项目
Q016	BatchNorm 为什么有效？训练和推理有什么区别？	能口述 + 能追问 + 能联系项目
Q018	为什么 ResNet 可以训练很深？	能口述 + 能追问 + 能联系项目
Q021	普通卷积、Group Conv、Depthwise Conv 有什么区别？	能口述 + 能追问 + 能联系项目
Q024	SGD 和 Adam 有什么区别？	能口述 + 能追问 + 能联系项目
Q026	Two-stage 和 One-stage Detector 的核心区别是什么？	能口述 + 能追问 + 能联系项目
Q027	Faster R-CNN 完整流程是什么？	能口述 + 能追问 + 能联系项目
Q028	ROI Pooling 和 ROI Align 有什么区别？	能口述 + 能追问 + 能联系项目
Q030	为什么小目标检测难？如何系统提升？	能口述 + 能追问 + 能联系项目
Q031	FPN 为什么有效？	能口述 + 能追问 + 能联系项目
Q032	IoU 是什么？作为 loss 有什么问题？	能口述 + 能追问 + 能联系项目
Q033	GIoU、DioU、CloU 有什么区别？	能口述 + 能追问 + 能联系项目
Q035	NMS 是什么？为什么需要？	能口述 + 能追问 + 能联系项目
Q037	Focal Loss 为什么能解决 dense detector 类别不平衡？	能口述 + 能追问 + 能联系项目
Q038	AP 和 mAP 到底怎么计算？	能口述 + 能追问 + 能联系项目
Q039	DETR 为什么不需要 Anchor 和传统 NMS？	能口述 + 能追问 + 能联系项目
Q040	线上检测 Recall 很低，如何系统定位？	能口述 + 能追问 + 能联系项目
Q043	U-Net 为什么在医学/工业分割中流行？	能口述 + 能追问 + 能联系项目

Q044	DeepLab 的核心思想是什么？ASPP 为什么有效？	能口述 + 能追问 + 能联系项目
Q046	Dice Loss 为什么适合前景稀少的分割？	能口述 + 能追问 + 能联系项目
Q059	ViT 如何把图像变成 Transformer 输入？	能口述 + 能追问 + 能联系项目
Q061	Self-Attention 在视觉里的复杂度是多少？	能口述 + 能追问 + 能联系项目
Q064	CLIP 是怎么实现图文对齐的？	能口述 + 能追问 + 能联系项目
Q066	SAM 的核心架构是什么？	能口述 + 能追问 + 能联系项目
Q067	SAM 为什么 zero-shot 强？SAM2 增加了什么？	能口述 + 能追问 + 能联系项目
Q092	为什么 FLOPs 降 50%，latency 不一定降 50%？	能口述 + 能追问 + 能联系项目
Q094	TensorRT 为什么快？	能口述 + 能追问 + 能联系项目
Q100	项目终极拷问：你的模型为什么提升了 3 个点？	能口述 + 能追问 + 能联系项目

附录 B：公式速查

概念	公式
Conv Params	$K_h \cdot K_w \cdot C_{in} \cdot C_{out} (+bias)$
Conv MACs	$H_{out} \cdot W_{out} \cdot K_h \cdot K_w \cdot C_{in} \cdot C_{out}$
Receptive Field	$r_l = r_{l-1} + (k_{l-1} - 1) d_{l-1}$
BatchNorm	$\hat{x} = (x - \mu) / \sqrt{\sigma^2 + \epsilon}; y = \gamma \hat{x} + \beta$
IoU	$ A \cap B / A \cup B $
Dice	$2 P \cap G / (P + G)$
Focal	$-\alpha(1-p)^\gamma \log p$
Stereo	$Z = fB/d$
Diffusion	$x_t = \sqrt{\alpha_t} x_0 + \sqrt{1 - \alpha_t} \epsilon$
CFG	$\epsilon = \epsilon_u + w(\epsilon_c - \epsilon_u)$
CLIP	$s_{ij} = v_i^T t_j / \tau$

附录 C：三段高频手撕代码

Batch IoU

```
def batch_iou(a,b,eps=1e-7):
    lt=torch.maximum(a[:,None,:2],b[None,:,:2])
    rb=torch.minimum(a[:,None,2:],b[None,:,2:])
    wh=(rb-lt).clamp(min=0)
    inter=wh[...,0]*wh[...,1]
    aa=(a[:,2]-a[:,0]).clamp(min=0)*(a[:,3]-a[:,1]).clamp(min=0)
    ab=(b[:,2]-b[:,0]).clamp(min=0)*(b[:,3]-b[:,1]).clamp(min=0)
    return inter/(aa[:,None]+ab[None,:]-inter+eps)
```

NMS

```
def nms(boxes,scores,thr=.5):
    order=scores.argsort(descending=True); keep=[]
    while order.numel()>0:
        i=order[0]; keep.append(i.item())
        if order.numel()==1: break
        rest=order[1:]
        iou=batch_iou(boxes[i:i+1],boxes[rest])[0]
        order=rest[iou<=thr]
    return keep
```

BatchNorm forward

```
def bn_forward(x,gamma,beta,eps=1e-5):
    mean=x.mean((0,2,3),keepdim=True)
    var=x.var((0,2,3),unbiased=False,keepdim=True)
    xhat=(x-mean)/torch.sqrt(var+eps)
    return gamma[None,:,:None]*xhat+beta[None,:,:None]
```

附录 D：项目拷打 30 问

01. 为什么选这个 baseline?
02. 最初的 failure analysis 是什么?
03. 数据规模/类别/目标尺寸分布?
04. train/val/test 如何防泄漏?
05. 标注规范和一致性如何?
06. 每个模块分别涨多少?
07. 多个随机种子稳定吗?
08. 涨点来自哪些场景?
09. 哪些场景退化?
10. 为什么选这个 loss?
11. 有哪些替代方案?
12. 参数/FLOPs/显存/latency?
13. latency 的硬件、batch、前后处理?
14. 线上线下 preprocessing 一致吗?
15. ONNX/TRT 数值对齐吗?

- 16. NMS/conf 阈值怎么选？
- 17. 业务更重 recall 还是 precision？
- 18. 如何做 OOD/拒识？
- 19. 线上 FP/FN 如何回流？
- 20. 如何回滚模型版本？
- 21. 增强是否伤害某类样本？
- 22. 如何处理 class imbalance？
- 23. 最失败的一次实验？
- 24. 2 倍数据预算先补什么？
- 25. 2 倍计算预算先加模型还是分辨率？
- 26. SLA 从 20ms 到 5ms 怎么改？
- 27. 换相机/城市/产线还能工作吗？
- 28. 创新还是工程组合？
- 29. 重做一次会删哪一步？
- 30. 一句话说明业务价值。

附录 E：30 天复习路线

时间	范围	目标
Day 1-4	Q1-25	传统 CV + CNN；每天手算 FLOPs/感受野/BN。
Day 5-10	Q26-40	检测；手撕 IoU/NMS，能画 Faster R-CNN/FPN/DETR。
Day 11-14	Q41-58	分割 + OCR；Dice/U-Net/DeepLab/CTC。
Day 15-19	Q59-75	ViT/CLIP/SAM + Diffusion。
Day 20-22	Q76-82	视频/3D/多模态。
Day 23-25	Q83-89	数据、噪声、半监督、Calibration、实验设计。
Day 26-27	Q90-98	量化、TensorRT、latency + 三段手撕。
Day 28-30	Q99-100	系统设计 + 项目拷打 + mock interview。

附录 F：公开依据与经典参考

公开面经用于佐证题型；论文和当前岗位用于核对技术定义与 2026 能力趋势。

[1] 公开面经：Conv2d/padding/R-CNN/Faster R-CNN/YOLO/FCN [\[link\]](#)

- [2] 公开面经: MobileNet/ROIALign/Smooth L1/NMS/BN/U-Net/Mask R-CNN [\[link\]](#)
- [3] 2025 公开面经: CNN vs Transformer、SAM/SAM2、工业缺陷、YOLOv10 [\[link\]](#)
- [4] OpenAI 2026: Multimodal Perception and Authentication [\[link\]](#)
- [5] OpenAI 2026: Researcher, Multimodal Safety [\[link\]](#)
- [6] ViT [\[link\]](#)
- [7] DETR [\[link\]](#)
- [8] SAM [\[link\]](#)
- [9] SAM 2 [\[link\]](#)
- [10] Faster R-CNN [\[link\]](#)
- [11] FPN [\[link\]](#)
- [12] Focal Loss [\[link\]](#)
- [13] U-Net [\[link\]](#)
- [14] DeepLabv3+ [\[link\]](#)
- [15] CLIP [\[link\]](#)
- [16] MAE [\[link\]](#)
- [17] DDPM [\[link\]](#)
- [18] Latent Diffusion [\[link\]](#)
- [19] ControlNet [\[link\]](#)

结语：真正的 Offer 不是背出 100 个答案

技术题尽量回答成：定义/公式 → 直觉 → 为什么这样设计 → 有什么问题 → 如何改进 → 在项目里怎么验证。

项目题尽量回答成：Failure → Hypothesis → Change → Ablation → Cost → Business Decision。

把自己的 2-3 个项目逐项映射到本书的数据、模型、loss、指标、消融、失败、部署和监控，才算真正完成复习。