

冲刺算法 Offer

深度学习算法岗面试 100 题

2026 专业版 · 真题归纳 × 原理推导 × 追问链 × 手写代码 × 工程排障

适用岗位	深度学习 / 大模型 / 多模态 / CV / 搜推算法工程师
题目规模	100 道核心题 + 500+ 追问触点
训练方式	先答题 → 看标准回答 → 原理拆解 → 追问 → 失分点
证据范围	2025-2026 公开候选人面经 + 经典原始论文 / 官方文档

版本日期：2026-09-01

方法声明：借鉴“以题带知识、层层追问”的训练理念，不复刻《剑指 Offer》的文字、题目或版式。

使用说明：这本 PDF 应该怎么刷

核心原则 每一道题至少练到“是什么 → 为什么 → 数学/shape → 什么时候失效 → 工程怎么排查”。仅能复述定义，通常不足以通过 2026 算法岗的连续追问。

推荐的 4 遍训练法

- 第 1 遍：只看题目，限时 60–90 秒口述；说不顺的题做标记。
- 第 2 遍：看“标准回答 + 原理拆解”，把公式和 tensor shape 自己重新写一遍。
- 第 3 遍：只看“连续追问”，模拟面试官打断式追问；每个追问控制在 30–60 秒。
- 第 4 遍：手写 MHA、NMS、InfoNCE、Loss Mask、显存估算和排障 checklist。

为什么 2026 版必须加入后训练和推理系统

公开的 2026 候选人面经已经把 SFT 数据、GRPO、PPO/DPO、Reward Hacking、GQA/MLA、KV Cache、FlashAttention、vLLM、FSDP/ZeRO、OOM 与 GPU 性能排查放在同一轮算法面试中。与此同时，BN/LN、优化器、反向传播和损失函数仍然是基础门槛。因此本书按“底层原理 + 现代 LLM + 工程系统”三线并行组织。

“真题”口径 题目来自公开候选人面经的高频问法归一化，并结合经典论文扩展；不声称是企业官方题库，也不使用任何非公开面试材料。

全书能力地图

章节	题号	核心能力	建议优先级
1. 神经网络与反向传播基础	01-10	先把“为什么能学”说清楚：表达能力、梯度传播、损失函数与初始化。	A
2. 优化器、归一化与正则化	11-20	从训练动力学解释 SGD/AdamW、Warmup、BN/LN/RMSNorm 与稳定性。	S
3. CNN 与计算机视觉基础	21-30	覆盖卷积、感受野、残差、检测损失、ViT 与数据增强。	A
4. 序列模型与语言模型基础	31-38	理解 RNN/LSTM 到 Encoder/Decoder 与 Tokenization 的演进。	A
5. Transformer 核心	39-55	2026 算法岗最核心模块：Attention、RoPE、GQA、KV Cache、FlashAttention。	S
6. LoRA、SFT 与大模型后训练	56-68	从参数高效微调到 PPO/DPO/GRPO，回答“模型如何被真正训练成可用系统”。	S
7. 对比学习、多模态与 Diffusion	69-78	从 InfoNCE、CLIP 到视频多模态，再到 Diffusion/DiT。	A
8. 训练工程与分布式训练	79-88	混合精度、梯度累积、DDP/FSDP/ZeRO 与 OOM/NaN/GPU 利用率排障。	S
9. 模型压缩与推理优化	89-95	量化、PagedAttention、Continuous Batching、Prefill/Decode 与延迟定位。	S
10. 项目深挖与系统题	96-100	把“会模型”升级为“能做项目”：模型选择、线上线下偏差、消融、故障定位与手写实现。	S

目录

01 神经网络与反向传播基础 Q01-Q10

先把“为什么能学”说清楚：表达能力、梯度传播、损失函数与初始化。

02 优化器、归一化与正则化 Q11-Q20

从训练动力学解释 SGD/AdamW、Warmup、BN/LN/RMSNorm 与稳定性。

03 CNN 与计算机视觉基础 Q21-Q30

覆盖卷积、感受野、残差、检测损失、ViT 与数据增强。

04 序列模型与语言模型基础 Q31-Q38

理解 RNN/LSTM 到 Encoder/Decoder 与 Tokenization 的演进。

05 Transformer 核心 Q39-Q55

2026 算法岗最核心模块：Attention、RoPE、GQA、KV Cache、FlashAttention。

06 LoRA、SFT 与大模型后训练 Q56-Q68

从参数高效微调到 PPO/DPO/GRPO，回答“模型如何被真正训练成可用系统”。

07 对比学习、多模态与 Diffusion Q69-Q78

从 InfoNCE、CLIP 到视频多模态，再到 Diffusion/DiT。

08 训练工程与分布式训练 Q79-Q88

混合精度、梯度累积、DDP/FSDP/ZeRO 与 OOM/NaN/GPU 利用率排障。

09 模型压缩与推理优化 Q89-Q95

量化、PagedAttention、Continuous Batching、Prefill/Decode 与延迟定位。

10 项目深挖与系统题 Q96-Q100

把“会模型”升级为“能做项目”：模型选择、线上线偏差、消融、故障定位与手写实现。

第 1 章 神经网络与反向传播基础

本章目标 先把“为什么能学”说清楚：表达能力、梯度传播、损失函数与初始化。

覆盖题目：Q01-Q10。建议先遮住答案口述，再阅读解析。

01 为什么神经网络必须引入非线性激活函数？

难度 ★☆☆ 频度 高频

面试官在考什么 判断候选人是否理解“深度”本身并不会自动增加表达能力。

60-90 秒标准回答

如果所有层都是线性变换，多层矩阵乘法仍可合并为一次线性变换；非线性激活使网络可以组合出弯曲的决策边界和分段函数，从而获得通用函数逼近能力。

$$h_2 = W_2(W_1x+b_1)+b_2 = (W_2W_1)x + (W_2b_1+b_2)$$

原理拆解 / 深度展开

- 把两层线性网络写成 $W_2(W_1x+b_1)+b_2$ ，可重新整理为 $W'x+b'$ 。
- 非线性不是“让梯度更大”，而是打破线性闭包。
- 现代 Transformer 的 Attention 本身含 softmax，但 FFN 仍需 GELU/SiLU 等非线性以增强逐 token 的特征变换能力。

面试官连续追问

- 如果只有最后一层加激活还算深度网络吗？
- ReLU 网络为什么能逼近非线性函数？
- Attention 里已经有 softmax，为什么还要 FFN 激活？

高频失分点

易错 把“层数多”直接等同于“表达能力强”。

易错 只会背“解决线性不可分”但不能证明多层线性可合并。

02 反向传播的本质是什么？Autograd 在做什么？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察链式法则、计算图和 reverse-mode AD。

60-90 秒标准回答

反向传播本质是链式法则在计算图上的高效复用。Forward 保存必要的中间量并建立依赖关系；Backward 从标量损失出发，按拓扑逆序计算 vector-Jacobian product，并把来自多条路径的梯度累加。

$$dL/dW = (dL/da) \cdot (da/dz) \cdot (dz/dW)$$

原理拆解 / 深度展开

- 对标量损失 L，参数很多而输出少，reverse-mode AD 比 forward-mode 更合适。
- 节点有多条后继路径时，梯度必须相加，这是计算图“累计梯度”的来源。
- PyTorch 的 backward() 默认把梯度累加到 .grad，因此训练循环中通常要 zero_grad。

面试官连续追问

- 数值微分和自动微分有什么区别？
- 为什么 backward 前要 zero_grad？
- in-place 操作为什么可能破坏反向传播？
- detach() 做了什么？

高频失分点

易错 把 Autograd 说成数值差分。

易错 忽略广播、共享参数或多路径导致的梯度求和。

03 为什么 Softmax 与 Cross Entropy 常一起使用？请推导梯度。

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察概率建模和现场推导能力。

60-90 秒标准回答

Softmax 把 logits 变成归一化分类概率，交叉熵对应最大化正确类别的对数似然。两者合并后，对 logit z_i 的梯度恰好是 $\pi_i - y_i$ ，形式简单且数值实现可以直接使用 log-sum-exp 保持稳定。

$$\partial L / \partial z_i = \pi_i - y_i$$

原理拆解 / 深度展开

- 对 one-hot 标签， $L = -\log p_y$ 。
- Softmax 的 Jacobian 含对角项 $\pi_i(1-\pi_i)$ 和非对角项 $-\pi_i\pi_j$ ，代入 CE 后会相消成 $\pi - y$ 。
- 框架中的 CrossEntropyLoss 通常直接接 logits，不要先手工 softmax。

面试官连续追问

- 为什么 CrossEntropyLoss 不需要先 softmax？

- log-sum-exp 为什么数值稳定？
- 多标签分类为什么不能直接用 softmax CE？

高频失分点

易错 把 logits 当概率输入 CrossEntropyLoss。

易错 忽视 softmax 的类别间耦合。

04 Sigmoid、Tanh、ReLU、GELU、SiLU 如何比较？

难度 ★☆☆ 频度 高频

面试官在考什么 考察激活函数的梯度、饱和性与现代网络选择。

60-90 秒标准回答

Sigmoid/Tanh 在大绝对值区域会饱和，深层传播时梯度易衰减；ReLU 简单高效但存在 dead ReLU；GELU 是平滑的概率式门控，Transformer 常用；SiLU/Swish 是 $x \cdot \text{sigmoid}(x)$ ，在现代 LLM/视觉网络中也常见。

原理拆解 / 深度展开

- Sigmoid 输出非零中心，可能让优化方向产生偏置。
- ReLU 正半轴梯度为 1，缓解饱和，但负半轴长期为 0 时神经元可能死亡。
- GELU/SiLU 保留负值的小幅响应，梯度更平滑。

面试官连续追问

- LeakyReLU 为什么能缓解 dead ReLU？
- GELU 和 ReLU 的计算代价差多少？
- 为什么门控 FFN 常用 SiLU/SwiGLU？

高频失分点

易错 把“GELU 一定优于 ReLU”说成普遍定律。

易错 只比较函数值，不比较梯度形状与任务环境。

05 什么是梯度消失与梯度爆炸？如何系统解决？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察深层网络训练稳定性的底层理解。

60-90 秒标准回答

深层网络反向传播会连续乘 Jacobian。若其典型奇异值长期小于 1，梯度指数衰减；大于 1 则指数放大。解决思路是控制信号尺度并提供短梯度路径：合理初始化、非饱和激活、Normalization、Residual、Gradient Clipping，以及对循环网络使用 LSTM/GRU。

$$\partial L / \partial h_0 = (\prod_l J_l) \cdot \partial L / \partial h_L$$

原理拆解 / 深度展开

- 不要只看单个权重大小，应理解 Jacobian 连乘和谱半径。
- Residual 让梯度中出现 identity path，使深层网络不必完全穿过所有非线性分支。
- Gradient clipping 主要控制爆炸，不是从根本上修复消失。

面试官连续追问

- 为什么 ResNet 能改善梯度传播？
- Pre-Norm Transformer 为什么更稳？
- clip by value 和 clip by norm 有何差异？

高频失分点

易错 把梯度消失归因于“学习率太小”。

易错 把 Gradient Clipping 当成解决所有训练不稳定的万能手段。

06 Xavier 与 Kaiming 初始化为什么有效？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察方差传播和初始化推导。

60-90 秒标准回答

初始化的目标是让前向激活和反向梯度的方差在层间大致保持稳定。Xavier 适合近似对称激活；Kaiming 针对 ReLU 约一半激活被截断的特点，在 fan_in 维度上放大方差补偿。

$$\text{Xavier: } \text{Var}(W) \approx 2/(\text{fan_in} + \text{fan_out}); \text{ Kaiming(ReLU): } \text{Var}(W) \approx 2/\text{fan_in}$$

原理拆解 / 深度展开

- 若输入各维独立且方差相同，可推导线性层输出方差与 $\text{fan_in} \cdot \text{Var}(W)$ 成正比。
- ReLU 后约保留一半二阶矩，因此 Kaiming 常取 $\text{Var}(W) = 2/\text{fan_in}$ 。
- 初始化与激活函数必须匹配。

面试官连续追问

- fan_in 与 fan_out 怎么选？
- 为什么过小初始化导致信号衰减？

→ Transformer 初始化为什么还会配合 residual scaling?

高频失分点

易错 只背公式，不说明“保持方差”的目标。

易错 忽略激活函数对二阶矩的影响。

07 什么是过拟合？如何判断与治理？

难度 ★☆☆ 频度 高频

面试官在考什么 考察泛化与实验诊断能力。

60-90 秒标准回答

过拟合不是“训练集准确率高”本身，而是训练误差继续下降时，验证误差不再改善甚至变差，说明模型对训练集特有噪声和偶然模式的拟合超过了可泛化规律。治理要从数据、容量、正则化和评估四个层面同时考虑。

原理拆解 / 深度展开

- 优先检查 train/val split 是否同分布、是否有泄漏。
- 数据层可扩充与增强；模型层可减小容量；优化层可用 weight decay、dropout、early stopping。
- 训练 loss 与业务指标不是同一个概念，需同时看目标指标。

面试官连续追问

- 训练集和验证集都很差属于什么问题？
- 数据增强为什么能起到正则化作用？
- Double descent 怎么理解？

高频失分点

易错 一看到验证集不涨就盲目加 Dropout。

易错 忽略数据泄漏和指标实现 bug。

08 Label Smoothing 为什么有效？什么时候可能有副作用？

难度 ★★☆☆ 频度 中高频

面试官在考什么 考察概率校准、正则化和损失目标。

60-90 秒标准回答

Label Smoothing 把 one-hot 标签从绝对的 0/1 变为带少量均匀质量的软标签，使模型不必把正确类别 logit 推到无限大，通常能抑制过度自信并改善泛化与 calibration。

$$y' = (1 - \epsilon)y + \epsilon/K$$

原理拆解 / 深度展开

- 常见形式 $y' = (1 - \epsilon)y + \epsilon/K$ 。
- 它改变的不只是标签噪声，还改变了最优 logit 间隔。
- 在知识蒸馏、开放集或需要非常锐利分布的任务中，过强 smoothing 可能损伤细粒度信息。

面试官连续追问

- Label Smoothing 与温度缩放有什么不同？
- 为什么它可能让 calibration 变好？
- 多标签问题怎么做 smoothing？

高频失分点

易错 认为 smoothing 越大越好。

易错 把它和 label noise 完全等同。

09

MSE、BCE、Cross Entropy 分别用于什么场景？

难度 ★☆☆ 频度 高频

面试官在考什么 考察任务建模和输出层匹配。

60-90 秒标准回答

MSE 常用于连续值回归；BCE 用于二分类或多标签分类，每个标签独立建模；Softmax Cross Entropy 用于互斥多分类。关键不是“记名字”，而是先确定目标变量的概率结构。

原理拆解 / 深度展开

- 二分类可用单 logit + BCEWithLogitsLoss。
- 多标签每一类独立 sigmoid；多分类各类概率和为 1。
- BCEWithLogitsLoss 比 sigmoid 后再 BCE 更数值稳定。

面试官连续追问

- 为什么回归也能用 Huber Loss？
- 类别不平衡时 BCE 怎么改？
- 多分类能不能用 MSE？

高频失分点

易错 混淆 multi-class 与 multi-label。

易错 在框架 loss 前重复做 sigmoid/softmax。

10 类别极度不平衡怎么办？指标怎么选？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察数据、损失、阈值和指标的完整思路。

60-90 秒标准回答

先确认业务代价，再从采样、损失、表征、阈值与指标五层处理。可做重采样、class weight、Focal Loss、hard negative mining，并根据 precision/recall 成本选择阈值。极不平衡任务不要只看 accuracy，通常 PR-AUC 比 ROC-AUC 更直观。

原理拆解 / 深度展开

- 负采样会改变训练先验，线上概率可能需要校准。
- 阈值不是固定 0.5，应基于业务成本和验证集选择。
- 当正类极稀少时，PR 曲线更直接展示正类识别质量。

面试官连续追问

- ROC-AUC 为什么在极不平衡时可能显得“虚高”？
- Focal Loss 的 γ 有什么作用？
- 重采样后如何做概率校准？

高频失分点

易错 只说“过采样/欠采样”。

易错 把 AUC 提升等同于线上收益提升。

第 2 章 优化器、归一化与正则化

本章目标 从训练动力学解释 SGD/AdamW、Warmup、BN/LN/RMSNorm 与稳定性。

覆盖题目：Q11–Q20。建议先遮住答案口述，再阅读解析。

11 SGD、Momentum、RMSProp、Adam 的核心差异是什么？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察优化器机制而非 API。

60–90 秒标准回答

SGD 直接沿当前梯度更新；Momentum 累积方向一致的历史梯度降低震荡；RMSProp 用梯度平方的指数平均对不同维度自适应缩放；Adam 同时维护一阶矩与二阶矩并做 bias correction。

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t; \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

原理拆解 / 深度展开

- Momentum 是低通滤波式的速度累积。
- Adam 的二阶矩不是 Hessian，只是梯度平方的移动平均。
- 小步数时 m 、 v 初始为 0 会有偏差，因此需要 bias correction。

面试官连续追问

- Adam 为什么通常收敛快？
- β_1/β_2 分别影响什么？
- Adam 的 epsilon 放在根号内外有区别吗？

高频失分点

易错 把 Adam 描述为“二阶优化”。

易错 忘记 bias correction。

12 Adam 与 AdamW 有什么区别？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察 weight decay 与 L2 在 adaptive optimizer 下不等价。

60–90 秒标准回答

AdamW 把 weight decay 从损失梯度中解耦，参数先按 Adam 的自适应梯度更新，再独立做比例衰减。对 SGD，适当缩放后 L2 与 weight decay 可等价；对 Adam 这两者一般不等价。

$$\theta \leftarrow \theta - \eta \cdot \text{AdamGrad}(\theta) - \eta \lambda \theta$$

原理拆解 / 深度展开

- L2 是把 λw 加到梯度里，会再经过 Adam 的按维自适应缩放。
- AdamW 的 decay 不经过 m/v 预条件器。
- 实践中通常不对 bias 和 normalization 的 scale/bias 做 weight decay。

面试官连续追问

- 为什么 LayerNorm 参数常不 decay?
- AdamW 中 lr 和 weight decay 如何耦合?
- L2 正则化与 MAP 有什么关系?

高频失分点

易错 把 AdamW 仅说成 “Adam 加了 L2”。

证据索引: P-AdamW

13 为什么某些视觉任务中 SGD 最终泛化可能优于 Adam?

难度 ★★☆☆ 频度 中频

面试官在考什么 考察优化几何和对经验规律的谨慎表达。

60-90 秒标准回答

这是经验现象而非定理。自适应优化器改变了各维有效步长和搜索几何，可能到达与 SGD 不同的极小值区域；SGD 的噪声与统一学习率在一些视觉任务上对应更好的泛化。但现代 Transformer 中 AdamW 已是主流，不能机械套用。

原理拆解 / 深度展开

- 优化器影响的不只是收敛速度，也影响隐式正则化。
- 需要在相同训练预算、scheduler、正则化下公平比较。
- 大模型训练的稳定性、稀疏梯度和超参敏感度使 AdamW 更实用。

面试官连续追问

- 什么叫 flat minimum? 它真的与泛化一一对应吗?
- 为什么大模型几乎不用纯 SGD?

高频失分点

易错 把 “SGD 泛化一定更好” 当绝对结论。

14

为什么 Transformer 常用 Learning Rate Warmup?

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察训练初期稳定性。

60-90 秒标准回答

训练早期参数随机、激活和梯度统计尚未稳定，Adam 的矩估计也处于建立阶段；若直接使用峰值学习率，深层残差网络容易出现过大更新。Warmup 让学习率从小到大逐步进入稳定区间。

原理拆解 / 深度展开

- Warmup 不是为了“让模型先学简单样本”，除非另有 curriculum。
- 它与大 batch、深层 residual、adaptive optimizer 常共同出现。
- Warmup 之后通常接 cosine 或 linear decay。

面试官连续追问

- Warmup steps 怎么定？
- Pre-Norm 能否减少 Warmup 需求？
- 大 batch 为什么常需要更谨慎的 LR 策略？

高频失分点

易错 把 warmup 解释为防止过拟合。

15

Cosine Learning Rate Scheduler 为什么常用?

难度 ★☆☆ 频度 高频

面试官在考什么 考察学习率时间尺度。

60-90 秒标准回答

Cosine decay 让学习率从高到低平滑下降，前期保留探索和快速学习，后期逐渐减小步长以精细收敛；相比阶梯下降，它没有突变，常与 warmup 组合。

$$\eta_t = \eta_{\min} + 0.5(\eta_{\max} - \eta_{\min})(1 + \cos(\pi t/T))$$

原理拆解 / 深度展开

- 周期末可保留 $\eta_{\min}$ 而非降到 0。
- Cosine 本身不是魔法，关键是合适的峰值 LR、总步数和 warmup。
- Cosine restart 是另一类周期性策略。

面试官连续追问

- Linear decay 与 cosine 如何选？
- 训练步数变化时 scheduler 怎么同步调整？

高频失分点

易错 只背公式，不会解释前后训练阶段的作用。

16 BatchNorm 的训练与推理过程分别是什么？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察统计量、可学习参数和 train/eval 差异。

60-90 秒标准回答

训练时 BN 用当前 mini-batch 的均值与方差标准化，再用 γ 、 β 恢复可学习的尺度和偏移，同时更新 running statistics；推理时不用当前 batch，而使用训练期间累计的 running mean/variance。

$$y = \gamma(x - \mu_B) / \sqrt{\sigma_B^2 + \epsilon} + \beta$$

原理拆解 / 深度展开

- BN 的 γ/β 使网络仍能学习恒等变换。
- train() / eval() 模式切换非常关键。
- 小 batch 下统计估计噪声大，是检测分割常见问题。

面试官连续追问

- BN 为什么可能有正则化效果？
- running variance 是怎么更新的？
- 为什么 batch=1 时 BN 很麻烦？

高频失分点

易错 认为推理也用当前 batch 统计。

易错 忽略 running stats。

证据索引: P-BN

17 为什么 Transformer 常用 LayerNorm，而 CNN 传统上大量用 BatchNorm？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察归一化维度与序列任务特点。

60-90 秒标准回答

BN 的统计跨样本 batch 维，效果依赖 batch 大小和样本组成；LN 对单个样本/token 的 hidden dimension 归一化，不依赖其他样本，因此对变长序列、小 batch、逐 token 自回归推理更自然。

原理拆解 / 深度展开

- Transformer 的 token 维度和 batch/sequence 都会动态变化，LN 的局部统计更稳定。
- CNN 传统大 batch 训练中，BN 的归纳偏置与正则化效果很有效。
- ViT 也大量使用 LN，说明选择更取决于架构与数据组织，而非“视觉/文本”二分。

面试官连续追问

- GroupNorm 处于什么位置？
- LN 是沿哪些维度归一化？
- 如果对 sequence 维归一化会怎样？

高频失分点

易错 只说“LN 不依赖 batch”而说不清具体统计维度。

18 RMSNorm 与 LayerNorm 有什么区别？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察现代 LLM normalization。

60-90 秒标准回答

LayerNorm 做去均值和按标准差缩放；RMSNorm 只按 root mean square 做尺度归一化，省掉均值中心化。许多 LLM 实践表明，控制激活尺度已足以获得稳定训练，同时计算更简单。

$$\text{RMS}(x) = \sqrt{\text{mean}(x_i^2) + \epsilon}$$

原理拆解 / 深度展开

- RMSNorm 常写为 $x / \text{RMS}(x) \cdot g$ 。
- 它没有减均值，所以输出不保证零均值。
- 性能优势通常来自更低的算子复杂度和良好工程实现，不应夸大。

面试官连续追问

- RMSNorm 是否一定更快？
- 为什么常与 Pre-Norm 搭配？
- RMSNorm 的 epsilon 有什么数值作用？

高频失分点

易错 说成“RMSNorm 没有可学习参数”。

19 Pre-Norm 与 Post-Norm 的区别是什么？为什么 Pre-Norm 更易训练深层网络？

难度 ★★★ 频度 极高频

面试官在考什么 考察残差路径与梯度传播。

60-90 秒标准回答

Post-Norm 是 $\text{LN}(x+F(x))$ ；Pre-Norm 是 $x+F(\text{LN}(x))$ 。Pre-Norm 的残差主干保留更直接的 identity path，梯度可以绕过子层非线性和归一化传播，因此深层 Transformer 往往更稳定。

Pre: $y=x+F(\text{LN}(x))$; **Post:** $y=\text{LN}(x+F(x))$

原理拆解 / 深度展开

- Pre-Norm 稳定不代表最终表达一定优于 Post-Norm。
- 非常深的模型还会结合 residual scaling、DeepNorm 等设计。
- 要能在纸上画出两种 block，而不是只背名字。

面试官连续追问

- 为什么 Pre-Norm 的梯度路径更直接？
- Pre-Norm 最后一层为什么常再加一个 norm？

高频失分点

易错 把 LN 放置顺序画反。

20 Dropout 为什么能防止过拟合？训练和推理如何处理？

难度 ★☆☆ 频度 高频

面试官在考什么 考察随机正则化与期望保持。

60-90 秒标准回答

训练时随机屏蔽部分激活，相当于不断扰动可用子网络，抑制神经元之间过强的协同适配；inverted dropout 会在训练时按 $1/(1-p)$ 缩放，使推理时可以直接关闭 dropout 而保持激活期望一致。

原理拆解 / 深度展开

- Dropout 主要是训练期随机性，不是推理时 ensemble 多次采样的必要条件。
- 在大模型里 dropout 比早期 CNN/MLP 的使用更依赖数据规模和正则化需求。
- MC Dropout 属于另一个不确定性估计用法。

面试官连续追问

- 为什么 inverted dropout 推理不用缩放？

→ Dropout 和 BatchNorm 混用有什么注意点？

高频失分点

易错 把 p 理解成“保留概率”时与框架参数搞反。

第 3 章 CNN 与计算机视觉基础

本章目标 覆盖卷积、感受野、残差、检测损失、ViT 与数据增强。

覆盖题目：Q21-Q30。建议先遮住答案口述，再阅读解析。

21 给定卷积参数，如何计算输出尺寸与参数量？

难度 ★☆☆ 频度 极高频

面试官在考什么 基础计算与边界意识。

60-90 秒标准回答

卷积输出尺寸由输入 H、padding P、dilation D、kernel K、stride S 决定；参数量与空间尺寸无关，只取决于输入/输出通道和卷积核大小。

$$H_{out} = \text{floor}((H + 2P - D(K - 1) - 1) / S + 1)$$

原理拆解 / 深度展开

- 二维卷积输出 $H_{out} = \text{floor}((H + 2P - D(K - 1) - 1) / S + 1)$ 。
- 参数量 $= C_{out} \cdot C_{in} / \text{groups} \cdot K_h \cdot K_w$ ，若有 bias 再加 C_{out} 。
- groups/depthwise 会改变参数量。

面试官连续追问

- dilation 为什么会增大有效感受野？
- same padding 如何计算？
- depthwise 卷积的 groups 等于多少？

高频失分点

易错 忘记 dilation 项。

易错 把 feature map 大小乘进参数量。

22 什么是感受野？如何计算多层网络的有效感受野？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察局部建模和结构设计。

60-90 秒标准回答

感受野是某一层单元在原输入上理论能影响到的区域。逐层计算时要同时维护当前 receptive field 和相邻单元在输入上的 jump；stride 会让后续 kernel 对原图跨更大步长。

原理拆解 / 深度展开

- 连续三个 stride=1 的 3×3 卷积理论感受野为 7×7 。
- 实际有效感受野的贡献通常中心更强，并不均匀。
- dilation 在不显著增加参数的情况下扩大感受野。

面试官连续追问

- 为什么两个 3×3 常比一个 5×5 更划算？
- stride/pooling 如何改变感受野 jump？

高频失分点

易错 只会按 kernel 大小简单相加，遇到 stride 就算错。

23 1×1 卷积有什么作用？

难度 ★☆☆ 频度 高频

面试官在考什么 考察通道混合和 bottleneck。

60-90 秒标准回答

1×1 卷积不扩大空间邻域，但会在每个 spatial location 上对通道向量做线性映射，因此可用于通道升/降维、特征融合和 bottleneck，显著减少后续大卷积计算量。

原理拆解 / 深度展开

- 对每个像素位置，它等价于共享参数的全连接层。
- ResNet bottleneck 常用 1×1 降维 $\rightarrow 3 \times 3 \rightarrow 1 \times 1$ 升维。
- 配合非线性后可增加网络深度和表达能力。

面试官连续追问

- 1×1 能改变 H/W 吗？
- 为什么它可以做通道融合？

高频失分点

易错 说成“只用于降采样”。

24 Depthwise Separable Convolution 为什么更省计算？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察轻量化卷积。

60-90 秒标准回答

普通卷积同时混合空间和通道；depthwise 先对每个通道独立做 $K \times K$ 空间卷积，再用 1×1 pointwise 卷积做通道混合，把乘法量从 $K^2 \text{CinCout}$ 分解为 $K^2 \text{Cin} + \text{CinCout}$ 。

普通： $K^2 \text{CinCout}$ ；可分离： $K^2 \text{Cin} + \text{CinCout}$

原理拆解 / 深度展开

- 当 Cout 很大时，节省比例非常明显。
- depthwise 本身不做跨通道信息融合，必须依赖 pointwise。
- 实际速度还取决于硬件 kernel 是否高效，FLOPs 少不必然 wall-clock 更快。

面试官连续追问

- MobileNet 中 width multiplier 有什么作用？
- 为什么 depthwise 在某些 GPU 上未必按 FLOPs 比例提速？

高频失分点

易错 只比较参数量，不讨论算子实现效率。

25 ResNet 为什么能训练很深？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察残差学习与优化。

60-90 秒标准回答

ResNet 把目标映射写为 $H(x)=x+F(x)$ ，让子层只需学习残差；更关键的是 shortcut 建立了 identity 信息/梯度通路，显著缓解深层网络的优化退化问题。

$$y=x+F(x)$$

原理拆解 / 深度展开

- “退化”不是过拟合：更深网络连训练误差都可能更高。
- 如果维度不同，需要 projection shortcut。
- Residual 是现代 Transformer 的核心结构之一。

面试官连续追问

- 为什么 $F(x)=0$ 时很容易表示恒等映射？
- ResNet v1/v2 有什么区别？
- 残差连接和 DenseNet 有何不同？

高频失分点

易错 把 ResNet 说成专门解决梯度消失而忽略 optimization degradation。

证据索引: P-ResNet

26 Batch 很小时为什么 BatchNorm 容易失效？有哪些替代？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察检测/分割训练实践。

60-90 秒标准回答

BN 依赖 mini-batch 对均值和方差的估计；batch 很小时估计噪声大，且不同 GPU 的局部 batch 更小。可用 SyncBN 汇总多卡统计，或改用 GroupNorm/LayerNorm，也可以冻结预训练 BN。

原理拆解 / 深度展开

- SyncBN 提高统计稳定性但增加通信。
- GroupNorm 按通道组统计，与 batch size 基本无关。
- 目标检测常受高分辨率限制，batch 小是常见场景。

面试官连续追问

- Frozen BN 的 running stats 从哪里来？
- GroupNorm 的 group 数怎么选？

高频失分点

易错 认为“只要 batch=1 BN 就完全不能用”，实际推理 eval 模式可用 running stats。

27 IoU 与 NMS 分别是什么？请说明 NMS 实现细节。

难度 ★★☆☆ 频度 极高频

面试官在考什么 检测算法基础与手写能力。

60-90 秒标准回答

IoU 衡量两个框交并比；NMS 先按置信度降序取最高分框，删除与其 IoU 超阈值的其他框，再迭代。工程实现要正确处理坐标边界、空集合、类别隔离和批量向量化。

$$\text{IoU} = \text{Area}(A \cap B) / \text{Area}(A \cup B)$$

原理拆解 / 深度展开

- 标准 NMS 是贪心算法。
- class-aware NMS 通常不同类别不互相抑制。
- Soft-NMS 不直接删除，而衰减重叠框分数。

面试官连续追问

- NMS 复杂度是多少？
- DIoU-NMS 为什么可能更合理？
- Anchor-free 模型还需要 NMS 吗？

高频失分点

易错 框面积计算时坐标制式不一致。

易错 忘记先排序或处理类别。

28 Focal Loss 为什么能处理前景/背景极度不平衡？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察难样本加权。

60-90 秒标准回答

Focal Loss 在交叉熵前乘 $(1-p_t)^\gamma$ ，使已被高置信度正确分类的 easy samples 权重快速衰减，把训练注意力转向困难样本； α_t 还可平衡正负类先验。

$$FL = -\alpha_t (1-p_t)^\gamma \log(p_t)$$

原理拆解 / 深度展开

- 当 $\gamma=0$ 时退化为加权 CE。
- γ 越大，对 easy example 的抑制越强。
- hard example 也可能是噪声，因此不能无限增大 γ 。

面试官连续追问

- Focal Loss 和 OHEM 的区别？
- 多分类如何定义 p_t ？

高频失分点

易错 说成“专门给正样本加权”。

29 ViT 与 CNN 的本质差异是什么？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察视觉架构归纳偏置与数据规模。

60-90 秒标准回答

CNN 把 locality 和 translation equivariance 直接编码进结构；ViT 把图像切成 patch token，通过 self-attention 建模全局关系，结构归纳偏置更弱，因此通常更依赖大规模数据/预训练，但扩展性与统一多模态接口更好。

原理拆解 / 深度展开

- Patch embedding 本质可用 stride=P 的卷积实现。
- ViT 仍需要位置编码，否则 patch 顺序不可辨。
- 现代视觉系统常混合卷积局部偏置和 Transformer 全局建模。

面试官连续追问

- 为什么 ViT 小数据上早期不如 CNN？
- CLS token 一定必要吗？
- Patch size 改变会如何影响 token 数和复杂度？

高频失分点

易错 把 ViT 描述为“没有任何局部性”。

证据索引: P-ViT

30

数据增强为什么有效？Mixup 与 CutMix 有什么不同？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察正则化与数据分布。

60–90 秒标准回答

数据增强通过引入任务允许的不变性扩展有效训练分布。Mixup 在像素与标签空间做凸组合，鼓励模型在样本间更平滑；CutMix 用局部区域替换，标签按面积比例混合，更保留局部高频结构。

原理拆解 / 深度展开

- 增强必须尊重标签语义，例如 OCR 不一定允许任意旋转。
- Mixup 让模型在样本间的函数更线性，具有正则化作用。
- CutMix 对检测/定位类视觉特征有时更自然。

面试官连续追问

- 增强过强为什么会伤害性能？
- RandAugment/AutoAugment 的思想是什么？

高频失分点

易错 认为所有增强都只会提升泛化。

第 4 章 序列模型与语言模型基础

本章目标 理解 RNN/LSTM 到 Encoder/Decoder 与 Tokenization 的演进。

覆盖题目：Q31–Q38。建议先遮住答案口述，再阅读解析。

31 RNN、LSTM、GRU 的主要区别是什么？

难度 ★★☆☆ 频度 中高频

面试官在考什么 考察序列模型基础。

60–90 秒标准回答

普通 RNN 用一个循环状态递推，长期依赖时梯度容易衰减/爆炸；LSTM 引入 cell state 与输入/遗忘/输出门控制信息流；GRU 把门控结构简化为 update/reset，参数更少。

原理拆解 / 深度展开

- LSTM 的加性 cell state 路径是长程传播的关键。
- GRU 不一定总比 LSTM 快，取决于实现和硬件。
- 今天大规模语言建模以 Transformer 为主，但循环网络仍用于某些流式/低延迟场景。

面试官连续追问

- LSTM 有哪几个门？
- 双向 RNN 为什么不能直接用于自回归生成？

高频失分点

易错 只会列门名，不解释信息如何保留/遗忘。

32 为什么 LSTM 能缓解梯度消失？

难度 ★★☆☆ 频度 中频

面试官在考什么 考察门控和加性记忆路径。

60–90 秒标准回答

LSTM 的 cell state 更新 $c_t = f_t \odot c_{t-1} + i_t \odot \hat{c}_t$ ，其中旧状态通过加法路径传递；对 c_{t-1} 的局部导数主要由 forget gate 控制，不需要每步都乘同一个循环权重矩阵，因此更容易保存长期梯度。

$$c_t = f_t \odot c_{t-1} + i_t \odot \hat{c}_t$$

原理拆解 / 深度展开

- 若 f_t 长期接近 1，信息可跨很多步保留。
- 它是“缓解”而非彻底消除梯度问题。
- 门控本身由 sigmoid 决定，可学习什么时候写入/遗忘。

面试官连续追问

- forget gate bias 为什么有时初始化为正？
- GRU 的长程路径如何对应？

高频失分点

易错 把 cell state 说成梯度永远等于 1。

33 Teacher Forcing 有什么问题？

难度 ★★☆☆ 频度 中频

面试官在考什么 考察训练/推理分布偏差。

60-90 秒标准回答

训练时 Teacher Forcing 把真实前一 token 作为下一步输入，而推理时只能使用模型自己的预测；一旦模型犯错，后续输入分布偏离训练分布并累积错误，这就是 exposure bias。

原理拆解 / 深度展开

- Scheduled sampling 曾尝试逐步混入模型预测，但也有目标不一致问题。
- 自回归 Transformer 训练同样使用 ground-truth shifted tokens，因此也存在广义 exposure bias。
- 后训练、序列级目标和数据构造可以缓解但不是完全消除。

面试官连续追问

- 为什么语言模型训练可以并行而推理不能？
- sequence-level training 怎么做？

高频失分点

易错 把 exposure bias 误解为过拟合。

34 BERT 的预训练目标是什么？为什么它适理解类任务？

难度 ★☆☆☆ 频度 高频

面试官在考什么 考察 Encoder 预训练思想。

60-90 秒标准回答

经典 BERT 使用 Masked Language Modeling，并在原论文中配合 Next Sentence Prediction。MLM 允许每个 token 同时利用左右上下文，因此得到双向表示，适合分类、NER、匹配和检索等理解任务。

原理拆解 / 深度展开

- BERT 是 Transformer Encoder stack，不是 autoregressive decoder。
- MLM 的 [MASK] 在下游不存在，后续工作对此做了改进。
- NSP 并非所有后续模型都保留。

面试官连续追问

- BERT 为什么不适合直接自由生成？
- RoBERTa 对 BERT 训练做了哪些典型改动？

高频失分点

易错 把 BERT 说成 decoder-only。

35 Encoder-only、Decoder-only、Encoder-Decoder 如何选择？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察任务建模与架构取舍。

60-90 秒标准回答

Encoder-only 擅长对完整输入做双向表示；Decoder-only 用 causal attention 统一为 next-token prediction，最自然地支持开放生成；Encoder-Decoder 将输入编码与输出生成分离，适合翻译、摘要等显式 seq2seq。

原理拆解 / 深度展开

- 架构选择与任务、训练数据、部署方式相关，不是能力排名。
- Decoder-only 的统一接口和 scaling 便利推动了 LLM 主流化。
- Encoder 模型在 embedding/retrieval 场景仍非常重要。

面试官连续追问

- T5 为什么属于 encoder-decoder？
- 为什么 decoder-only 也能做分类？

高频失分点

易错 认为 decoder-only 可以无代价替代所有 encoder 模型。

36 BPE、WordPiece、SentencePiece 为什么存在？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察 Tokenization 与词表权衡。

60-90 秒标准回答

词级词表容易 OOV 且规模巨大，字符级序列又太长；subword 在两者之间折中，把常见词或词根保留为较长 token，把罕见词拆成较短单位。BPE 基于频繁 pair merge，WordPiece 使用不同的合并准则，SentencePiece 更像直接在原始字符串上训练 tokenizer 的框架。

原理拆解 / 深度展开

- Tokenizer 会影响序列长度、跨语言公平性和推理成本。
- 数字、代码、中文和低资源语言的切分特征差异明显。
- 词表扩大可缩短序列，但增大 embedding/output matrix。

面试官连续追问

- 如何手写一个最简 BPE?
- 为什么 tokenizer 会影响 LLM 的算术能力?

高频失分点

易错 把 SentencePiece 当成单一的分词算法。

37 Padding Token 为什么通常不参与 Loss?

难度 ★☆☆ 频度 高频

面试官在考什么 考察 mask 与 batch 化。

60-90 秒标准回答

不同长度序列组成 batch 时会补 PAD；PAD 不是真实监督信号，如果参与交叉熵，模型会被大量无意义 token 牵引。通常把对应 label 设为 ignore_index（如 -100），并在 attention 中也用 padding mask 防止无效位置被关注。

原理拆解 / 深度展开

- loss mask 和 attention mask 是两件不同的事。
- Instruction tuning 还常对 user prompt 部分屏蔽 loss，只监督 assistant answer。
- 右 padding/左 padding 会影响位置与生成实现。

面试官连续追问

- 为什么 prompt token 也可能 mask loss?
- pad_token_id 和 eos_token_id 能否设相同?

高频失分点

易错 只处理 loss，不处理 attention mask。

38 Causal Mask 与 Padding Mask 有什么区别?

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察 Attention mask 语义。

60-90 秒标准回答

Causal mask 限制位置 i 只能看到 $j \leq i$ ，防止自回归训练偷看未来；padding mask 屏蔽补齐位置，避免无效 token 参与注意力。实际实现常把两者组合为一个 additive/bool mask。

$$M_{ij}=0 \ (j \leq i), \ -\infty \ (j > i)$$

原理拆解 / 深度展开

- 加性 mask 常对禁止位置加一个极小值，使 softmax 后近似 0。
- 训练时 causal mask 让所有位置可并行计算，但每个位置只用左上下文。
- FlashAttention 等 kernel 对 mask 支持方式可能不同。

面试官连续追问

- 为什么 causal LM 训练仍能并行？
- mask 放在 softmax 前还是后？

高频失分点

易错 softmax 后再粗暴乘 mask 却不重新归一化。

第 5 章 Transformer 核心

本章目标 2026 算法岗最核心模块：Attention、RoPE、GQA、KV Cache、FlashAttention。

覆盖题目：Q39–Q55。建议先遮住答案口述，再阅读解析。

39 从头讲一个现代 Transformer Block。

难度 ★★☆☆ 频度 极高频

面试官在考什么 核心架构总览。

60–90 秒标准回答

现代 decoder block 通常是 Pre-Norm：输入先 RMSNorm/LayerNorm，经过 causal self-attention 后与残差相加；再 norm，经过 FFN/SwiGLU 后再残差相加。多层堆叠后再做 final norm 和输出头。

原理拆解 / 深度展开

- 原始 Transformer 使用 Post-Norm，现代 LLM 大量使用 Pre-Norm。
- Attention 负责 token mixing，FFN 负责每个 token 的 channel/feature mixing。
- Residual、Normalization、position encoding 与 attention kernel 是理解整个模型的四个轴。

面试官连续追问

- 画出 QKV、RoPE、GQA 在 block 中的位置。
- 为什么 FFN 隐藏维度通常大于 d_{model} ？

高频失分点

易错 只会背 “Attention+FFN” 但画不出 tensor flow。

证据索引：P-Transformer

40 写出 Scaled Dot-Product Attention，并解释每一步。

难度 ★★☆☆ 频度 极高频

面试官在考什么 Attention 公式、shape 与语义。

60–90 秒标准回答

先用 QK^T 计算每个 query 对所有 key 的相似度，除以 $\sqrt{d_k}$ 控制尺度，加 mask 后 softmax 得到权重，最后对 V 加权求和。

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k})V$$

原理拆解 / 深度展开

- $Q:[B,H,T_q,D_h]$, $K:[B,H,T_k,D_h]$, $score:[B,H,T_q,T_k]$ 。
- softmax 通常沿 key 维。
- V 决定真正被聚合的内容，K 决定如何被匹配。

面试官连续追问

- cross-attention 时 Q/K/V 来自哪里？
- 如果 softmax 温度变化会怎样？

高频失分点

易错 softmax 维度写错。

易错 K 转置维度不正确。

证据索引: P-Transformer

41 为什么 Attention 要除以 $\sqrt{d_k}$?

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察方差推导。

60-90 秒标准回答

若 q 、 k 各维近似独立、零均值、单位方差，则点积 $q \cdot k$ 是 d_k 个乘积之和，方差随 d_k 增长。logit 过大时 softmax 进入饱和区、梯度很小；除以 $\sqrt{d_k}$ 使尺度大致恢复到 $O(1)$ 。

$$\text{Var}(q \cdot k) \approx d_k \Rightarrow \text{std} \approx \sqrt{d_k}$$

原理拆解 / 深度展开

- 这是 variance scaling，不是单纯“防止数值溢出”。
- 如果使用 cosine attention，尺度问题会以另一种方式处理。
- 训练可学习 temperature 也是相似思想。

面试官连续追问

- 为什么不是除以 d_k ?
- 如果 $d_k=64$ ，不缩放会出现什么？

高频失分点

易错 只说“为了归一化”但不会推导。

42

Q、K、V 从语义和线性代数上分别是什么？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察是否真正理解 Attention。

60-90 秒标准回答

Q 是当前位置用于“查询什么信息”的表示，K 是各位置用于被匹配的索引表示，V 是匹配后真正参与聚合的内容表示。三者通常都是同一输入经过不同线性投影，因此模型可以分别学习“如何匹配”和“传递什么”。

原理拆解 / 深度展开

- Self-attention 中 Q/K/V 同源但投影不同。
- Cross-attention 中 Q 常来自 decoder，K/V 来自 encoder/外部模态。
- QK 相似度只是路由权重，最终输出在 V 的线性组合空间中。

面试官连续追问

- 为什么 K 与 V 可以共享 head 数而 Q 更多？
- 能否直接令 $Q=K=V=x$ ？

高频失分点

易错 用数据库类比后就停止，不回到矩阵公式。

43

Self-Attention 的时间和显存复杂度是多少？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察复杂度分解。

60-90 秒标准回答

注意力 score 矩阵大小为 $T \times T$ ； QK^T 和 $\text{score} \cdot V$ 的主要复杂度约 $O(T^2d)$ ，显式保存 score/probability 会带来 $O(T^2)$ 激活内存。线性投影还包含 $O(Td^2)$ ，短序列/大 d 时也不可忽略。

Dense attention: time $\approx O(T^2d)$, attention-matrix memory $\approx O(T^2)$

原理拆解 / 深度展开

- 不能笼统说 Transformer 全部都是 $O(T^2d)$ 。
- FlashAttention 不改变 exact dense attention 的主要 FLOP 阶数，但显著降低中间矩阵的 HBM 读写。
- Decode 时由于 $T_q=1$ ，单步 attention 是 $O(Td)$ ，但累计生成仍增长。

面试官连续追问

- 什么时候 QKV projection 比 attention matrix 更贵？
- 长上下文为何首先遇到显存问题？

高频失分点

易错 把显存复杂度和 KV cache 复杂度混为一谈。

44 Multi-Head Attention 为什么比单头更有表达力？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察子空间分解和并行头。

60-90 秒标准回答

MHA 把 d_{model} 切成多个 head，每个 head 使用独立投影在不同表示子空间做 attention，然后 concat 再线性融合；这样模型可以并行学习不同关系模式，而不是让一个相似度矩阵承担所有路由结构。

原理拆解 / 深度展开

- 在固定 d_{model} 下，多头并不一定显著增加 attention FLOPs。
- head 太多会让单头维度过小。
- 实际 head 可能出现冗余，因此出现 head pruning、GQA 等优化。

面试官连续追问

- head 数越多越好吗？
- 不同 head 是否真的学到可解释语义？

高频失分点

易错 说“多头就是 ensemble”过于粗糙。

45 为什么 Attention 需要位置编码？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察 permutation 性质。

60-90 秒标准回答

不含位置的信息时，self-attention 对输入 token 的置换具有相应的置换等变性，模型无法知道“谁在前谁在后”。位置编码把顺序信息注入 token 表示或 QK 交互，使相同 token 在不同位置产生不同关系。

原理拆解 / 深度展开

- 绝对位置可加到 embedding；相对位置可直接改 attention score；RoPE 通过旋转 Q/K 注入相对位置信息。
- 位置编码不仅用于顺序，还影响长上下文外推能力。

面试官连续追问

- 为什么 position embedding 不能只加在第一层后就完全消失？
- 2D 图像位置如何处理？

高频失分点

易错 说成 “Attention 不看上下文”，而实际它看内容但不天然知道顺序。

46 Absolute Position、Relative Position、RoPE 有什么区别？

难度 ★★★ 频度 极高频

面试官在考什么 考察现代位置编码。

60-90 秒标准回答

绝对位置直接给第 i 个 token 一个位置向量；相对位置让注意力显式依赖 $i-j$ ；RoPE 对 Q 、 K 的不同二维子空间按位置做旋转，使 $q_m^T k_n$ 自然包含 $m-n$ 的相对位置信息，同时不直接修改 V 。

$$(R_m q)^T (R_n k) = q^T R_{\{n-m\}} k$$

原理拆解 / 深度展开

- RoPE 的关键是 $R_m^T R_n = R_{\{n-m\}}$ 。
- 不同频率对应不同位置尺度。
- 长上下文扩展常对 RoPE 频率/尺度做插值或重标定。

面试官连续追问

- RoPE 为什么只旋转 Q/K ？
- NTK-aware scaling / YaRN 想解决什么？
- RoPE 外推为什么会退化？

高频失分点

易错 只说 “RoPE 是相对位置编码”，不会解释旋转内积性质。

47 Transformer 的 FFN 到底做什么？为什么不能删？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察 Attention 与 FFN 分工。

60-90 秒标准回答

Attention 主要在 token 之间路由和混合信息；FFN 对每个 token 独立地做高维非线性特征变换，提供大量参数容量。删掉 FFN 会显著降低模型的逐位置表示变换能力和总体容量。

原理拆解 / 深度展开

- 经典 FFN: $W_2 \cdot \sigma(W_1 x)$ ，中间维度常扩张。
- 现代 LLM 常用 GLU/SwiGLU 门控结构。

- FFN 往往占模型参数和 FLOPs 的大头之一。

面试官连续追问

- SwiGLU 为什么有两路投影？
- 为什么 FFN 可以视为 key-value memory 的一种近似解释？

高频失分点

易错 把 FFN 说成“只为增加非线性”。

48

MHA、MQA、GQA 的区别？为什么 GQA 能省 KV Cache？

难度 ★★★ 频度 极高频

面试官在考什么 考察现代 LLM inference architecture。

60-90 秒标准回答

MHA 每个 query head 都有自己的 K/V head；MQA 让所有 query head 共享一组 K/V；GQA 则让一组 query heads 共享一个 K/V head。由于 decode 需要缓存历史 K/V，减少 KV head 数会近似按比例降低 KV Cache。

$$\text{KV cache} \propto \text{layers} \times \text{batch} \times \text{seq} \times \text{kv_heads} \times \text{head_dim} \times 2(K,V)$$

原理拆解 / 深度展开

- Q head 数保持多头表达，KV head 数减少主要优化 memory bandwidth。
- GQA 在质量与推理成本之间折中，是现代 LLM 常用方案。
- MLA 进一步用低秩潜表示压缩 K/V，可作为高级追问。

面试官连续追问

- KV Cache 大小如何公式化？
- MQA 为什么可能有质量损失？
- GQA 如何从 MHA checkpoint 转换？

高频失分点

易错 说成 GQA 减少了 Q 的 head 数。

49

KV Cache 的原理是什么？显存如何估算？

难度 ★★★ 频度 极高频

面试官在考什么 考察自回归推理与显存估算。

60-90 秒标准回答

生成第 t 个 token 时，历史 token 的 K/V 在模型参数不变的条件下不会改变，因此可以缓存，下一步只计算新 token 的 K/V 并让新 query 与全部历史 key 做 attention。这样避免反复重算历史层。

$$M_{KV} \approx 2LBTH_{kv}D_h \cdot \text{bytes}$$

原理拆解 / 深度展开

- 近似大小： $2 \times L \times B \times T \times H_{kv} \times D_h \times \text{bytes_per_element}$ 。
- 长上下文、大 batch 下 KV cache 可能超过权重本身成为瓶颈。
- Prefix cache 可在多个共享前缀请求间复用部分 KV。

面试官连续追问

- 为什么不缓存 Q?
- Beam search 如何影响 KV cache?
- KV quantization 有什么风险?

高频失分点

易错 只说“缓存 Attention 结果”。

50 FlashAttention 为什么快？它有没有把 $O(T^2)$ 变成 $O(T)$?

难度 ★★★ 频度 极高频

面试官在考什么 考察 GPU memory hierarchy 与 IO-aware 算法。

60-90 秒标准回答

FlashAttention 仍计算 exact dense attention，主要 FLOP 阶数仍是二次；它通过 tiling 把 Q/K/V 分块搬到片上 SRAM，在块内完成 matmul、online softmax 与累积，避免把完整 $T \times T$ attention matrix 多次写回 HBM，从而大幅降低 IO 与中间显存。

原理拆解 / 深度展开

- GPU 常受 memory bandwidth 而非纯 FLOPs 限制。
- online softmax 需要维护每行 running max 与 normalization factor 才能分块且数值稳定。
- FlashAttention-2/3 进一步优化并行划分和硬件利用。

面试官连续追问

- 为什么必须 online softmax?
- HBM 和 SRAM 的差异是什么?
- 什么时候 FlashAttention 收益不大?

高频失分点

易错 错误声称复杂度从 $O(T^2)$ 降到 $O(T)$ 。

易错 只说“融合 kernel”而不解释减少 HBM 读写。

证据索引: P-FlashAttention

51 Sparse Attention / Sliding Window Attention 为什么有用?

难度 ★★☆☆ 频度 高频

面试官在考什么 考察长上下文结构化稀疏。

60-90 秒标准回答

Dense attention 让每个 token 关注全部历史，成本随 T^2 增长；滑窗把每个 token 的可见范围限制为局部 w ，理论复杂度可降到 $O(Twd)$ 。再搭配少量全局 token 或周期性全局层，可以在成本与长程依赖之间折中。

原理拆解 / 深度展开

- 局部 attention 会损失任意远距离的直接连接。
- 模型可通过多层传播间接扩大感受范围。
- 结构稀疏只有在 kernel/硬件实现支持时才能兑现 wall-clock 收益。

面试官连续追问

- Longformer/Mistral 类滑窗各自如何保持全局信息？
- 稀疏模式为什么不一定更快？

高频失分点

易错 只看理论 FLOPs，不看稀疏 kernel 的实现开销。

52 为什么现代通用大模型大量采用 Decoder-only?

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察训练目标统一与 scaling。

60-90 秒标准回答

Decoder-only 用 next-token prediction 把各种文本、代码、指令和工具轨迹统一成序列建模问题；训练目标简单、数据可混合、架构易扩展，并天然支持开放式生成和 in-context learning，因此在通用大模型中形成强工程优势。

原理拆解 / 深度展开

- 不是因为 encoder “能力弱”。
- 很多检索/embedding 系统仍更适合 encoder。
- 多模态也可把视觉 token 序列化后接入 decoder-only 主干。

面试官连续追问

→ 为什么 decoder-only 能做理解任务？

→ Prefix LM 与 causal LM 有何差异？

高频失分点

易错 把“主流”说成理论最优。

53 Transformer 相比 RNN 为什么更适合大规模训练？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察并行与路径长度。

60-90 秒标准回答

训练时 Transformer 可以一次并行处理整段 token 的 QKV 和 FFN；RNN 的 h_t 依赖 h_{t-1} ，时间维存在严格串行。Self-attention 还让任意两个 token 的直接交互路径更短，有利于长程依赖学习。

原理拆解 / 深度展开

- 推理时 decoder Transformer 仍是 token-by-token 串行。
- Attention 的并行优势以更高的 $O(T^2)$ 计算/显存为代价。
- 现代状态空间模型试图重新探索线性序列建模。

面试官连续追问

→ 为什么 Transformer 训练并行而生成不并行？

→ RNN 的 memory complexity 是否一定更高？

高频失分点

易错 只说“Transformer 更快”，忽略序列长度和硬件条件。

54 长上下文模型真正面临哪些问题？

难度 ★★★ 频度 极高频

面试官在考什么 考察不仅会背 context window。

60-90 秒标准回答

问题至少包含：Attention 计算/IO、KV Cache 显存、位置编码外推、长文信息利用效率、lost-in-the-middle、检索噪声与上下文稀释。一个模型宣称支持更长窗口，不等于能稳定利用整个窗口。

原理拆解 / 深度展开

- 训练 context length 与推理最大长度要区分。
- 长文本 benchmark 要测 needle retrieval、multi-hop、global aggregation 等不同能力。
- 系统层可通过 chunking、RAG、prefix cache、KV 压缩降低成本。

面试官连续追问

- 如何评价 1M context 是否“真的有用”？
- RoPE scaling 与 continued pretraining 的关系？

高频失分点

易错 把最大 token 数当作唯一指标。

55 请手写 Multi-Head Attention，必须处理 shape、mask 与数值稳定。

难度 ★★★ 频度 极高频

面试官在考什么 2026 真实面试高频手写题。

60-90 秒标准回答

正确实现应从 [B,T,D] 投影 Q/K/V，reshape 为 [B,H,T,Dh]；计算 $\text{score} = QK^T / \sqrt{D_h}$ ，应用 causal/padding mask，softmax 后与 V 相乘，再转回 [B,T,D] 并输出投影。

原理拆解 / 深度展开

- mask 必须 broadcast 到 [B,H,T,T] 或可兼容形状。
- softmax 建议用框架稳定实现；混合精度下注意极小 mask 值。
- transpose 后 reshape 前可能需要 contiguous。

手写 / 代码骨架

```
def mha(x, q_proj, k_proj, v_proj, o_proj, n_heads, mask=None):
    B, T, D = x.shape
    Dh = D // n_heads
    def split(z):
        return z.view(B, T, n_heads, Dh).transpose(1, 2)
    q, k, v = split(q_proj(x)), split(k_proj(x)), split(v_proj(x))
    scores = (q @ k.transpose(-2, -1)) / (Dh ** 0.5)
    if mask is not None:
        scores = scores.masked_fill(~mask, float('-inf'))
    attn = scores.softmax(dim=-1)
    y = attn @ v
    y = y.transpose(1, 2).contiguous().view(B, T, D)
    return o_proj(y)
```

面试官连续追问

- 如何支持 cross-attention？
- 如何改成 GQA？
- 如何做 KV cache decode path？

高频失分点

易错 忘记 $\text{sqrt}(D_h)$ 。

易错 softmax 维度错误。

易错 mask 方向反了。

证据索引: *M-Ali-MHA*

第 6 章 LoRA、SFT 与大模型后训练

本章目标 从参数高效微调到 PPO/DPO/GRPO，回答“模型如何被真正训练成可用系统”。

覆盖题目：Q56–Q68。建议先遮住答案口述，再阅读解析。

56 LoRA 的数学原理是什么？为什么低秩更新可行？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察 PEFT 的核心假设。

60–90 秒标准回答

LoRA 冻结原权重 W_0 ，只学习增量 $\Delta W = BA$ ，其中 rank r 远小于输入/输出维度。它基于一个经验假设：大模型适配某个任务时，真正需要的权重更新具有较低的内在维度，因此用低秩子空间即可表达主要变化。

$$W = W_0 + (\alpha/r)BA$$

原理拆解 / 深度展开

- 可训练参数从 $d_{\text{out}} \cdot d_{\text{in}}$ 降为 $r(d_{\text{in}} + d_{\text{out}})$ 。
- 训练时常使用缩放 α/r 。
- 部署时可把 BA merge 回 W_0 ，因此不一定引入额外推理层。

面试官连续追问

- 为什么 Q/K/V/FFN 选择不同 target modules 会影响效果？
- rank 越大越好吗？
- LoRA 与 adapter 的 latency 差异？

高频失分点

易错 说“原模型本身是低秩”。

易错 把参数减少比例和显存减少比例混为一谈。

证据索引：P-LoRA

57 LoRA Rank 怎么选？为什么经典初始化常让一侧为零？

难度 ★★★ 频度 极高频

面试官在考什么 考察 LoRA 训练动力学。

60-90 秒标准回答

rank 控制适配容量；过小可能欠拟合，过大增加显存并降低 PEFT 优势。经典做法让一侧随机、一侧零，使初始 $\Delta W=0$ ，模型从 base behavior 起步，同时另一侧能在第一步获得非零梯度并逐渐打开更新通道。

原理拆解 / 深度展开

- 若 A、B 都为 0，乘积结构会导致两侧初始梯度都可能为 0。
- 不同层的最佳 rank 可能不同，AdaLoRA 等方法做动态分配。
- rank 选择要结合 domain shift、数据量与 target modules。

面试官连续追问

- A/B 哪个置零有区别吗？
- LoRA+ 为什么给 A/B 不同学习率？
- DoRA 改了什么？

高频失分点

易错 把“rank 越高性能越好”当作单调规律。

58**QLoRA 与 LoRA 的区别是什么？4-bit 基座为什么还能训练？**

难度 ★★☆☆ 频度 高频

面试官在考什么 考察量化微调。

60-90 秒标准回答

QLoRA 把冻结的 base weights 以低比特形式存储/参与前向，仍只训练高精度 LoRA 参数；反向传播需要对输入和 LoRA 路径求梯度，但无需更新量化的 base 权重，因此可显著降低显存。

原理拆解 / 深度展开

- 经典 QLoRA 使用 NF4、double quantization 和 paged optimizer 等设计。
- 计算时量化权重通常需要按 kernel 需求反量化到计算 dtype。
- 量化误差会影响微调上限，尤其是小模型或强 domain shift。

面试官连续追问

- 为什么 optimizer state 主要来自 LoRA 参数？
- NF4 的直觉是什么？
- QLoRA 与 GPTQ/AWQ 有什么不同？

高频失分点

易错 说成“所有训练都在 4-bit 中完成”。

59**Full Fine-tuning 与 LoRA 应该如何选择？**

难度 ★★☆☆ 频度 高频

面试官在考什么 考察工程 trade-off。

60-90 秒标准回答

选择取决于目标性能、domain shift、数据规模、显存/训练预算与部署方式。LoRA 适合快速、多任务、多租户适配；Full FT 自由度最高，在数据足够且任务偏移大时可能有更高上限，但训练、存储和版本管理成本都更高。

原理拆解 / 深度展开

- 多 adapter 可共享一份 base，运营成本低。
- LoRA 不能自动修复 base 缺失的基础能力。
- 要用相同 token budget 和数据做公平对比。

面试官连续追问

- 什么时候 LoRA 会明显输给 Full FT？
- 多 LoRA merge 会发生什么？

高频失分点

易错 只按 GPU 是否够用做决策，不看任务偏移和部署。

60 SFT 的完整数据流程应该怎么设计？

难度 ★★★ 频度 极高频

面试官在考什么 2026 阿里等岗位直接考察。

60-90 秒标准回答

SFT 的核心通常在数据而非 optimizer：先明确能力 taxonomy，再做采集、去重、质量过滤、安全/隐私过滤、格式统一、指令-回答构造、难度与领域配比、长度控制、tokenization、train/val 去泄漏划分，最后训练并按能力切片评测。

原理拆解 / 深度展开

- 相似样本去重应跨 train/val，防止 benchmark leakage。
- 数据配比决定模型行为先验，不能简单按原始量堆叠。
- 长样本会显著影响 token-level batch 与吞吐，需要按 token 预算采样。

面试官连续追问

- 高质量数据怎么打分？
- 不同语言/领域如何配比？
- 如何控制 refusal/format 数据比例？

高频失分点

易错 只说“清洗→训练”。

易错 只按样本条数配比，忽略 token 数。

证据索引: M-Ali-2026

61 SFT 时如何设计 Label Mask? 为什么 user prompt 常不计算 Loss?

难度 ★★☆☆ 频度 高频

面试官在考什么 考察 instruction tuning 训练目标。

60-90 秒标准回答

Padding 必须 mask；对于单轮 instruction tuning，常只对 assistant response 计算 next-token loss，使梯度集中在“如何回答”而非复述 prompt。多轮对话可按模板选择是否训练 assistant 历史轮次。

原理拆解 / 深度展开

- 如果全序列都计算 loss，模型也会学习预测 system/user 文本，这未必符合目标。
- mask 设计必须与 chat template、shifted labels 对齐。
- 工具调用/思维轨迹数据还可能对特定字段做选择性监督。

面试官连续追问

- 为什么有些预训练式 SFT 会全量算 loss?
- 多轮对话 mask 如何构造?

高频失分点

易错 off-by-one：把当前位置而不是下一 token label mask 错。

62 SFT Loss 剧烈震荡或突然 NaN，如何排查?

难度 ★★★ 频度 极高频

面试官在考什么 考察真实训练经验。

60-90 秒标准回答

先按“数据→数值→优化器→batch→分布式”分层定位。检查异常超长/空回答/非法 token、loss 与 logits 的 NaN/Inf、学习率与 warmup、gradient norm、混合精度溢出、batch token 数波动、数据 shard 与梯度同步。不要第一反应就换模型。

原理拆解 / 深度展开

- 记录 per-batch token count、loss、grad norm、max logit 能快速锁定异常样本。

- FP16 更容易 overflow，BF16 动态范围更大。
- 如果只有特定 rank NaN，要检查数据 shard 与 collective。

面试官连续追问

- 如何定位是哪一个 sample 触发 NaN?
- gradient norm 正常但 loss 震荡说明什么?

高频失分点

易错 直接把 LR 降 10 倍而不定位根因。

63

经典 PPO-based RLHF 由哪些模型组成？目标是什么？

难度 ★★★ 频度 极高频

面试官在考什么 考察 RLHF pipeline。

60-90 秒标准回答

经典 RLHF 常包含 policy/actor、reference policy、reward model，以及 PPO 中用于估计 value 的 critic。policy 生成回答，reward model 给序列奖励，critic 估计优势；PPO 通过 clipped policy ratio 限制单次策略更新，reference KL 进一步约束模型不要偏离基座过远。

$$L_{clip} = E[\min(r_t A_t, \text{clip}(r_t, 1-\epsilon, 1+\epsilon)A_t)]$$

原理拆解 / 深度展开

- PPO clip 与 reference KL 是两种不同约束。
- reward 往往是 sequence-level，需要用 advantage/return 分配到 token-level 更新。
- RLHF 训练昂贵的关键在 rollout 和多个模型常驻显存。

面试官连续追问

- Actor/Critic/Reference/Reward 各是否更新?
- GAE 是什么?
- 为什么 PPO 训练不稳定?

高频失分点

易错 把 reward model 和 critic 混为一谈。

64

DPO 为什么不需要显式 Reward Model 与在线 RL?

难度 ★★★ 频度 极高频

面试官在考什么 考察 preference optimization。

60-90 秒标准回答

DPO 从 KL-regularized RLHF 的最优策略关系出发，把隐式 reward 写成 policy 与 reference 的 log-prob ratio，最终把偏好对 (winner, loser) 转成一个 logistic classification objective，直接优化 policy，无需训练独立 reward model、critic 或 rollout loop。

原理拆解 / 深度展开

- DPO 仍需要 preference pairs 和 reference policy。
- β 控制相对 reference 的偏移尺度。
- DPO 简化了 pipeline，但并不代表所有在线探索问题都可被离线偏好替代。

面试官连续追问

- DPO loss 写出来。
- β 太大/太小意味着什么？
- DPO 与 IPO/ORPO/KTO 有何区别？

高频失分点

易错 说 “DPO 没有 reward”，更准确是没有显式独立 reward model。

证据索引: P-DPO

65 GRPO 相比 PPO 的关键变化是什么？优势估计从哪里来？

难度 ★★★ 频度 极高频

面试官在考什么 2026 高频后训练真题。

60-90 秒标准回答

GRPO 对同一个 prompt 采样一组 responses，用组内 reward 的相对统计构造 advantage，从而不再依赖独立 value/critic 网络。这样减少模型常驻显存和 critic 训练成本，特别适合可验证 reward 的推理任务。

$$A_i \approx (r_i - \mu_{\text{group}}) / (\sigma_{\text{group}} + \epsilon)$$

原理拆解 / 深度展开

- 典型 advantage 可用 $(r_i - \text{mean}(r)) / \text{std}(r)$ 标准化。
- 仍需处理 policy ratio、KL、采样分布和 reward 质量。
- 组内奖励都相同或方差很小时，学习信号会退化。

面试官连续追问

- GRPO 为什么适合数学/代码？
- group size 怎么影响方差和成本？
- DAPO/GSPO 试图修正 GRPO 的哪些问题？

高频失分点

易错 说 GRPO “完全没有 value 概念”而忽略它用相对 reward 构造 advantage。

证据索引: P-GRPO

66 RLHF / GRPO 为什么常需要 KL Constraint?

难度 ★★★ 频度 极高频

面试官在考什么 考察策略漂移与稳定性。

60-90 秒标准回答

Reward model/规则只是任务目标的代理，如果只最大化 reward，policy 可能偏离预训练语言分布、出现退化或 reward hacking。KL penalty 把优化限制在 reference 附近，在“任务改进”和“保留原模型能力”之间做 trust-region 式折中。

原理拆解 / 深度展开

- KL 可以作为 loss penalty，也可用于 reward shaping 或自适应控制。
- β 太大时模型学不动，太小时漂移明显。
- 不同 token 的 KL 与 sequence-level KL 聚合方式会影响优化。

面试官连续追问

- forward KL / reverse KL 有何差别？
- KL 是否一定要显式加入 GRPO？

高频失分点

易错 认为 KL 越小越好。

67 什么是 Reward Hacking? 如何发现与抑制?

难度 ★★★ 频度 极高频

面试官在考什么 考察目标错配和对齐工程。

60-90 秒标准回答

Reward hacking 是模型找到能提高代理 reward、却没有真正完成目标的策略，例如堆格式、关键词、冗长模板或利用 evaluator 漏洞。发现它要对 reward 与真实任务指标解耦监控，并做人审、隐藏测试、对抗样本和跨 evaluator 复核。

原理拆解 / 深度展开

- 单一 reward 容易被投机，多维 reward 也可能出现权重博弈。
- 可验证任务应尽量使用结果验证器；开放任务需要多评审器与人工抽查。
- 训练中 reward 持续涨但外部 benchmark 不涨，是典型警报。

面试官连续追问

- 长度偏置如何形成？
- 多个 reward model 冲突怎么聚合？
- self-rewarding 如何避免自我放大错误？

高频失分点

易错 把 reward hacking 仅理解为安全攻击；它首先是优化目标代理失真。

证据索引: M-Ali-2026

68 如何判断 RL/Post-training 训练“达标”？

难度 ★★★ 频度 高频

面试官在考什么 考察评估体系而非单指标。

60-90 秒标准回答

不能只看训练 reward。至少分四层：优化稳定性（reward/KL/entropy/clip/grad norm）、任务能力（held-out accuracy/pass rate）、行为质量（格式、安全、简洁性）、泛化与回归（基础 benchmark、不同领域/语言）。最终还要做人审和线上 A/B。

原理拆解 / 深度展开

- reward 与目标指标的相关性要定期验证。
- 按能力 taxonomy 做 slice evaluation 比单平均分更能发现退化。
- post-training 还要监控 catastrophic forgetting 和 verbosity bias。

面试官连续追问

- 什么叫 Goodhart's Law？
- 为什么 benchmark 提升但用户体验可能下降？

高频失分点

易错 用训练 reward 作为唯一 early stopping 指标。

第 7 章 对比学习、多模态与 Diffusion

本章目标 从 InfoNCE、CLIP 到视频多模态，再到 Diffusion/DiT。

覆盖题目：Q69–Q78。建议先遮住答案口述，再阅读解析。

69 InfoNCE Loss 是什么？为什么适合对比学习？

难度 ★★☆☆ 频度 极高频

面试官在考什么 2026 搜推/多模态高频。

60–90 秒标准回答

InfoNCE 把一个 query 的正样本与一组负样本一起做 softmax 分类：提高 q 与 k+ 相似度，同时降低与 k- 的相似度。它既可视作对比分类目标，也与互信息下界估计有关。

$$L = -\log \frac{\exp(\text{sim}(q, k_+))}{\sum_j \exp(\text{sim}(q, k_j))}$$

原理拆解 / 深度展开

- 通常先对 embedding L2 normalize，再用 cosine/dot-product similarity。
- in-batch negatives 能高效扩大负样本数量，但引入 false negative 风险。
- 对称 CLIP loss 会同时 image→text 和 text→image。

面试官连续追问

- 为什么 batch size 对对比学习很重要？
- InfoNCE 和 triplet loss 有什么差异？

高频失分点

易错 默认所有 batch 内其他样本都是可靠负样本。

证据索引：M-Ali-InfoNCE

70 InfoNCE 中 Temperature τ 起什么作用？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察 softmax 几何。

60–90 秒标准回答

τ 决定相似度 logits 的缩放。 τ 较小会让 softmax 更尖锐，梯度更集中到 hardest negatives； τ 较大分布更平滑。它直接影响 embedding 空间的分离力度、训练稳定性与 false negative 敏感度。

原理拆解 / 深度展开

- τ 与 embedding norm 有耦合，因此常先 normalize embedding。
- 可固定也可学习。
- τ 太小可能让少数错误负样本主导梯度。

面试官连续追问

- 0.1 和 0.4 会发生什么差异？
- 为什么 CLIP 学习 logit scale？

高频失分点

易错 说“温度越小越好”。

证据索引: M-Ali-InfoNCE

71 对比学习中的 False Negative 如何处理？

难度 ★★★ 频度 高频

面试官在考什么 考察真实落地踩坑。

60-90 秒标准回答

False negative 是语义上应该接近、却被采样为负的样本，会把正确邻居错误推远。可利用标签/行为图过滤、multi-positive objective、debiasing、teacher similarity、语义阈值，以及更谨慎的 hard-negative mining。

原理拆解 / 深度展开

- 热门 item 作为大量负样本会改变训练先验，推荐场景尤其明显。
- hard negative 不是越难越好，过难可能就是 false negative。
- 要评估采样分布与线上候选分布是否一致。

面试官连续追问

- 热门负采样会造成什么 bias？
- in-batch negative 如何去重？

高频失分点

易错 把“相似但不是正标签”一律当 hard negative。

证据索引: M-Ali-InfoNCE

72 CLIP 为什么能做 Zero-shot 分类？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察视觉语言对齐。

60-90 秒标准回答

CLIP 在大规模图文对上用对比学习把匹配图片与文本映射到同一 embedding 空间。分类时把类别写成自然语言 prompt，得到各类别文本向量，再比较图片向量与文本向量相似度，因此无需为新类别训练独立分类头。

原理拆解 / 深度展开

- prompt wording 会影响 zero-shot 性能，因此出现 prompt ensemble/prompt learning。
- CLIP 学的是跨模态相似度，不是传统固定标签分类器。
- 对比训练规模与数据质量是泛化关键。

面试官连续追问

- 为什么需要双向 loss?
- CLIP embedding 能否直接做检索?

高频失分点

易错 把 zero-shot 说成“模型没见过任何相关语义”。

73 如何把 Text-only LLM 改造成多模态模型?

难度 ★★★ 频度 极高频

面试官在考什么 考察 VLM 标准架构。

60-90 秒标准回答

常见路径是使用 vision encoder 把图片编码成视觉 token，经 projector/Q-Former/adapter 对齐到 LLM hidden space，再与文本 token 拼接或通过 cross-attention 输入语言模型；训练通常分对齐预训练、指令微调，再按需要做偏好/强化学习。

原理拆解 / 深度展开

- 投影层是模态接口，容量过小会成为信息瓶颈。
- vision encoder 可冻结、部分解冻或联合训练。
- 视觉 token 数量直接影响上下文和推理成本。

面试官连续追问

- 为什么 projector 可能成为瓶颈?
- 图片分辨率提高后 token 数怎么控制?
- 早融合与 cross-attention 有何不同?

高频失分点

易错 只说“接一个视觉编码器”，不解释 token 对齐与训练阶段。

74 多模态模型如何处理视频？视觉 token 爆炸怎么办？

难度 ★★★ 频度 极高频

面试官在考什么 2026 多模态面试热点。

60-90 秒标准回答

视频先做帧/clip 采样，经视觉编码器得到空间 token，再做 temporal pooling、token merging、resampler 或层次编码，压缩成可被 LLM 消化的视频 token。核心矛盾是时空信息完整性与上下文/计算成本。

原理拆解 / 深度展开

- 均匀抽帧可能错过短关键事件，应考虑 shot/event-aware sampling。
- 视觉 token 远多于文本时，loss 和梯度可能被视觉模态主导，需要采样/权重/对齐策略。
- 长视频还需处理时间位置编码。

面试官连续追问

- 如何保留关键动作？
- 视频问答如何设计 temporal grounding？
- 帧率与分辨率如何折中？

高频失分点

易错 默认“多抽帧一定更好”。

证据索引: M-Ali-2026

75 Diffusion 的 Forward Process 是什么？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察扩散模型基本概率过程。

60-90 秒标准回答

Forward diffusion 逐步向数据 x_0 加 Gaussian noise，构造一个已知的 Markov chain，最终 x_T 接近标准高斯；由于高斯性质，可以直接从 x_0 一步采样任意 x_t ，而无需真的循环 t 次。

$$x_t = \sqrt{\alpha_t} x_0 + \sqrt{(1-\alpha_t)} \epsilon$$

原理拆解 / 深度展开

- $q(x_t|x_{t-1})$ 由 β_t 控制噪声强度。
- 累积 α_t 后可得到 closed-form $x_t = \sqrt{\alpha_t} x_0 + \sqrt{(1-\alpha_t)} \epsilon$ 。
- 训练学习逆过程的参数化。

面试官连续追问

- 为什么 forward process 不需要学习？
- noise schedule 会影响什么？

高频失分点

易错 只说“不断加噪声”，不会写闭式采样。

76 Diffusion 为什么经常预测 Noise?

难度 ★★☆☆ 频度 高频

面试官在考什么 考察训练目标参数化。

60-90 秒标准回答

由于 x_t 可写成干净样本与高斯噪声的线性组合，模型可以接收 (x_t, t) 回归真实 ϵ ，形成稳定的 MSE 训练目标；从预测噪声可反推出对 x_0 或 score 的估计。不同模型也可选择 x_0 -prediction 或 v -prediction。

原理拆解 / 深度展开

- ϵ -prediction 不是唯一正确参数化。
- 不同时间步的 SNR 差异会让 loss weighting 很重要。
- v -prediction 常用于某些现代生成模型以改善不同噪声区间平衡。

面试官连续追问

- score matching 与 noise prediction 的关系？
- 为什么 timestep embedding 必须输入网络？

高频失分点

易错 认为推理时模型是在“预测随机噪声”，实际上是在估计应去掉的噪声成分。

77 Latent Diffusion 为什么比 Pixel Diffusion 更便宜?

难度 ★★☆☆ 频度 高频

面试官在考什么 考察生成模型系统设计。

60-90 秒标准回答

先用 autoencoder 把高分辨率图像压缩到低空间尺寸 latent，再在 latent 上运行 diffusion，大幅减少每一步 U-Net/Transformer 的 token/像素数量；最终 decoder 把 latent 还原成图像。

原理拆解 / 深度展开

- 压缩带来计算收益，但 autoencoder 的重建质量决定细节上限。
- latent 通道数虽增加，空间降采样通常仍带来巨大节省。
- 文本条件常通过 cross-attention 注入。

面试官连续追问

- VAE 为什么而不是普通 AE？

→ latent compression 过强会发生什么？

高频失分点

易错 只按参数量解释速度，不讨论每步空间分辨率。

78

U-Net Diffusion 与 DiT 有什么区别？

难度 ★★★ 频度 高频

面试官在考什么 考察生成架构向 Transformer 演进。

60-90 秒标准回答

传统 diffusion backbone 多用多尺度 U-Net；DiT 把 latent patchify 后交给 Transformer block，结合 timestep/class/text condition 做噪声或 velocity 预测。Transformer 的优势在于架构统一和更清晰的 compute scaling，但高分辨率 token 数会带来 attention 成本。

原理拆解 / 深度展开

- DiT 不是把 diffusion 改成 autoregressive，它仍处于扩散训练框架。
- conditioning 可通过 adaptive LayerNorm、cross-attention 等注入。
- 现代图像/视频生成大量采用 Transformer-based diffusion/flow backbone。

面试官连续追问

→ DiT 为什么适合 scaling？

→ Patch size 如何影响 FLOPs 和细节？

高频失分点

易错 把 DiT 与 ViT 完全等同，忽略 timestep/condition 与 diffusion objective。

证据索引：P-DiT

第 8 章 训练工程与分布式训练

本章目标 混合精度、梯度累积、DDP/FSDP/ZeRO 与 OOM/NaN/GPU 利用率排障。

覆盖题目：Q79–Q88。建议先遮住答案口述，再阅读解析。

79 FP16、BF16、FP32 的差异是什么？为什么大模型偏爱 BF16？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察数值格式与动态范围。

60–90 秒标准回答

FP16 和 BF16 都是 16 bit，但 FP16 给更多 mantissa、较少 exponent；BF16 保留与 FP32 相同数量级的 exponent bits，因此动态范围远大于 FP16，更不容易 overflow/underflow，代价是尾数精度较低。

原理拆解 / 深度展开

- 训练稳定性更依赖动态范围时 BF16 很有优势。
- 硬件是否支持 BF16 是前提。
- optimizer state 是否 FP32 是另外一层问题。

面试官连续追问

- 为什么 FP16 常需要 loss scaling？
- TF32 又是什么？

高频失分点

易错 说 BF16 比 FP16 “精度更高”，应区分数值范围与尾数精度。

80 Mixed Precision 为什么能提速？Loss Scaling 的作用是什么？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察 Tensor Core 与数值稳定。

60–90 秒标准回答

混合精度让大部分 GEMM/卷积使用 FP16/BF16，提高 Tensor Core 吞吐并降低显存/带宽；对需要高动态范围或累积精度的部分保持 FP32。FP16 下小梯度可能 underflow，loss scaling 先放大 loss/grad，更新前再缩回。

原理拆解 / 深度展开

- 动态 loss scaling 会在检测到 overflow 时降低 scale。
- BF16 一般不依赖 loss scaling。
- 混合精度收益取决于算子是否进入高效 kernel。

面试官连续追问

- 为什么 LayerNorm/softmax 有时用更高精度累计？
- master weights 是什么？

高频失分点

易错 认为所有 tensor 都变成 FP16。

81 Gradient Accumulation 如何得到更大的 Effective Batch?

难度 ★☆☆ 频度 高频

面试官在考什么 考察显存预算和优化等价性。

60-90 秒标准回答

将多个 micro-batch 的梯度累加后再执行一次 optimizer.step，可把 effective batch 近似扩大为 $\text{micro_batch} \times \text{accumulation_steps} \times \text{data_parallel_size}$ 。若 loss 每步已取 mean，要正确处理缩放。

$$B_{\text{eff}} = B_{\text{micro}} \times N_{\text{acc}} \times N_{\text{DP}}$$

原理拆解 / 深度展开

- 与真正大 batch 并非完全等价：BN 统计、dropout 随机性和优化器 step 频率不同。
- scheduler 通常按 optimizer step 而不是 micro-step 更新。
- 分布式下可用 no_sync 减少中间 all-reduce。

面试官连续追问

- 为什么 accumulation 后 LR 可能要调整？
- DDP no_sync 怎么用？

高频失分点

易错 每个 micro-step 都 optimizer.step，等于没累积。

82 Gradient Checkpointing 为什么能省显存？代价是什么？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察 activation memory。

60-90 秒标准回答

普通反向传播需要保存大量 forward activations；checkpointing 只保留少数边界激活，在 backward 时重新执行部分 forward 恢复中间值，因此用额外计算换 activation memory。

原理拆解 / 深度展开

- 它不直接减少参数/optimizer state。
- 重计算区间越大，显存越省但额外 FLOPs 越多。
- 随机算子需要正确保存/恢复 RNG state 才能保持一致。

面试官连续追问

- 为什么 activation 在长序列训练中可能超过参数显存？
- checkpoint 每一层是否最优？

高频失分点

易错 把它和 checkpoint 保存模型权重混淆。

83 DDP 的核心原理是什么？为什么每卡模型保持一致？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察数据并行与 collective。

60-90 秒标准回答

DDP 在每个 rank 保存完整模型副本，输入数据分片；backward 过程中把各 rank 的梯度按 bucket 做 all-reduce/平均，因此每张卡得到相同梯度并独立执行相同 optimizer step，参数继续保持一致。

原理拆解 / 深度展开

- DDP 常通过 autograd hook 在梯度 ready 时重叠通信。
- DistributedSampler 保证数据分片。
- 如果某些参数在不同 rank 未参与 backward，可能出现同步问题。

面试官连续追问

- all-reduce 为什么可同时求和和广播？
- gradient bucketing 有什么意义？

高频失分点

易错 说 DDP 在每步同步参数而不是主要同步梯度。

84 ZeRO-1/2/3 与 FSDP 的核心区别和关系是什么？

难度 ★★★ 频度 极高频

面试官在考什么 2026 大模型训练核心工程题。

60-90 秒标准回答

ZeRO 按训练状态逐级分片：Stage 1 分 optimizer states，Stage 2 再分 gradients，Stage 3 再分 parameters。PyTorch FSDP 的 FULL_SHARD 与 ZeRO-3 思想相近：参数按需 all-gather，反向后 reduce-scatter，并让每个 rank 常驻自己的 shard。

原理拆解 / 深度展开

- 越高 stage 省显存越多，但通信与调度更复杂。
- FSDP 还涉及 wrap policy、state_dict、mixed precision、prefetch 等工程细节。
- ZeRO/FSDP 都是 data-parallel family 的内存分片，不等同于 Tensor Parallel。

面试官连续追问

- ZeRO-2 为什么参数仍复制？
- FSDP forward 前为什么 all-gather？
- checkpoint 怎么保存？

高频失分点

易错 把 ZeRO-3 和 Tensor Parallel 混为一谈。

证据索引：D-FSDP

85 Data Parallel、Tensor Parallel、Pipeline Parallel 怎么区分？

难度 ★★★ 频度 极高频

面试官在考什么 考察 3D parallelism。

60–90 秒标准回答

DP 切数据、复制模型；TP 在一层内部切矩阵/attention heads，让单层跨设备协作；PP 按层切模型，用 micro-batch 流水穿过多个 stage。超大模型常组合 $DP \times TP \times PP$ ，并进一步加 sequence/context parallel。

原理拆解 / 深度展开

- TP 通信频繁但解决单层放不下；PP 降低每卡层数但有 pipeline bubble。
- DP 的扩展受 optimizer/parameter replication 限制，因此常与 ZeRO/FSDP 结合。
- 并行策略要按拓扑和模型结构设计。

面试官连续追问

- Column Parallel 与 Row Parallel Linear 如何通信？
- PP 的 1F1B 是什么？

高频失分点

易错 只会背“切数据/切模型”，说不出通信位置。

86 CUDA OOM 怎么系统排查，而不是只减 batch？

难度 ★★★ 频度 极高频

面试官在考什么 工程排障能力。**60-90 秒标准回答**

先拆显存组成：参数、梯度、optimizer states、activations、KV/临时 workspace、通信 buffer 与碎片。再看 OOM 发生在 forward/backward/optimizer 哪个阶段，结合 profiler 和 memory summary 决定用 mixed precision、checkpoint、ZeRO/FSDP、sequence/batch 调整或 allocator 配置。

原理拆解 / 深度展开

- 训练 OOM 与推理 OOM 的主导项不同。
- 长序列常由 activation/attention memory 主导。
- 峰值临时 tensor 也可能造成“平均显存明明够”的 OOM。

面试官连续追问

- Adam 训练 7B 为什么 optimizer state 很大？
- memory fragmentation 怎么判断？

高频失分点**易错** 只回答 batch size ↓。**87 Loss 变 NaN/Inf，如何定位根因？**

难度 ★★★ 频度 极高频

面试官在考什么 考察数值调试方法。**60-90 秒标准回答**

建立数值断点：输入→关键层激活/logits→loss→grad→optimizer state，逐步检查 isfinite，并记录首次出现异常的 step/rank/sample。常见原因包括 LR 过高、FP16 overflow、除零/log(0)、异常数据、梯度爆炸、归一化方差过小或自定义 kernel bug。

原理拆解 / 深度展开

- anomaly detection 很慢，适合缩小范围后使用。
- gradient clipping 若只能延迟 NaN，根因可能仍在。
- 某个 rank 单独 NaN 时优先看 shard data/custom op/collective。

面试官连续追问

- 为什么 softmax 手写容易 overflow？
- 如何做 numerically stable log-softmax？

高频失分点**易错** NaN 后继续训练并期待 optimizer 自愈。

88

GPU 利用率只有 30%，如何排查？

难度 ★★★ 频度 极高频

面试官在考什么 考察性能分析思路。

60-90 秒标准回答

先判断 GPU 在等什么：数据加载/CPU 预处理、H2D 拷贝、小 kernel launch、同步点、通信、batch 太小或 memory-bound。使用 PyTorch Profiler/Nsight 把时间拆成 CPU、CUDA kernel、Memcpy、NCCL，而不是先盲目改模型。

原理拆解 / 深度展开

- DataLoader 可检查 num_workers、prefetch、pin_memory。
- 许多小 op 可通过 fusion/compile 减少 launch overhead。
- 多卡低利用率要看 communication overlap 和 straggler。

面试官连续追问

- GPU Util 高但吞吐低又意味着什么？
- MFU 与 GPU utilization 有何区别？

高频失分点

易错 只看 nvidia-smi 的瞬时利用率判断性能。

第 9 章 模型压缩与推理优化

本章目标 量化、PagedAttention、Continuous Batching、Prefill/Decode 与延迟定位。

覆盖题目：Q89–Q95。建议先遮住答案口述，再阅读解析。

89 INT8/INT4 Quantization 为什么能省显存并可能加速？

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察推理压缩与 bandwidth。

60–90 秒标准回答

低比特量化把权重/激活用更少 bit 表示，直接减少模型存储和内存带宽；若硬件有高效 INT8/INT4 GEMM kernel，还可提升吞吐。实际显存还包含 scale/zero-point、KV cache、workspace，不能只按参数 bit 数估算。

原理拆解 / 深度展开

- weight-only quantization 主要减少权重带宽。
- activation quantization 更难，因为动态范围和 outlier。
- group-wise scale 在精度与 metadata 之间折中。

面试官连续追问

- 为什么 LLM 有 outlier channels？
- AWQ/GPTQ 的基本思想差异？

高频失分点

易错 认为 4-bit 一定比 8-bit 快 2 倍。

90 PTQ 与 QAT 有什么区别？

难度 ★★☆☆ 频度 高频

面试官在考什么 考察量化训练路径。

60–90 秒标准回答

PTQ 在训练完成后通过 calibration/权重优化量化，成本低；QAT 在训练中模拟量化和舍入误差，使模型主动适应低比特表示，通常更能保精度，但训练复杂度和成本更高。

原理拆解 / 深度展开

- fake quantization 在 forward 模拟量化，backward 常用 STE 近似。
- LLM 大模型常优先 PTQ/weight-only，因为重新训练成本极高。

- calibration 数据必须代表真实分布。

面试官连续追问

- 什么是 calibration?
- 为什么 per-channel 通常比 per-tensor 更准?

高频失分点

易错 把 QAT 理解为真的用 int 反向传播全部算子。

91 vLLM / PagedAttention 解决了什么问题?

难度 ★★★ 频度 极高频

面试官在考什么 2026 推理系统高频。

60-90 秒标准回答

PagedAttention 的核心是 KV Cache memory management: 把每个请求逻辑连续的 KV 序列切成固定块, 映射到可非连续的 GPU 物理块, 类似虚拟内存分页, 减少动态长度请求的碎片和预留浪费, 并支持更灵活的共享/复制。

原理拆解 / 深度展开

- 它与 FlashAttention 解决的问题不同: 一个偏 serving KV 管理, 一个偏 attention kernel IO。
- 更高 KV 利用率允许更大的 batch, 间接提升 throughput。
- Copy-on-write 可支持并行采样/beam 的共享前缀。

面试官连续追问

- 为什么传统 contiguous KV 会浪费?
- block size 太大/太小有什么 trade-off?

高频失分点

易错 把 PagedAttention 说成把 attention 复杂度降为线性。

证据索引: P-vLLM

92 Continuous Batching 为什么能提高 LLM Serving 吞吐?

难度 ★★☆☆ 频度 极高频

面试官在考什么 考察动态请求调度。

60-90 秒标准回答

LLM 请求输出长度不同, 静态 batch 会让已完成请求占着 batch 等最长请求。Continuous batching 在 decode 的迭代边界动态移出完成请求、加入新请求, 使 GPU 持续保持较高并发和 token-level batch 利用率。

原理拆解 / 深度展开

- 吞吐提升可能以单请求排队/调度策略变化为代价。
- prefill 很大时还需做 chunked prefill 或优先级调度，防止 decode 被阻塞。
- batch 的单位可以理解为当前 iteration 处理的 token/request 集。

面试官连续追问

- 如何避免长 prompt 饿死短请求？
- throughput 与 P99 latency 如何权衡？

高频失分点

易错 只说“把请求凑成 batch”，没有解释动态加入/移出。

93 Prefill 与 Decode 的性能特征有什么区别？

难度 ★★★ 频度 极高频

面试官在考什么 考察 LLM Serving roofline 思维。

60-90 秒标准回答

Prefill 一次并行处理整段 prompt，矩阵规模大、算术强度高，常偏 compute-bound；Decode 每步通常只有一个新 token，但要读取大量模型权重和 KV，矩阵瘦小，常偏 memory-bandwidth/latency-bound。

原理拆解 / 深度展开

- TTFT 主要受 queue+prefill 影响；TPOT/ITL 主要受 decode 调度和带宽影响。
- batching 可以显著提高 decode 的矩阵规模和硬件利用。
- 长 context decode 还会增加读取 KV 的成本。

面试官连续追问

- 为什么 decode 的 FLOPs 少却可能很慢？
- Prefill/Decode 分离部署有什么好处？

高频失分点

易错 认为 GPU 算力峰值越高 decode 一定越快。

94 Speculative Decoding 的原理是什么？为什么能保持目标模型分布？

难度 ★★★ 频度 高频

面试官在考什么 考察生成加速。

60-90 秒标准回答

用便宜 draft model 连续提出多个候选 token，target model 一次并行验证一段候选；根据接受/拒绝规则尽量批量接受，从而减少 target model 的串行 forward 次数。严格算法可通过校正采样保持与目标模型一致的分布。

原理拆解 / 深度展开

- 收益取决于 draft 与 target 的一致率和验证开销。
- draft 太弱接受率低，太强又失去成本优势。
- greedy 场景可使用更简单的验证变体。

面试官连续追问

- 为什么一次 target forward 能验证多个 token？
- 接受率如何影响 speedup 上限？

高频失分点

易错 说成“小模型生成完，大模型只做一次打分”。

95

线上 LLM 突然变慢，如何分层定位？

难度 ★★★ 频度 极高频

面试官在考什么 系统诊断能力。

60-90 秒标准回答

把端到端 latency 拆成 Queue、Preprocess、Prefill、Decode、Network、Postprocess；同时监控 TTFT、TPOT、input/output tokens、batch size、GPU/显存、KV occupancy、queue depth、NCCL 与 kernel time。先找发生变化的层，再关联流量/版本/配置变更。

原理拆解 / 深度展开

- 平均延迟正常而 P99 恶化，常见是排队、长请求、straggler 或资源争抢。
- 吞吐下降但 GPU 利用率高，可能是序列变长或 memory-bound。
- 需要与基线版本做 canary/A-B 对照。

面试官连续追问

- 如何区分排队慢和模型本身慢？
- KV cache 命中率下降会怎样？
- 为什么 token 长度分布变化会导致延迟突增？

高频失分点

易错 第一反应就是换 FlashAttention 或加 GPU。

第 10 章 项目深挖与系统题

本章目标 把“会模型”升级为“能做项目”：模型选择、线上线下偏差、消融、故障定位与手写实现。

覆盖题目：Q96–Q100。建议先遮住答案口述，再阅读解析。

96 项目中为什么选择这个模型，而不是另一个模型？

难度 ★★★ 频度 极高频

面试官在考什么 项目深挖第一问题，考察决策链。

60–90 秒标准回答

用“业务约束→数据特征→候选模型→离线实验→消融→线上成本/收益”回答，而不是说“因为先进”。要给出至少一个被淘汰方案、具体指标和部署约束，证明选择是实验决策。

原理拆解 / 深度展开

- 模型复杂度必须与 latency、memory、吞吐、可维护性同时评估。
- 离线提升若非常小而系统复杂度大，未必值得上线。
- 选择过程应有 baseline 和 ablation 证据。

面试官连续追问

- 为什么不用更大的模型？
- 这个组件删掉损失多少？
- 线上限制变化后你会怎么重新选？

高频失分点

易错 只讲最终方案，不讲对照实验。

97 Offline 指标提升，Online 指标为什么可能下降？

难度 ★★★ 频度 极高频

面试官在考什么 考察训练-服务闭环。

60–90 秒标准回答

常见原因包括 train-serving skew、数据分布漂移、label leakage、离线指标与业务目标错配、概率校准变化、延迟/超时、探索机制和反馈回路。排查时要把模型预测质量与系统/策略影响分开。

原理拆解 / 深度展开

- AUC 提升不意味着阈值下 precision/recall 一定提升。
- 排序指标提升不等于 GMV/留存提升。

- 线上模型改变曝光后会反过来改变后续训练数据，形成 feedback loop。

面试官连续追问

- 如何判断是模型问题还是 serving 问题？
- 什么是 counterfactual evaluation？

高频失分点

易错 把所有线上回落归因于 distribution shift。

98

什么是 Ablation Study？怎样做才有说服力？

难度 ★★★ 频度 极高频

面试官在考什么 考察因果归因和实验设计。

60-90 秒标准回答

Ablation 是通过逐项移除/加入模块，在其他训练预算和设置尽量一致时测量独立贡献。好的消融不仅比较最终指标，还要报告成本、方差和模块间交互，避免“最终方案涨了 5% 就把功劳都算给新模块”。

原理拆解 / 深度展开

- 单因素 ablation 简单但可能漏掉交互效应。
- 至少多 seed 或给置信区间，防止把训练噪声当提升。
- 还要做 negative results：哪些尝试失败、为什么。

面试官连续追问

- 两个模块各自不涨、一起涨怎么解释？
- 如何控制实验预算公平？

高频失分点

易错 不同实验同时改数据、LR、模型，导致无法归因。

99

训练 Loss 一直下降，但验证指标不涨，怎么办？

难度 ★★★ 频度 极高频

面试官在考什么 考察系统诊断而非“调参反射”。

60-90 秒标准回答

先确认评估 pipeline 和数据切分，再区分过拟合、objective mismatch、label noise、distribution shift、metric saturation 与训练/验证预处理不一致。只有确定是模型泛化问题后，再谈正则化、数据增强、容量与训练策略。

原理拆解 / 深度展开

- 若 val loss 也降但业务 metric 不涨，优先怀疑 objective/metric mismatch。
- 若只有某 slice 不涨，应做分桶分析而不是看总平均。
- 验证集污染会产生相反的虚假乐观。

面试官连续追问

- 如何发现 metric bug?
- AUC 不涨但 logloss 降可能说明什么?

高频失分点

易错 不检查评估代码，直接继续加层/换 optimizer。

100 现场从零实现 Attention / BN / InfoNCE，面试官真正考什么？

难度 ★★★ 频度 极高频

面试官在考什么 总结手写题的方法论：公式→shape→边界→数值稳定→复杂度。

60-90 秒标准回答

面试官不只看是否记得 API，而是看能否把数学对象翻译成 tensor shape，并处理 broadcast、mask、batch、数值稳定与边界。最佳回答方式是先写 shape invariant，再写公式，再写代码，最后给复杂度和测试用例。

原理拆解 / 深度展开

- Attention：先锁定 [B,H,T,Dh]；BN：先明确统计维度；InfoNCE：先构造 [B,B] similarity matrix 与正样本对角线。
- 代码后主动写 2-3 个单元测试：shape、极端输入、与框架实现对齐。
- 真正高级的候选人会说明 mixed precision、分布式或大 batch 下的变化。

手写 / 代码骨架

```
# 通用手写题顺序
# 1) 写输入/输出 shape
# 2) 写核心数学式
# 3) 明确 reduce / softmax / normalize 维度
# 4) 处理 mask、eps、空样本等边界
# 5) 给时间/空间复杂度
# 6) 与框架 reference 做数值测试
```

面试官连续追问

- 如何测试自己的 MHA 与 torch 实现等价?
- InfoNCE 如何做双向 loss?
- BN 推理态如何写?

高频失分点

易错 上来就写代码，shape 错了再边写边补。

附录 A | 最值得优先拿下的 30 题

优先级	题号	题目	必须掌握到什么程度
1	Q05	什么是梯度消失与梯度爆炸？如何系统解决？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
2	Q11	SGD、Momentum、RMSProp、Adam 的核心差异是什么？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
3	Q12	Adam 与 AdamW 有什么区别？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
4	Q16	BatchNorm 的训练与推理过程分别是什么？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
5	Q17	为什么 Transformer 常用 LayerNorm，而 CNN 传统上大量用 BatchNorm？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
6	Q19	Pre-Norm 与 Post-Norm 的区别是什么？为什么 Pre-Norm 更易训练深层网络？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
7	Q25	ResNet 为什么能训练很深？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
8	Q39	从头讲一个现代 Transformer Block。	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
9	Q40	写出 Scaled Dot-Product Attention，并解释每一步。	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
10	Q41	为什么 Attention 要除以 $\sqrt{d_k}$ ？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
11	Q43	Self-Attention 的时间和显存复杂度是多少？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
12	Q44	Multi-Head Attention 为什么比单头更有表达力？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
13	Q46	Absolute Position、Relative Position、RoPE 有什么区别？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
14	Q47	Transformer 的 FFN 到底做什么？为什么不能删？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
15	Q48	MHA、MQA、GQA 的区别？为什么 GQA 能省 KV Cache？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
16	Q49	KV Cache 的原理是什么？显存如何估算？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。
17	Q50	FlashAttention 为什么快？它有没有把 $O(T^2)$ 变成 $O(T)$ ？	能写公式/shape，能回答至少 3 个追问，能说明失败场景。

优先级	题号	题目	必须掌握到什么程度
18	Q52	为什么现代通用大模型大量采用 Decoder-only?	能写公式/shape, 能回答至少 3 个追问, 能说明失败场景。
19	Q55	请手写 Multi-Head Attention, 必须处理 shape、mask 与数值稳定。	能写公式/shape, 能回答至少 3 个追问, 能说明失败场景。
20	Q56	LoRA 的数学原理是什么? 为什么低秩更新可行?	能写公式/shape, 能回答至少 3 个追问, 能说明失败场景。
21	Q57	LoRA Rank 怎么选? 为什么经典初始化常让一侧为零?	能写公式/shape, 能回答至少 3 个追问, 能说明失败场景。
22	Q60	SFT 的完整数据流程应该怎么设计?	能写公式/shape, 能回答至少 3 个追问, 能说明失败场景。
23	Q62	SFT Loss 剧烈震荡或突然 NaN, 如何排查?	能写公式/shape, 能回答至少 3 个追问, 能说明失败场景。
24	Q63	经典 PPO-based RLHF 由哪些模型组成? 目标是什么?	能写公式/shape, 能回答至少 3 个追问, 能说明失败场景。
25	Q64	DPO 为什么不需要显式 Reward Model 与在线 RL?	能写公式/shape, 能回答至少 3 个追问, 能说明失败场景。
26	Q65	GRPO 相比 PPO 的关键变化是什么? 优势估计从哪里来?	能写公式/shape, 能回答至少 3 个追问, 能说明失败场景。
27	Q66	RLHF / GRPO 为什么常需要 KL Constraint?	能写公式/shape, 能回答至少 3 个追问, 能说明失败场景。
28	Q67	什么是 Reward Hacking? 如何发现与抑制?	能写公式/shape, 能回答至少 3 个追问, 能说明失败场景。
29	Q86	CUDA OOM 怎么系统排查, 而不是只减 batch?	能写公式/shape, 能回答至少 3 个追问, 能说明失败场景。
30	Q95	线上 LLM 突然变慢, 如何分层定位?	能写公式/shape, 能回答至少 3 个追问, 能说明失败场景。

附录 B | 典型“连续追问链”

Attention 追问链

模拟路径 Attention 公式 → 为什么除 $\sqrt{d_k}$ → 复杂度 → MHA 为什么 → MHA/MQA/GQA → KV Cache 显存 → Decode 为什么慢 → FlashAttention → PagedAttention → P99 仍高怎么查

LoRA 追问链

模拟路径 $\Delta W = BA$ → 参数量怎么算 → rank 如何选 → A/B 初始化 → target modules → QLoRA → 4-bit 前向 → 何时输给 Full FT → 多 Adapter 部署

训练故障追问链

模拟路径 Loss 抖动 → 先查数据还是 LR → grad norm → FP16 overflow → 某一 rank NaN → OOM 发生阶段 → activation checkpoint → FSDP/ZeRO → GPU 利用率

项目追问链

模拟路径 为什么选这个模型 → baseline 是什么 → 提升来自哪里 → 消融 → 离线/线上差异 → P99 成本 → 失败实验 → 如果资源减半怎么改

附录 C | 7 / 14 / 30 天刷题路线

7 天冲刺

训练目标 目标：先拿下 S 级问题。

Day 1 基础+优化 (Q1–20) ; Day 2 Transformer 基础 (Q39–47) ; Day 3 KV/GQA/FlashAttention (Q48–55) ; Day 4 LoRA/SFT (Q56–62) ; Day 5 PPO/DPO/GRPO (Q63–68) ; Day 6 分布式+推理 (Q79–95) ; Day 7 手写题+项目追问。

14 天强化

训练目标 目标：每题能承受至少 3 次追问。

每天 7–8 题：上午口述，晚上公式/代码复盘；第 7、14 天只做模拟面试和错题回炉。

30 天完整训练

训练目标 目标：100 题全部口述 + 重点题手写 + 项目打磨。

前 20 天每日 5 题；第 21–25 天做专题串联；第 26–28 天做 3 轮 60 分钟模拟；第 29 天只复盘错题；第 30 天做最终面试脚本。

附录 D | 面试官评分标准：从 40 分回答到 90 分回答

层级	典型表现	示例：FlashAttention
40 分	只会定义/名词	“FlashAttention 更快、更省显存。”
60 分	能解释核心机制	“通过分块和 kernel fusion 减少中间 attention matrix 的显存。”
80 分	能讲数学/硬件/边界	“exact attention，主要 FLOP 阶数不变；关键是 HBM↔SRAM IO、tiling 与 online softmax。”
90+ 分	能连接工程排障与替代方案	“能说明何时收益有限，并区分 FlashAttention、GQA、KV Cache、PagedAttention 分别解决什么瓶颈。”

参考资料与证据索引

证据分级 M- 开头为公开候选人面经，用于判断“近期真实问法与频度”；P-/D- 开头为原始论文或官方文档，用于校正理论与工程事实。面经不是企业官方题库。

- [M-Ali-2026] 阿里大模型算法岗面经（2026-07，候选人公开面经） [原文](#)
- [M-Ali-MHA] 阿里搜推算法工程师面经（2026-08，含 InfoNCE 与手写 MHA） [原文](#)
- [M-Ali-InfoNCE] 阿里搜推面经：InfoNCE、temperature、负采样（2026-08） [原文](#)
- [M-Byte-2026] 字节跳动大模型算法岗面经（2026，PPO/GRPO/DAPO/多模态） [原文](#)
- [M-Byte-Train] 字节跳动大模型算法岗面经（2026-04，FSDP/DDP/LoRA/OOM/Checkpoint） [原文](#)
- [M-SenseTime] 商汤大模型算法应用面经（RAG、ZeRO 等） [原文](#)
- [M-Infra-2025] 2025 春招实习面经汇总（FlashAttention、KV Cache、分布式） [原文](#)
- [P-Transformer] Vaswani et al., Attention Is All You Need [原文](#)
- [P-ResNet] He et al., Deep Residual Learning for Image Recognition [原文](#)
- [P-BN] Ioffe & Szegedy, Batch Normalization [原文](#)
- [P-AdamW] Loshchilov & Hutter, Decoupled Weight Decay Regularization [原文](#)
- [P-LoRA] Hu et al., LoRA: Low-Rank Adaptation of Large Language Models [原文](#)
- [P-DPO] Rafailov et al., Direct Preference Optimization [原文](#)
- [P-GRPO] Shao et al., DeepSeekMath（提出 GRPO） [原文](#)
- [P-FlashAttention] Dao et al., FlashAttention: IO-Aware Exact Attention [原文](#)
- [P-vLLM] Kwon et al., Efficient Memory Management for LLM Serving with PagedAttention [原文](#)
- [D-FSDP] PyTorch FullyShardedDataParallel documentation (updated 2026) [原文](#)
- [P-ViT] Dosovitskiy et al., An Image is Worth 16x16 Words [原文](#)
- [P-DiT] Peebles & Xie, Scalable Diffusion Models with Transformers [原文](#)

— 完 —