

剑指 Quant Offer

金融量化算法岗 · 面试 100 题

Quantitative Research · Financial ML · HFT Algorithms · Derivatives



100 道题 · 10 大模块 · 标准解 · 追问树 · 易错点 · 面试表达

Professional Edition 2026

使用说明：这不是“背答案”的题库

本手册采用《剑指 Offer》式的问题驱动结构，但内容针对 Quantitative Research / Financial ML / Algorithm Developer / Systematic Research 岗位重新设计。每道题不仅给答案，更强调“你为什么这样建模、假设在哪里、如何验证、下一层追问是什么”。

“真题”的口径需要严格：只有公司官方公开 guide/mock interview 明确出现的题，才标注为“官方公开题型”；其余题目是根据当前官方面试说明、岗位能力要求以及量化研究的高频知识结构重构的高可信题型，不冒充某家公司未公开的内部题库。

建议把每题练成两种回答：30 秒版本给出结论与关键假设；3 分钟版本补推导、边界条件、失败模式和工程含义。高级面试真正区分候选人的，通常不是公式数量，而是研究可信度、问题结构化和 debug 能力。

官方题型校准（截至 2026-09-01）

- Jane Street: Quant Trading/Research guide 明确覆盖 probability、expected value、making markets；QR interview 是 trading 与 software engineering 的混合。
- Two Sigma: QR/Modeling 明确覆盖 open-ended data analysis、coding & algorithms、statistics / research domain。
- Citadel: QR 第一轮明确覆盖 programming、research ability、data structures/algorithms、problem solving。
- HRT: Algorithm Developer 公开描述强调 mathematics/statistics/data analysis + C++/Python，并对大量 market/financial data 做 predictive modeling。
- DRW: 当前 ML Quant 岗强调 high-dimensional noisy data、forecasting、现代 ML 与 research-to-production。

推荐学习路径

通用 QR / Financial ML A 概率 → B 统计 → G 研究方法 → D 时序 → E ML → J Coding → F 微观结构 → H 优化 → C 随机过程 → I 衍生品

HFT / Algo Developer A + F + J 优先，再补 B/D/G/E。

Options / Derivatives Quant A + C + I 优先，B/D/H/J 为第二层。

面试评分的五层结构

层级	面试官在听什么	典型失败
1. 定义问题	随机对象、信息集、时间轴、目标函数是否清楚	直接套公式
2. 推导正确	概率/统计/算法步骤是否自治	条件方向、独立性、复杂度出错
3. 假设意识	知道结论依赖哪些假设	把模型当现实
4. 验证意识	会 OOS、ablation、robustness、debug	只报单一分数

5. 工程落地 知道数据、延迟、成本与生产 parity；典型失败是把 notebook 结果直接等同于 live。

目录 / Knowledge Map

模块	题号	核心能力	优先级
A. 概率论、条件概率与期望	01-010	样本空间 · Bayes · 期望 · stopping time	★★★★★
B. 数理统计与统计推断	11-020	MLE · SE · 检验 · multiple testing	★★★★★
C. 随机过程	21-030	Brownian · martingale · OU · Markov/HMM	★★★★☆
D. 时间序列与计量	31-040	平稳 · unit root · GARCH · 异步采样	★★★★★
E. 机器学习与 Financial ML	41-050	baseline · calibration · drift · online debug	★★★★★
F. 市场微观结构	51-060	quote · queue · fill · impact · latency	★★★★☆
G. 数据、回测与研究方法论	61-070	PIT · leakage · cost · walk-forward · lineage	★★★★★
H. 组合、风险与优化	71-080	covariance · shrinkage · risk · optimization	★★★★☆
I. 衍生品与定价	81-090	no-arbitrage · BS · Greeks · IV · hedging	★★★★☆
J. Coding、算法与量化系统	91-100	streaming · top-k · as-of · cache · parity	★★★★★

100 题速查索引

01-50	51-100
001 两枚公平六面骰子的点数和为 10，概率是多少？	051 Bid、Ask、Mid、Spread 分别是什么？为什么 last price 可能不如 mid？
002 抛 3 枚公平硬币，已知至少一个反面，恰好两个正面的概率？	052 什么是 Bid-Ask Bounce？
003 连续抽两张牌：有放回与无放回的本质区别是什么？	053 什么是 Adverse Selection？
004 证明线性期望不要求随机变量独立。	054 Order Book Imbalance 如何定义？为什么不能把它当永恒预测信号？
005 一直抛公平硬币，直到第一次出现 HH，期望抛多少次？	055 Price-Time Priority 是什么？
006 Coupon Collector：集齐 n 种卡片平均需要抽多少次？	056 为什么 Fill Probability 是 execution simulation 的关键？
007 X 与 Y 不相关，是否意味着独立？	057 Market Impact 的 temporary 与 permanent 如何理解？
008 X,Y 独立且服从 $U(0,1)$ ，求 $E[\max(X,Y)]$ 。	058 Tick Size 为什么会改变市场行为？
009 低基准率事件：阳性测试后真正为阳性的后验概率怎么算？	059 什么是 Microprice？为什么可能不同于 Mid？
010 如何构造相同边缘分布、但联合行为完全不同的随机变量？	060 Latency 为什么既是系统问题，也是统计问题？
011 Bernoulli 参数 p 的 MLE 是什么？	061 什么是 Look-Ahead Bias？
012 正态分布均值/方差的 MLE 是什么？为什么样本方差常除以 n-1？	062 什么是 Survivorship Bias？
013 Bias-Variance Tradeoff 如何从预测误差分解理解？	063 Corporate Actions 为什么会把回测搞坏？
014 p-value 到底表示什么？	064 Point-in-Time Data 是什么？
015 测试 10,000 个特征，总会出现显著结果，怎么处理？	065 为什么 transaction cost 不能简单固定减 1bp？
016 为什么普通 OLS t-stat 在金融时间序列里常失真？	066 一个 backtest Sharpe=3，你信吗？第一步做什么？
017 Ridge 与 Lasso 的本质区别？	067 Walk-Forward Validation 怎么做？
018 Bootstrap 为什么不能直接 IID resample 金融时间序列？	068 Alternative Data 有大量 missing values，怎么处理？
019 Mean、Median、Trimmed Mean 在异常值下如何权衡？	069 如何判断 improvement 是真 signal 还是 research overfitting？
020 95% Confidence Interval 的正确频率学解释是什么？	070 一个可复现 Quant Research Experiment 应保存什么？
021 Brownian Motion 的核心性质是什么？	071 推导 Minimum-Variance Portfolio。
022 为什么 Brownian Motion 几乎处处不可微？	072 为什么直接使用 sample covariance matrix 很危险？
023 什么是 Martingale？	073 什么是 Covariance Shrinkage？
024 Optional Stopping Theorem 为什么不能随便套？	074 PCA 在风险模型里是什么意思？
025 几何布朗运动为什么保持价格为正？	075 VaR 与 Expected Shortfall 有什么区别？
026 Ornstein-Uhlenbeck Process 的长期均值是什么？	076 为什么 Volatility Targeting 不等于风险恒定？
027 Poisson Process 的 inter-arrival time 为什么是指数分布？	077 什么是 Marginal Contribution to Risk？
028 给定 Markov transition matrix，如何求 stationary distribution？	078 为什么 Portfolio Optimization 容易产生极端权重？
029 Kalman Filter 的本质是什么？	079 如何把 turnover/transaction-cost penalty 放入优化？
030 HMM 与普通 Markov Chain 的区别？	080 Factor Neutralization 怎么理解？

031 什么叫弱平稳 (weak stationarity) ?	081 Put-Call Parity 是什么? 如何从无套利推导?
032 AR(1) 什么时候平稳? 长期方差和 ACF 是什么?	082 Black-Scholes 的核心假设是什么? 哪些明显不现实?
033 Random Walk 为什么 non-stationary?	083 为什么 Black-Scholes PDE 中真实 drift μ 消失?
034 什么是 Unit Root? ADF test 在检验什么?	084 Delta 是什么? 它是不是“期权上涨概率”?
035 为什么两个独立 Random Walk 回归会产生 Spurious Regression?	085 Gamma 为什么重要?
036 什么是 Cointegration?	086 Vega 是什么? 为什么 vanilla option 通常 Vega>0?
037 Granger Causality 是真正的因果吗?	087 Implied Volatility 如何从期权价格反求?
038 为什么收益自相关低, 但平方收益自相关高?	088 为什么存在 Volatility Smile/Skew?
039 为什么金融时间序列不能随机 train/test split?	089 American 与 European Option 最大区别是什么?
040 Tick data 中两个资产的相关性如何估计? 直接时间戳对齐有什么问题?	090 为什么离散 Delta Hedging 不能完全复制连续理论?
041 训练准确率 99%, 测试 52%, 你首先检查什么?	091 长度 N 的序列, 如何 O(N) 计算 rolling mean?
042 为什么线性模型在金融预测中仍然重要?	092 Streaming 数据中实时维护 median 怎么做?
043 Random Forest 与 Gradient Boosting 的根本区别?	093 十亿行数据只找最大的 1000 个元素, 如何做?
044 Feature scaling 为什么会造成未来信息泄漏?	094 如何实现 event-driven order-book reconstruction?
045 一个 feature 的 IC 很低, 是否一定没有价值?	095 给无序 trade events, 如何检测 timestamp 问题?
046 如何判断分类概率是否 calibrated?	096 SQL 中如何做 As-Of Join?
047 Finance 中为什么 accuracy 往往不是好指标?	097 为什么 NumPy 通常比 Python for-loop 快?
048 什么时候 Transformer 可能优于传统时间序列模型?	098 C++ Quant/HFT 面试为什么常问 cache locality?
049 什么是 Concept Drift?	099 Research code 与 production code 最大区别是什么?
050 模型 offline 很好, 上线立即下降, 如何系统排查?	100 压轴: Backtest 与 Live 表现差异巨大, 如何系统定位?

CHAPTER A

概率论、条件概率与期望

建立不确定性推理的原子能力：样本空间、条件概率、期望、停止时间与依赖结构。

你必须会	你必须能解释	你必须会质疑
样本空间、Bayes、期望递推	独立性/条件概率为什么改变	看似等概率是否真的等概率

001. 两枚公平六面骰子的点数和为 10，概率是多少？

难度 ★☆☆	标签 概率 计数 Jane Street 公开题型	模块 A · 概率论、条件概率与期望
--------	-------------------------------	--------------------

标准解 共有 36 个等概率有序结果；和为 10 的只有 (4,6)、(5,5)、(6,4)，所以 $P(S=10)=3/36=1/12$ 。

推导 / Why 关键不是背 1/12，而是先建立等概率的“原子样本空间”。点数和 2~12 并不等概率：例如和为 7 有 6 种组合，而和为 2 只有 1 种。

追问树

- 如果骰子不是公平的，如何写成卷积？
- 三枚骰子之和的分布如何高效计算？
- 为什么“11 个可能的和”不能直接给出 1/11？

高频错误

- 把可观察结果“点数和”误当成等概率状态。
- 漏掉有序性，把 (4,6) 与 (6,4) 合并。

面试表达 先说“我会在 36 个等概率有序结果上计数”，再给 3 个命中结果。面试官听到这句话，就知道你的样本空间定义是正确的。

002. 抛 3 枚公平硬币，已知至少一个反面，恰好两个正面的概率？

难度 ★☆☆	标签 条件概率 样本空间 Jane Street 公开题型	模块 A · 概率论、条件概率与期望
--------	-----------------------------------	--------------------

标准解 条件“至少一个 T”排除 HHH，剩余 7 个等概率序列；其中 HHT、HTH、THH 满足“恰好两个 H”，故概率为 3/7。

推导 / Why 也可写 $P(A|B)=P(A\cap B)/P(B)=(3/8)/(7/8)=3/7$ 。条件信息不是附注，而是重新定义概率空间。

追问树

- 如果已知“第一枚是反面”，答案是多少？
- 如果已知“至少一个正面”，如何变化？
- 何时条件会破坏原来的独立性？

高频错误

- 直接使用无条件的 3/8。
- 把“至少一个反面”理解成“某个指定位置是反面”。

面试表达 一句话定位：先把条件事件 B 写清楚，再把所有概率都放到 B 里计算。

003. 连续抽两张牌：有放回与无放回的本质区别是什么？

难度 ★☆☆	标签 独立性 条件概率 抽样	模块 A · 概率论、条件概率与期望
--------	--------------------	--------------------

标准解 有放回时第二次分布不受第一次影响，通常独立；无放回时总体组成改变，第二次概率依赖第一次结果。

推导 / Why 例如连续两张梅花：有放回为 $(13/52)^2=1/16$ ；无放回为 $(13/52)*(12/51)$ 。“同边缘分布”与“相互独立”是两个概念。

追问树

- 超几何分布从哪里来？
- 大总体下无放回为什么可近似独立？
- 协方差符号是什么？

高频错误

- 把“每次都从一副牌抽”误认为独立。
- 只说公式，不解释总体状态为什么改变。

面试表达 先回答 dependency structure，再给公式；量化面试更关心你是否能识别依赖。

004. 证明线性期望不要求随机变量独立。

难度 ★★☆☆	标签 期望 indicator trick 证明	模块 A · 概率论、条件概率与期望
---------	------------------------------	--------------------

标准解 对任意可积 X, Y ，都有 $E[X+Y]=E[X]+E[Y]$ ；独立性不是条件。

推导 / Why 离散情形：对联合分布求和， $\sum (x+y)p(x,y)=\sum x p_X(x)+\sum y p_Y(y)$ 。连续情形同理由积分线性得到。它使复杂计数题能令 $X=\sum I_i$ ，然后 $E[X]=\sum P(I_i=1)$ 。

追问树

- 方差的可加性为什么通常需要独立或零协方差？
- 用 indicator 计算 fixed points 的期望。
- 什么时候交换求和与期望需要额外条件？

高频错误

- 把“线性期望”和“方差可加”混为一谈。

面试表达 面试中先明确：“独立只在乘法期望、方差分解等地方出现；期望本身是线性算子。”

005. 一直抛公平硬币，直到第一次出现 HH，期望抛多少次？

难度 ★★☆☆	标签 Stopping time 状态递推 模式重叠	模块 A · 概率论、条件概率与期望
---------	--------------------------------	--------------------

标准解 设 E_0 为当前没有尾随 H， E_1 为当前尾随一个 H。 $E_0=1+0.5E_0+0.5E_1$ ； $E_1=1+0.5*0+0.5E_0$ 。解得 $E_0=6$ 。

推导 / Why 核心是模式有重叠：在状态 H 后再来 T 会回到起点；再来 H 则完成。不能把“HH 概率为 $1/4$ ”简单倒数成 4，因为相邻窗口并不独立。

追问树

- 第一次出现 HT 的期望是多少？
- HHH 呢？
- 如何用自动机/KMP 状态构造一般 pattern 的等待时间？

高频错误

- 把每两个 toss 当成独立 block。
- 忘记 HH 的前缀/后缀重叠。

面试表达 先定义最小充分状态，再写 Bellman 式递推，是最稳的现场方法。

006. Coupon Collector：集齐 n 种卡片平均需要抽多少次？

难度 ★★☆☆	标签 几何分布 调和级数 渐近	模块 A · 概率论、条件概率与期望
---------	---------------------	--------------------

标准解 答案 $E[T]=nH_n=n(1+1/2+\dots+1/n)\approx n(\log n+\gamma)$ 。

推导 / Why 已有 k 种时，下一张是新品种的概率为 $(n-k)/n$ ，等待时间期望 $n/(n-k)$ 。把 $k=0,\dots,n-1$ 的阶段等待时间相加即可。

追问树

- 方差量级是什么？
- 集齐 90% 种类需要多少？
- 非均匀类别概率时怎么改？

高频错误

- 只看最后一张最难等，却忘了把每个阶段相加。

面试表达 强调“把全局 stopping time 拆成 n 个 geometric waiting time”，比直接背 nH_n 更有价值。

007. X 与 Y 不相关，是否意味着独立？

难度 ★☆☆	标签 相关性 依赖 反例	模块 A · 概率论、条件概率与期望
--------	------------------	--------------------

标准解 一般不意味着。例： $X \sim U(-1,1)$ ， $Y=X^2$ 。 Y 完全由 X 决定，但 $\text{Cov}(X,Y)=E[X^3]-E[X]E[X^2]=0$ 。

推导 / Why 零相关只排除了线性依赖。独立则要求联合分布可分解： $p(x,y)=p(x)p(y)$ 。Gaussian 联合分布是重要特例：零相关可推出独立。

追问树

- 为什么联合高斯是特例？
- 哪些统计量能检测非线性依赖？
- rank correlation 与 Pearson 有何差别？

高频错误

- 说“相关系数为 0 就没有关系”。

面试表达 先给反例，再补“jointly Gaussian 情形例外”，回答会更完整。

008. X, Y 独立且服从 $U(0,1)$ ，求 $E[\max(X,Y)]$ 。

难度 ★★☆☆	标签 Order statistics CDF	模块 A · 概率论、条件概率与期望
---------	---------------------------	--------------------

标准解 令 $M=\max(X,Y)$ 。 $P(M \leq z)=z^2$ ，故 $f_M(z)=2z$ ， $E[M]=\int_0^1 2z^2 dz=2/3$ 。

推导 / Why 更一般地， n 个独立 $U(0,1)$ 的最大值 CDF 为 z^n ，均值为 $n/(n+1)$ 。这是 order statistics 的最简单入口。

追问树

- 求 min 的期望。
- 最大值方差是多少？
- 一般分布的最大值 CDF 怎么写？

高频错误

- 直接对 $\max(x,y)$ 二重积分但区域拆分出错。

面试表达 优先从 CDF 做最大/最小值题，往往比直接积分更短。

009. 低基准率事件：阳性测试后真正为阳性的后验概率怎么算？

难度 ★★☆☆	标签 Bayes base rate posterior	模块 A · 概率论、条件概率与期望
---------	----------------------------------	--------------------

标准解 若 prevalence=1%, sensitivity=99%, false-positive=5%, 则
 $P(D|+) = 0.99 \cdot 0.01 / [0.99 \cdot 0.01 + 0.05 \cdot 0.99] \approx 16.7\%$ 。

推导 / Why 即使测试本身很准，极低 base rate 也会让 false positives 占据阳性样本的大部分。金融异常检测、欺诈检测和稀有事件预测都存在同一问题。

追问树

- 若先验从 1% 变 10%，后验怎样变化？
- precision/recall 与 Bayes 的关系？

高频错误

- 忽略先验，直接回答 99%。

面试表达 先写“后验 $\propto$ 似然 $\times$ 先验”，再代数值，是最清楚的表达。

010. 如何构造相同边缘分布、但联合行为完全不同的随机变量？

难度 ★★☆☆	标签 Joint distribution copula 直觉	模块 A · 概率论、条件概率与期望
---------	-----------------------------------	--------------------

标准解 令 $X \sim N(0,1)$ 。取 $Y=X$ 、 $Y=-X$ 、或独立 $Y \sim N(0,1)$ ，三种情形 Y 的边缘分布完全相同，但 Corr 分别为 1、-1、0。

推导 / Why 这说明 marginal information 不足以决定 dependence。风险建模里，相关结构、尾部依赖与 copula 的重要性由此而来。

追问树

- 相同 Pearson correlation 能否仍有不同尾部依赖？
- 为什么极端风险不能只靠相关矩阵？

高频错误

- 只比较均值和方差，忽略联合分布。

面试表达 回答时强调“同 marginals $\neq$ 同 joint”，然后给三个构造，面试表达非常干净。

CHAPTER B

数理统计与统计推断

把“看见效果”升级为“知道效果是否可信”：估计、显著性、稳健标准误与多重检验。

你必须会	你必须能解释	你必须会质疑
MLE、SE、检验、多重比较	统计显著 vs 可复制	标准误假设是否成立

011. Bernoulli 参数 p 的 MLE 是什么？

难度 ★☆☆

标签 MLE | Bernoulli | 一致性

模块 B · 数理统计与统计推断

标准解 对 $x_i \in \{0,1\}$, $\log L(p) = \sum x_i \log p + (n - \sum x_i) \log(1-p)$, 一阶条件给 $\hat{p} = \bar{x}$ 。

推导 / Why 它同时是样本成功率、无偏估计, $\text{Var}(\hat{p}) = p(1-p)/n$; 由 CLT, $\sqrt{n}(\hat{p} - p)$ 渐近正态。

追问树

- MLE 为何具有不变性？
- 边界 $p=0/1$ 时 Fisher information 如何？

高频错误

- 忘记参数域 $p \in [0,1]$ 。

面试表达 把 likelihood、score、一阶条件、统计性质按顺序说完即可。

012. 正态分布均值/方差的 MLE 是什么？为什么样本方差常除以 $n-1$ ？

难度 ★★☆☆

标签 MLE | 无偏性 | 自由度

模块 B · 数理统计与统计推断

标准解 $\hat{\mu} = \bar{x}$; $\sigma^2_{\text{MLE}} = (1/n) \sum (x_i - \bar{x})^2$ 。后者有向下偏差；无偏样本方差用 $1/(n-1)$ 。

推导 / Why 估计 μ 后，残差满足 $\sum (x_i - \bar{x}) = 0$ ，只剩 $n-1$ 个自由方向。MLE 优化 likelihood，不承诺无偏。

追问树

- MLE 方差估计的 bias 是多少？
- 为什么 $n-1$ 修正不等于“更好”在所有 loss 下？

高频错误

- 把 MLE 和 unbiased estimator 当成同一个概念。

面试表达 先明确“MLE 是 n ，无偏估计是 $n-1$ ”，这是该题最关键的分界。

013. Bias-Variance Tradeoff 如何从预测误差分解理解？

难度 ★★☆☆	标签 泛化 正则化 噪声	模块 B · 数理统计与统计推断
---------	------------------	------------------

标准解 在平方损失下，期望测试误差可分为 $\text{irreducible noise} + \text{Bias}^2 + \text{Variance}$ 。模型复杂度通常使 bias 下降、variance 上升。

推导 / Why 金融信噪比低、样本依赖强且分布漂移，variance 往往比通用 benchmark 更危险，所以简单模型和强正则化经常具有竞争力。

追问树

- Bagging 主要降低哪一项？
- Boosting 主要影响什么？
- double descent 如何扩展经典图景？

高频错误

- 把训练误差当泛化误差。

面试表达 最好把“低信噪比下 variance 是主要敌人”说出来，体现量化语境。

014. p-value 到底表示什么？

难度 ★☆☆	标签 假设检验 p-value 解释	模块 B · 数理统计与统计推断
--------	------------------------	------------------

标准解 p-value 是在 H_0 成立条件下，观察到当前统计量或更极端结果的概率；它不是 $P(H_0|\text{data})$ 。

推导 / Why 频率学派把参数视为固定、样本为随机。p-value 小表示数据与 H_0 不相容，不等于效果大、不等于研究可复制，也不等于 H_1 概率高。

追问树

- $p=0.049$ 与 $p=0.051$ 本质差异大吗？
- 统计显著与经济显著如何区分？

高频错误

- 把 0.05 解读为“ H_0 只有 5% 概率为真”。

面试表达 给出条件方向：“ $P(\text{data or more extreme} | H_0)$ ”，可避免最常见反向条件错误。

015. 测试 10,000 个特征，总会出现显著结果，怎么处理？

难度 ★★☆☆

标签 Multiple testing | FDR | 研究过拟合

模块 B · 数理统计与统计推断

标准解 需要控制 family-wise error 或 false discovery rate: Bonferroni/Holm 控制 FWER, Benjamini-Hochberg 控制 FDR; 更重要的是保留 untouched OOS 与独立验证。

推导 / Why 如果每个 null test $\alpha=5\%$, 在全为 null 且近似独立时, 期望会出现约 500 个“显著”结果。量化研究还要记录全部尝试, 而不是只记录成功因子。

追问树

- Bonferroni 为什么保守?
- 相关假设下 BH 需要哪些条件?
- 如何估计 research degrees of freedom?

高频错误

- 只对最终选中的特征做单次 t-test。

面试表达 把 “multiple testing correction + untouched holdout + research log” 作为三层防线。

016. 为什么普通 OLS t-stat 在金融时间序列里常失真？

难度 ★★☆☆

标签 OLS | HAC | 序列相关

模块 B · 数理统计与统计推断

标准解 普通标准误依赖误差独立同方差; 金融数据常有 heteroskedasticity、serial correlation 和 overlapping labels, 使标准误被低估或高估。

推导 / Why 可使用 Newey-West/HAC、cluster-robust SE 或 block bootstrap。重点不是机械换一个标准误, 而是先识别 dependence structure。

追问树

- Newey-West bandwidth 怎么选?
- overlapping k-day returns 的相关结构是什么?

高频错误

- 只看回归系数, 不审查 residual。

面试表达 回答顺序: 假设被破坏 → 标准误为什么错 → 根据依赖结构选择修正。

017. Ridge 与 Lasso 的本质区别？

难度 ★★☆☆	标签 Regularization 高维特征 共线性	模块 B · 数理统计与统计推断
---------	--------------------------------	------------------

标准解 Ridge 加 L2 penalty，连续收缩并擅长稳定高度相关特征；Lasso 加 L1 penalty，可产生稀疏解并做变量选择。

推导 / Why 几何上 L1 约束域有尖角，更容易让最优点落在坐标轴。高度相关特征下 Lasso 可能不稳定地“挑一个”，Ridge 更平滑地共享权重。

追问树

- Elastic Net 为什么适合成组相关特征？
- 标准化为什么重要？

高频错误

- 说“Lasso 一定比 Ridge 更可解释”。

面试表达 量化语境补一句：稳定性往往比稀疏性更重要，因此要做 selection stability。

018. Bootstrap 为什么不能直接 IID resample 金融时间序列？

难度 ★★☆☆	标签 Bootstrap 依赖 block resampling	模块 B · 数理统计与统计推断
---------	--------------------------------------	------------------

标准解 普通 bootstrap 会打乱时间次序并破坏 autocorrelation/volatility clustering。对依赖序列更常用 moving block、circular block 或 stationary bootstrap。

推导 / Why block length 是 bias-variance 权衡：太短保不住依赖，太长有效样本数又太少。

追问树

- 如何 bootstrap Sharpe ratio？
- cluster bootstrap 适合什么面板数据？

高频错误

- 对每日收益逐点随机抽样后声称保留了时间结构。

面试表达 先说明“resampling unit 必须匹配依赖单位”，这句话可泛化到很多数据。

019. Mean、Median、Trimmed Mean 在异常值下如何权衡？

难度 ★☆☆	标签 Robust statistics 异常值	模块 B · 数理统计与统计推断
--------	----------------------------	------------------

标准解 Mean 对极端值敏感，median 的 breakdown point 可达 50%；trimmed mean 在鲁棒性与 Gaussian efficiency 间折中。

推导 / Why 没有“永远最优”的中心估计：若近似正态且无污染，mean 效率高；若 heavy-tailed/outliers 明显，robust estimator 往往更稳。

追问树

- Huber estimator 的直觉？
- winsorization 与 trimming 区别？

高频错误

- 看到 outlier 就无脑删除。

面试表达 重点是先判断数据生成机制，再选择 estimator，而不是按习惯 winsorize。

020. 95% Confidence Interval 的正确频率学解释是什么？

难度 ★★☆☆	标签 置信区间 coverage calibration	模块 B · 数理统计与统计推断
---------	----------------------------------	------------------

标准解 参数在频率学派中是固定的。95% CI 的含义是：若重复采样并重复构造区间，长期约 95% 的区间覆盖真实参数。

推导 / Why 单次实验生成后，区间要么覆盖、要么不覆盖；“参数有 95% 概率位于这个已经生成的区间”是贝叶斯式表述，需要先验才能严谨成立。

追问树

- prediction interval 与 confidence interval 区别？
- bootstrap CI 有哪些形式？

高频错误

- 把 coverage 与 posterior probability 混为一谈。

面试表达 一句话说清“随机的是区间，不是固定参数”，就抓住核心。

CHAPTER C

随机过程

掌握连续时间与隐状态建模语言：Brownian motion、martingale、OU、Poisson、Markov/HMM/Kalman。

你必须会	你必须能解释	你必须会质疑
Markov、martingale、SDE 状态	连续时间直觉	定理条件是否满足

021. Brownian Motion 的核心性质是什么？

难度 ★★☆☆

标签 随机过程 | Brownian Motion

模块 C · 随机过程

标准解 $W_0=0$ ；独立、平稳增量； $W_t - W_s \sim N(0, t-s)$ ；样本路径连续。其 covariance 为 $\text{Cov}(W_s, W_t) = \min(s, t)$ 。

推导 / Why 从增量结构即可得到 $\text{Var}(W_t) = t$ 。它是连续时间随机模型的基准噪声过程，也是 Itô calculus 的基础。

追问树

- 为什么是 Markov process?
- 为什么又是 martingale?
- quadratic variation 是多少?

高频错误

- 把“连续路径”误认为“可微”。

面试表达 按初值、增量分布、独立性、连续性四条定义回答最完整。

022. 为什么 Brownian Motion 几乎处处不可微？

难度 ★★★

标签 尺度分析 | quadratic variation | Itô 直觉

模块 C · 随机过程

标准解 小时间间隔 h 上增量尺度约 $\sqrt{h}$ ，差商尺度约 $\sqrt{h}/h = 1/\sqrt{h}$ ，随 $h \rightarrow 0$ 不稳定，因此不能像平滑函数那样微分。

推导 / Why 更深层地，Brownian path 有非零 quadratic variation，而有限变差光滑路径的二次变差为 0。这导致 Itô 公式多出 $1/2 f''$ 项。

追问树

- $dW^2 = dt$ 的直觉是什么?
- 为什么 ordinary chain rule 失效?

高频错误

- 只说“它很抖”而不给尺度解释。

面试表达 用 $O(\sqrt{h})$ 对 $O(h)$ 的尺度比值，是最短也最有说服力的回答。

023. 什么是 Martingale ?

难度 ★★☆☆	标签 条件期望 公平游戏 过滤	模块 C · 随机过程
---------	---------------------	-------------

标准解 相对 filtration $\mathcal{F}_t$ ，可积过程 X_t 若满足 $E[X_{t+1}|\mathcal{F}_t]=X_t$ （连续时间相应定义），则为 martingale。

推导 / Why 它表达“给定当前全部可用信息，下一步条件均值不变”。martingale 可以高度波动，也不要求独立增量。

追问树

- submartingale/supermartingale?
- $W_t^2 - t$ 为什么是 martingale?

高频错误

- 把 martingale 说成“未来与现在独立”。

面试表达 一定带上 filtration，否则定义不完整。

024. Optional Stopping Theorem 为什么不能随便套？

难度 ★★☆☆	标签 Stopping time martingale 条件	模块 C · 随机过程
---------	------------------------------------	-------------

标准解 $E[M_\tau]=E[M_0]$ 需要额外条件，如 τ 有界、过程有界、或适当的一致可积性。任意 stopping time 下结论可能失败。

推导 / Why 直觉：如果允许无限拖延并利用极端尾部，期望与极限交换可能出问题。经典“翻倍直到赢”的直觉错误就来自忽略尾部和资本约束。

追问树

- 给一个不满足条件的反例思路。
- uniform integrability 为什么有用？

高频错误

- 只要看到 martingale + stopping time 就直接等期望。

面试表达 先声明定理需要 regularity conditions，再讨论具体题满足哪一条。

025. 几何布朗运动为什么保持价格为正？

难度 ★★☆☆	标签 SDE GBM Itô	模块 C · 随机过程
---------	--------------------	-------------

标准解 $dS = \mu S dt + \sigma S dW$ 的解为 $S_t = S_0 \exp[(\mu - \sigma^2/2)t + \sigma W_t]$ ，指数始终为正。

推导 / Why 对 $\log S$ 应用 Itô 公式得到 $d \log S = (\mu - \sigma^2/2)dt + \sigma dW$ ，积分后再指数化。 $\sigma^2/2$ 是 Itô correction。

追问树

- $E[S_t]$ 是什么？
- median path 与 mean path 有何差异？

高频错误

- 忘记 $-\sigma^2/2$ correction。

面试表达 现场推导时从 $f(S) = \log S$ 开始，是标准路径。

026. Ornstein-Uhlenbeck Process 的长期均值是什么？

难度 ★★☆☆	标签 Mean reversion OU SDE	模块 C · 随机过程
---------	------------------------------	-------------

标准解 对 $dX = \theta(\mu - X)dt + \sigma dW$ ，条件均值为 $E[X_t | X_0] = \mu + (X_0 - \mu)e^{-\theta t}$ ， $\theta > 0$ 时长期趋于 μ 。

推导 / Why 显式解还给出长期方差 $\sigma^2/(2\theta)$ 。 $e^{-\theta t}$ 显示 mean-reversion speed；half-life 为 $\ln 2/\theta$ 。

追问树

- 如何离散化成 AR(1)？
- $\theta < 0$ 会怎样？
- 估计 half-life 的陷阱？

高频错误

- 看到均值回归就默认可交易，忽略参数估计和非平稳。

面试表达 把长期均值、速度、长期方差三件事一起说，层次更完整。

027. Poisson Process 的 inter-arrival time 为什么是指数分布？

难度 ★★☆☆	标签 Poisson Exponential memoryless	模块 C · 随机过程
---------	---------------------------------------	-------------

标准解 $P(T>t)=P(N_t=0)=\exp(-\lambda t)$ ，故 $T\sim\text{Exp}(\lambda)$ 。指数分布具有 memoryless property。

推导 / Why 反过来，独立同分布指数等待时间的计数过程就是 homogeneous Poisson process。

追问树

- 叠加两个 Poisson process 会怎样？
- thinning 后速率是多少？

高频错误

- 把 event count 与 waiting time 分布混淆。

面试表达 用 survival function 一步推导最简洁。

028. 给定 Markov transition matrix，如何求 stationary distribution？

难度 ★★☆☆	标签 Markov chain stationary ergodicity	模块 C · 随机过程
---------	---	-------------

标准解 求行向量 π 满足 $\pi P = \pi$ 、 $\sum \pi_i = 1$ 、 $\pi_i \geq 0$ 。有限不可约链必有唯一 stationary distribution；若再非周期，则分布从任意初值收敛到它。

推导 / Why “存在/唯一”和“从任意初态收敛”是不同层次：aperiodicity 主要影响收敛行为。

追问树

- reversible chain 与 detailed balance？
- eigenvalue 1 的意义？

高频错误

- 把 stationary distribution 与某一步当前 distribution 混为一谈。

面试表达 回答时分开说 existence、uniqueness、convergence 三个问题。

029. Kalman Filter 的本质是什么？

难度 ★★★	标签 State space Bayesian filtering 线性高斯	模块 C · 随机过程
--------	--	-------------

标准解 在线性高斯状态空间模型下，Kalman filter 递归维护 latent state 的条件均值与协方差：先 prediction，再用 observation innovation update。

推导 / Why Kalman gain $K = P^- - C^T(CP^- - C^T + R)^{-1}$ 本质是在模型预测不确定性与观测噪声之间做权衡。R 大则更信模型， P^- 大则更信新观测。

追问树

- innovation 应满足什么性质？
- EKF/UKF 为什么出现？

高频错误

- 只背矩阵公式，不解释 uncertainty weighting。

面试表达 把它讲成“在线 Bayesian Gaussian posterior update”，比背公式更高级。

030. HMM 与普通 Markov Chain 的区别？

难度 ★★☆☆	标签 HMM latent state EM	模块 C · 随机过程
---------	----------------------------	-------------

标准解 Markov Chain 的状态本身可观测；HMM 的状态 Z_t 隐藏，观测 X_t 通过 emission distribution 由 Z_t 生成。

推导 / Why 典型问题：filtering/smoothing 用 forward-backward，最可能状态路径用 Viterbi，参数学习可用 Baum-Welch/EM。

追问树

- regime-switching model 与 HMM 的关系？
- identifiability 有什么问题？

高频错误

- 把 Viterbi 与 forward-backward 的目标混淆。

面试表达 先画“latent state → observation”的图景，再说三类算法。

CHAPTER D

时间序列与计量

处理量化数据最根本的时间依赖、非平稳、波动聚类与异步采样。

你必须会	你必须能解释	你必须会质疑
平稳、unit root、ACF、GARCH	时间依赖与异步性	回归是否伪关系

031. 什么叫弱平稳 (weak stationarity) ?

难度 ★☆☆	标签 时间序列 stationarity	模块 D · 时间序列与计量
--------	------------------------	----------------

标准解 均值 $E[X_t] = \mu$ 不随时间变；方差有限且恒定； $\text{Cov}(X_t, X_{t-k})$ 只依赖 lag k ，不依赖绝对时间 t 。

推导 / Why 弱平稳只约束一、二阶矩；严格平稳要求任意有限维联合分布对时间平移不变。高斯过程中二者关系更紧。

追问树

- 严格平稳一定弱平稳吗？
- 为什么趋势会破坏平稳？

高频错误

- 只说“均值方差不变”，漏掉自协方差结构。

面试表达 定义题要完整列三条，并顺手区分 strict stationarity。

032. AR(1) 什么时候平稳？长期方差和 ACF 是什么？

难度 ★★☆☆	标签 AR(1) ACF 稳定性	模块 D · 时间序列与计量
---------	----------------------	----------------

标准解 $X_t = \phi X_{t-1} + \varepsilon_t$ 在 $|\phi| < 1$ 时协方差平稳；若 $\text{Var}(\varepsilon) = \sigma^2$ ，则 $\text{Var}(X) = \sigma^2 / (1 - \phi^2)$ ， $\rho(k) = \phi^k$ 。

推导 / Why 递归展开 $X_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$ ，只有 $|\phi| < 1$ 时平方可和，才得到稳定的无限 MA 表示。

追问树

- $\phi \approx 1$ 时 finite sample 有什么问题？
- $\phi < 0$ 的 ACF 形状？

高频错误

- 把 $\phi \leq 1$ 当作条件，漏掉负数绝对值。

面试表达 用 $\text{MA}(\infty)$ 展开解释 $|\phi| < 1$ ，比只背条件更扎实。

033. Random Walk 为什么 non-stationary ?

难度 ★☆☆	标签 Unit root 随机游走	模块 D · 时间序列与计量
--------	---------------------	----------------

标准解 $X_t = X_0 + \sum_{i=1}^t \epsilon_i$, 因此 $\text{Var}(X_t) = t\sigma^2$ 随 t 增长, 自协方差也依赖绝对时间, 不满足弱平稳。

推导 / Why 但一阶差分 $\Delta X_t = \epsilon_t$ 可以是平稳的, 所以 random walk 是 $I(1)$ 的典型例子。

追问树

- 带 drift 的 random walk?
- 为什么 level 回归容易伪回归?

高频错误

- 只说“它有趋势”, 但随机游走并不一定有确定性趋势。

面试表达 用方差随时间增长这个一行证明最直接。

034. 什么是 Unit Root ? ADF test 在检验什么 ?

难度 ★★☆☆	标签 ADF unit root 检验方向	模块 D · 时间序列与计量
---------	---------------------------	----------------

标准解 $AR(1)$ 中 $\phi=1$ 是 unit root。ADF 的原假设 H_0 是存在 unit root (非平稳); 只有显著拒绝 H_0 才支持平稳/无 unit root。

推导 / Why ADF 通过加入滞后差分吸收高阶序列相关; 趋势项/截距规格选择会影响临界值和结论。

追问树

- KPSS 与 ADF 的原假设为何相反?
- 结构突变为什么会影响 unit-root test?

高频错误

- p-value 大就宣布“平稳”。

面试表达 先明确 H_0 的方向, 是这题最重要的防错点。

035. 为什么两个独立 Random Walk 回归会产生 Spurious Regression ?

难度 ★★☆☆	标签 伪回归 非平稳 t-stat	模块 D · 时间序列与计量
---------	-----------------------	----------------

标准解 非平稳 level 含有持续随机趋势，使标准 OLS 的经典渐近分布失效；即使两过程独立，也可能出现高 R^2 和显著 t-stat。

推导 / Why 这不是“数据太少”，而是 stochastic trend 让回归残差结构不满足标准假设。差分或 cointegration framework 才是正确处理方向。

追问树

- Durbin-Watson 会表现怎样？
- 为什么增加样本反而不自动解决？

高频错误

- 看到高 R^2 就相信经济关系。

面试表达 明确说“高 R^2 可以纯粹来自共同的积分阶数”，体现计量意识。

036. 什么是 Cointegration ?

难度 ★★☆☆	标签 Cointegration ECM 长期关系	模块 D · 时间序列与计量
---------	-------------------------------	----------------

标准解 若 X_t, Y_t 各自 $I(1)$ ，但存在 β 使 $Y_t - \beta X_t$ 为 $I(0)$ ，则二者 cointegrated。

推导 / Why 它描述长期均衡误差是平稳的；误差修正模型 ECM 将短期变化与偏离长期均衡的误差项结合。高相关不等于 cointegration。

追问树

- Engle-Granger 两步法？
- Johansen 适合什么场景？

高频错误

- 用 correlation 代替 cointegration test。

面试表达 回答里必须出现“非平稳序列的某个线性组合平稳”。

037. Granger Causality 是真正的因果吗？

难度 ★★☆☆	标签 预测因果 时序 混杂	模块 D · 时间序列与计量
---------	-------------------	----------------

标准解 不是结构因果。它检验的是：在已有 Y 的过去信息后，加入 X 的过去是否显著提高对 Y 的预测。

推导 / Why 共同驱动因素、时间戳错位、异步采样和遗漏变量都可能制造 Granger relation。它是 incremental predictive information，不是干预意义的因果。

追问树

- VAR 中如何做检验？
- instantaneous causality 又是什么？

高频错误

- 把 “Granger causes” 按日常语言直接解释成因果。

面试表达 最好主动加一句 “prediction $\neq$ intervention”。

038. 为什么收益自相关低，但平方收益自相关高？

难度 ★★☆☆	标签 Volatility clustering GARCH	模块 D · 时间序列与计量
---------	----------------------------------	----------------

标准解 市场方向可能接近不可预测，但波动强度具有持续性。于是 $\text{Corr}(r_t, r_{t-k})$ 小，而 $\text{Corr}(r_t^2, r_{t-k}^2)$ 显著。

推导 / Why GARCH(1,1): $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$ ，用过去 shock 与过去条件方差描述 volatility persistence。

追问树

- $\alpha + \beta$ 接近 1 意味着什么？
- 为何 leverage effect 需要 EGARCH/GJR？

高频错误

- 把 “收益不可预测” 误解为 “波动也不可预测”。

面试表达 先拆 direction 与 magnitude 两类可预测性。

039. 为什么金融时间序列不能随机 train/test split ?

难度 ★☆☆	标签 时间泄漏 walk-forward validation	模块 D · 时间序列与计量
--------	-------------------------------------	----------------

标准解 随机切分会让未来样本进入训练、过去样本进入测试，破坏实际部署时“只能用过去预测未来”的信息约束；overlapping labels/rolling features 时泄漏更严重。

推导 / Why 应使用 chronological split、rolling/expanding walk-forward；若标签跨时间区间，还要考虑 purge/embargo 思想以减少区间重叠。

追问树

- validation set 如何滚动？
- 什么时候 random split 仍可用于某些 cross-sectional 问题？

高频错误

- “模型没直接看到 test label，所以没有 leakage”。

面试表达 先画时间轴，任何 split 设计都回到 information availability。

040. Tick data 中两个资产的相关性如何估计？直接时间戳对齐有什么问题？

难度 ★★★	标签 异步数据 Epps effect sampling	模块 D · 时间序列与计量
--------	----------------------------------	----------------

标准解 高频成交异步，直接按事件——对齐会混入 stale prices 和人工 lead-lag。常见处理包括 time bars、previous-tick interpolation、refresh time 等。

推导 / Why 采样过细时 microstructure noise 与异步性使相关性向低频不同，形成 Epps effect；采样过粗又丢失短时动态。频率选择本身就是 bias-variance tradeoff。

追问树

- midquote 与 trade price 哪个更适合？
- Hayashi-Yoshida estimator 的思想？

高频错误

- 把“没有同一毫秒成交”当 missing value 随便填 0。

面试表达 先指出 asynchronous observations，再讨论同步化方法及其偏差。

CHAPTER E

机器学习与 Financial ML

围绕低信噪比、漂移和 research-to-production，理解模型选择、校准与线上诊断。

你必须会	你必须能解释	你必须会质疑
baseline、校准、drift、debug	模型复杂度何时值得	offline 分数是否可信

041. 训练准确率 99%，测试 52%，你首先检查什么？

难度 ★★☆☆	标签 Debugging leakage overfit	模块 E · 机器学习与 Financial ML
---------	----------------------------------	---------------------------

标准解 第一反应应是实验审计：数据泄漏、split、target leakage、preprocessing leakage、重复样本、标签定义，再考虑模型容量/正则化。

推导 / Why 量化研究中巨大 train-test gap 经常不是“神经网络太大”这么简单，而是时间结构或数据管道出错。先验证实验可信度，再优化模型。

追问树

- 如何构造 leakage checklist?
- 如何定位重复样本污染?

高频错误

- 一上来调 dropout、learning rate。

面试表达 面试官通常喜欢“先怀疑数据和评估，再怀疑模型”的顺序。

042. 为什么线性模型在金融预测中仍然重要？

难度 ★★☆☆	标签 Linear model inductive bias 鲁棒性	模块 E · 机器学习与 Financial ML
---------	--	---------------------------

标准解 低参数、低方差、易正则、易解释、训练快、监控简单，对低信噪比和强漂移环境非常有吸引力。

推导 / Why 复杂模型只有在足够数据、稳定非线性和可控部署约束下才应获得复杂度预算。baseline 的价值不仅是分数，也用于检测“复杂模型究竟学到了什么”。

追问树

- 何时非线性模型更合理?
- 如何用 residual analysis 判断线性不足?

高频错误

- 把模型复杂度与研究成熟度画等号。

面试表达 先讲 statistical efficiency，再讲 engineering simplicity。

043. Random Forest 与 Gradient Boosting 的根本区别？

难度 ★★☆☆	标签 Tree ensemble bagging boosting	模块 E · 机器学习与 Financial ML
---------	---------------------------------------	---------------------------

标准解 RF 通过 bootstrap + feature randomness 并行训练多棵树，主要降低 variance；GBDT 顺序拟合当前 residual/negative gradient，逐步降低 bias。

推导 / Why RF 相对稳健、易并行；boosting 更容易达到强预测性能，但对 learning rate、tree depth、early stopping 更敏感。

追问树

- XGBoost 的二阶近似？
- 为什么 bagging 需要低相关基学习器？

高频错误

- 说“RF 防过拟合，GBDT 会过拟合”这种绝对化。

面试表达 用“parallel variance reduction vs sequential residual fitting”概括。

044. Feature scaling 为什么会造成未来信息泄漏？

难度 ★☆☆	标签 Preprocessing pipeline leakage	模块 E · 机器学习与 Financial ML
--------	---------------------------------------	---------------------------

标准解 如果先在全量数据上 fit mean/std、PCA、imputer、winsorization threshold，再切 train/test，就把 test/future 的分布统计注入训练过程。

推导 / Why 正确做法是所有可学习预处理只在 train fit，然后冻结用于 validation/test；rolling/live 环境还要保证 fit window 不越过时点。

追问树

- cross-validation 中 scaler 应放哪里？
- quantile transform 有何额外风险？

高频错误

- 认为“标准化没用 label，所以不算 leakage”。

面试表达 把 preprocessing 当模型的一部分进行 versioning 与 fit。

045. 一个 feature 的 IC 很低，是否一定没有价值？

难度 ★★☆☆	标签 Signal evaluation interaction nonlinearity	模块 E · 机器学习与 Financial ML
---------	---	---------------------------

标准解 不一定。单变量线性相关可能低，但特征可能只在特定 regime、尾部、非线性区间或与其他特征交互时有用。

推导 / Why 同时也要警惕反方向：高 in-sample IC 可能来自 leakage/overfit。应做 rank IC、conditional analysis、mutual information、ablation、OOS utility 等多视角评估。

追问树

- IC stability 如何看？
- 横截面 IC 与时序相关如何区分？

高频错误

- 把单个 Pearson correlation 当最终 feature verdict。

面试表达 回答“低 IC 只是低线性边际关系，不等于低条件/联合信息量”。

046. 如何判断分类概率是否 calibrated？

难度 ★★☆☆	标签 Calibration Brier reliability	模块 E · 机器学习与 Financial ML
---------	--------------------------------------	---------------------------

标准解 把预测概率分桶，看预测 0.7 的样本是否约 70% 为正；可用 reliability diagram、Brier score、ECE。

推导 / Why 若排序能力好但 calibration 差，可用 Platt scaling、isotonic regression、temperature scaling 等后处理；校准必须在独立 validation 上做。

追问树

- AUC 很高但 calibration 很差可能吗？
- Brier score 如何分解？

高频错误

- 把 classification accuracy 当 calibration。

面试表达 先明确 discrimination 与 calibration 是两个维度。

047. Finance 中为什么 accuracy 往往不是好指标？

难度 ★☆☆	标签 Imbalanced data metric utility	模块 E · 机器学习与 Financial ML
--------	---------------------------------------	---------------------------

标准解 类别不平衡时 accuracy 可被 majority class 轻易“刷高”；更关键的是业务损失/收益通常不对称，分类对错的代价并不相同。

推导 / Why 应根据任务选 PR-AUC、log loss、Brier、rank metrics、cost-sensitive metric 或更贴近预测任务的 utility proxy。

追问树

- 何时 ROC-AUC 会误导？
- 阈值选择如何依赖成本矩阵？

高频错误

- 默认用 accuracy 比所有模型。

面试表达 先问“错误的代价是否对称、基准率多少”，再选 metric。

048. 什么时候 Transformer 可能优于传统时间序列模型？

难度 ★★★	标签 Transformer 长序列 多变量	模块 E · 机器学习与 Financial ML
--------	----------------------------	---------------------------

标准解 当数据规模足够、存在长程依赖、多变量/多模态交互强，且 latency/compute 允许时，attention 模型可能有优势。

推导 / Why 但它也带来参数量、过拟合、非平稳、显存、部署延迟和解释性成本。应与 linear/GBDT/RNN/state-space 等强基线在严格 walk-forward 上比较。

追问树

- 因果 masking 如何做？
- positional encoding 对 irregular time 有何问题？
- context length 增长的成本？

高频错误

- “Transformer 更先进，所以一定更好”。

面试表达 面试官更喜欢条件化判断：数据、结构、预算满足什么条件时值得用。

049. 什么是 Concept Drift ?

难度 ★★☆☆	标签 Distribution shift drift monitoring	模块 E · 机器学习与 Financial ML
---------	--	---------------------------

标准解 可区分 $P(X)$ 改变的 covariate shift、 $P(Y)$ 改变的 label shift，以及更关键的 $P(Y|X)$ 改变，即 concept drift。

推导 / Why 金融环境制度、参与者、微观结构和宏观 regime 都可让关系发生漂移。监控不仅看 feature drift，也要看 residual、calibration 与 segment performance。

追问树

- 如何区分 covariate shift 和 concept drift?
- retraining cadence 怎么决定?

高频错误

- 只监控输入均值方差。

面试表达 用概率分布分解 $P(X,Y)=P(Y|X)P(X)$ 回答最清楚。

050. 模型 offline 很好，上线立即下降，如何系统排查？

难度 ★★☆☆	标签 Research-to-production debug MLOps	模块 E · 机器学习与 Financial ML
---------	---	---------------------------

标准解 按 Data→Feature→Model→Inference→Evaluation→Environment 分层核对：timestamp、schema、null、feature version、checkpoint、feature order、precision、latency、online metric 定义。

推导 / Why 最好做 same-input parity test：把同一批原始事件同时送入 research pipeline 与 production pipeline，逐层比较中间产物，定位第一处分叉。

追问树

- 如何设计 shadow deployment?
- 如何监控 feature freshness?

高频错误

- 直接归因于“市场 regime 变了”。

面试表达 先排除实现差异，再讨论 distribution shift。

CHAPTER F

市场微观结构

理解盘口、成交、队列、adverse selection、execution 与 latency 对研究结果的约束。

你必须会	你必须能解释	你必须会质疑
quote/order/queue/latency	成交与可观察状态差异	simulation 是否过度乐观

051. Bid、Ask、Mid、Spread 分别是什么？为什么 last price 可能不如 mid？

难度 ★☆☆	标签 Microstructure quote price	模块 F · 市场微观结构
--------	-----------------------------------	---------------

标准解 $\text{Mid} = (\text{Bid} + \text{Ask}) / 2$, $\text{Spread} = \text{Ask} - \text{Bid}$ 。last trade 可能 stale 且受 bid-ask bounce 影响；mid 更接近当前双边报价状态，但也不代表可无成本成交。

推导 / Why 进一步可区分 quoted spread、effective spread 与 realized spread，它们对应不同微观结构含义。

追问树

- locked/crossed market 怎么理解？
- mid 在单边盘口很薄时有什么问题？

高频错误

- 把 mid 当作无摩擦可成交价格。

面试表达 先把四个定义说清，再强调 quote state 与 trade print 的信息差。

052. 什么是 Bid-Ask Bounce？

难度 ★★☆☆	标签 Microstructure noise 短期自相关	模块 F · 市场微观结构
---------	---------------------------------	---------------

标准解 即使 latent value 不变，交易价也可能在 bid 与 ask 间交替，制造机械的高频价格变化和短期负自相关。

推导 / Why 因此用 trade-to-trade return 估计极短周期波动/相关性会被微观结构噪声污染，midquote return 往往更适合某些研究问题。

追问树

- Roll spread estimator 的直觉？
- 采样频率升高为什么噪声占比更大？

高频错误

- 把每个价格跳动都解释成基本面信息。

面试表达 强调 “observed trade price = latent price + microstructure component”。

053. 什么是 Adverse Selection ?

难度 ★★☆☆	标签 Conditional probability information microstructure	模块 F · 市场微观结构
---------	---	---------------

标准解 成交事件本身可能携带对手方信息，因此成交条件下的未来价格分布可能不同于无条件分布： $P(\text{future} | \text{trade}) \neq P(\text{future})$ 。

推导 / Why 这解释了为什么仅用当前 mid/spread 评估被动报价风险是不够的；需要看 order flow、trade direction、state transition 等条件信息。

追问树

- 如何从 realized spread 看 adverse selection?
- 为什么大单/快单可能更有信息?

高频错误

- 把所有成交对手都视为随机无信息流。

面试表达 用 Bayes/conditional distribution 语言描述，比只说“被聪明钱打”更专业。

054. Order Book Imbalance 如何定义？为什么不能把它当永恒预测信号？

难度 ★★☆☆	标签 LOB imbalance state feature	模块 F · 市场微观结构
---------	------------------------------------	---------------

标准解 简单一档 imbalance 可写 $I = (V_{\text{bid}} - V_{\text{ask}}) / (V_{\text{bid}} + V_{\text{ask}})$ 。它只是 state summary，预测关系受 cancellation、hidden liquidity、tick size、horizon 和事件类型影响。

推导 / Why 更稳妥研究会比较多档 depth、queue changes、event-time dynamics，并做跨日/跨品种/跨 regime 的 OOS 稳定性检验。

追问树

- 多档 imbalance 怎么聚合?
- event time 与 clock time 差别?

高频错误

- 把某篇论文里的单一公式直接当通用 alpha。

面试表达 面试题答“定义 + 条件化 + 验证”，避免把 feature 讲成策略。

055. Price-Time Priority 是什么？

难度 ★☆☆	标签 Matching engine queue priority	模块 F · 市场微观结构
--------	---------------------------------------	---------------

标准解 通常先按价格优先，再在同价位按进入时间排序。因而同一 best price 上，不同订单的 queue position 会影响 fill probability。

推导 / Why 研究中只看到 top-of-book price/size 不足以重构个人订单成交，需要追踪 order arrivals、cancellations、executions 与自身队列位置。

追问树

- pro-rata matching 与 price-time 有何区别？
- replace order 会不会丢 priority？

高频错误

- 把“价格触及”当“自己的订单一定成交”。

面试表达 把 matching rule 与 simulation bias 联系起来。

056. 为什么 Fill Probability 是 execution simulation 的关键？

难度 ★★☆☆	标签 Execution model queue simulation bias	模块 F · 市场微观结构
---------	---	---------------

标准解 价格到达你的限价不代表订单必然成交；前方 queue、trade size、cancel、latency、partial fill 都决定实际 fill。

推导 / Why 若回测假设“touch=full fill”，会系统性高估 execution quality。研究应明确 fill model 的可观察状态、假设与校准方式。

追问树

- 如何用历史 order-level data 校准？
- 没有 L3 数据时如何做敏感性分析？

高频错误

- 用 mid-price signal 回测，却忽略 execution layer。

面试表达 先指出“price path $\neq$ fill path”。

057. Market Impact 的 temporary 与 permanent 如何理解？

难度 ★★☆☆	标签 Impact execution cost information	模块 F · 市场微观结构
---------	--	---------------

标准解 temporary impact 随交易结束后部分回撤，更多反映流动性供需；permanent component 反映信息或持久的价格重估。

推导 / Why 真实估计很难，因为自然价格变化与自家交易影响纠缠，存在 selection bias；需要控制订单条件、市场状态及 post-trade horizon。

追问树

- 平方根 impact law 是经验规律还是定律？
- 怎么区分 impact 与 alpha？

高频错误

- 把所有 post-trade move 都归因于自己的交易。

面试表达 答题重点是 identification problem，而不是背一个 impact 公式。

058. Tick Size 为什么会改变市场行为？

难度 ★★☆☆	标签 Tick size queue competition liquidity	模块 F · 市场微观结构
---------	--	---------------

标准解 tick 大时 spread 更容易被最小跳动约束、同价位 queue 竞争更强；tick 小时价格改善更细、quote 更新可能更频繁。

推导 / Why 因此 feature 分布、queue dynamics、spread statistics 和模型参数都可能随 tick regime 改变，跨市场迁移要重新校准。

追问树

- tick/price ratio 为什么更重要？
- tick change 的 natural experiment 如何研究？

高频错误

- 认为盘口模型只需做 price normalization 就可跨品种复用。

面试表达 从离散价格网格对行为的约束讲起。

059. 什么是 Microprice ? 为什么可能不同于 Mid ?

难度 ★★☆☆	标签 Microprice imbalance short-horizon state	模块 F · 市场微观结构
---------	---	---------------

标准解 常见定义用对侧 depth 对 bid/ask 加权，例如 $(Ask * V_{bid} + Bid * V_{ask}) / (V_{bid} + V_{ask})$ 。盘口不平衡时会偏离简单 mid。

推导 / Why 它表达“当前双边 depth 对短期下一步价格状态的非对称性”的一种启发式 summary，并非普适 fair value。

追问树

- 为何权重要用对侧 volume?
- 如何扩展到多档 order book?

高频错误

- 把 microprice 当确定的未来价格。

面试表达 说清它是 state-dependent estimator，而不是无套利价格。

060. Latency 为什么既是系统问题，也是统计问题？

难度 ★★☆☆	标签 Latency signal decay distribution	模块 F · 市场微观结构
---------	--	---------------

标准解 模型基于 X_t 做出决策，但实际作用于市场是 $t+\Delta$ ； Δ 越大，state 可能变化、queue 可能重排、signal 可能衰减，因而 $P(Y|X, \Delta)$ 也变化。

推导 / Why 所以 backtest 应使用 end-to-end latency distribution，而非只给固定延迟；研究模型和系统性能要联合评估。

追问树

- 如何测 signal half-life?
- 随机 latency jitter 怎么模拟?

高频错误

- 把 latency 仅视为工程 SLA，与模型独立。

面试表达 一句话：“latency changes the conditioning information set.”

CHAPTER G

数据、回测与研究方法论

最重要的一章：时间戳、PIT、survivorship、cost model、walk-forward、研究过拟合与可复现。

你必须会	你必须能解释	你必须会质疑
PIT、walk-forward、cost、lineage	真实信息集	任何异常好结果

061. 什么是 Look-Ahead Bias ?

难度 ★☆☆	标签 Backtest leakage timestamp	模块 G · 数据、回测与研究方法论
--------	-----------------------------------	--------------------

标准解 在历史时点 t 的决策中使用了实际只能在 t 之后获得的信息。它可以来自 label、数据发布时间、修订值、全样本预处理或错误对齐。

推导 / Why 防线是 point-in-time feature construction：每个 feature 都应有 event time、available time/knowledge time，回放时只允许 $\text{available_time} \leq \text{decision_time}$ 。

追问树

- 财报数据发布日期与报告期末的区别？
- 延迟 vendor feed 怎么处理？

高频错误

- 用数据行上的“日期”代替真正可获得时间。

面试表达 问自己：这一列在历史那一刻真的已经知道了吗？

062. 什么是 Survivorship Bias ?

难度 ★☆☆	标签 Universe delisting 历史数据	模块 G · 数据、回测与研究方法论
--------	--------------------------------	--------------------

标准解 若用今天仍存在的资产列表回看历史，就会系统性遗漏退市、破产、并购等消失样本，使过去的可选 universe 被“幸存者”污染。

推导 / Why 正确回测需要 point-in-time membership、delisting returns、symbol mapping 等历史主数据。

追问树

- 指数成分股回测如何避免？
- 基金数据库中的 survivorship bias？

高频错误

- 认为 price series 完整就等于 universe 完整。

面试表达 先区分“历史数据”与“历史当时可投资集合”。

063. Corporate Actions 为什么会把回测搞坏？

难度 ★★☆☆	标签 Adjusted data split dividend	模块 G · 数据、回测与研究方法论
---------	-------------------------------------	--------------------

标准解 split、dividend、merger、spin-off、symbol change 会改变价格/股数/现金流。若不按研究目标正确调整，收益、volume、position accounting 都会出现假跳变。

推导 / Why 例如 2-for-1 split 的原始价格约减半，但这不是 -50% 经济损失。应明确使用 raw、price-adjusted 还是 total-return series。

追问树

- volume 如何随 split 调整？
- dividend 在 close-to-close return 中怎么处理？

高频错误

- 只调整价格，不调整份额/volume。

面试表达 先明确“研究变量的经济含义”，再选 adjustment convention。

064. Point-in-Time Data 是什么？

难度 ★★☆☆	标签 PIT revision data lineage	模块 G · 数据、回测与研究方法论
---------	----------------------------------	--------------------

标准解 指在历史时点真正可获得的那一版数据，而不是今天数据库回填/修订后的最终历史。

推导 / Why 宏观数据、基本面、评级、指数成分等都可能 revision。理想数据模型至少区分 event/effective time 与 knowledge/ingestion time，实现 bitemporal lineage。

追问树

- vintage data 为什么重要？
- 如何存储 restatement？

高频错误

- 直接用“最新数据库的历史列”。

面试表达 量化数据工程的核心：事实发生时间与我们知道事实的时间是两条轴。

065. 为什么 transaction cost 不能简单固定减 1bp ?

难度 ★★☆☆	标签 Cost model spread impact	模块 G · 数据、回测与研究方法论
---------	---------------------------------	--------------------

标准解 真实成本依赖 spread、size、liquidity、volatility、participation、latency、execution style 和 market state；固定常数只适合粗略 stress baseline。

推导 / Why 更专业做法是将 quoted/effective spread、fees、slippage、impact 分层建模，并做参数敏感性测试。

追问树

- cost model 应如何 OOS 校准？
- 为什么 turnover 不是成本的充分统计量？

高频错误

- 把 cost 当模型外的固定后处理项。

面试表达 一句话：“cost model itself is a predictive model.”

066. 一个 backtest Sharpe=3，你信吗？第一步做什么？

难度 ★★★	标签 Research skepticism audit Sharpe	模块 G · 数据、回测与研究方法论
--------	---	--------------------

标准解 先审计，不先兴奋：leakage、timestamp、costs、multiple testing、survivorship、overlap、concentration、regime、capacity、implementation bug。

推导 / Why 随后做 OOS、subperiod、universe、parameter perturbation、feature ablation、placebo、独立复现。极高结果首先提高“数据/研究错误”的先验概率。

追问树

- Sharpe 的 standard error 如何估？
- 非正态/自相关下 Sharpe inference？

高频错误

- 只做一次 train/test split 就宣布可复制。

面试表达 面试官在听的是研究品格：异常好结果应触发更严格审计。

067. Walk-Forward Validation 怎么做？

难度 ★★☆☆	标签 OOS rolling expanding	模块 G · 数据、回测与研究方法论
---------	------------------------------	--------------------

标准解 保持严格时间顺序：用过去训练、紧接着的未来验证；可 expanding window 或 fixed rolling window，多个 period 连续滚动。

推导 / Why hyperparameter tuning 也必须嵌套在当期训练窗口内，不能用最终 test period 反复调参。样本重叠时应额外处理 purge/embargo。

追问树

- rolling vs expanding 何时选？
- regime drift 下窗口多长？

高频错误

- 每次都看 test 再改模型，导致 test 变训练集。

面试表达 画一条时间轴，比口头描述更不容易错。

068. Alternative Data 有大量 missing values，怎么处理？

难度 ★★☆☆	标签 Missingness MNAR 数据质量	模块 G · 数据、回测与研究方法论
---------	------------------------------	--------------------

标准解 先判断 missing mechanism 和业务过程：MCAR/MAR/MNAR。缺失可能本身携带信息，不能默认 fillna(0)；更不能未来值回填。

推导 / Why 可增加 missing indicator、按可获得历史做 forward-fill、模型化缺失、分群处理，并检查 vendor coverage 变化是否制造伪 signal。

追问树

- forward-fill 最大允许间隔？
- coverage expansion 如何造成 backtest bias？

高频错误

- 缺失=0、缺失=均值的机械处理。

面试表达 先问“为什么缺失”，再问“怎么填”。

069. 如何判断 improvement 是真 signal 还是 research overfitting ?

难度 ★★★	标签 OOS ablation robustness	模块 G · 数据、回测与研究方法论
--------	--------------------------------	--------------------

标准解 使用 untouched holdout、walk-forward、parameter stability、subsample/universe/regime checks、multiple-testing control、ablation、placebo、独立实现。

推导 / Why 一个稳健 signal 应对合理的细节扰动“渐变”而非“悬崖式消失”。同时要记录所有实验尝试，避免只看赢家。

追问树

- deflated Sharpe 的思想？
- 怎样设计 placebo feature？

高频错误

- 通过更多调参把 holdout 调好。

面试表达 把“可证伪性”和“稳定性”作为研究质量标准。

070. 一个可复现 Quant Research Experiment 应保存什么？

难度 ★★☆☆	标签 Reproducibility lineage MLOps	模块 G · 数据、回测与研究方法论
---------	--------------------------------------	--------------------

标准解 至少保存 dataset/universe/version、timestamps、feature code commit、label、split、model config、seed、cost model、metrics、environment、artifacts。

推导 / Why 更成熟系统应做到从任何结果反向追踪到原始数据快照与代码，支持“同输入同版本确定性重放”。

追问树

- 随机 GPU 算子怎么做可复现？
- 数据 revision 后如何对比？

高频错误

- 只保存 notebook 和最终 CSV。

面试表达 提出“research lineage + immutable manifest”会很加分。

CHAPTER H

组合、风险与优化

从 covariance estimation 到稳定化优化：risk decomposition、shrinkage、constraints 与 turnover。

你必须会	你必须能解释	你必须会质疑
covariance、risk、regularization	优化为什么放大噪声	输入估计是否稳定

071. 推导 Minimum-Variance Portfolio °

难度 ★★★	标签 Portfolio optimization Lagrange	模块 H · 组合、风险与优化
--------	--------------------------------------	-----------------

标准解 求 $\min_w w^T \Sigma w$ s.t. $1^T w = 1$ 。Lagrange 一阶条件 $2\Sigma w - \lambda 1 = 0$ ，得到 $w^* = \Sigma^{-1} 1 / (1^T \Sigma^{-1} 1)$ 。

推导 / Why 若再加目标收益约束 $w^T \mu = \mu_0$ ，则引入第二个 multiplier，得到经典 efficient frontier。

追问树

- Σ singular 怎么办？
- 允许 cash/risk-free asset 后如何变化？

高频错误

- 忘记 covariance matrix 必须可逆/需正则化。

面试表达 先写优化问题与约束，再推一阶条件。

072. 为什么直接使用 sample covariance matrix 很危险？

难度 ★★☆☆	标签 Covariance high-dimensional conditioning	模块 H · 组合、风险与优化
---------	---	-----------------

标准解 当维度 p 与样本 n 同量级时，样本协方差特征值噪声大、condition number 高；求逆会进一步放大 estimation error。

推导 / Why 常用 shrinkage、factor covariance、PCA、regularized inverse 等。优化器对 Σ^{-1} 敏感，所以 covariance estimation 往往比优化算法本身更重要。

追问树

- $p > n$ 时 rank 是多少？
- Ledoit-Wolf shrinkage 的目标？

高频错误

- 认为更多资产只会带来更多 diversification。

面试表达 强调 “inverse amplifies noise”。

073. 什么是 Covariance Shrinkage ?

难度 ★★☆☆	标签 Shrinkage bias-variance risk model	模块 H · 组合、风险与优化
---------	---	-----------------

标准解 将 noisy sample S 与结构 target F 混合: $\hat{\Sigma} = (1-\lambda)S + \lambda F$ 。牺牲少量 bias, 换取显著 variance/conditioning 改善。

推导 / Why target 可是 diagonal、constant-correlation、factor-based 等; λ 不应拍脑袋, 可用解析估计或 CV/utility 选择。

追问树

- $\lambda=0/1$ 分别意味着什么?
- precision matrix 如何正则?

高频错误

- 把 shrinkage 理解为“把所有 correlation 调低”。

面试表达 用 bias-variance 语言解释而不是只给公式。

074. PCA 在风险模型里是什么意思 ?

难度 ★★☆☆	标签 PCA eigenportfolio factor	模块 H · 组合、风险与优化
---------	----------------------------------	-----------------

标准解 对 covariance/equivalent correlation matrix 做特征分解, 主要 eigenvectors 描述解释最多共同方差的正交方向, 可视作统计因子。

推导 / Why 第一主成分常近似 broad common mode, 但 PCA 因子是样本统计对象, 符号/旋转/稳定性都需检验, 不保证天然有经济含义。

追问树

- 标准化前后 PCA 有何差异?
- rolling PCA 的 factor identity 怎么对齐?

高频错误

- 直接把 PC1 命名为“市场因子”而不验证。

面试表达 区分“variance explanation”与“economic interpretation”。

075. VaR 与 Expected Shortfall 有什么区别？

难度 ★★☆☆	标签 Tail risk VaR ES	模块 H · 组合、风险与优化
---------	-------------------------	-----------------

标准解 VaR_α 是损失分布的 α 分位数； ES_α 是超越 VaR 尾部条件下的平均损失，更刻画 tail severity。

推导 / Why VaR 不告诉你阈值之后有多糟； ES 在常见条件下具有更好的 coherent risk measure 性质。估计两者都高度依赖尾部分布与样本量。

追问树

- 正态分布下 VaR/ES 闭式？
- backtesting tail risk 有何困难？

高频错误

- 把 99% VaR 解读为“最大损失”。

面试表达 明确 “quantile vs conditional tail mean”。

076. 为什么 Volatility Targeting 不等于风险恒定？

难度 ★★☆☆	标签 Vol targeting estimation lag risk	模块 H · 组合、风险与优化
---------	--	-----------------

标准解 它只根据估计 volatility 调整 exposure，但估计有 lag/error；jumps、correlation shifts、liquidity、tail risk 都不被单一 σ 完整捕获。

推导 / Why 当 volatility 突增时，基于过去窗口的 target 反应可能滞后；如果所有参与者同步去杠杆，还可能出现反馈效应。

追问树

- EWMA vs rolling std？
- vol estimator half-life 怎么影响响应？

高频错误

- 把 realized/forecast vol 当确定值。

面试表达 “target estimated risk, not true future risk” 是核心。

077. 什么是 Marginal Contribution to Risk ?

难度 ★★☆☆	标签 Risk decomposition gradient	模块 H · 组合、风险与优化
---------	----------------------------------	-----------------

标准解 $\sigma_p = \sqrt{w^T \Sigma w}$, 边际风险 $\partial \sigma_p / \partial w_i = (\Sigma w)_i / \sigma_p$; component risk contribution 为 $RC_i = w_i (\Sigma w)_i / \sigma_p$ 。

推导 / Why Euler homogeneous property 下, $\sum_i RC_i = \sigma_p$ 。它用于理解某个 position 对组合总体风险的贡献, 而不是单看 standalone volatility。

追问树

- variance contribution 版本怎么写?
- risk parity 的条件?

高频错误

- 把风险贡献等同于权重乘单资产波动率。

面试表达 先算 gradient, 再乘 position, 逻辑最清晰。

078. 为什么 Portfolio Optimization 容易产生极端权重 ?

难度 ★★☆☆	标签 Estimation error inverse problem constraints	模块 H · 组合、风险与优化
---------	---	-----------------

标准解 经典解常含 $\Sigma^{-1} \mu$ 。 μ 与 Σ 的微小估计误差经过逆矩阵和线性优化会被放大, 优化器会“利用噪声”给出极端 long/short 权重。

推导 / Why 常见稳定化: shrinkage、L1/L2、box/gross constraints、turnover penalty、robust optimization。

追问树

- 为什么 expected return estimation 比 covariance 更难?
- constraint 会引入什么 bias?

高频错误

- 认为极端权重说明“模型有强 conviction”。

面试表达 说“optimizer is an error maximizer if inputs are noisy”很形象。

079. 如何把 turnover/transaction-cost penalty 放入优化？

难度 ★★☆☆	标签 Convex optimization turnover regularization	模块 H · 组合、风险与优化
---------	--	-----------------

标准解 可写 $\max_w w^T \mu - \lambda w^T \Sigma w - \gamma \|w - w_{old}\|_1$ ；L1 更接近线性换手成本并产生 no-trade region，L2 更平滑易优化。

推导 / Why 真实成本可能是 piecewise/nonlinear，需根据 spread/impact model 扩展。penalty 系数应通过 OOS utility 与 cost calibration 决定。

追问树

- L1 非光滑怎么解？
- 约束与 penalty 有何等价关系？

高频错误

- 只对最终结果事后减成本，不在优化中考虑。

面试表达 把成本放进 objective，体现“预测和执行联合优化”。

080. Factor Neutralization 怎么理解？

难度 ★★☆☆	标签 Residualization exposure confounding	模块 H · 组合、风险与优化
---------	---	-----------------

标准解 若 signal x 含已知 exposure F ，可回归 $x = F\beta + \epsilon$ ，取 residual ϵ 作为 neutralized signal；也可直接在优化约束中要求 $F^T w = 0$ 。

推导 / Why neutralization 删除的是与 F 线性可解释的部分。若真实 signal 本来就通过该 factor 表现，过度 neutralize 会同时删除价值。

追问树

- 按行业/市值做横截面 neutralization？
- residualization 的 look-ahead 风险？

高频错误

- 把 neutralization 当无损预处理。

面试表达 先问“想控制的是风险暴露还是预测信息？”再决定做法。

CHAPTER I

衍生品与定价

面向 options/derivatives quant 的无套利、Black-Scholes、Greeks、IV 与离散对冲基础。

你必须会	你必须能解释	你必须会质疑
no-arbitrage、Greeks、IV	模型假设与对冲	连续理论到现实的缺口

081. Put-Call Parity 是什么？如何从无套利推导？

难度 ★★☆☆	标签 Options no-arbitrage parity	模块 I · 衍生品与定价
---------	------------------------------------	---------------

标准解 无股息欧式期权： $C - P = S_0 - Ke^{-rT}$ 。比较组合 A: long call + PV(K) 与组合 B: long put + stock；到期两者 payoff 都是 $\max(S_T, K)$ 。

推导 / Why 若当前价格不相等，则可构造初始净现金流并在到期得到同一 payoff，违背无套利。

追问树

- 有连续股息 q 时怎么改？
- American option parity 为什么变成不等式？

高频错误

- 只背公式，不会画到期 payoff。

面试表达 无套利题先构造“到期 payoff 完全相同的两个组合”。

082. Black-Scholes 的核心假设是什么？哪些明显不现实？

难度 ★★☆☆	标签 Black-Scholes assumptions model risk	模块 I · 衍生品与定价
---------	---	---------------

标准解 经典模型假设 GBM、常数 σ/r 、连续交易、无摩擦、可连续对冲、无套利、欧式行权等。现实存在 smile/skew、jumps、stochastic vol、离散对冲、交易成本和流动性约束。

推导 / Why 面试更关注“假设-结果”映射：哪个假设被破坏，会影响哪部分定价/对冲结论。

追问树

- local vol/stochastic vol 分别放松什么？
- jump diffusion 解决什么尾部特征？

高频错误

- 把模型假设背成清单但不理解用途。

面试表达 列假设后至少举 2-3 个现实偏离与后果。

083. 为什么 Black-Scholes PDE 中真实 drift μ 消失？

难度 ★★

标签 Risk-neutral pricing | delta hedge | PDE

模块 I · 衍生品与定价

标准解 对 $V(S,t)$ 用 Itô，构造 delta-hedged portfolio 消去 dW 风险；局部无风险组合在无套利下只能赚 r ，因此 PDE 中出现 r 而非真实世界 μ 。

推导 / Why 这展示了完整市场中的复制定价：价格由可复制现金流和无套利决定，不需要投资者对 underlying 的真实 drift 预测。

追问树

- risk-neutral measure 如何与 PDE 对应？
- 不完备市场为什么不唯一？

高频错误

- 说“因为假设 $\mu=r$ ”。这不是推导的本质。

面试表达 关键词：hedge out diffusion risk $\rightarrow$ riskless portfolio $\rightarrow$ earn r 。

084. Delta 是什么？它是不是“期权上涨概率”？

难度 ★★

标签 Greeks | Delta | sensitivity

模块 I · 衍生品与定价

标准解 $\Delta = \partial V / \partial S$ ，是 option value 对 underlying 小变化的一阶敏感度，也是连续复制中的 hedge ratio。它不应普遍直接解释成“上涨概率”。

推导 / Why 在特定 Black-Scholes 表达中 $N(d_1)$ 、 $N(d_2)$ 各自有不同数学/风险中性解释，不能混为一谈。

追问树

- call delta 的范围？
- cash-or-nothing digital 的 delta 行为？

高频错误

- 把 $N(d_1)$ 或 delta 直接等同 exercise probability。

面试表达 先把 sensitivity/hedge ratio 讲清，再讨论模型特定概率解释。

085. Gamma 为什么重要？

难度 ★★☆☆	标签 Greeks convexity hedging error	模块 I · 衍生品与定价
---------	---------------------------------------	---------------

标准解 $\text{Gamma} = \partial^2 V / \partial S^2$ ，描述 delta 对 S 的变化，也即 payoff/value 的局部 convexity。二阶近似 $\Delta V \approx \text{Delta} \cdot \Delta S + 0.5 \cdot \text{Gamma} \cdot (\Delta S)^2$ 。

推导 / Why 高 gamma 意味着 delta 变化快，离散对冲误差和再平衡频率更敏感；near-expiry ATM option 常见 gamma 集中。

追问树

- gamma 与 theta 的 BS 关系？
- long gamma 为什么通常 long convexity？

高频错误

- 只说“gamma 是二阶导数”而不连接动态 hedging。

面试表达 把数学敏感度与 hedge stability 联系起来。

086. Vega 是什么？为什么 vanilla option 通常 Vega>0？

难度 ★★☆☆	标签 Greeks volatility convexity	模块 I · 衍生品与定价
---------	------------------------------------	---------------

标准解 $\text{Vega} = \partial V / \partial \sigma$ 。对普通欧式 vanilla，增加不确定性会扩大终值分布，而凸性 payoff 受益，所以 vega 通常为正。

推导 / Why 严格说是模型参数敏感度，不是 realized vol 本身。不同期限/执行价的 vega 形成 volatility surface risk。

追问树

- vega 最大大致在哪？
- volga/vomma 是什么？

高频错误

- 把 implied vol 上升与 realized vol 上升视为同一件事。

面试表达 用 convexity + risk-neutral expectation 解释正 vega。

087. Implied Volatility 如何从期权价格反求？

难度 ★★☆☆	标签 Numerical methods IV root finding	模块 I · 衍生品与定价
---------	--	---------------

标准解 求 σ 使 $C_{BS}(\sigma) = C_{\text{market}}$ 。通常无闭式反解，可用 bisection/Brent；Newton 利用 vega 作导数但在 vega 很小时可能不稳。

推导 / Why 实现还需检查 no-arbitrage price bounds、初值、极短期限和深度 ITM/OTM 数值稳定性。

追问树

- Newton update 公式？
- 为什么 bisection 更稳但慢？

高频错误

- 对不满足价格上下界的 market price 仍强求 IV。

面试表达 先做 bounds，再 root-finding，是 production-grade 思路。

088. 为什么存在 Volatility Smile/Skew？

难度 ★★☆☆	标签 Vol surface fat tails model misspecification	模块 I · 衍生品与定价
---------	---	---------------

标准解 真实收益不是 constant-vol lognormal；jumps、stochastic vol、leverage effect、fat tails 及供需共同使不同 strike/maturity 的 BS implied vol 不同。

推导 / Why 所以 implied volatility 是把市场价格映射回 BS 参数空间的“报价坐标”，不是某个真正恒定 σ 的直接观测。

追问树

- smile 与 skew 的区别？
- term structure 说明什么？

高频错误

- 看到 smile 就简单说“市场错定价”。

面试表达 把 IV surface 视为“model-implied coordinate system”。

089. American 与 European Option 最大区别是什么？

难度 ★★☆☆	标签 Early exercise optimal stopping	模块 I · 衍生品与定价
---------	--------------------------------------	---------------

标准解 American 可在到期前任意允许时点行权，因此是 optimal stopping problem，价值至少不低于对应 European。

推导 / Why 提前行权价值取决于 carry/dividend/interest 等。数值方法常见 binomial tree、finite difference、Longstaff-Schwartz。

追问树

- 无股息 American call 为何通常不应提前行权？
- free boundary 是什么？

高频错误

- 只说 “American 更贵”，忽略某些情形价值可相同。

面试表达 关键词：exercise flexibility → stopping option。

090. 为什么离散 Delta Hedging 不能完全复制连续理论？

难度 ★★☆☆	标签 Discrete hedging model risk P&L	模块 I · 衍生品与定价
---------	--	---------------

标准解 连续复制假设可无限频繁、无成本交易，真实世界存在离散时间、交易成本、jump、vol misspecification 和 latency，因此会出现 hedging error。

推导 / Why 在小步长近似下，gamma、realized vs implied variance、rebalancing interval 等共同决定误差结构。交易更频繁可降离散误差，却提高成本。

追问树

- hedging frequency 如何权衡？
- jump risk 为什么无法用连续 delta 完全对冲？

高频错误

- 认为提高频率必然越好。

面试表达 把 “discretization error vs transaction cost” 作为核心 trade-off。

CHAPTER J

Coding、算法与量化系统

将研究落到可扩展代码：streaming、top-k、order book、as-of join、cache locality 与 parity debugging。

你必须会	你必须能解释	你必须会质疑
streaming、top-k、state machine	复杂度 + memory behavior	research/live 是否 parity

091. 长度 N 的序列，如何 $O(N)$ 计算 rolling mean ?

难度 ★☆☆

标签 Sliding window | 算法 | streaming

模块 J · Coding、算法与量化系统

标准解 维护窗口和 $S_t = S_{t-1} + x_t - x_{t-W}$ ，每步 $O(1)$ ，总 $O(N)$ ，空间可做到 $O(W)$ 或若只需均值则视输入结构更低。

推导 / Why 数值实现应考虑浮点累计误差、NaN、窗口启动阶段和并行/分块边界。

追问树

- rolling variance 如何 $O(N)$?
- Welford algorithm 适合什么场景?

高频错误

- 每个窗口重新 sum，做成 $O(NW)$ 。

面试表达 先说 “reuse overlapping work”，再给递推式。

092. Streaming 数据中实时维护 median 怎么做？

难度 ★★☆☆

标签 Heap | streaming median | DSA

模块 J · Coding、算法与量化系统

标准解 两个堆：max-heap 保存 lower half，min-heap 保存 upper half，维持 size 差 ≤ 1 且 $\max(\text{lower}) \leq \min(\text{upper})$ 。插入 $O(\log N)$ ，查询 median $O(1)$ 。

推导 / Why 若题目变成 sliding-window median，需要额外支持删除旧元素，可用 balanced BST/multiset、indexed heap 或 lazy deletion。

追问树

- 如何处理重复值?
- 滑动窗口版本复杂度?

高频错误

- 只回答 “排序后取中位数”，每次 $O(N \log N)$ 。

面试表达 先区分 append-only streaming 和 sliding window，这是常见追问分叉。

093. 十亿行数据只找最大的 1000 个元素，如何做？

难度 ★☆☆	标签 Top-K heap large data	模块 J · Coding、算法与量化系统
--------	------------------------------	-----------------------

标准解 维护 size $k=1000$ 的 min-heap。遍历元素：若堆未满 push；否则只在 $x > \text{heap_min}$ 时替换。复杂度 $O(N \log k)$ ，空间 $O(k)$ 。

推导 / Why 若数据分布式，可先每个 shard 求 local top-k，再对所有 local top-k 做一次 global top-k。

追问树

- 若 k 很接近 N 呢？
- Quickselect 的平均复杂度？

高频错误

- 完整排序 $O(N \log N)$ 。

面试表达 把 memory constraint 与 distributed merge 一起说，体现工程感。

094. 如何实现 event-driven order-book reconstruction？

难度 ★★★	标签 State machine hash map ordered map	模块 J · Coding、算法与量化系统
--------	---	-----------------------

标准解 维护 $\text{order_id} \rightarrow$ 订单元数据，价格档 $\rightarrow$ 队列/聚合量；按 sequence 处理 ADD/CANCEL/MODIFY/EXECUTE，更新状态并验证不变量。

推导 / Why 生产级要处理 duplicate/missing/out-of-order messages、snapshot recovery、sequence gap、不同 matching rules。数据结构选择受 L2/L3 需求和延迟预算影响。

追问树

- 为什么只用 $\text{price} \rightarrow \text{size}$ 不够重建 L3？
- 如何检测负 size/未知 order cancel？

高频错误

- 忽略 sequence gap 仍继续更新状态。

面试表达 把它讲成 deterministic replayable state machine。

095. 给无序 trade events，如何检测 timestamp 问题？

难度 ★★☆☆

标签 Timestamp | clock | data QA

模块 J · Coding、算法与量化系统

标准解 首先区分 exchange/event timestamp、receive timestamp、local processing timestamp；分别检查单调性、延迟分布、负延迟、不可能的顺序、跨源 clock skew。

推导 / Why 事件无序可能来自 packet reorder、batching、多通道、clock synchronization，并非简单 sort 一次就能解决；sort 可能掩盖真实 causal order。

追问树

- sequence number 与 timestamp 冲突时信谁？
- 如何估计 clock offset？

高频错误

- 看到乱序就按 timestamp 排序后当作真相。

面试表达 先梳理每种时间的语义，再做 QA。

096. SQL 中如何做 As-Of Join ？

难度 ★★☆☆

标签 SQL | time series join | point-in-time

模块 J · Coding、算法与量化系统

标准解 对每个左表时点 t，找右表满足 $q_time \leq t$ 的最近一条记录，即 $\operatorname{argmax} q_time$ 。可用 lateral join/correlated subquery/window 或时序数据库原生 asof join。

推导 / Why 必须明确 partition key（如 symbol）和 tolerance，否则可能把很久以前的 stale quote 错配给 trade。

追问树

- forward as-of 与 backward as-of？
- 如何避免 cross-symbol join？

高频错误

- ordinary equality join 导致大量 missing；或不加 $\leq t$ 条件造成未来泄漏。

面试表达 把 “same key + latest timestamp not after decision time” 说清。

097. 为什么 NumPy 通常比 Python for-loop 快？

难度 ★★☆☆	标签 Vectorization memory Python runtime	模块 J · Coding、算法与量化系统
---------	--	-----------------------

标准解 核心不是语法，而是把循环放入编译后的连续内存内核，减少 Python interpreter/object overhead，并利用 SIMD/cache-friendly access。

推导 / Why 但 vectorization 会创建巨大 temporary arrays 时可能内存带宽受限；某些操作用 numba/Cython/分块更好。

追问树

- broadcasting 为什么可能爆内存？
- contiguous vs strided array？

高频错误

- 回答“因为 NumPy 是 C 写的”就结束。

面试表达 从 interpreter overhead、memory layout、SIMD 三层解释。

098. C++ Quant/HFT 面试为什么常问 cache locality？

难度 ★★☆☆	标签 CPU cache data layout latency	模块 J · Coding、算法与量化系统
---------	--------------------------------------	-----------------------

标准解 Big-O 相同不代表实际延迟相同。连续 array/vector 能更好利用 cache line 与 prefetch；linked list 的 pointer chasing 容易造成 cache miss。

推导 / Why 高吞吐/低延迟场景还关心 branch prediction、allocation、NUMA、false sharing、memory bandwidth。

追问树

- AoS vs SoA？
- 为什么 unordered_map 也可能 cache-unfriendly？

高频错误

- 只用渐近复杂度判断性能。

面试表达 强调 “modern performance is often memory-bound, not arithmetic-bound”。

099. Research code 与 production code 最大区别是什么？

难度 ★★☆☆	标签 Software engineering research-to-prod	模块 J · Coding、算法与量化系统
---------	--	-----------------------

标准解 research 优先迭代速度与可探索性；production 优先 correctness、determinism、latency、observability、fault tolerance、versioning、tests。

推导 / Why 理想流程是 idea→experiment→validation→specification→production parity→monitoring，而不是把 notebook 直接部署。研究代码也应尽量形成可复用、可测试的 feature/label library。

追问树

- 如何做 offline-online feature parity?
- 什么应写 unit test / property test?

高频错误

- 把 production 化理解成“把 Python 改成 C++”。

面试表达 强调 correctness/reproducibility 比语言更本质。

100. 压轴：Backtest 与 Live 表现差异巨大，如何系统定位？

难度 ★★☆☆	标签 系统诊断 research parity distribution shift	模块 J · Coding、算法与量化系统
---------	--	-----------------------

标准解 构建差异树：Data → Feature/Model → Simulation/Execution → Code/Infra → Distribution。先用 same-input replay 找 research 与 production 的第一处分叉；前四层排除后再讨论 regime/concept drift。

推导 / Why Data 查 timestamp/version/PIT；Model 查 checkpoint/preprocessing/feature order；Simulation 查 fill/cost/latency/impact；Code 查数值、状态、event ordering；最后才比较 $P_{live}(X,Y)$ 与 $P_{hist}(X,Y)$ 。

追问树

- 如何设计 golden replay dataset?
- 如何区分 execution miss 与 predictive decay?
- 如何把诊断自动化成监控?

高频错误

- 一上来归因“市场变了”。
- 只对最终 PnL，不比较中间 state。

面试表达 这是高级面试最看重的结构化能力：先证明系统一致，再解释市场变化。

终章：把 100 题压缩成 8 条面试主线

01 不确定性 Probability → Conditional Probability → Bayes → Expectation

02 统计可信度 Estimation → Standard Error → Testing → Multiple Testing → Robustness

03 时间依赖 Stationarity → AR/MA → Volatility → State Space → Regime Change

04 预测模型 Linear → Trees → Boosting → Deep Learning → Calibration → Drift

05 数据可信度 Timestamp → PIT → Leakage → Survivorship → Missingness → Revisions

06 市场状态 Quote → Order Book → Queue → Fill → Impact → Latency

07 研究闭环 Hypothesis → Experiment → OOS → Ablation → Reproduction → Monitoring

08 工程落地 Algorithms → Streaming → Large Data → Production Parity → Debugging

30 秒 / 3 分钟回答模板

30 秒版本 ① 定义对象与信息集；② 给核心结论/公式；③ 点出关键假设；④ 用一句话说明边界或易错点。

3 分钟版本 ① 从最小模型推导；② 给替代解法或复杂度；③ 解释假设为何需要；④ 讨论 OOS/数值/工程风险；⑤ 接住一个自然追问。

开放研究题 ① 明确目标和 label；② 数据可获得性与时间轴；③ baseline；④ validation protocol；⑤ leakage/cost/shift；⑥ ablation 与 failure analysis。

面试前 14 天冲刺建议

时间	任务
Day 1-2	A 概率 + B 统计：全部能口算/白板推导。
Day 3-4	G 回测研究方法：建立 leakage/PIT/validation checklist。
Day 5-6	D 时间序列：AR、unit root、cointegration、GARCH、异步采样。
Day 7-8	E Financial ML：baseline、calibration、drift、offline-online debug。
Day 9-10	J Coding：heap/sliding window/as-of join/state machine，计时手写。
Day 11	F 微观结构：quote/order/queue/fill/latency 的概念链。
Day 12	H/C/I 按目标岗位补齐。
Day 13	做 2 次 60 分钟 mock：10 分钟概率 + 20 分钟 data + 20 分钟 coding + 10 分钟复盘。
Day 14	只复盘错题与表达，不再扩题。

参考资料与题型依据

以下资料用于校准 2026 年量化研究/算法岗位的官方题型范围。本手册中的大多数题是基于这些公开能力要求重构的高频面试题型；只有明确出现在官方 guide 中的题才标注为官方公开题型。

- Jane Street - Probability & Markets Guide — <https://www.janestreet.com/probability-markets/>
- Jane Street - Interviewing / Quantitative Research — <https://www.janestreet.com/join-jane-street/interviewing/>
- Two Sigma - Interviewing for Quantitative Research & Modeling — <https://www.twosigma.com/interviewing-for-quantitative-research-modeling/>
- Citadel - Our Quantitative Research Interview Process — <https://www.citadel.com/careers/career-perspectives/our-quantitative-research-interview-process/>
- Hudson River Trading - Student Opportunities / Algorithm Developer — <https://www.hudsonrivertrading.com/student-opportunities/>
- Optiver - Quantitative Research & Machine Learning — <https://www.optiver.com/join-us/jobs/quantitative-research-and-machine-learning/>
- DRW - Quantitative Researcher, Machine Learning — <https://www.drw.com/work-at-drw/listings/quantitative-researcher-machine-learning-3256559>

说明

本书定位为面试学习资料，强调概率、统计、机器学习、数据工程与金融建模知识，不构成投资、交易或其他财务决策建议。

版本：Professional Edition 2026-09-01。