

NLP / LLM 算法岗面试 100 题

体系化题解 · 白板推导 · 追问树 · 工程陷阱 · 代码 Debug

2026 专业版

定位

面向 NLP、搜索/RAG、大模型训练、后训练、数据与 AI Infra 算法岗位。采用“题目 → 60 秒回答 → Know-Why → 失分点 → 追问树 → 代码/公式”的原创题解结构，强调一题多问和面试现场表达。

本资料为学习整理，不是任何公司的内部题库；“公开题型”来自公开面经/开源题库的同类问法，“岗位能力映射”来自公开职位要求。候选人报告不代表公司官方面试政策。

使用说明：如何把“会”变成“能过面试”

建议用三层回答法：第一层 30–60 秒给结论；第二层 2–3 分钟补公式、机制和边界；第三层在追问中讨论工程 trade-off、失败模式与实现细节。真正高分答案不是“讲得长”，而是**结构清楚、Know-Why 充分、能被追问而不崩**。

本书每题的固定结构

1. **题目与考察目标**：先判断面试官到底想区分什么能力。
2. **60 秒标准回答**：适合首轮表达，避免一上来陷进细节。
3. **深度解析**：补充公式、机制、边界条件和工程意义。
4. **高频失分点**：指出“听起来对、实际上不够”的答案。
5. **追问树**：模拟面试官继续向下挖 2–4 层。
6. **白板/代码**：需要时给出最短可写版本和测试思路。

难度与频率

难度从 ★ 到 ★★★★★ 表示推导/实现深度；频率是基于公开题库、公开面经重复出现程度与当前岗位能力要求的综合排序，不代表任何公司的内部统计。

目录

使用说明	i
第一章 数学、概率与机器学习基础	1
Q001 为什么分类任务通常用交叉熵而不是 MSE?	2
Q002 Precision、Recall、F1: 什么时候 Accuracy 会骗人?	3
Q003 AUC 的两种理解为什么等价?	4
Q004 L1、L2 正则化与 MAP 的关系	5
Q005 Bias-Variance Trade-off 在大模型时代还成立吗?	6
Q006 BatchNorm 与 LayerNorm: Transformer 为什么偏爱 LN?	7
Q007 Dropout 为什么有效? 大模型里为什么常变少?	8
Q008 类别极度不平衡怎么处理?	9
Q009 什么是概率校准 Calibration?	10
Q010 贝叶斯基准率陷阱: 99% 准确率为何不代表 99% 可信?	11
Q011 超长文件如何等概率抽取 k 行? Reservoir Sampling	12
Q012 Adam 与 AdamW 到底差在哪?	13
第二章 统计 NLP 与传统 NLP	14
Q013 HMM: 三个基本问题与两条核心假设	15
Q014 CRF 和 HMM 有什么根本区别?	16
Q015 BERT 后为什么还要接 CRF?	17
Q016 CRF 的 Emission 与 Transition Matrix 分别表示什么?	18
Q017 中文分词: 传统方法与 LLM 时代如何看?	19
Q018 NER 模型为什么从 HMM 演化到 BERT/LLM?	20
Q019 n-gram Language Model 的核心问题与 Kneser-Ney 直觉	21
Q020 TF-IDF 的公式、直觉与局限	22
Q021 BM25 相比 TF-IDF 改进了什么?	23
Q022 编辑距离: 动态规划怎么写? 如何降空间?	24
Q023 文本分类方案如何随数据规模演进?	25
Q024 NLP 数据增强: 怎么保证不破坏标签?	26
第三章 表示学习与序列模型	27
Q025 CBOW 与 Skip-Gram: 输入输出正好相反吗?	28

Q026 Word2Vec 为什么需要 Negative Sampling?	29
Q027 Hierarchical Softmax 为什么是 $O(\log V)$?	30
Q028 SGNS 为什么与 PMI Matrix Factorization 有关系?	31
Q029 GloVe 与 Word2Vec 的差异	32
Q030 静态词向量为什么解决不了一词多义?	33
Q031 RNN 为什么梯度消失/爆炸?	34
Q032 LSTM 为什么缓解长依赖问题?	35
Q033 GRU 与 LSTM 怎么选?	36
Q034 Seq2Seq 为什么需要 Attention?	37

第四章 Transformer 核心原理 38

Q035 Self-Attention 的完整计算流程	39
Q036 为什么 Attention 要除以 $\sqrt{d_k}$?	40
Q037 为什么 Q、K、V 要用不同投影?	41
Q038 Multi-Head Attention 为什么不是一个大 Head?	42
Q039 Self-Attention 的复杂度到底是多少?	43
Q040 Causal Mask 是怎么工作的?	44
Q041 为什么 Transformer 必须注入位置信息?	45
Q042 Sinusoidal Positional Encoding 的设计直觉	46
Q043 RoPE: 如何把相对位置写进 QK 点积?	47
Q044 为什么 RoPE 通常只作用于 Q/K, 不作用于 V?	48
Q045 RoPE 为什么会有长度外推问题? YaRN/PI 在解决什么?	49
Q046 Pre-LN 与 Post-LN: 为什么深层模型更偏 Pre-Norm?	50
Q047 Transformer 为什么 Attention 后还需要 FFN?	51
Q048 GELU、ReLU 与 SiLU/SwiGLU 怎么比较?	52
Q049 SwiGLU 为什么成了现代 LLM 常客?	53
Q050 MHA、MQA、GQA: 为什么共享 K/V 能省 KV Cache?	54

第五章 BERT、GPT 与大模型预训练 55

Q051 BERT 原始预训练任务: MLM 与 NSP	56
Q052 为什么 BERT 不能天然像 GPT 一样左到右生成?	57
Q053 BERT 与 GPT: 双向理解和因果生成如何取舍?	58
Q054 BPE、WordPiece、Unigram/SentencePiece 有什么区别?	59
Q055 为什么 LLM 普遍使用 Subword/Byte Tokenization?	60
Q056 Decoder LM Loss: 为什么每个 token 都是监督信号?	61
Q057 Perplexity: 什么时候能比、什么时候不能比?	62
Q058 Weight Tying: 为什么输入 Embedding 与 LM Head 可以共享?	63
Q059 Scaling Law: 为什么不能只堆参数?	64
Q060 大模型训练为什么必须去重?	65
Q061 为什么“数据质量越高越好”是危险说法?	66

Q062 Mixed Precision: BF16 为什么常比 FP16 稳?	67
Q063 Gradient Checkpointing: 省了什么、付出什么?	68
Q064 MoE: 为什么参数变大但每 token 计算不同比例增长?	69
第六章 SFT、PEFT 与对齐	70
Q065 Pretraining 与 SFT 的本质区别	71
Q066 LoRA 的低秩假设到底是什么?	72
Q067 LoRA 应该加 Q/V 还是加所有 Linear?	73
Q068 QLoRA 为什么能在更小显存上微调大模型?	74
Q069 知识蒸馏有哪些层级?	75
Q070 RLHF 的经典 Pipeline 与 KL 约束	76
Q071 REINFORCE 是 On-policy 还是 Off-policy?	77
Q072 REINFORCE 为什么加 Baseline 不引入偏差?	78
Q073 DPO 为什么不需要显式 Reward Model?	79
Q074 PPO、DPO、GRPO: 什么时候选哪一个?	80
第七章 检索、搜索与 RAG	81
Q075 Sparse Retrieval 与 Dense Retrieval 的核心差异	82
Q076 Bi-Encoder 与 Cross-Encoder: 为什么一快一准?	83
Q077 为什么搜索系统通常是多阶段 Retrieval→Rerank?	84
Q078 Dense Retrieval 的负样本怎么构造?	85
Q079 HNSW: 为什么多层小世界图能快速 ANN?	86
Q080 IVF-PQ: 如何用聚类与乘积量化压缩十亿向量?	87
Q081 RAG Chunking: 为什么“固定 500 tokens”不是答案?	88
Q082 Hybrid Search 与 RRF: 为什么排名融合常比 raw score 加权稳?	89
Q083 为什么 Reranker 通常比 Retriever 更准?	90
Q084 如何完整评估一个 RAG 系统?	91
第八章 数据工程与 Evaluation	92
Q085 预训练数据清洗 Pipeline 应如何设计?	93
Q086 Exact Dedup 与 MinHash: 何时用哪一个?	94
Q087 Benchmark Decontamination 为什么不能只做 Exact Match?	95
Q088 合成数据质量: Validity、Faithfulness、Diversity、Utility	96
Q089 LLM-as-a-Judge 有哪些系统性偏差?	97
Q090 离线指标涨了, 为什么线上可能变差?	98
第九章 推理、分布式与 AI Infra	99
Q091 KV Cache 为什么能显著加速自回归 Decode?	100
Q092 KV Cache 大小怎么估算?	101
Q093 Quantization 为什么能提升 LLM 推理吞吐?	102
Q094 Continuous Batching 与 PagedAttention 解决什么?	103

Q095 Speculative Decoding 为什么能“保证分布”又加速?	104
Q096 DP、TP、PP、EP: 四种并行怎么组合?	105
第十章 手写代码与 Debug	106
Q097 手写 Numerical Stable Softmax	107
Q098 手写 Multi-Head Attention: Shape、Mask、Contiguous	108
Q099 Vectorized 1-NN: 禁止 Python For-loop	109
Q100 Transformer Debug + 实现 KV Cache: 综合终局题	110
附录 A 高频公式速查	111
附录 B 代码题检查清单	112
附录 C 30 天刷题路线	113
附录 D 公开来源与真实性说明	114
最后一页	116

第 1 篇

数学、概率与机器学习基础

本篇目标：把公式讲清楚只是及格；能解释假设、边界条件和指标失真，才是算法岗水平。

题目范围：Q1 为什么分类任务通常用交叉熵而不是 MSE?、Q2 Precision、Recall、F1：什么时候 Accuracy 会骗人?、Q3 AUC 的两种理解为什么等价?、Q4 L1、L2 正则化与 MAP 的关系、Q5 Bias-Variance Trade-off 在大模型时代还成立吗?、Q6 BatchNorm 与 LayerNorm：Transformer 为什么偏爱 LN?、Q7 Dropout 为什么有效? 大模型里为什么常变少?、Q8 类别极度不平衡怎么处理?、Q9 什么是概率校准 Calibration?、Q10 贝叶斯基准率陷阱：99% 准确率为何不代表 99% 可信?、Q11 超长文件如何等概率抽取 k 行? Reservoir Sampling、Q12 Adam 与 AdamW 到底差在哪?

Q001 为什么分类任务通常用交叉熵而不是 MSE?

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

损失函数

MLE

Softmax

面试官在考什么：判断候选人是否能把“经验用法”还原成概率建模与梯度性质。

题目：多分类为什么常用 Softmax + Cross Entropy，而不是对 one-hot 标签直接做 MSE?

60 秒标准回答

交叉熵对应分类分布的负对数似然；配合 Softmax 后，对 logit 的梯度简洁为“预测概率 - 标签”。MSE 并非不能用于分类，但概率解释更弱，且与 Softmax 组合时梯度常更不利。

白板公式

$$p_k = \frac{e^{z_k}}{\sum_j e^{z_j}}, \quad L = - \sum_k y_k \log p_k, \quad \frac{\partial L}{\partial z_k} = p_k - y_k$$

深度解析：Know-Why

- 从最大似然出发：若 y 服从 categorical distribution，最大化 $P(y|x)$ 等价于最小化 $-\log p_y$ 。
- Softmax + CE 的链式求导发生消项，梯度直接反映概率误差，利于优化。
- “CE 一定比 MSE 好”不是数学定理；特殊任务、校准目标或非标准输出空间可能采用其他损失。

高频失分点

- 只说“CE 收敛快”但解释不了为什么。
- 把“分类用 CE、回归用 MSE”当成不可违反的规则。

追问树

1. 二分类 BCE 与多分类 CE 有什么关系？
2. Label Smoothing 改变了什么？
3. 为什么回归 MSE 可由高斯噪声假设推出？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q002 Precision、Recall、F1：什么时候 Accuracy 会骗人？

难度 ★★ 频率 ★★★★★ 依据高频公开题型

指标

类别不平衡

面试官在考什么：考察指标是否与业务错误成本建立联系。

题目：解释 Precision、Recall、F1；给出 Accuracy 很高但模型不可用的例子。

60 秒标准回答

Precision 关注“预测为正的有多少是真的”；Recall 关注“真正正例找回多少”；F1 是二者调和平均。类别极不平衡时，全预测多数类也可获得很高 Accuracy。

白板公式

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F_1 = \frac{2PR}{P + R}$$

深度解析：Know-Why

- 指标选择必须回到 FP 与 FN 的业务成本：风控、召回、审核、检索任务的权衡不同。
- F1 不使用 TN，因此更聚焦正类识别，但也因此不是所有业务都适合。
- 阈值变化会移动 Precision-Recall，需要结合 PR 曲线或固定 Recall 下看 Precision。

高频失分点

- 只背公式，不说明 threshold。
- 把 F1 当成“永远比 Accuracy 好”。

追问树

1. Macro-F1 与 Micro-F1 区别？
2. 为什么 PR-AUC 在稀有正例场景常比 ROC-AUC 更有解释力？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q003 AUC 的两种理解为什么等价？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

AUC

排序

统计

面试官在考什么：从指标公式深入到排序统计解释。

题目：除了“ROC 曲线下面积”，AUC 还能怎么解释？为什么对类别比例相对不敏感？

60 秒标准回答

AUC 可以解释为随机取一个正样本和一个负样本时，模型把正样本打分排在负样本前的概率。它本质评价正负样本的 pairwise ranking。

白板公式

$$AUC \approx P(s(x^+) > s(x^-))$$

深度解析：Know-Why

- ROC 横轴 FPR、纵轴 TPR；改变阈值扫过所有排序位置。
- pairwise 概率解释与 Mann-Whitney U statistic 紧密相关。
- 类别比例变化不直接改变正负对的相对排序，但数据分布漂移仍会改变 AUC。

高频失分点

- 误以为 AUC 与阈值无关就意味着线上阈值不重要。
- 忽略 ties 的处理。

追问树

1. AUC=0.5、1、0 分别意味着什么？
2. 为什么高 AUC 模型仍可能 calibration 很差？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q004 L1、L2 正则化与 MAP 的关系

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

正则化

先验

面试官在考什么：考察优化、概率视角和稀疏性直觉。

题目：L1 与 L2 有何区别？为什么可以分别联系 Laplace/Gaussian 先验？

60 秒标准回答

L1 倾向稀疏解，L2 倾向平滑缩小参数。MAP 中，负对数先验会以正则项形式进入目标函数，因此不同先验对应不同惩罚。

白板公式

$$\mathcal{L}_{MAP} = -\log p(D|w) - \log p(w)$$

深度解析：Know-Why

- L1 在 0 附近存在尖点，更容易把系数压到恰好 0。
- L2 对大权重惩罚更强且可微，优化通常更稳定。
- 深度学习中的 weight decay 与 “把 L2 加到 loss” 在自适应优化器下并不完全等价。

高频失分点

- 只说 “L1 防过拟合，L2 也防过拟合”。
- 混淆 regularization coefficient 与 learning rate。

追问树

1. 为什么 AdamW 要 decouple weight decay?
2. Elastic Net 是什么?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q005 Bias-Variance Trade-off 在大模型时代还成立吗？

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

泛化 过拟合

面试官在考什么：检验候选人能否从经典统计学习过渡到过参数化模型。

题目：解释 Bias-Variance；参数远多于样本时，为什么现代深度网络不一定按“模型越大越过拟合”简单发展？

60 秒标准回答

经典分解仍提供直觉，但现代深度学习存在过参数化、隐式正则化、预训练与数据规模效应，不能只用“参数数量”判断泛化。

深度解析：Know-Why

- 高 bias：模型表达不足；高 variance：对训练样本扰动敏感。
- SGD、weight decay、数据增强、预训练等改变有效容量。
- Double descent 表明测试误差可能在插值阈值附近先升后降。

高频失分点

- 把“大模型不会过拟合”当成结论。
- 没有区分训练误差、验证误差和能力泛化。

追问树

1. 什么是 double descent？
2. 早停为什么可视为正则化？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q006 BatchNorm 与 LayerNorm: Transformer 为什么偏爱 LN?

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

Normalization

面试官在考什么：理解统计维度、训练/推理差异与序列建模。

题目：BN 和 LN 分别沿什么维度归一化？Transformer 为什么通常采用 LN/RMSNorm？

60 秒标准回答

BN 依赖 batch 统计；LN 对单个 token/样本的 hidden dimension 做归一化，不依赖 batch size，适合变长序列与自回归推理。

白板公式

$$LN(x) = \gamma \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta$$

深度解析：Know-Why

- BN 训练与推理使用的统计不同，需要 running mean/variance。
- LN 在每个位置内部归一化，更适合 sequence model。
- 现代 LLM 常用 RMSNorm：不减均值，只按 RMS 缩放，结构更简洁。

高频失分点

- 说“LN 不受序列长度影响”但没说明归一化轴。
- 忽略 Pre-LN/Post-LN。

追问树

1. RMSNorm 与 LayerNorm 差异？
2. 为什么很深的 Transformer 常偏好 Pre-Norm？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q007 Dropout 为什么有效？大模型里为什么常变少？

难度 ★★ 频率 ★★★★★☆ 依据高频公开题型

正则化

面试官在考什么：区分训练噪声、集成直觉和规模效应。

题目：Dropout 如何防过拟合？为什么很多大模型配置中的 dropout 很小甚至为 0？

60 秒标准回答

Dropout 随机屏蔽神经元，降低 co-adaptation，可理解为噪声正则和近似子网络集成。超大规模预训练数据下，传统过拟合压力降低，过强 dropout 反而可能损失有效容量与训练效率。

深度解析：Know-Why

- 训练时通常使用 inverted dropout，使期望激活尺度保持不变。
- Dropout 与 stochastic depth、attention dropout 是不同粒度的随机正则。
- 数据规模、训练 token 数和模型规模共同决定是否需要较强 dropout。

高频失分点

- 把 dropout 当作推理时也随机丢弃。
- 把“0 dropout”误解为完全没有任何正则化。

追问树

1. 为什么 BatchNorm 与 dropout 有时会相互影响？
2. Transformer 里可以在哪些位置加 dropout？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q008 类别极度不平衡怎么处理？

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

不平衡学习

Hard Negative

面试官在考什么：从数据、loss、采样与指标四层回答。

题目：正例只有万分之一，你会如何训练和评估？

60 秒标准回答

先定义错误成本，再组合采样、loss reweight、hard negative mining 与适配指标。关键不是机械地 oversample，而是保持训练分布、校准与线上阈值的一致性。

白板公式

$$L_{focal} = -(1 - p_t)^\gamma \log p_t$$

深度解析：Know-Why

- 数据层：分层采样、正例增强、难负例挖掘。
- 目标层：class weight、focal loss、pairwise ranking。
- 评估层：PR-AUC、Recall@ 固定 Precision、成本敏感指标。

高频失分点

- 对测试集做过采样导致指标失真。
- 只用 accuracy。

追问树

1. Focal Loss 为什么能聚焦 hard example?
2. Hard negative mining 如何避免 false negatives?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q009 什么是概率校准 Calibration?

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

Calibration

Confidence

面试官在考什么：判断候选人是否理解“分对”与“置信度可信”是两件事。

题目：一个准确率很高的分类器为什么仍可能不 calibrated? 怎么校准?

60 秒标准回答

若模型给出 0.8 概率的一组样本中约 80% 真为正例，则较为 calibrated。准确率只看 argmax 是否正确，不约束概率数值的可靠性。

深度解析：Know-Why

- 常用 ECE、Brier score、reliability diagram。
- Temperature scaling 在验证集上学习单个温度参数，通常保持分类排序但改变置信度。
- LLM 的 token probability、verbal confidence 与任务正确率之间也存在校准问题。

高频失分点

- 把 softmax 最大值直接当“真实概率”。
- 在测试集上拟合温度。

追问树

1. 温度 $T > 1$ 会让分布怎样变化?
2. Calibration 和 ranking 能否同时优秀/差?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q010 贝叶斯基准率陷阱：99% 准确率为何不代表 99% 可信？

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

Bayes

Base Rate

面试官在考什么：检验条件概率直觉。

题目：某事件发生率 1%，检测器灵敏度 99%、假阳性率 1%。检测为阳性时真实为阳性的概率是多少？

60 秒标准回答

约为 50%。因为基准率极低，99% 的正常样本中仍会产生约 1% 的假阳性，数量与真阳性相当。

白板公式

$$P(D|+) = \frac{P(+|D)P(D)}{P(+|D)P(D) + P(+|\neg D)P(\neg D)}$$

深度解析：Know-Why

- 先画 10000 人/样本的频数表通常比直接代公式更不易错。
- 准确率、灵敏度、特异度、阳性预测值不是同一概念。
- 在稀有事件检测中必须显式考虑 prior/base rate。

高频失分点

- 把 $P(+|D)$ 当成 $P(D|+)$ 。
- 忽略假阳性率。

追问树

1. 如果基准率变成 10% 呢？
2. 阈值调整如何影响 PPV/NPV？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q011 超长文件如何等概率抽取 k 行? Reservoir Sampling

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

随机算法

流式计算

面试官在考什么：考察流式算法证明能力。

题目：文件太大无法载入内存，如何只用 $O(k)$ 内存等概率抽取 k 行？

60 秒标准回答

使用 Reservoir Sampling：先装入前 k 个元素；第 i 个元素以 k/i 概率进入水库，并随机替换一个已有元素。最终每个元素被保留的概率均为 k/N 。

深度解析：Know-Why

- 关键是能证明早期元素在后续多次“可能被替换”后最终概率仍为 k/N 。
- 适用于未知总长度的 streaming data。
- 分布式场景可扩展为加权/合并水库。

高频失分点

- 只描述算法，不会证明等概率。
- i 与下标从 0/1 开始混乱。

追问树

1. 如何做 weighted reservoir sampling?
2. 如果多机各处理一个 shard，如何合并？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q012 Adam 与 AdamW 到底差在哪？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

优化器

Weight Decay

面试官在考什么：区分“L2 正则”与“参数衰减”的优化路径。

题目：为什么 AdamW 要把 weight decay 从梯度更新中解耦？

60 秒标准回答

Adam 对每个参数使用自适应缩放；若把 L2 项直接加入梯度，正则项也会被同样缩放，已不等价于传统 weight decay。AdamW 直接对参数做衰减，再执行 Adam 更新。

白板公式

$$\theta_{t+1} = (1 - \eta\lambda)\theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \epsilon}}$$

深度解析：Know-Why

- Adam 使用一阶矩和二阶矩估计，对梯度尺度自适应。
- Bias correction 修正训练早期矩估计偏向 0 的问题。
- 现代 Transformer 训练通常对 bias、norm 参数不做 weight decay。

高频失分点

- 把 AdamW 仅理解为“Adam + L2”。
- 忽略 epsilon 与数值稳定性。

追问树

1. 为什么 warmup 常与 AdamW 搭配？
2. β_1 、 β_2 分别影响什么？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

第 2 篇

统计 NLP 与传统 NLP

本篇目标：传统方法仍然是理解现代 NLP 的地基，尤其是序列标注、检索和特征工程。

题目范围：Q13 HMM：三个基本问题与两条核心假设、Q14 CRF 和 HMM 有什么根本区别？、Q15 BERT 后为什么还要接 CRF？、Q16 CRF 的 Emission 与 Transition Matrix 分别表示什么？、Q17 中文分词：传统方法与 LLM 时代如何看？、Q18 NER 模型为什么从 HMM 演化到 BERT/LLM？、Q19 n-gram Language Model 的核心问题与 Kneser-Ney 直觉、Q20 TF-IDF 的公式、直觉与局限、Q21 BM25 相比 TF-IDF 改进了什么？、Q22 编辑距离：动态规划怎么写？如何降空间？、Q23 文本分类方案如何随数据规模演进？、Q24 NLP 数据增强：怎么保证不破坏标签？

Q013 HMM：三个基本问题与两条核心假设

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

HMM

序列模型

面试官在考什么：从概率图角度理解早期序列标注。

题目：HMM 的状态、观测、转移、发射分别是什么？三个基本问题如何求解？

60 秒标准回答

HMM 是生成式序列模型，假设隐藏状态满足一阶马尔可夫，当前观测只依赖当前隐藏状态。Evaluation 用 Forward，Decoding 用 Viterbi，Learning 常用 Baum-Welch/EM。

深度解析：Know-Why

- 联合分布可分解为初始状态、状态转移和发射概率的乘积。
- Forward 计算所有路径概率之和；Viterbi 只保留最优路径。
- HMM 对特征依赖假设强，难以使用丰富重叠特征。

高频失分点

- 把 Forward 与 Viterbi 混淆。
- 只背算法名称，不会写递推。

追问树

1. Backward 算法作用？
2. 为什么 EM 能训练含隐变量模型？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q014 CRF 和 HMM 有什么根本区别？

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

CRF 判别模型

面试官在考什么：考察生成式与判别式序列建模。

题目：Linear-chain CRF 为什么适合序列标注？与 HMM 相比优势在哪里？

60 秒标准回答

HMM 建模 $P(X,Y)$ ，CRF 直接建模 $P(Y|X)$ ，可自由使用输入特征并通过全局归一化建模标签序列依赖。

白板公式

$$P(y|x) = \frac{\exp s(x, y)}{\sum_{y'} \exp s(x, y')}$$

深度解析：Know-Why

- CRF 的 score 通常由 emission 与 transition 累加。
- 分母需要对所有标签序列求和，可用动态规划计算 partition function。
- CRF 避免 MEMM 的局部归一化 label bias 问题。

高频失分点

- 把 CRF 当成“一个分类器层”。
- 说 CRF 一定比 token softmax 好。

追问树

1. 什么是 label bias?
2. CRF 训练的负对数似然如何计算？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q015 BERT 后为什么还要接 CRF?

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

BERT-CRF

NER

面试官在考什么：理解 contextual feature 与 structured prediction 分工。

题目：BERT 已经很强，NER 为什么仍有人在顶部加 CRF?

60 秒标准回答

BERT 提供上下文 token 表示与 emission score；若逐 token 独立 softmax，标签之间没有显式转移约束。CRF 可学习 BIO/BIOES 等标签转移偏好并做全局最优解码。

深度解析：Know-Why

- BERT 解决“看上下文”，CRF 解决“标签序列结构”。
- 在数据量大、标签规则简单时，纯 token classifier 也可能足够。
- 生成式 LLM 做结构化抽取时，约束方式又发生变化。

高频失分点

- 把 CRF 说成“纠正 BERT 错误”的万能模块。
- 没有说明训练/解码差异。

追问树

1. 如何禁止 O→I-PER 之类非法转移?
2. Viterbi 的时间复杂度?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q016 CRF 的 Emission 与 Transition Matrix 分别表示什么？

难度 ★★ 频率 ★★★★★☆ 依据高频公开题型

CRF Viterbi

面试官在考什么：是否真正理解 BERT-CRF 的张量。

题目：给定序列长度 T 、标签数 K ，emission 和 transition 分别是什么 shape？总分如何计算？

60 秒标准回答

Emission 通常为 $T \times K$ ，表示每个位置属于每个标签的局部分数；Transition 为 $K \times K$ ，表示相邻标签转移分数。序列总分是两者沿路径累加。

深度解析：Know-Why

- 可以加入 START/STOP 状态。
- 训练计算 gold path score 与 log-partition 的差。
- 解码用 Viterbi，把 sum-product 换成 max-product/max-sum。

高频失分点

- transition 不是“词之间转移”。
- 把概率和未归一化 score 混淆。

追问树

1. 如何 batch 化 CRF？
2. padding mask 如何处理？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q017 中文分词：传统方法与 LLM 时代如何看？

难度 ★★ 频率 ★★★★★ 依据高频公开题型

分词

序列标注

面试官在考什么：区分 NLP task segmentation 与 tokenizer segmentation。

题目：中文分词有哪些经典方法？为什么它与 BPE/SentencePiece 的 tokenization 不是同一个问题？

60 秒标准回答

中文分词任务目标是恢复“词”边界，可用词典、HMM、CRF、BiLSTM-CRF、BERT 标注；LLM tokenizer 的 subword 切分主要服务模型计算与词表压缩，不保证语言学意义上的词。

深度解析：Know-Why

- 最大匹配依赖词典，简单但歧义处理弱。
- 序列标注可用 B/M/E/S 或 BIO 标签。
- 下游任务未必需要显式中文分词，端到端 subword 模型常直接学习。

高频失分点

- 把“Tokenizer”与“中文分词”混为一谈。
- 只列工具名。

追问树

1. 新词发现怎么做？
2. 分词错误会如何传播到检索/NER？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q018 NER 模型为什么从 HMM 演化到 BERT/LLM?

难度 ★★ 频率 ★★★★★☆ 依据高频公开题型

NER 演化

面试官在考什么：考察候选人是否能用“解决前一代缺陷”讲技术史。

题目：请按 HMM→CRF→BiLSTM-CRF→BERT-CRF→LLM 解释每一步解决了什么问题。

60 秒标准回答

演化主线是：从强独立假设到判别式特征、再到自动上下文表示、预训练知识，最终到生成式统一接口。每一代都在减少人工特征并扩大上下文/知识利用。

深度解析：Know-Why

- CRF 建标签结构；BiLSTM 学双向上下文；BERT 引入大规模预训练。
- LLM 可以通过 schema constrained generation 统一实体、关系、事件抽取。
- 工业系统仍可能保留轻量 BERT/CRF，因为延迟与成本更优。

高频失分点

- 用“新模型一定淘汰旧模型”回答。
- 忽略标注成本和部署约束。

追问树

1. 嵌套 NER 如何做？
2. 实体边界与类型如何分别建模？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q019 n-gram Language Model 的核心问题与 Kneser-Ney 直觉

难度 ★★★★★ 频率 ★★★☆☆ 依据 高频公开题型

语言模型

Smoothing

面试官在考什么：考察统计语言模型的稀疏性与平滑。

题目：为什么 n-gram 必须做 smoothing? Kneser-Ney 的关键思想是什么？

60 秒标准回答

有限语料下大量 n-gram 从未出现，MLE 会给 0 概率。Kneser-Ney 不仅看一个词出现多少次，还看它出现在多少种不同上下文中，用 continuation probability 改善低阶分布。

深度解析：Know-Why

- Backoff/interpolation 在高阶证据不足时退到低阶模型。
- 简单 add-one 会把过多概率质量分给未见事件。
- Kneser-Ney 对 “San Francisco” 这类固定搭配后的词频偏差处理更合理。

高频失分点

- 说 smoothing 只是 “避免 $\log 0$ ”。
- 不会解释 continuation count。

追问树

1. Good-Turing 在估计什么？
2. 为什么神经 LM 仍然需要处理 OOV/tokenization？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q020 TF-IDF 的公式、直觉与局限

难度 ★★ 频率 ★★★★★ 依据高频公开题型

TF-IDF

检索

面试官在考什么：检索基础必须秒答。

题目：解释 TF、IDF；为什么一个词在当前文档高频但在全库常见时不应有高权重？

60 秒标准回答

TF 表示局部词频，IDF 抑制全局常见词。TF-IDF 是局部重要性与全局稀有性的乘积。

白板公式

$$TFIDF(t, d) = TF(t, d) \cdot \log \frac{N}{df(t)}$$

深度解析：Know-Why

- TF 可用 raw count、log-normalized 等形式。
- IDF 有平滑版本，避免 $df=0$ 或极端权重。
- 局限：词频饱和不足、长度归一化弱、完全依赖 lexical match。

高频失分点

- 公式写对但不会解释为什么。
- 说 TF-IDF 能做语义匹配。

追问树

1. 余弦相似度为什么常与 TF-IDF 搭配？
2. 停用词与 IDF 的关系？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q021 BM25 相比 TF-IDF 改进了什么？

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

BM25

RAG

面试官在考什么：搜索与 RAG 的核心基础题。

题目：BM25 中 k_1 与 b 分别控制什么？为什么要做 TF saturation 和文档长度归一化？

60 秒标准回答

BM25 认为词频收益应递减，并根据文档长度相对平均长度做归一化。 k_1 控制 TF 饱和速度， b 控制长度归一化强度。

白板公式

$$\text{score}(D, Q) = \sum_{q \in Q} \text{IDF}(q) \frac{f(q, D)(k_1 + 1)}{f(q, D) + k_1(1 - b + b|D|/\text{avgdl})}$$

深度解析：Know-Why

- 同一个 query term 出现 20 次不应比 2 次“重要十倍”。
- 长文更容易偶然包含查询词，需长度校正。
- BM25 对实体、数字、稀有术语往往非常强，因此现代 RAG 常保留 sparse retrieval。

高频失分点

- 把 BM25 说成“加权 TF-IDF”而无细节。
- 忘记 query term 可累加。

追问树

1. BM25 和 dense retrieval 如何融合？
2. 为什么 RRF 常比 raw score 加权更稳？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q022 编辑距离：动态规划怎么写？如何降空间？

难度 ★★ 频率 ★★★★★ 依据高频公开题型

DP 字符串

面试官在考什么：经典代码题，兼顾 NLP 场景。

题目：求 Levenshtein distance：插入、删除、替换代价均为 1。写状态转移和复杂度。

60 秒标准回答

$dp[i][j]$ 表示 $s[:i]$ 变成 $t[:j]$ 的最小代价。字符相同取左上角，否则取删除、插入、替换三者最小值加一。时间 $O(mn)$ ，空间可压缩到 $O(\min(m,n))$ 。

白板公式

$$dp_{ij} = \min\{dp_{i-1,j} + 1, dp_{i,j-1} + 1, dp_{i-1,j-1} + [s_i \neq t_j]\}$$

深度解析：Know-Why

- 初始化第一行/列对应连续插入或删除。
- 可扩展不同操作权重、Damerau transposition。
- 在拼写纠错、OCR、ASR、去重中常用。

高频失分点

- 边界条件漏掉空串。
- 把替换写成两次操作。

追问树

1. 如何恢复具体编辑路径？
2. 如何做 banded DP 加速近似匹配？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q023 文本分类方案如何随数据规模演进？

难度 ★★ 频率 ★★★★★☆ 依据高频公开题型

文本分类

工程选择

面试官在考什么：考察模型选择而不是背模型列表。

题目：从小数据、低延迟到大数据/LLM，文本分类可有哪些方案？

60 秒标准回答

从 TF-IDF+LR/SVM、TextCNN/RNN、BERT classifier，到 zero/few-shot LLM 与 SFT。方案选择受数据量、标签稳定性、延迟、成本、可解释性影响。

深度解析：Know-Why

- 小数据高维稀疏场景，线性模型常是强 baseline。
- BERT 类 encoder 在固定标签空间通常比生成式 LLM 更经济。
- 标签频繁变化或任务开放时，instruction LLM 灵活性更强。

高频失分点

- 一上来就用最大模型。
- 不先做 baseline 和错误分析。

追问树

1. 多标签分类怎么做？
2. 层级标签如何建模？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q024 NLP 数据增强：怎么保证不破坏标签？

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

数据增强 合成数据

面试官在考什么：区分“生成更多文本”与“生成有效监督”。
题目：列举 NLP 数据增强方法，并说明怎样验证 label preservation。

60 秒标准回答

可做同义改写、回译、上下文替换、模板/LLM 生成、counterfactual augmentation。关键要验证语义和标签不被改变，并控制分布漂移与模式坍塌。

深度解析：Know-Why

- 对情感、否定、数值、实体任务，轻微改写也可能改标签。
- LLM 生成可扩大覆盖，但会继承教师偏差与套话。
- 应按 validity、faithfulness、diversity、utility 评估，而不是只看 fluency。

高频失分点

- 把“更多样本”自动等价于“更高效果”。
- 数据增强后不做去重。

追问树

1. 怎样生成 hard negatives?
2. 如何通过 proxy training 评估合成数据效用?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

第 3 篇

表示学习与序列模型

本篇目标：从静态词向量到上下文表示，理解“表示、记忆、长依赖”如何一步步演化。

题目范围：Q25 CBOW 与 Skip-Gram:输入输出正好相反吗?、Q26 Word2Vec 为什么需要 Negative Sampling?、Q27 Hierarchical Softmax 为什么是 $O(\log|V|)$?、Q28 SGNS 为什么与 PMI Matrix Factorization 有关系?、Q29 GloVe 与 Word2Vec 的差异、Q30 静态词向量为什么解决不了一词多义?、Q31 RNN 为什么梯度消失/爆炸?、Q32 LSTM 为什么缓解长依赖问题?、Q33 GRU 与 LSTM 怎么选?、Q34 Seq2Seq 为什么需要 Attention?

Q025 CBOW 与 Skip-Gram：输入输出正好相反吗？

难度 ★★ 频率 ★★★★★☆ 依据高频公开题型

Word2Vec

面试官在考什么：掌握经典表示学习目标。

题目：CBOW 和 Skip-Gram 的训练目标、速度与低频词表现有何差异？

60 秒标准回答

CBOW 用上下文预测中心词，更新更聚合、训练快；Skip-Gram 用中心词预测上下文，一词产生多个训练对，对低频词通常更友好但计算更重。

深度解析：Know-Why

- 二者都基于 distributional hypothesis。
- 窗口大小决定更偏句法还是主题语义。
- 真正大词表训练还需要 hierarchical softmax 或 negative sampling。

高频失分点

- 只说“一个正一个反”不谈优化特点。

追问树

1. window size 怎么选？
2. subsampling 高频词有什么作用？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q026 Word2Vec 为什么需要 Negative Sampling?

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

Word2Vec

采样

面试官在考什么：理解从 full softmax 到二分类近似。

题目：词表几十万时，Skip-Gram full softmax 为什么昂贵？Negative Sampling 如何改写目标？

60 秒标准回答

full softmax 每次需对整个词表归一化。Negative Sampling 把一个正 word-context 对与 K 个噪声负样本做二分类，使单步复杂度从 $O(|V|)$ 降到 $O(K)$ 。

白板公式

$$\log \sigma(v_o^\top v_i) + \sum_{k=1}^K \log \sigma(-v_k^\top v_i)$$

深度解析：Know-Why

- 负样本分布经典做法与 $\text{unigram}^{0.75}$ 有关。
- Negative Sampling 的目标不是精确估计语言模型概率，而是学习好 embedding。
- K 越大通常估计更好但计算更贵。

高频失分点

- 误以为 negative sample 就是随机采句子。
- 不知道正负样本分别优化什么。

追问树

1. 为什么高频词采样分布要平滑？
2. 与 Noise Contrastive Estimation 有何联系？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q027 Hierarchical Softmax 为什么是 $O(\log|V|)$?

难度 ★★★ 频率 ★★★☆☆ 依据高频公开题型

Word2Vec

Huffman

面试官在考什么：理解树结构概率分解。

题目：Hierarchical Softmax 如何把多分类变成一系列二分类？为什么常用 Huffman Tree？

60 秒标准回答

每个词是树的叶子，预测词等价于从根走到该叶子的多次二分类。路径长度约 $O(\log|V|)$ ；Huffman 让高频词路径更短，降低平均计算量。

深度解析：Know-Why

- 每个内部节点有一个 binary classifier。
- 词概率是路径上分支概率的乘积。
- 与 negative sampling 相比，它更接近显式归一化的概率模型。

高频失分点

- 把 Huffman 树理解为用词向量做压缩。

追问树

1. 什么时候 HS 可能优于 negative sampling?
2. 为什么 rare word 路径更长?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q028 SGNS 为什么与 PMI Matrix Factorization 有关系？

难度 ★★★★★ 频率 ★★★★★☆☆ 依据高频公开题型

PMI

表示学习

面试官在考什么：考察理论深度。

题目：为什么常说 Skip-Gram with Negative Sampling 隐式分解 shifted PMI matrix？

60 秒标准回答

在理想化最优条件下，word-context 内积近似 $\text{PMI}(w, c) - \log k$ 。说明预测式 embedding 与共现统计矩阵并非完全割裂。

白板公式

$$\text{PMI}(w, c) = \log \frac{P(w, c)}{P(w)P(c)}, \quad v_w^\top v_c \approx \text{PMI}(w, c) - \log k$$

深度解析：Know-Why

- PMI 衡量联合出现相对独立出现的提升。
- 负采样数量 k 引入 shift。
- 真实训练中低维约束、采样、subsampling 等使关系是近似而非精确。

高频失分点

- 把等式当成训练代码中显式计算 PMI。

追问树

1. PPMI 为什么把负 PMI 截为 0？
2. SVD 与 embedding 有什么关系？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q029 GloVe 与 Word2Vec 的差异

难度 ★★ 频率 ★★★★★ 依据高频公开题型

GloVe

共现

面试官在考什么：理解 count-based 与 predictive 两类方法。

题目：GloVe 为什么强调 global co-occurrence？与 Word2Vec 的训练视角有什么不同？

60 秒标准回答

GloVe 显式使用词共现矩阵并拟合 log co-occurrence；Word2Vec 从局部窗口采样训练预测任务。二者都将统计结构压入低维向量。

深度解析：Know-Why

- GloVe 的 weighting function 抑制极少或极高共现带来的不稳定。
- Word2Vec 更像在线采样优化，GloVe 更显式依赖预统计。
- 今天两者主要作为理解 embedding 的经典基础。

高频失分点

- 只说 “GloVe 是全局、Word2Vec 是局部” 但不解释目标函数。

追问树

1. 为什么词向量能出现线性类比？
2. 静态 embedding 的根本限制？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q030 静态词向量为什么解决不了一词多义？

难度 ★★ 频率 ★★★★★☆ 依据高频公开题型

Contextual Embedding

面试官在考什么：从 Word2Vec 过渡 BERT 的关键逻辑。

题目：“bank”在河岸与银行语境中为什么需要不同表示？ELMo/BERT 如何解决？

60 秒标准回答

静态 embedding 为词表中每个词给一个固定向量；contextual encoder 让 token 表示成为整个上下文的函数，因此同一 token 在不同句子中可得到不同向量。

深度解析：Know-Why

- ELMo 用双向语言模型的上下文状态；BERT 用双向 Transformer。
- tokenization 后的 subword 还需通过上下文组合成词义。
- contextual embedding 并不保证所有语义可线性分离。

高频失分点

- 把 contextual embedding 解释成“每个词有多个预存向量”。

追问树

1. 句向量怎么从 BERT token 表示得到？
2. 为什么 [CLS] 不一定是最佳通用语义向量？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q031 RNN 为什么梯度消失/爆炸?

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

RNN

梯度

面试官在考什么：理解长依赖困难的数学原因。

题目：从链式法则解释 RNN 梯度为何随时间步指数衰减或放大。

60 秒标准回答

跨时间梯度包含多个循环 Jacobian 的乘积；若主导奇异值长期小于 1，梯度衰减，若大于 1，则爆炸。激活函数导数也会放大这一现象。

白板公式

$$\frac{\partial h_t}{\partial h_{t-k}} = \prod_i J_i$$

深度解析：Know-Why

- gradient clipping 主要治爆炸，不解决长期消失。
- 正交/单位初始化可改善早期稳定性。
- LSTM、残差、Attention 都是在建立更短/更稳定的信息路径。

高频失分点

- 只说“因为 sigmoid”。
- 把 exploding 与 vanishing 的解决方法混为一谈。

追问树

1. 为什么 tanh 也会梯度消失?
2. Truncated BPTT 是什么?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q032 LSTM 为什么缓解长依赖问题？

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

LSTM Gate

面试官在考什么：理解 cell state 的加法路径。

题目：LSTM 的 cell state 为什么比普通 RNN 更利于梯度传播？

60 秒标准回答

LSTM 将 cell update 设计成加法路径 $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$ ；当 forget gate 接近 1 时，跨时间导数可接近恒等映射，减少连续非线性乘积造成的衰减。

白板公式

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

深度解析：Know-Why

- 门控让模型学习“写入、保留、输出”。
- 并非完全消除梯度问题，只是显著改善。
- 长序列并行性仍弱，这是 Transformer 取代 RNN 的重要原因之一。

高频失分点

- 把 LSTM 说成“不会梯度消失”。

追问树

1. forget gate bias 为什么常初始化为正值？
2. LSTM 与 Highway/Residual 的共同思想？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q033 GRU 与 LSTM 怎么选？

难度 ★★ 频率 ★★★★★ 依据高频公开题型

GRU

LSTM

面试官在考什么：考察参数与表达能力的 trade-off。

题目：GRU 的 reset/update gate 与 LSTM 的多门结构有何差异？

60 秒标准回答

GRU 合并了 cell/hidden state，门更少、参数更少；LSTM 控制更细。性能没有绝对结论，应结合数据、序列长度、延迟和模型规模。

深度解析：Know-Why

- GRU update gate 同时承担部分 forget/input 的作用。
- 小数据或轻量模型场景 GRU 仍可能有优势。
- 现代大规模 NLP 主干更多使用 Transformer，但 RNN 在流式/时序任务仍有价值。

高频失分点

- 说“GRU 是简化版所以一定差”。

追问树

1. 双向 GRU 能否用于自回归生成？
2. 流式推理为什么 RNN 有天然优势？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q034 Seq2Seq 为什么需要 Attention?

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

Seq2Seq

Attention

面试官在考什么：理解固定向量瓶颈如何催生 Attention。

题目：原始 Encoder-Decoder 将整个源句压成一个向量有什么问题？Attention 如何解决？

60 秒标准回答

固定长度上下文向量对长序列构成信息瓶颈。Attention 让 decoder 在每个生成步骤对所有 encoder hidden states 动态加权读取，不必依赖单一最终状态。

深度解析：Know-Why

- Bahdanau additive attention 与 dot-product attention 计算形式不同。
- Attention 权重可视为软对齐，但不应简单当作解释性真值。
- Transformer 进一步去掉递归，直接用 attention 建 token-to-token 交互。

高频失分点

- 只说 “Attention 让模型关注重要词” 过于空泛。

追问树

1. 为什么 dot-product 更适合 GPU?
2. Encoder-Decoder attention 与 self-attention 的 Q/K/V 来源分别是什么?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

第 4 篇

Transformer 核心原理

本篇目标：这是全书权重最高的一篇：要求会画结构、会推公式、会算复杂度、会解释工程取舍。

题目范围：Q35 Self-Attention 的完整计算流程、Q36 为什么 Attention 要除以 $\sqrt{d_k}$?、Q37 为什么 Q、K、V 要用不同投影?、Q38 Multi-Head Attention 为什么不是一个大 Head?、Q39 Self-Attention 的复杂度到底是多少?、Q40 Causal Mask 是怎么工作的?、Q41 为什么 Transformer 必须注入位置信息?、Q42 Sinusoidal Positional Encoding 的设计直觉、Q43 RoPE：如何把相对位置写进 QK 点积?、Q44 为什么 RoPE 通常只作用于 Q/K，不作用于 V?、Q45 RoPE 为什么会有长度外推问题? YaRN/PI 在解决什么?、Q46 Pre-LN 与 Post-LN：为什么深层模型更偏 Pre-Norm?、Q47 Transformer 为什么 Attention 后还需要 FFN?、Q48 GELU、ReLU 与 SiLU/SwiGLU 怎么比较?、Q49 SwiGLU 为什么成了现代 LLM 常客?、Q50 MHA、MQA、GQA：为什么共享 K/V 能省 KV Cache?

Q035 Self-Attention 的完整计算流程

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

Transformer

QKV

面试官在考什么：Transformer 第一必答题。

题目：从 X 到 Q/K/V、score、softmax、output，完整写出 Self-Attention。

60 秒标准回答

线性投影得到 $Q=XW_Q$ 、 $K=XW_K$ 、 $V=XW_V$ ；计算缩放点积 $QK^T/\sqrt{d_k}$ ，加入 mask 后 softmax 得到注意力权重，再乘 V 聚合内容。

白板公式

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}} + M\right)V$$

深度解析：Know-Why

- Q/K 决定匹配， V 提供被读取内容。
- mask 应在 softmax 前加到 logits。
- 实现时最常见错误是 shape、transpose、softmax dimension。

高频失分点

- 忘记 scale。
- 把 softmax 做在 query 维。

追问树

1. cross-attention 时 $Q/K/V$ 来自哪里？
2. 为什么可以把 attention 看成 content-addressable memory？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q036 为什么 Attention 要除以 $\sqrt{d_k}$?

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

Attention

数值稳定

面试官在考什么：经典 “Know-Why” 题。

题目：如果 Q、K 分量方差约为 1，点积的方差随 d_k 如何变化？

60 秒标准回答

点积是 d_k 项随机变量之和，方差约随 d_k 增长。logit 过大使 softmax 饱和，梯度集中甚至接近 0。除以 $\sqrt{d_k}$ 将尺度稳定在 $O(1)$ 。

白板公式

$$\text{Var}(q^\top k) \approx d_k \quad \Rightarrow \quad \text{Var}\left(\frac{q^\top k}{\sqrt{d_k}}\right) \approx 1$$

深度解析：Know-Why

- 这是 variance control，不是为了“让结果小于 1”。
- 若初始化/归一化方式改变，实际分布会不同，但 scale 仍是稳健设计。
- FlashAttention 不改变这个数学定义。

高频失分点

- 说“防止梯度爆炸”但没有 softmax 饱和链路。

追问树

1. 为什么不是除 d_k ?
2. cosine attention 是否还需要类似温度?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q037 为什么 Q、K、V 要用不同投影？

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

QKV

表示

面试官在考什么：考察“匹配空间”与“内容空间”解耦。

题目：为什么不能简单令 $Q=K=V=X$ ？

60 秒标准回答

Q/K 负责定义“谁与谁相关”，V 负责定义“相关后读取什么”。独立投影允许模型在匹配空间与内容空间学习不同子空间，从而提高表达能力。

深度解析：Know-Why

- Self-attention 中输入同源不代表表示角色相同。
- Cross-attention 更直观：Q 来自 decoder，K/V 来自 encoder。
- 部分高效架构会共享/压缩 K/V，但不是取消角色分工。

高频失分点

- 回答成“因为论文这么设计”。

追问树

1. Q 和 K 能不能共享矩阵？有什么代价？
2. MQA/GQA 共享的到底是什么？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q038 Multi-Head Attention 为什么不是一个大 Head?

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

MHA 子空间

面试官在考什么：解释多头的表示意义和工程实现。
题目：多个 head 与一个同维度的大 head 有什么本质区别？

60 秒标准回答

每个 head 拥有独立 Q/K/V 投影并在较低维子空间计算 attention, 可并行学习不同关系模式; concat 后再用 W_O 混合。它引入结构化的多子空间分解。

深度解析：Know-Why

- 多头不保证每个 head 自动对应人类可解释功能。
- 头数增加会减小每头维度，过多可能损伤表达。
- 现代模型还有 head pruning、GQA 等结构变化。

高频失分点

- 说“每个头看不同位置”但无机制解释。

追问树

1. 为什么 d_model 通常能被 h 整除？
2. 不同 head 的 attention matrix 是否彼此独立？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q039 Self-Attention 的复杂度到底是多少？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

复杂度

长上下文

面试官在考什么：要求拆出 projection、attention、FFN 而非只背 $O(n^2)$ 。

题目：给定序列长 n 、hidden d ，Transformer block 的主要计算复杂度有哪些？

60 秒标准回答

QKV/输出投影约 $O(nd^2)$ ，attention score 与加权约 $O(n^2d)$ ，FFN 约 $O(nd\ d_{ff})$ 。长序列时 n^2 项主导；大 d 、短序列时矩阵投影/FFN 也可能主导。

深度解析：Know-Why

- Attention memory 传统实现需要存 $n \times n$ score/概率。
- FlashAttention 降低 HBM IO 和中间内存，但数学复杂度仍是 quadratic。
- KV cache 改变的是自回归 decode 的重复计算结构。

高频失分点

- 只写 $O(n^2)$ 不说明 d 。
- 把 FlashAttention 说成线性 attention。

追问树

1. 什么时候 FFN FLOPs 比 attention 更大？
2. 长上下文有哪些稀疏/线性近似路线？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q040 Causal Mask 是怎么工作的？

难度 ★★ 频率 ★★★★★ 依据高频公开题型

Mask

Decoder

面试官在考什么：实现必会，方向错一行就泄漏未来。

题目：GPT 的 causal mask 应屏蔽哪一半矩阵？为什么是在 softmax 前加 $-\infty$ ？

60 秒标准回答

第 i 个 query 只能访问位置 $\leq i$ 的 key，未来位置 logit 加 $-\infty$ ，softmax 后概率变为 0。实际实现需同时处理 padding、cache offset 与 batch shape。

深度解析：Know-Why

- 常见矩阵约定 row=query、col=key，因此是上三角 future 区域被屏蔽。
- prefill 时是完整三角 mask；单 token decode 配合 cache 时通常无需显式大三角矩阵。
- mask dtype 与极小值选择需兼顾 FP16/BF16。

高频失分点

- 方向反了导致训练 label leakage。
- mask broadcast shape 错。

追问树

1. padding mask 与 causal mask 如何合并？
2. KV cache 时 position offset 如何影响 mask？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q041 为什么 Transformer 必须注入位置信息？

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

Position

Permutation

面试官在考什么：理解 attention 的置换等变性。

题目：没有位置编码时，Transformer 能区分“狗咬人”和“人咬狗”吗？

60 秒标准回答

纯 self-attention 对输入 token 的置换具有等变性，本身没有绝对顺序概念。必须通过绝对、相对或旋转位置机制把序列位置注入计算。

深度解析：Know-Why

- 位置可以加到 embedding，也可作用在 attention score/QK 上。
- 不同机制对长度外推、相对关系与实现成本影响不同。
- 因果 mask 本身提供部分顺序约束，但不等价于完整位置表示。

高频失分点

- 说“因为 RNN 有顺序而 Transformer 没有”但不够形式化。

追问树

1. 只用 causal mask 能不能完全替代 position encoding?
2. 相对位置编码有什么优势?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q042 Sinusoidal Positional Encoding 的设计直觉

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

位置编码

频率

面试官在考什么：理解不同频率与相对位移关系。

题目：为什么正弦位置编码使用不同频率的 $\sin/\cos$ ？

60 秒标准回答

不同维度使用不同波长，可把位置映射到多尺度周期信号； $\sin/\cos$ 的角度加法关系使相对位移可由线性组合表达，同时无需学习参数。

深度解析：Know-Why

- 低频维度表达长尺度，高频维度表达局部变化。
- 理论上可生成任意位置，但模型是否能外推仍取决于训练。
- 绝对相加式位置编码会同时影响 Q/K/V 的输入。

高频失分点

- 说“因为 $\sin/\cos$ 连续所以能外推”过度简化。

追问树

1. 为什么成对使用 $\sin$ 与 $\cos$ ？
2. learned absolute position 的优缺点？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q043 RoPE: 如何把相对位置写进 QK 点积?

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

RoPE

长上下文

面试官在考什么: 现代 LLM 核心必考。

题目: 请用二维旋转说明 RoPE。为什么 $q_m^\top k_n$ 最终只与相对位置 $m-n$ 有关?

60 秒标准回答

RoPE 将 Q/K 的二维通道成对旋转, 位置 m 对应旋转 R_m 。由于 $R_m^\top R_n = R_{\{n-m\}}$, 点积自然只依赖相对旋转差, 从而把相对位置信息编码进 attention score。

白板公式

$$q_m = R_m W_Q x_m, \quad k_n = R_n W_K x_n, \quad q_m^\top k_n = x_m^\top W_Q^\top R_{n-m} W_K x_n$$

深度解析: Know-Why

- 不是给 embedding 直接加位置向量。
- 不同通道使用不同旋转频率。
- RoPE 兼具绝对相位和相对点积性质, 是现代 decoder LLM 常用方案。

高频失分点

- 只会画旋转矩阵, 不会解释 $R_m^\top R_n$ 。
- 把 RoPE 当作可学习参数。

追问树

1. RoPE 的 base/频率如何影响长上下文?
2. 为什么只旋转 Q/K?

复习动作: 先闭卷讲 60 秒, 再任选一个追问继续讲 3 分钟。

Q044 为什么 RoPE 通常只作用于 Q/K，不作用于 V？

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

RoPE

QKV

面试官在考什么：检验是否真正理解位置影响路径。

题目：如果 V 也做旋转会怎样？为什么主流实现只对 Q/K 做 RoPE？

60 秒标准回答

位置需要直接影响“注意力路由”，即 $q \cdot k$ 的相关性。V 承载被聚合的内容表示；对 V 强制旋转会让内容本身随绝对位置变换，增加不必要耦合。

深度解析：Know-Why

- 这是设计选择而非严格定理。
- 最终输出仍通过 attention weights 间接包含位置影响。
- 某些变体可能对 value 做其他位置相关处理，但需重新验证。

高频失分点

- 说“V 不需要位置”过度绝对。

追问树

1. 如果没有 W_O ，会发生什么？
2. 相对位置 bias 与 RoPE 的作用位置有何不同？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q045 RoPE 为什么会有长度外推问题？YaRN/PI 在解决什么？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

RoPE Scaling

Long Context

面试官在考什么：长上下文岗位区分度高。

题目：训练长度 4K，直接推到 64K 时为什么性能可能崩？位置插值/频率缩放的核心思想是什么？

60 秒标准回答

超出训练区间后，RoPE 相位与频率组合进入未见分布，高频维度尤其容易快速旋转。位置插值、NTK-aware scaling、YaRN 等方法本质上重新映射位置或频率，使更长上下文落入模型可适应的相位范围。

深度解析：Know-Why

- 不能只靠把 `max_position_embeddings` 改大。
- 外推不仅是 attention 位置，还涉及训练数据是否包含长依赖。
- 不同 frequency band 可能需要不同缩放策略。

高频失分点

- 把所有方法统称“把位置除一个数”。

追问树

1. 为什么高频和低频维度的外推困难不同？
2. 长上下文评测应如何防止“只会 passkey”假提升？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q046 Pre-LN 与 Post-LN：为什么深层模型更偏 Pre-Norm？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

Normalization

Residual

面试官在考什么：考察梯度路径。

题目：原始 Transformer 的 Post-LN 与现代常见 Pre-LN 有什么差别？

60 秒标准回答

Post-LN 是 $\text{LN}(x+F(x))$ ；Pre-LN 是 $x+F(\text{LN}(x))$ 。Pre-LN 保留更直接的 identity residual path，深层网络梯度传播通常更稳定。

深度解析：Know-Why

- Post-LN 有时最终表示质量更好但更难训练，需要 warmup/初始化技巧。
- RMSNorm 常与 Pre-Norm 组合。
- 稳定训练还涉及 residual scaling、初始化、深度等。

高频失分点

- 只说“Pre-LN 更稳定”不会解释 residual Jacobian。

追问树

1. 为什么 Pre-LN 可能导致有效深度问题？
2. DeepNorm/ μ Param 等方法解决什么？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q047 Transformer 为什么 Attention 后还需要 FFN?

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

FFN

Token Mixing

面试官在考什么：区分 token mixing 与 channel mixing。

题目：如果 Attention 已经让所有 token 交互，为什么每层还要大 FFN?

60 秒标准回答

Attention 主要在序列维度路由/混合 token 信息；FFN 对每个位置独立进行高容量非线性特征变换，在 hidden/channel 维度完成表示重组。两者互补。

深度解析：Know-Why

- 经典 FFN 是升维 → 激活 → 降维。
- 现代 LLM 中 FFN 参数量常占 block 很大比例。
- MoE 主要替换/扩展的正是 FFN 子层。

高频失分点

- 说 FFN 只是“增加非线性”不够。

追问树

1. d_{ff} 为什么常大于 d_{model} ?
2. SwiGLU 为什么通常需要三组投影?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q048 GELU、ReLU 与 SiLU/SwiGLU 怎么比较？

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

激活函数

面试官在考什么：从经典 Transformer 过渡现代 LLM。

题目：BERT 用 GELU，很多现代 LLM 用 SwiGLU，核心差异是什么？

60 秒标准回答

ReLU 硬截断负值；GELU 平滑按输入大小门控；SiLU 也是平滑自门控。SwiGLU 进一步使用两路线性投影做乘法 gate，提升 FFN 表达能力。

深度解析：Know-Why

- 平滑激活通常对大规模优化更友好。
- SwiGLU 的参数/FLOPs 需通过中间维度调整与普通 FFN 对齐。
- 激活选择与初始化、精度、硬件 kernel 也相关。

高频失分点

- 只背公式不谈结构。

追问树

1. 为什么 gated FFN 更有表达力？
2. SiLU 的导数有什么特点？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q049 SwiGLU 为什么成了现代 LLM 常客?

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

SwiGLU

FFN

面试官在考什么：理解 gated MLP 的具体计算。

题目：写出 SwiGLU 的计算图，并解释 gate 分支的作用。

60 秒标准回答

输入分别经过 value/up 投影与 gate 投影，gate 分支经 SiLU 后与 value 分支逐元素相乘，再做 down projection。模型可学习按特征动态控制信息通过。

深度解析：Know-Why

- 与单路线性 + 激活相比，多一条门控分支增加参数与计算。
- 常通过减小 intermediate size 保持总参数/FLOPs 接近。
- gate saturation、低精度 kernel 实现也影响效率。

高频失分点

- 把 SwiGLU 写成 SiLU(Wx) 后直接 W2。

追问树

1. GEGLU 与 SwiGLU 区别？
2. 为什么乘法交互常比纯加法更强？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q050 MHA、MQA、GQA: 为什么共享 K/V 能省 KV Cache?

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

GQA

KV Cache

面试官在考什么: 连接模型结构与推理内存。

题目: MHA、MQA、GQA 的 Q head 与 KV head 数量关系是什么?

60 秒标准回答

MHA 每个 Q head 对应独立 K/V head; MQA 所有 Q heads 共用一组 K/V; GQA 多个 Q heads 共享一组 KV, 在质量与 cache/带宽之间折中。KV cache 大小与 KV head 数近似线性相关。

深度解析: Know-Why

- Decode 阶段常 memory-bandwidth bound, 因此减少 K/V 很有价值。
- GQA 不直接减少 Q/O 投影或 FFN 参数。
- 训练质量损失与共享粒度有关。

高频失分点

- 说 GQA 是“减少 attention heads”不准确。

追问树

1. 给定 32 Q heads、8 KV heads, group size 是多少?
2. MQA 为什么可能损失质量?

复习动作: 先闭卷讲 60 秒, 再任选一个追问继续讲 3 分钟。

第 5 篇

BERT、GPT 与大模型预训练

本篇目标：从训练目标、Tokenizer、Scaling 到 MoE，回答要同时连接建模与数据。

题目范围：Q51 BERT 原始预训练任务：MLM 与 NSP、Q52 为什么 BERT 不能天然像 GPT 一样左到右生成？、Q53 BERT 与 GPT：双向理解和因果生成如何取舍？、Q54 BPE、WordPiece、Unigram/SentencePiece 有什么区别？、Q55 为什么 LLM 普遍使用 Subword/Byte Tokenization？、Q56 Decoder LM Loss：为什么每个 token 都是监督信号？、Q57 Perplexity：什么时候能比、什么时候不能比？、Q58 Weight Tying：为什么输入 Embedding 与 LM Head 可以共享？、Q59 Scaling Law：为什么不能只堆参数？、Q60 大模型训练为什么必须去重？、Q61 为什么“数据质量越高越好”是危险说法？、Q62 Mixed Precision：BF16 为什么常比 FP16 稳？、Q63 Gradient Checkpointing：省了什么、付出什么？、Q64 MoE：为什么参数变大但每 token 计算不同比例增长？

Q051 BERT 原始预训练任务：MLM 与 NSP

难度 ★★ 频率 ★★★★★ 依据高频公开题型

BERT

Pretraining

面试官在考什么：理解 encoder-only 训练信号。

题目：BERT 的 MLM 与 NSP 分别做什么？后来为什么很多模型去掉 NSP？

60 秒标准回答

MLM 随机遮蔽部分 token，用双向上下文预测；NSP 判断两段是否连续。后续工作发现更长训练、更多数据、更合理 sentence packing 等比 NSP 本身更关键，因此不少模型取消或替换它。

深度解析：Know-Why

- MLM 训练/推理存在 [MASK] mismatch。
- 动态 masking 可让不同 epoch 看到不同 mask。
- BERT 的双向性来自非 causal self-attention。

高频失分点

- 把 MLM 说成自回归。

追问树

1. 15% mask 的 token 如何处理？
2. SOP 与 NSP 有什么不同？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q052 为什么 BERT 不能天然像 GPT 一样左到右生成？

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

BERT vs GPT

面试官在考什么：从概率分解解释架构差异。

题目：BERT 会预测词，为什么不能直接当 GPT 用？

60 秒标准回答

BERT 的 MLM 学的是被遮蔽位置在双向上下文条件下的条件分布，并没有训练完整的自回归链式分解。GPT 直接优化 $P(x_t|x_{<t})$ ，与逐 token 生成过程一致。

深度解析：Know-Why

- 可以用 Gibbs-like iterative masking 生成，但效率与分布不同。
- Encoder-only 更适合表示/理解；decoder-only 统一生成接口。
- Prefix-LM/encoder-decoder 是中间路线。

高频失分点

- 回答“因为 BERT 是 encoder，GPT 是 decoder”但不说明训练目标。

追问树

1. T5 为什么能生成？
2. BERT 做填空生成的局限？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q053 BERT 与 GPT：双向理解和因果生成如何取舍？

难度 ★★ 频率 ★★★★★ 依据高频公开题型

Encoder vs Decoder

面试官在考什么：面试必须能从 attention mask、objective、任务形态三层比较。

题目：BERT 与 GPT 的核心差异是什么？

60 秒标准回答

BERT encoder 使用双向 self-attention, 适合固定输入上的表征与判别; GPT decoder 使用 causal mask 做自回归 next-token prediction, 天然适合开放式生成与 in-context learning。

深度解析：Know-Why

- BERT 并非不能做生成，GPT 也不只做生成，但 inductive bias 不同。
- 大规模 decoder-only 通过 prompt 将很多理解任务转成生成。
- 检索双塔仍大量使用 encoder，因为吞吐和向量表示更经济。

高频失分点

- 把“encoder 更懂语义”当作绝对事实。

追问树

1. 为什么 decoder-only 成为通用 LLM 主流？
2. encoder-decoder 在翻译/条件生成中的优势？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q054 BPE、WordPiece、Unigram/SentencePiece 有什么区别？

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

Tokenizer

面试官在考什么：Tokenizer 是数据与模型接口。

题目：比较 BPE、WordPiece、Unigram；SentencePiece 又是什么层级的概念？

60 秒标准回答

BPE 迭代合并高频 pair；WordPiece 使用与似然/评分相关的合并准则；Unigram 从候选子词集合出发，通过概率模型逐步删减。SentencePiece 是可直接在原始文本上训练/编码的工具框架，常实现 BPE 或 Unigram。

深度解析：Know-Why

- Tokenizer 决定序列长度、词表大小、数字/代码切分和多语言公平性。
- byte-level 方法可避免 OOV。
- 同一模型参数量下，tokenizer 改变实际可见字符长度与训练 token 预算。

高频失分点

- 把 SentencePiece 当作一种唯一算法。

追问树

1. 为什么中文/代码的 token fertility 很重要？
2. tokenizer vocabulary 越大越好吗？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q055 为什么 LLM 普遍使用 Subword/Byte Tokenization?

难度 ★★ 频率 ★★★★★☆ 依据高频公开题型

Tokenizer

OOV

面试官在考什么：理解词表大小与序列长度的折中。

题目：word-level、character-level、subword 各有什么问题？

60 秒标准回答

词级词表巨大且 OOV；字符级词表小但序列过长。Subword/byte 方案在开放词汇覆盖与序列长度之间折中，并能组合罕见词。

深度解析：Know-Why

- 词表增大可缩短序列但增加 embedding/LM head 参数。
- byte fallback 保证任意 Unicode 内容可编码。
- 多语言 tokenizer 的 token 分配会影响不同语言的计算公平性。

高频失分点

- 只说“解决 OOV”。

追问树

1. 数字为什么经常被奇怪切分？
2. Tokenizer 会影响算术能力吗？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q056 Decoder LM Loss: 为什么每个 token 都是监督信号?

难度 ★★ 频率 ★★★★★ 依据高频公开题型

Next-token Prediction

面试官在考什么: 理解预训练目标与数据规模。

题目: 写出自回归语言模型的因子分解和 loss。

60 秒标准回答

通过链式法则把序列概率分解为每个位置的 next-token 条件概率; 训练时 teacher forcing 一次前向可对多个位置并行计算交叉熵, 因此每个 token 都提供监督。

白板公式

$$P(x_{1:T}) = \prod_{t=1}^T P(x_t | x_{<t}), \quad L = - \sum_t \log P(x_t | x_{<t})$$

深度解析: Know-Why

- 训练可并行, 但生成必须按序列依赖逐步 decode。
- padding/packing 时要正确构造 loss mask。
- instruction tuning 常只对 assistant 部分计算 loss。

高频失分点

- 把“预测下一个词”误认为训练也是一个 token 一个 token 跑。

追问树

1. 为什么 teacher forcing 会产生 exposure bias?
2. packing 多条文档时边界如何处理?

复习动作: 先闭卷讲 60 秒, 再任选一个追问继续讲 3 分钟。

Q057 Perplexity: 什么时候能比、什么时候不能比?

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

PPL

Eval

面试官在考什么: 避免指标误用。

题目: PPL 的定义是什么? 为什么不同 tokenizer 的 PPL 不宜直接横比?

60 秒标准回答

PPL 是平均 token NLL 的指数。Tokenizer 改变 token 单位与序列长度, 因此 “每 token 困惑度” 基准不同; 同 tokenizer、同数据预处理下比较更有意义。

深度解析: Know-Why

- PPL 是 intrinsic metric, 不保证下游任务能力。
- 文档边界、context length 与评测 sliding window 都会影响结果。
- 可以用 bits-per-byte/character 增强跨 tokenizer 可比性。

高频失分点

- PPL 越低就宣称模型所有能力更强。

追问树

1. 为什么中文与英文 PPL 不能直接比?
2. PPL 与 cross-entropy 的关系?

复习动作: 先闭卷讲 60 秒, 再任选一个追问继续讲 3 分钟。

Q058 Weight Tying: 为什么输入 Embedding 与 LM Head 可以共享?

难度 ★★ 频率 ★★★☆☆ 依据高频公开题型

Embedding

LM Head

面试官在考什么: 理解词表输入输出对偶结构。

题目: 把 input embedding E 与 output projection W 设为 E^T 有什么好处?

60 秒标准回答

输入和输出都位于同一词汇空间, 共享参数可减少大词表带来的参数量, 并鼓励输入/输出语义表示对齐。

深度解析: Know-Why

- 大词表模型中 embedding/head 可占显著参数。
- 共享后两端梯度共同更新同一矩阵。
- 并非所有架构都必须 tying, 维度/并行策略也会影响。

高频失分点

- 认为 tying 不改变训练动态。

追问树

1. 输出 bias 还需要吗?
2. 矩阵并行下怎么切词表 head?

复习动作: 先闭卷讲 60 秒, 再任选一个追问继续讲 3 分钟。

Q059 Scaling Law: 为什么不能只堆参数?

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

Scaling

Compute

面试官在考什么：理解参数、数据、算力的联合预算。

题目：Scaling law 说明了什么？为什么固定数据量无限增大模型不是高效策略？

60 秒标准回答

经验上 loss 对模型规模、数据量、计算量呈近似幂律下降，但存在资源配比。模型增大时若数据不足，会进入 data-limited 区域；反之小模型过度训练也可能 compute-inefficient。

深度解析：Know-Why

- 不同研究给出的最优 token/parameter 比例依赖设定。
- 现代训练还受数据质量、重复、多模态、后训练目标影响。
- Scaling law 是经验规律，不是所有能力的精确预测公式。

高频失分点

- 死记某个 “20 tokens/param” 比例当永恒定律。

追问树

1. Chinchilla-style compute optimality 的核心结论？
2. 为什么 inference cost 会改变最优训练选择？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q060 大模型训练为什么必须去重？

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

Dedup

Memorization

面试官在考什么：数据工程高频。

题目：同一网页重复 100 次会发生什么？Exact、MinHash、substring dedup 分别解决什么？

60 秒标准回答

重复相当于隐式上采样，会浪费 compute、扭曲分布、增加记忆与 benchmark contamination 风险。精确去重查完全相同，MinHash 查近重复文档，substring/句子去重查局部复制。

深度解析：Know-Why

- 去重“越彻底越好”也不成立：重复频率可能携带重要性信号。
- 保留哪个代表文档应考虑质量与 provenance。
- 多阶段去重往往需要外部排序/索引，不能简单单遍流式完成。

高频失分点

- 只会说 hash 去重。

追问树

1. MinHash 为什么能估计 Jaccard?
2. 跨语言/改写语义重复怎么处理?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q061 为什么“数据质量越高越好”是危险说法？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

Data Quality

Distribution

面试官在考什么：考察数据分布工程意识。

题目：如果只保留最像 Wikipedia/教材的文本，会发生什么？

60 秒标准回答

过强过滤提高平均可读性，但可能降低覆盖、多样性、长尾与独特 token 数。真正目标应是训练效用，而不是某个单一 quality classifier 分数。

深度解析：Know-Why

- 质量模型本身带有教师偏好与域偏差。
- 高质量小数据重复多 epoch 可能不如更大、适度噪声的数据。
- 应通过小模型/proxy training 与 downstream ablation 验证过滤策略。

高频失分点

- “越干净越好”是典型错误。

追问树

1. 如何设计 quality bucket?
2. 如何量化 diversity 与 coverage?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q062 Mixed Precision: BF16 为什么常比 FP16 稳?

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

BF16

Numerical

面试官在考什么：基础训练工程题。

题目：FP16、BF16、FP32 在 exponent/mantissa 上有什么关键差异？

60 秒标准回答

BF16 与 FP32 拥有相同 exponent 位数，动态范围大，虽然尾数精度较低，但更不易因大/小值溢出；FP16 尾数更细但 exponent 窄，常需要 loss scaling。

深度解析：Know-Why

- 权重、激活、梯度、optimizer state 不一定全部同精度。
- 矩阵乘可用低精度输入、高精度累加。
- 低精度训练的瓶颈不仅是表示，还包括 kernel 与通信。

高频失分点

- 把 BF16 说成“精度比 FP16 高”。

追问树

1. 什么是 dynamic loss scaling?
2. FP8 训练又多了哪些校准问题?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q063 Gradient Checkpointing: 省了什么、付出什么?

难度 ★★ 频率 ★★★★★☆ 依据高频公开题型

Memory

Recompute

面试官在考什么: 理解 activation memory 与 compute trade-off。

题目: 为什么 checkpointing 能显著省显存?

60 秒标准回答

正常反向传播需保存中间 activation; checkpointing 只保留部分节点, 反向时重新 forward 计算丢失 activation, 因此以额外 FLOPs 换取更低峰值内存。

深度解析: Know-Why

- 对超长序列/深层模型 activation memory 很可观。
- checkpoint 粒度影响重算比例与调度开销。
- 与 offload、ZeRO、sequence parallel 可组合。

高频失分点

- 误以为减少 optimizer state。

追问树

1. 如何选择 checkpoint 边界?
2. 为什么重算会影响随机 dropout 一致性?

复习动作: 先闭卷讲 60 秒, 再任选一个追问继续讲 3 分钟。

Q064 MoE：为什么参数变大但每 token 计算不同比例增长？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

MoE

Routing

面试官在考什么：连接模型容量、稀疏激活与通信。

题目：Top-k MoE 如何工作？主要工程难点是什么？

60 秒标准回答

Router 为每个 token 选择少数 experts，仅激活对应 FFN；因此总参数可随 expert 数增长，而每 token FLOPs 近似只与激活的 k 个 experts 相关。难点是负载均衡、路由、all-to-all 通信与容量溢出。

深度解析：Know-Why

- 通常 attention 仍是 dense，MoE 替换 FFN。
- load balancing auxiliary loss 防止所有 token 挤向少数 expert。
- Expert Parallel 把不同 experts 分布到设备。

高频失分点

- 说“MoE 推理完全不增加内存”。

追问树

1. 什么是 expert capacity factor?
2. router z-loss / aux loss 的作用?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

第 6 篇

SFT、PEFT 与对齐

本篇目标：后训练不只是记术语；重点是目标函数、数据语义、稳定性和何时选择哪种方法。

题目范围：Q65 Pretraining 与 SFT 的本质区别、Q66 LoRA 的低秩假设到底是什么？、Q67 LoRA 应该加 Q/V 还是加所有 Linear？、Q68 QLoRA 为什么能在更小显存上微调大模型？、Q69 知识蒸馏有哪些层级？、Q70 RLHF 的经典 Pipeline 与 KL 约束、Q71 REINFORCE 是 On-policy 还是 Off-policy？、Q72 REINFORCE 为什么加 Baseline 不引入偏差？、Q73 DPO 为什么不需要显式 Reward Model？、Q74 PPO、DPO、GRPO：什么时候选哪一个？

Q065 Pretraining 与 SFT 的本质区别

难度 ★★ 频率 ★★★★★ 依据高频公开题型

SFT

Objective

面试官在考什么：区分世界建模与行为监督。

题目：Pretraining 和 SFT 的数据形态、loss mask、目标分别是什么？

60 秒标准回答

预训练主要对自然文本做 next-token modeling，学习语言/知识分布；SFT 用 instruction-response 等行为数据教模型如何按期望方式响应，常只对 assistant tokens 计算 loss。

深度解析：Know-Why

- SFT 数据量通常远小于预训练，但监督密度更高。
- 把 QA 全文当普通 LM 训练更接近 mid-training；只训 answer 更接近 SFT。
- SFT 会塑造风格，也可能造成能力遗忘，需要数据混合与学习率控制。

高频失分点

- 把 SFT 说成“继续预训练”而不区分监督掩码。

追问树

1. 为什么 SFT 后模型更会遵循指令？
2. SFT 数据重复会有什么风险？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q066 LoRA 的低秩假设到底是什么？

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

LoRA PEFT

面试官在考什么：必须会公式、参数量和部署。

题目：LoRA 为什么只学习 BA 而冻结 W0？rank r 表示什么？

60 秒标准回答

假设任务适配所需权重增量 ΔW 位于低维子空间，可写为 BA，其中 $r \ll d$ 。这样显著减少可训练参数与 optimizer state，同时保留基座权重。

白板公式

$$W = W_0 + \Delta W = W_0 + BA, \quad A \in \mathbb{R}^{r \times d_{in}}, B \in \mathbb{R}^{d_{out} \times r}$$

深度解析：Know-Why

- 通常 B 可零初始化，使初始 $\Delta W=0$ 。
- 有 scaling α/r 控制更新尺度。
- 推理可将 LoRA merge 回原权重，或动态加载多个 adapter。

高频失分点

- 说“LoRA 是低精度训练”。

追问树

1. 参数量如何计算？
2. rank 越大是否一定越好？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q067 LoRA 应该加 Q/V 还是加所有 Linear?

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

LoRA Target Modules

面试官在考什么：考察适配容量与成本选择。

题目：早期常只对 Q/V 加 LoRA，为什么今天也常覆盖 K/O/FFN?

60 秒标准回答

LoRA 本质适用于任何线性层。只加少数 attention 投影参数少、成本低；覆盖 FFN 与更多投影提供更大适配容量。应由任务、预算和 ablation 决定。

深度解析：Know-Why

- FFN 往往占大量参数，因此对领域迁移可能重要。
- 不同模块对 rank 敏感性不同。
- QLoRA 中基座量化不改变 LoRA 的目标模块逻辑。

高频失分点

- 把“Q/V 最优”当固定结论。

追问树

1. 如何用 rank allocation 做自适应 LoRA?
2. adapter merge 后还能切换任务吗?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q068 QLoRA 为什么能在更小显存上微调大模型？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

QLoRA

Quantization

面试官在考什么：理解 4-bit base + 高精度 adapter 的组合。

题目：QLoRA 的 NF4、double quantization、paged optimizer 分别解决什么？

60 秒标准回答

基座权重以 4-bit 量化存储并冻结，训练只更新 LoRA；NF4 针对近似正态权重设计码本，double quantization 进一步压缩量化尺度，paged optimizer 缓解显存峰值。

深度解析：Know-Why

- 计算通常需要反量化到更高精度参与 matmul。
- “4-bit 训练”不意味着所有梯度/激活都是 4-bit。
- 量化误差对不同层/任务敏感。

高频失分点

- 把 QLoRA 与 GPTQ/AWQ 纯推理量化混为一谈。

追问树

1. NF4 为什么适合正态分布权重？
2. 哪些模块通常保持更高精度？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q069 知识蒸馏有哪些层级？

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

Distillation

面试官在考什么：从 logits 到 reasoning/data distillation。

题目：Response、Feature、Relation Distillation 分别蒸馏什么？LLM 时代又出现哪些新形态？

60 秒标准回答

Response distillation 对齐教师输出分布/文本，Feature distillation 对齐中间表示，Relation distillation 对齐样本/注意力关系。LLM 时代还大量使用教师生成的 SFT、偏好、推理轨迹作为数据蒸馏。

深度解析：Know-Why

- soft target 的 temperature 可暴露类别相似性。
- 生成式数据蒸馏更依赖教师错误与风格偏差控制。
- 学生容量决定能否吸收教师全部知识。

高频失分点

- 认为学生一定能达到教师。

追问树

1. temperature 对 KL 有什么作用？
2. reasoning distillation 的隐藏风险？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q070 RLHF 的经典 Pipeline 与 KL 约束

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

RLHF

PPO

面试官在考什么：对齐主线必答。

题目：从 SFT、偏好数据、Reward Model 到 PPO，完整描述经典 RLHF。

60 秒标准回答

先 SFT 得到可用 policy; 收集偏好训练 reward model; 再用 RL 最大化奖励, 同时通过对 reference policy 的 KL penalty 防止策略过度偏离。

白板公式

$$\max_{\theta} \mathbb{E}[r(x, y)] - \beta KL(\pi_{\theta}(\cdot|x) \parallel \pi_{ref}(\cdot|x))$$

深度解析：Know-Why

- RM 学的是人类偏好代理而非客观真值。
- PPO 需要在线采样、value/advantage 等组件，成本高。
- KL 系数控制“奖励优化”与“保持原模型”之间的权衡。

高频失分点

- 把 RLHF 简化成“人打分然后强化学习”。

追问树

1. 为什么 reward hacking 会发生？
2. PPO clipping 在限制什么？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q071 REINFORCE 是 On-policy 还是 Off-policy?

难度 ★★★ 频率 ★★★★★☆ 依据高频公开题型

Policy Gradient

面试官在考什么：RL 基础真假题。

题目：写出 REINFORCE 梯度估计，并说明为什么经典形式是 on-policy。

60 秒标准回答

REINFORCE 用当前策略采样 trajectory，并用 return 乘 log-policy gradient，因此经典形式是 on-policy Monte Carlo policy gradient。

白板公式

$$\nabla J(\theta) = \mathbb{E}_{\tau \sim \pi_{\theta}} [R(\tau) \nabla_{\theta} \log \pi_{\theta}(\tau)]$$

深度解析：Know-Why

- 无 value function 的原始 REINFORCE 方差很大。
- 可以加入 baseline 不改变期望梯度。
- off-policy 需要 importance sampling 等修正。

高频失分点

- 把“使用历史 buffer”默认当 REINFORCE。

追问树

1. 为什么 log-derivative trick 成立？
2. Monte Carlo 与 TD 的差异？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q072 REINFORCE 为什么加 Baseline 不引入偏差?

难度 ★★★★★ 频率 ★★★★★☆ 依据高频公开题型

Variance Reduction

面试官在考什么：考察期望推导。

题目：为什么可以把 R 换成 $R-b(s)$? baseline 有什么约束?

60 秒标准回答

若 baseline 不依赖当前 action, 则 $E[b(s) \nabla \log \pi(a|s)] = 0$, 因此不改变梯度期望, 却可降低 return 的方差。

深度解析：Know-Why

- 最佳 baseline 与条件期望/价值函数相关。
- Advantage $A=Q-V$ 可视为中心化后的相对好坏。
- baseline 如果偷偷依赖 action, 可能引入偏差。

高频失分点

- 只说“减均值所以方差小”。

追问树

1. Actor-Critic 如何学习 baseline?
2. GAE 在做什么?

复习动作：先闭卷讲 60 秒, 再任选一个追问继续讲 3 分钟。

Q073 DPO 为什么不需要显式 Reward Model?

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

DPO Preference

面试官在考什么：后训练高频核心。

题目：给定 chosen/rejected，DPO 的优化对象是什么？与 PPO-RLHF 相比缺少了什么？

60 秒标准回答

DPO 从 KL-regularized preference model 的闭式关系出发，直接提高 chosen 相对 rejected 在 policy/reference log-ratio 上的优势，不需单独训练 RM 和在线 PPO。

白板公式

$$L = -\log \sigma \left(\beta \left[\log \frac{\pi_{\theta}(y_w|x)}{\pi_{ref}(y_w|x)} - \log \frac{\pi_{\theta}(y_l|x)}{\pi_{ref}(y_l|x)} \right] \right)$$

深度解析：Know-Why

- reference policy 提供“偏离基座多少”的基线。
- β 控制 preference 强度与 KL 约束尺度。
- DPO 更简单稳定，但依赖离线 preference 数据质量，探索能力弱于在线 RL。

高频失分点

- 说 DPO 完全没有 reward 概念。

追问树

1. 如果 chosen/rejected 差异很小会怎样？
2. IPO/KTO/ORPO 与 DPO 的动机差异？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q074 PPO、DPO、GRPO：什么时候选哪一个？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

RL Preference Reasoning

面试官在考什么：考察方法选择而非名词堆砌。
题目：比较 PPO、DPO、GRPO 类方法的数据需求、在线采样、value model 与适用场景。

60 秒标准回答

PPO 是在线 policy optimization，显式 reward/value，灵活但复杂；DPO 用离线偏好直接优化，简单稳定；GRPO 类方法对同一问题采一组候选，基于组内相对奖励构造 advantage，可省 value model，适合有可验证 reward 的 reasoning。

深度解析：Know-Why

- 可验证任务能用 unit test/答案 checker 降低 Judge 偏差。
- 在线 RL 能探索新策略，但成本和 reward hacking 风险更高。
- 不存在“新方法一定替代旧方法”。

高频失分点

- 只比较公式，不谈数据/工程条件。

追问树

1. GRPO 的组内标准化有什么作用？
2. 纯 outcome reward 会导致哪些过程错误？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

第 7 篇

检索、搜索与 RAG

本篇目标：现代 NLP 算法岗的高频能力域：召回、排序、索引、切块、负样本与端到端评测。

题目范围：Q75 Sparse Retrieval 与 Dense Retrieval 的核心差异、Q76 Bi-Encoder 与 Cross-Encoder: 为什么一快一准?、Q77 为什么搜索系统通常是多阶段 Retrieval→Rerank?、Q78 Dense Retrieval 的负样本怎么构造?、Q79 HNSW: 为什么多层小世界图能快速 ANN?、Q80 IVF-PQ: 如何用聚类与乘积量化压缩十亿向量?、Q81 RAG Chunking: 为什么“固定 500 tokens”不是答案?、Q82 Hybrid Search 与 RRF: 为什么排名融合常比 raw score 加权稳?、Q83 为什么 Reranker 通常比 Retriever 更准?、Q84 如何完整评估一个 RAG 系统?

Q075 Sparse Retrieval 与 Dense Retrieval 的核心差异

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

BM25 Dense Retrieval

面试官在考什么：现代搜索必答。
题目：BM25 与 dense retriever 各擅长什么？为什么生产常混合？

60 秒标准回答

Sparse 强于精确词面、稀有实体、数字与可解释性；Dense 把 query/document 映射到低维向量，擅长语义匹配。二者错误模式互补，混合检索常提升 recall。

深度解析：Know-Why

- Dense 需要 ANN 索引与 embedding 更新。
- Sparse 对词汇不匹配弱，但对新实体常稳。
- 多语言/跨语言检索时 dense 优势可能更明显。

高频失分点

- 把 dense 说成“永远比 BM25 好”。

追问树

1. SPLADE 属于 sparse 还是 dense?
2. hybrid score 怎么融合?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q076 Bi-Encoder 与 Cross-Encoder: 为什么一快一准?

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

Retriever

Reranker

面试官在考什么: 理解双塔索引与交互编码。

题目: Bi-Encoder 与 Cross-Encoder 的计算差异如何决定使用位置?

60 秒标准回答

Bi-Encoder 独立编码 query/document, 文档向量可离线索引, 适合大规模召回; Cross-Encoder 将 q,d 拼接后做完整 token 交互, 相关性建模更细但每个 pair 都要推理, 适合 reranking。

深度解析: Know-Why

- 双塔 score 常用 dot/cosine, 也可学习 late interaction。
- cross encoder 不适合对百万文档逐一打分。
- ColBERT 处于两者之间: 保留 token-level late interaction。

高频失分点

- 说 “Cross-Encoder 没法缓存任何东西” 过度。

追问树

1. 为什么双塔容易受 representation bottleneck 影响?
2. ColBERT 的 MaxSim 是什么?

复习动作: 先闭卷讲 60 秒, 再任选一个追问继续讲 3 分钟。

Q077 为什么搜索系统通常是多阶段 Retrieval→Rerank?

难度 ★★ 频率 ★★★★★ 依据高频公开题型

Search Pipeline

面试官在考什么：考察系统级 recall/precision/cost 权衡。

题目：为什么不直接用最强 Cross-Encoder 对全库搜索？

60 秒标准回答

大库中昂贵模型无法逐文档运行，因此先用高召回、低成本 retriever 把候选从百万/十亿缩到百/千，再用更强 reranker 精排，最后给 LLM 少量高质量 context。

深度解析：Know-Why

- 每阶段的目标不同：召回阶段优先 Recall，排序阶段优先 top quality。
- 可继续加 rule/authority/freshness 重新排序。
- 端到端优化要避免某阶段指标提升却损伤最终回答。

高频失分点

- 只说“为了快”。

追问树

1. 候选 K 取多大怎么定？
2. cascade 如何做早退？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q078 Dense Retrieval 的负样本怎么构造？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

Contrastive Learning

Negatives

面试官在考什么：检索训练核心题。

题目：随机负样本、in-batch negative、hard negative 各有什么优缺点？

60 秒标准回答

随机负样本多但太容易；in-batch 利用同批其他文档提高效率；hard negative 语义/词面接近但不相关，学习信号强。难点是 false negative：看似负例其实也能回答。

深度解析：Know-Why

- DPR 类方法常从 BM25 挖 hard negative。
- 更强 retriever 挖出的 negatives 更难，但可能形成自举偏差。
- 可用 teacher reranker/标签做 denoise。

高频失分点

- 把所有非正例都当真负例。

追问树

1. 多正例 query 如何训练？
2. temperature 对 contrastive loss 有何作用？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q079 HNSW: 为什么多层小世界图能快速 ANN?

难度 ★★★★★ 频率 ★★★★★☆ 依据高频公开题型

ANN

HNSW

面试官在考什么：向量检索工程基础。

题目：HNSW 的层级结构与 greedy search 如何工作？主要参数影响什么？

60 秒标准回答

HNSW 上层稀疏，负责长距离导航；逐层下降到更密集的底层做局部搜索。efSearch 控制查询候选宽度，M 控制图连边数，影响 recall、内存与延迟。

深度解析：Know-Why

- 构建阶段 efConstruction 影响图质量和建索引成本。
- HNSW 通常高 recall、低延迟，但内存占用较高。
- 动态增删与过滤支持取决于具体实现。

高频失分点

- 把 HNSW 说成聚类索引。

追问树

1. M 太大有什么代价？
2. 为什么图搜索会有局部最优风险？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q080 IVF-PQ: 如何用聚类与乘积量化压缩十亿向量?

难度 ★★★★★ 频率 ★★★★★☆ 依据高频公开题型

ANN

Quantization

面试官在考什么: 考察大规模向量库取舍。

题目: IVF 和 PQ 各自解决什么?

60 秒标准回答

IVF 用粗聚类把向量分桶, 查询只探测 n_{probe} 个簇以减少候选; PQ 把向量分成多个子空间并分别量化, 用短码近似距离, 显著降低内存和带宽。

深度解析: Know-Why

- $nlist/nprobe$ 控制速度-召回。
- PQ codebook 训练数据分布很重要。
- 可先用 compressed distance 粗排, 再回原向量 rerank。

高频失分点

- 误以为 PQ 是把每个维度独立 int8。

追问树

1. OPQ 为什么先旋转?
2. IVF 与 HNSW 可否组合?

复习动作: 先闭卷讲 60 秒, 再任选一个追问继续讲 3 分钟。

Q081 RAG Chunking：为什么“固定 500 tokens”不是答案？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

RAG Chunking

面试官在考什么：理解 retrieval unit 与 context trade-off。
题目：如何选择 chunk size、overlap 与边界？

60 秒标准回答

chunk 太小会丢上下文和指代，太大降低检索精度并浪费 context。应结合文档结构、标题层级、段落/语义边界、模型窗口与 query 粒度，通过 retrieval + end-to-end eval 调参。

深度解析：Know-Why

- 可做 parent-child retrieval：小块召回、大块返回。
- overlap 能缓解边界切断，但增加重复与索引量。
- 表格、代码、FAQ、合同应使用不同结构感知切分。

高频失分点

- 只按 token 数切，无结构意识。

追问树

1. 如何处理超长表格？
2. query-aware chunking 是否值得？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q082 Hybrid Search 与 RRF：为什么排名融合常比 raw score 加权稳？

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

Hybrid

RRF

面试官在考什么：Sparse+Dense 实战题。

题目：BM25 score 和 cosine score 量纲不同，如何融合？

60 秒标准回答

可做归一化后加权，但跨 query 的 score 分布不稳定。RRF 只使用各系统的 rank，以 $1/(k+\text{rank})$ 累加，减少不同打分尺度造成的校准问题。

白板公式

$$RRF(d) = \sum_j \frac{1}{k + \text{rank}_j(d)}$$

深度解析：Know-Why

- RRF 无需训练，baseline 强。
- rank-based 融合会丢失 score gap 信息。
- 可进一步学习 LambdaMART/神经融合模型。

高频失分点

- 直接 bm25+cosine 不做任何 scale 处理。

追问树

1. RRF 中 k 的作用？
2. 何时学习式融合更好？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q083 为什么 Reranker 通常比 Retriever 更准?

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

Reranking

面试官在考什么：解释 interaction 的价值。

题目：同一个 query/document，为什么 Cross-Encoder reranker 能纠正 Bi-Encoder?

60 秒标准回答

双塔在独立编码时把整段压入向量，细粒度 token 交互在打分时丢失；Cross-Encoder 允许 query token 与 document token 在每层 attention 中直接交互，可识别否定、实体关系和细微语义。

深度解析：Know-Why

- 代价是 candidate 数线性乘昂贵推理。
- 可用 smaller cross-encoder 或 listwise reranker 控制成本。
- 训练时 hard negatives 尤其重要。

高频失分点

- 认为 reranker 一定需要 LLM。

追问树

1. pointwise/pairwise/listwise ranking loss 差异?
2. 如何蒸馏 reranker 到 retriever?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q084 如何完整评估一个 RAG 系统?

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

RAG Eval

Groundedness

面试官在考什么：必须拆检索与生成，不能只看答案。

题目：设计 RAG 离线评测体系。

60 秒标准回答

至少分 retrieval 与 generation：检索看 Recall@K、MRR/NDCG、gold evidence coverage；生成看 correctness、faithfulness/groundedness、citation accuracy；最终再看 end-to-end task success、latency、cost。

深度解析：Know-Why

- 若 gold doc 未召回，生成错应归因 retrieval。
- 答案正确但引用错，仍是 groundedness/citation failure。
- LLM-as-judge 需用人工集/确定性验证校准。

高频失分点

- 只看 BLEU/ROUGE。
- 只评价生成，不评价召回。

追问树

1. 没有 gold evidence 时怎么评？
2. 线上如何做 failure taxonomy？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

第 8 篇

数据工程与 Evaluation

本篇目标：数据质量不是“看起来干净”，而是来源可追踪、错误可验证、训练后有效。

题目范围：Q85 预训练数据清洗 Pipeline 应如何设计?、Q86 Exact Dedup 与 MinHash：何时用哪一个?、Q87 Benchmark Decontamination 为什么不能只做 Exact Match?、Q88 合成数据质量：Validity、Faithfulness、Diversity、Utility、Q89 LLM-as-a-Judge 有哪些系统性偏差?、Q90 离线指标涨了，为什么线上可能变差?

Q085 预训练数据清洗 Pipeline 应如何设计？

难度 ★★★★★ 频率 ★★★★★ 依据 高频公开题型

Data Curation Pipeline

面试官在考什么：现代基础模型岗高频系统题。
题目：从 Common Crawl/文档源到可训练 shard，给出完整数据管线。

60 秒标准回答

典型链路：来源/许可登记 → 解析与正文抽取 → Unicode 规范化 → 语言识别 → 质量/重复/PII 过滤 → Exact/MinHash/substring 去重 → benchmark decontamination → 统计/分层 → tokenize/-pack/shard。每一步都应保存原因、版本和 retention。

深度解析：Know-Why

- 低成本高精度规则应尽量放前面，昂贵模型过滤放后面。
- 过滤策略需要 per-domain/per-language 校准。
- “流式 pipeline” 不代表全局去重能单遍完成。

高频失分点

- 只列步骤，不谈 observability/provenance。
- 删除样本不保存原因。

追问树

1. 为什么先抽取正文再做语言识别？
2. 如何重跑阈值而不重算昂贵信号？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q086 Exact Dedup 与 MinHash：何时用哪一个？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

Dedup

MinHash

面试官在考什么：要求会 Jaccard、LSH 概率与工程阶段。

题目：为什么 exact hash 查不到轻微改写？MinHash 如何近似 Jaccard？

60 秒标准回答

Exact 对规范化文本求 hash，只能抓完全相同；MinHash 对 shingle 集计算多个最小哈希，利用“最小哈希相等概率等于 Jaccard”的性质，再用 LSH 分桶高效找近重复。

白板公式

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}, \quad P[h_{\min}(A) = h_{\min}(B)] = J(A, B)$$

深度解析：Know-Why

- 通常先 exact 降规模，再 MinHash。
- LSH 阈值不是硬阈值，而是 S 型候选概率。
- 去重簇代表样本应按质量/provenance 选，而非随机先到。

高频失分点

- 把 MinHash 当语义 embedding。

追问树

1. band 数与每 band hash 数怎么影响召回/精度？
2. 中文做 word/char n-gram 怎么选？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q087 Benchmark Decontamination 为什么不能只做 Exact Match?

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

Contamination Eval Integrity

面试官在考什么：评测可信度核心题。
题目：预训练语料里评测题可能被改写、变量替换或只复制答案，怎么查？

60 秒标准回答

应从 exact match 扩展到 n-gram、长公共子串、规范化匹配、语义候选检索；代码/数学还需变量重命名、数值与答案泄漏检测。没有字符串命中不代表没有污染。

深度解析：Know-Why

- 需要冻结 benchmark 版本与数据 snapshot。
- 合成数据教师模型也可能记忆 benchmark 后再改写。
- 污染分析应记录文档来源与 cluster/provenance。

高频失分点

- 把去重等同去污染。

追问树

1. 训练后如何估计 contamination?
2. 语义去污染的 false positive 怎么控制?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q088 合成数据质量：Validity、Faithfulness、Diversity、Utility

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

Synthetic Data Quality

面试官在考什么：合成数据岗的核心方法论题。
题目：一条合成样本“读起来很好”为什么仍可能是坏训练数据？

60 秒标准回答

需要四层质量：Validity 样本结构成立；Faithfulness 忠于 seed/事实；Diversity 扩大支持集而非复读教师；Utility 通过实际训练验证带来边际收益。LLM Judge 只能覆盖其中部分。

深度解析：Know-Why

- 有锚改写通常比完全自由生成更易验证事实一致性。
- 可验证领域优先执行器/单元测试，而非单一 Judge。
- 最终标准是 proxy/full training ablation，而不是文本美学。

高频失分点

- 只用一个 LLM 打 1-5 分。
- 忽略 source lineage。

追问树

1. 怎样做 atomic claim verification?
2. 合成比例如何通过 proxy model 搜索?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q089 LLM-as-a-Judge 有哪些系统性偏差？

难度 ★★★★★ 频率 ★★★★★ 依据 高频公开题型

Judge Bias

面试官在考什么：Eval 题高频。
题目：为什么 LLM Judge 不能直接当 ground truth？

60 秒标准回答

Judge 可能存在位置、长度、风格、自偏好与共享知识盲区；同源 judge/generator 错误还会高度相关。因此应使用确定性验证、外部证据、多模型交叉与人工校准。

深度解析：Know-Why

- pairwise 比 absolute score 往往更稳定，但也有 position bias。
- 评测 prompt 与输出顺序需要随机化/对称化。
- Judge 分数应与人类标注做相关性和分群误差分析。

高频失分点

- “强模型 judge 就可靠”。

追问树

1. 如何检测 verbosity bias？
2. 多 Judge 投票为什么也不一定独立？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q090 离线指标涨了，为什么线上可能变差？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

Offline-Online Gap

A

B

面试官在考什么：真正工业算法岗必问。

题目：一个 reranker 离线 NDCG 上升，但线上 CTR/成功率下降，如何分析？

60 秒标准回答

可能来自数据分布错配、metric proxy 不对应业务、延迟上升、召回链路变化、长尾 regression、用户行为反馈环等。应走 offline→shadow→A/B→monitoring，并建立可归因的 failure taxonomy。

深度解析：Know-Why

- 线上目标常是多目标：质量、延迟、成本、安全、留存。
- 离线测试集可能被迭代过拟合。
- A/B 还需样本量、显著性与 guardrail 指标。

高频失分点

- 认为线上下降说明离线指标“没用”。

追问树

1. 如何设置 guardrail metric?
2. 怎样做 counterfactual/off-policy evaluation?

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

第 9 篇

推理、分布式与 AI Infra

本篇目标：越接近大模型核心团队，越会考内存、带宽、通信与可靠性。

题目范围：Q91 KV Cache 为什么能显著加速自回归 Decode?、Q92 KV Cache 大小怎么估算?、Q93 Quantization 为什么能提升 LLM 推理吞吐?、Q94 Continuous Batching 与 PagedAttention 解决什么?、Q95 Speculative Decoding 为什么能“保证分布”又加速?、Q96 DP、TP、PP、EP：四种并行怎么组合?

Q091 KV Cache 为什么能显著加速自回归 Decode?

难度 ★★★★★ 频率 ★★★★★ 依据公开候选人报告 + 高频系统题

Inference

KV Cache

面试官在考什么：公开高阶面经代表题。

题目：生成第 t 个 token 时，过去 token 的哪些计算可以复用？

60 秒标准回答

在 causal decoder 中，历史 token 的 K/V 在后续步骤不会改变。缓存每层历史 K/V 后，每次只计算新 token 的 Q/K/V，并让新 Q 读取缓存 K/V，避免对整个 prefix 重复做投影与 attention 前处理。

深度解析：Know-Why

- prefill 仍是对 prompt 的批量计算。
- decode 每步 query length ≈ 1 ，但 key length 随上下文增长。
- cache 带来巨大显存/带宽成本，促使 GQA、PagedAttention、KV quantization。

高频失分点

- 说缓存 Q/K/V 全部；通常历史 Q 不需要。
- 用 torch.cat 每步复制整个 cache。

追问树

1. prefill 与 decode 的性能瓶颈为何不同？
2. beam search 如何复制/重排 KV cache？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q092 KV Cache 大小怎么估算？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

Memory

GQA

面试官在考什么：要求现场心算数量级。

题目：给定层数 L 、序列 T 、KV heads H_{kv} 、head dim D 、dtype bytes，KV cache 公式是什么？

60 秒标准回答

每层每 token 需存 K 和 V，因此近似 $2 \times L \times T \times H_{kv} \times D \times \text{bytes}$ ；还需乘 batch/并发请求。
GQA/MQA 通过降低 H_{kv} 线性降低 cache。

白板公式

$$M_{KV} \approx 2 \cdot L \cdot T \cdot H_{kv} \cdot D_h \cdot \text{bytes} \cdot \text{batch}$$

深度解析：Know-Why

- 实际系统还有 block metadata、对齐、碎片化。
- 长上下文服务经常由 KV memory 而非权重 memory 决定并发。
- KV cache quantization 可继续压缩，但会有精度代价。

高频失分点

- 忘记 K+V 的 2。
- 把 Q heads 误当 KV heads。

追问树

1. 一个 32-layer、8 KV head、head dim 128、16K context、BF16 请求需要多少？
2. 为什么 GQA 对 decode 特别有效？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q093 Quantization 为什么能提升 LLM 推理吞吐？

难度 ★★★★★ 频率 ★★★★★☆ 依据高频公开题型

INT8

INT4

Memory Bandwidth

面试官在考什么：理解 inference 常是 memory-bound。

题目：把 FP16 权重变 INT4 为什么可能更快？仅仅是“计算更少”吗？

60 秒标准回答

很多 decode matmul 的算术强度低，瓶颈是从 HBM 搬权重。INT4 将权重带宽降到 FP16 的约 1/4，提高可服务吞吐；同时依赖硬件/kernel 是否高效支持低精度计算。

深度解析：Know-Why

- weight-only 与 activation quantization 风险不同。
- group-wise/per-channel scale 控制误差。
- outlier channel 常需要特殊处理。

高频失分点

- 认为量化一定线性提速 4 倍。

追问树

1. GPTQ、AWQ 思路差异？
2. 为什么小 batch decode 更 memory-bound？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q094 Continuous Batching 与 PagedAttention 解决什么？

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

Serving Scheduling

面试官在考什么：大模型服务核心。
题目：静态 batch 对变长生成为什么浪费？Paged KV memory 有什么作用？

60 秒标准回答

Continuous batching 在请求完成后即时补入新请求，提高 GPU occupancy；PagedAttention 将 KV cache 分块管理，避免为每个请求预留连续最大长度空间，降低碎片与动态扩容成本。

深度解析：Know-Why

- 调度还要考虑 prefill/decode 混部和长请求公平性。
- page/block 太小 metadata 多，太大内部碎片多。
- prefix caching 可复用相同前缀 KV。

高频失分点

- 把 PagedAttention 说成改变 attention 数学。

追问树

1. chunked prefill 是什么？
2. 如何避免长 prompt 阻塞短请求？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q095 Speculative Decoding 为什么能“保证分布”又加速？

难度 ★★★★★ 频率 ★★★★★☆ 依据高频公开题型

Speculative Decoding

面试官在考什么：考察 sampling correctness 与系统收益。

题目：draft model 一次提议多个 token，target model 如何验证？什么时候反而不快？

60 秒标准回答

小模型先生成候选序列，大模型用一次并行前向验证多个位置，通过接受/拒绝规则保持目标分布。若接受率高，一次 target forward 确认多个 token；若 draft 慢或接受率低，收益会消失。

深度解析：Know-Why

- 收益取决于 draft-target 匹配、batch、硬件与输出长度。
- 可用同模型小头/Medusa 类多 token head 作为 draft。
- 验证阶段是并行的，但最终依然尊重自回归分布。

高频失分点

- 说“先小模型生成，直接让大模型纠错”太粗。

追问树

1. 接受率如何估计？
2. 为什么 temperature 越高可能影响 acceptance？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q096 DP、TP、PP、EP：四种并行怎么组合？

难度 ★★★★★ 频率 ★★★★★ 依据当前岗位能力要求 + 公开系统面经

Distributed Training

面试官在考什么：大模型核心工程题。

题目：解释 Data/Tensor/Pipeline/Expert Parallel，各自主要通信是什么？

60 秒标准回答

DP 复制模型分数据，梯度需 all-reduce/reduce-scatter；TP 切单层矩阵，层内频繁通信；PP 按层切 stage，产生 pipeline bubbles；EP 把 MoE experts 分设备，token routing 需要 all-to-all。大规模训练常多维组合。

深度解析：Know-Why

- ZeRO/FSDP 属于数据并行下参数/梯度/optimizer state 分片。
- TP 通信频率高，偏好高速互联。
- PP microbatch 数影响 bubble 比例。

高频失分点

- 把 ZeRO 当第五种完全独立并行。

追问树

1. 为什么 TP 通常限制在单节点高速互联？
2. all-reduce 与 reduce-scatter+all-gather 的关系？

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

第 10 篇

手写代码与 Debug

本篇目标：最终区分“背过”和“做过”的部分：正确性、数值稳定性、shape、复杂度与边界测试。

题目范围：Q97 手写 Numerical Stable Softmax、Q98 手写 Multi-Head Attention: Shape、Mask、Contiguous、Q99 Vectorized 1-NN：禁止 Python For-loop、Q100 Transformer Debug + 实现 KV Cache：综合终局题

Q097 手写 Numerical Stable Softmax

难度 ★★★ 频率 ★★★★★ 依据高频公开题型

Coding

Numerical

面试官在考什么：最小代码却最能暴露数值意识。

题目：不用框架 softmax，如何防止 exp overflow？

60 秒标准回答

利用 softmax 对所有 logit 同减常数不变，通常减去每行最大值，使最大指数为 $\exp(0)=1$ ，再归一化。

深度解析：Know-Why

- batch 情况要沿最后一维求 max/sum 并 keepdims。
- log-softmax 更应使用 logsumexp 稳定实现。
- 极端低精度还要注意 underflow，但通常影响小概率项。

高频失分点

- 直接 `np.exp(x)`。
- 忘记 `axis`。

追问树

1. 写 stable logsumexp。
2. cross entropy 如何避免先显式算 softmax？

最小代码 / 测试骨架

```
def softmax(x, axis=-1):  
    x = x - x.max(axis=axis, keepdims=True)  
    e = np.exp(x)  
    return e / e.sum(axis=axis, keepdims=True)
```

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q098 手写 Multi-Head Attention: Shape、Mask、Contiguous

难度 ★★★★★ 频率 ★★★★★ 依据高频公开题型

PyTorch

Attention

面试官在考什么：高频白板/现场 coding。

题目：不调用 nn.MultiheadAttention，实现 self-attention。列出关键 shape。

60 秒标准回答

输入 [B,T,D] 线性投影后 reshape 为 [B,H,T,Dh]；score 为 $q @ k^T \rightarrow [B,H,T,T]$ ；scale、mask、softmax 后乘 v，再 transpose/contiguous/reshape 回 [B,T,D] 并过输出投影。

深度解析：Know-Why

- transpose 后 tensor 可能 non-contiguous，view 前需 contiguous 或使用 reshape。
- padding mask、causal mask 的 broadcast shape 要验证。
- 生产实现要考虑 fused QKV、FlashAttention 与 dropout。

高频失分点

- softmax dim 错。
- 忘 scale/mask。
- head 维与 seq 维调换。

追问树

1. 加入 GQA 怎么改 shape?
2. KV cache 后 query/key length 分别是多少?

最小代码 / 测试骨架

```
q = Wq(x).view(B,T,H,Dh).transpose(1,2)
k = Wk(x).view(B,T,H,Dh).transpose(1,2)
v = Wv(x).view(B,T,H,Dh).transpose(1,2)
score = (q @ k.transpose(-2,-1)) / math.sqrt(Dh)
score = score.masked_fill(mask == 0, float("-inf"))
a = torch.softmax(score, dim=-1)
y = a @ v
y = y.transpose(1,2).contiguous().view(B,T,D)
y = Wo(y)
```

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q099 Vectorized 1-NN: 禁止 Python For-loop

难度 ★★★★★ 频率 ★★★★★☆ 依据公开候选人报告题型

NumPy

Vectorization

面试官在考什么：公开高阶 coding 题型。

题目：给 $X[N,d]$ 、 $Q[M,d]$ ，求每个 query 最近邻，避免构造 $M \times N \times d$ broadcast。

60 秒标准回答

利用 $\|q-x\|^2 = \|q\|^2 + \|x\|^2 - 2q \cdot x$ ，一次矩阵乘得到所有 pair distance 的核心项，只构造 $M \times N$ 矩阵。

白板公式

$$\|q - x\|^2 = \|q\|^2 + \|x\|^2 - 2q^\top x$$

深度解析：Know-Why

- 时间仍是 $O(MNd)$ ，但 BLAS/GPU 吞吐高且避免三维临时张量。
- 数值误差可能让 dist^2 出现极小负数，可 clip。
- 当 N 极大需 block/chunk 或 ANN，不能真的生成完整 $M \times N$ 。

高频失分点

- 只把 for-loop 换成 Python list comprehension。
- 广播生成三维 tensor 导致 OOM。

追问树

1. 如何把 L2 nearest neighbor 写成线性层 argmax?
2. cosine nearest neighbor 如何向量化?

最小代码 / 测试骨架

```
q2 = (Q**2).sum(1, keepdims=True)
x2 = (X**2).sum(1)[None, :]
d2 = q2 + x2 - 2 * (Q @ X.T)
idx = d2.argmin(1)
```

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

Q100 Transformer Debug + 实现 KV Cache：综合终局题

难度 ★★★★★ 频率 ★★★★★ 依据公开候选人报告题型

Debug

KV Cache

Systems

面试官在考什么：用一题检验模型原理、PyTorch 正确性与系统意识。

题目：给数百行 Transformer，找四处 bug，再加 KV cache。你先检查什么？

60 秒标准回答

先按不变量排查：shape、causal mask、scale、softmax dim、residual/norm、position offset、dtype/device；再把历史 K/V 变成显式 state。prefill 写入整段 cache；decode 只追加新 K/V，新 Q 读取历史 + 当前 K/V。

深度解析：Know-Why

- 最危险 bug 是“代码能跑但数学错”：mask 方向、softmax axis、position offset。
- 直接 torch.cat 每步会反复复制 cache，生产应预分配或 paged blocks。
- cache state 必须与 batch reorder、beam、sequence length、RoPE position 保持一致。

高频失分点

- 只修语法错误。
- 缓存了历史 Q。
- 忘记 cache 中 RoPE 后/前的表示约定。

追问树

1. 如何为 KV cache 写单元测试？
2. 如何验证 cache decode 与 full forward logits 一致？
3. 如何扩展到 GQA 与 prefix caching？

最小代码 / 测试骨架

```
# 核心测试思想（伪代码）
full = model(tokens).logits
cache = None
outs = []
for t in range(tokens.size(1)):
    y, cache = model(tokens[:, t:t+1], cache=cache, use_cache=True)
    outs.append(y.logits)
step = torch.cat(outs, dim=1)
assert torch.allclose(full, step, atol=tol)
```

复习动作：先闭卷讲 60 秒，再任选一个追问继续讲 3 分钟。

第 A 篇

高频公式速查

主题	核心公式/记忆点
Cross Entropy	$L = - \sum_k y_k \log p_k$; Softmax+CE: $\partial L / \partial z_k = p_k - y_k$ 。
AUC	$P(s(x^+) > s(x^-))$, 本质是 pairwise ranking。
BM25	TF saturation + document length normalization。
Attention	$\text{softmax}(QK^T / \sqrt{d_k})V$ 。
RoPE	$R_m^T R_n = R_{n-m}$, 相对位置进入 QK 点积。
Decoder LM	$P(x) = \prod_t P(x_t x_{<t})$ 。
LoRA	$W = W_0 + BA$, $r \ll d$ 。
DPO	优化 chosen/rejected 的 policy-reference log-ratio 差。
MinHash	$P(h_{\min}(A) = h_{\min}(B)) = J(A, B)$ 。
KV Cache	$2 \times \text{layers} \times \text{tokens} \times KVheads \times headdim \times \text{bytes}$ 。

第 B 篇

代码题检查清单

1. **Shape**: 先在纸上写每个 tensor shape, 再写代码。
2. **Axis**: softmax、sum、max 的维度是否正确?
3. **Mask**: 方向、broadcast、dtype、cache offset 是否正确?
4. **Numerical**: exp/log/division 是否稳定? 是否要减 max、加 epsilon?
5. **Complexity**: 有没有无意构造三维/四维巨大临时张量?
6. **Contiguous**: transpose 后使用 view 是否安全?
7. **State**: KV cache、RNN hidden、optimizer state 是否与 batch reorder 一致?
8. **Tests**: 至少覆盖空输入/长度 1、随机小例子、与慢实现对拍、极值/低精度。

第 C 篇

30 天刷题路线

时间	主线	目标
Day 1-4	Q1-24	补齐 ML + 传统 NLP；所有公式能闭卷写。
Day 5-7	Q25-34	把 Word2Vec→RNN→LSTM→Attention 演化讲成一条因果链。
Day 8-14	Q35-50	Transformer 核心；重点 Q35/36/39/43/45/46/50。
Day 15-18	Q51-64	预训练、Tokenizer、数据、混合精度、MoE。
Day 19-22	Q65-74	LoRA/QLoRA、RLHF、DPO、GRPO；每题能讲选择条件。
Day 23-25	Q75-84	搜索/RAG；能设计完整两阶段检索与评测。
Day 26-27	Q85-90	数据清洗、去重、污染、合成数据、Judge。
Day 28	Q91-96	KV Cache、量化、Serving、分布式并行。
Day 29	Q97-100	闭卷写代码、对拍、Debug。
Day 30	Mock	随机抽 10 题：每题 60 秒回答 + 3 分钟追问；记录所有“知道但讲不顺”的点。

第 D 篇

公开来源与真实性说明

本书不声称拥有任何公司的内部面试题。题目来源分为三类：公开候选人报告中的具体题型、开源/公开 NLP 面试题库中反复出现的同类题型、由 2026 年公开岗位能力要求映射出的高概率能力题。候选人报告具有个体差异，只能作为“曾有人公开报告被问过”的证据，不代表公司固定题库。

2026 岗位能力参考

- OpenAI, Research Engineer: 强调 bug-free ML code、massive-scale distributed ML systems。
<https://openai.com/careers/research-engineer-san-francisco/>
- OpenAI, Research Engineer, Retrieval & Search: document search、knowledge retrieval、web-scale search、vector databases/search indices。
<https://openai.com/careers/research-engineer-retrieval-and-search-applied-engineering-san-francisco/>
- OpenAI, Research Engineer / Research Scientist / AI Systems Engineer, RSI: LLM training、evaluations、synthetic data、RL environments、distributed systems。
<https://openai.com/careers/research-engineer-research-scientist-ai-systems-engineer-rsi-san-francisco/>
- Apple, Machine Learning Engineer, Natural Language Generation: SFT、RLHF、prompt engineering、data synthesis、automatic evaluation、RAG，以及端到端 data curation 到 evaluation。
<https://jobs.apple.com/en-ca/details/200636204-3337/machine-learning-engineer-natural-language-generation-input-experience>

公开题型/面经参考

- Exponent, OpenAI Research Engineer Interview Experience (candidate-reported): 报告过 Transformer bug hunting、KV cache、all_gather/noisy communication 等题型。
<https://www.tryexponent.com/experiences/openai-machine-learning-engineer-interview-c7b6a2>
- GitHub, km1994/NLP-Interview-Notes: CRF、TF-IDF、Word2Vec、Transformer 等传统与深度 NLP 高频题整理。
<https://github.com/km1994/NLP-Interview-Notes>

- GitHub, amusi/Deep-Learning-Interview-Book - 自然语言处理: Transformer/BERT/NLP 面试知识整理与公开资料索引。
<https://github.com/amusi/Deep-Learning-Interview-Book>
- GitHub, yanqiangmiffy/NLP-Interview-Notes: 多家公司公开 NLP 面经与传统算法问题汇总。
<https://github.com/yanqiangmiffy/NLP-Interview-Notes>

最后一页：真正应该记住的不是 100 个答案

60 秒标准回答

面试官常从一个简单问题连续向下挖：定义 → 公式 → 为什么 → 边界 → 缺点 → 改进 → 工程实现 → 线上失败。因此最有效的准备方式不是背 100 段话，而是把 100 题织成几条因果链：

Word2Vec → RNN/LSTM → Attention → Transformer → BERT/GPT → RoPE/GQA → Pre-training → SFT/DPO/RL → Retrieval/RAG → Data/Eval → Inference/Distributed。