


强化学习算法岗 面试宝典

100 道高频真题 · 深度解析 · 手撕实现 · 系统设计

游戏 RL / 机器人控制 / Offline RL / LLM Post-training / GRPO · DAPO · GSPO

强化学习算法知识地图



面试策略：先建立 Bellman / bias-variance / on-off policy 三条主线，再把每个算法视为对某个 failure mode 的修复。

2026.09 版

原创整理 · 题目驱动式组织 · 参考“剑指 Offer”式面试学习方法，不复刻其文字或版式

使用说明：这不是“背八股”，而是一套面试推理路径

定位 公开面经中的问题经常不是孤立问答，而是“定义 → 公式 → 为什么 → 失败模式 → 工程实现 → 项目迁移”的连续追问。本书按这一链路组织。


“真题”口径：标注为“公开面经真题/母题”的问题可在公开面经中找到直接对应或高度一致问法；其余为基于这些母题与原论文演化出的高频追问题。问题均进行了原创改写，不声称逐字复现任何公司内部题目。

建议答题节奏：先给 30 秒结论，再讲 3-5 分钟机制；若面试官继续追，进入公式推导、failure mode、工程监控与系统设计。

全书反复强调三条主线：

1. Bellman / Bootstrap：价值从哪里来，误差如何传播？
2. Bias-Variance / Credit Assignment：为什么要 MC、TD、GAE、Critic、Group Baseline？
3. Distribution Shift / Policy Update：为什么需要 Replay、Importance Sampling、Trust Region、KL、Conservative Objective？

PPO / GRPO 训练闭环：面试必须能从数据流解释公式



PPO：Critic + GAE 估计 advantage；GRPO：同 prompt 多样本组内相对 reward 估计 advantage；DAPO/GSPO 继续修复长 CoT 训练中的稳定性。

2026 加权 大模型后训练岗位已明显从“会 PPO/RLHF”升级到“PPO vs GRPO、DAPO/GSPO、KL、手撕 PPO/GRPO、长 CoT rollout 与 GPU 利用率”。本书将 71-90 题作为核心章节。

目录

章节页码已按本版最终分页固定如下。

章节索引（用于 PDF 快速定位）

章节	题号	起始页	主题	建议权重
第一章	01-15	5	MDP / Bellman / DP / MC / TD	★★★★☆
第二章	16-28	21	Q-learning / DQN 系列	★★★★☆
第三章	29-48	35	Policy Gradient / Actor-Critic / PPO	★★★★★
第四章	49-58	56	DDPG / TD3 / SAC 连续控制	★★★★☆
第五章	59-70	67	Offline RL / Model-based / Multi-Agent / Sim2Real	★★★☆☆
第六章	71-90	80	RLHF / DPO / GRPO / DAPO / GSPO	★★★★★
第七章	91-100	101	Debug / RL Infra / 系统设计 / 手撕实现	★★★★★

冲刺地图：先攻哪 20 题？

传统强化学习算法岗 Top 20: 07、12、13、16、17、18、19、20、22、29、30、33、36、38、39、41、42、43、52、54。

LLM Post-training / Reasoning RL Top 15: 39、41、42、43、45、71、73、75、76、79、81、85、86、90、99。

手撕实现 Top 10: Tabular Q-learning、DQN target、Replay Buffer、Double DQN、REINFORCE、Actor-Critic、GAE、PPO clipped loss、SAC loss、GRPO group advantage。

LLM Post-training 强化学习演化主线



核心演化：PPO 解决“更新太大” → DPO 绕开在线 RL → GRPO 去 Critic → DAPO 修复 GRPO 长 CoT pathology → GSPO 重新思考 sequence-level 优化粒度。

第一章 MDP / Bellman / DP / MC / TD

本章主线 本章决定你能否“从公式解释算法”。重点不是定义，而是 Bellman、bootstrap、bias-variance 与 on/off-policy 四个坐标。

Q001 什么是 MDP? 五元组分别代表什么?

题型: 基础母题

频率: ★★★★★

难度: ★★☆☆☆

岗位: 全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 MDP 用 (S, A, P, R, γ) 描述序贯决策: 状态、动作、转移、奖励和折扣。真正关键是动作会改变未来状态分布, 因此优化的是长期回报而不是单步奖励。

深入解析

- 先说对象: agent 在环境中按照策略 $\pi(a|s)$ 交互, 目标最大化期望折扣回报。
- $P(s'|s,a)$ 描述动力学; R 可依赖 (s,a,s') ; γ 控制远期奖励权重与有效决策 horizon。
- 面试中要主动指出: 实际项目往往不满足完全可观测, 常落到 POMDP, 需要用历史、RNN/Transformer 或 belief state 补足信息。

关键公式

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

高频追问

- POMDP 与 MDP 的区别?
- LLM 每生成一个 token 如何映射到 MDP?

易错点 不要把“Markov”误解成未来与过去无关; 它是“给定当前状态后, 历史不再提供额外预测信息”。

面试官评分标准 优秀回答会把定义连接到项目中的 state/action/reward 设计。

Q002 一句话解释 Markov Property。

题型：公开面经母题

频率：★★★★★

难度：★★☆☆☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 给定当前状态 S_t 后，下一状态分布不再依赖更早历史：当前状态应是对决策所需历史信息的充分统计量。

深入解析

- 形式上是条件独立，而不是物理世界“没有记忆”。
- 若观测 o_t 不具 Markov 性，可以堆叠帧、加入历史统计、使用 RNN/Transformer，或者维护 belief state。
- 工程上先问“state 是否足够”，比盲目换算法更重要。

关键公式

$$P(S_{t+1}|S_0,A_0,...,S_t,A_t) = P(S_{t+1}|S_t,A_t)$$

高频追问

- frame stacking 为什么有效？
- history encoder 会不会自动让问题变成 MDP？

易错点 “观测”不等于“状态”；传感器给出的 o_t 可能只是 partial observation。

Q003 为什么 Return 需要折扣因子 γ ?

题型：基础扩展

频率：★★★★☆

难度：★★☆☆☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 γ 让无限时域 return 有界，也表达时间偏好并控制 credit assignment 的有效跨度。

深入解析

- 数学层面：若奖励有界且 $\gamma < 1$ ，则无穷和收敛。
- 优化层面： γ 越接近 1，远期影响更强，但方差、bootstrap error 与 credit assignment 难度也增加。
- 可用 $1/(1-\gamma)$ 粗略理解有效时间尺度，但它不是严格 episode 长度。

关键公式

$$H_{\text{eff}} \approx 1/(1-\gamma)$$

高频追问

- $\gamma=1$ 什么时候合理？
- 机器人控制中 γ 太大会出现什么现象？

易错点 不要把 γ 只解释成“未来奖励不重要”，很多任务使用折扣也为了数学和估计稳定性。

Q004 $V(s)$ 、 $Q(s,a)$ 、 $A(s,a)$ 有什么关系？

题型：基础母题

频率：★★★★★

难度：★★☆☆☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 V 是状态价值， Q 是在状态 s 先执行 a 后的价值， $A=Q-V$ 衡量动作相对该状态平均行为的好坏。

深入解析

- $V^\pi(s) = E_{a \sim \pi} Q^\pi(s, a)$ 。
- Advantage 是 policy gradient 中高频对象：用相对价值代替绝对 return 可降低方差。
- PPO/GAE 里估计的是 A ；GRPO 则用同一 prompt 下 group reward 的相对差异替代显式 value critic。

关键公式

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$$

高频追问

- 为什么 A 的期望为 0？
- 为什么 critic 常学 V 而不是 Q ？

易错点 不能说 advantage “就是 reward”；它包含未来回报与 baseline。

Q005 推导 Bellman Expectation Equation。

题型：核心推导

频率：★★★★★

难度：★★★★☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 Bellman 的核心是把长期 return 递归拆成“当前一步奖励 + 下一状态的折扣价值”。

深入解析

- 从 $G_t = r_{t+1} + \gamma G_{t+1}$ 出发，对策略和环境随机性取条件期望。
- V 方程对动作按 π 加权，再对转移 P 加权。
- 它是 policy evaluation 的固定点；DP、TD、Critic 都是在不同信息条件下逼近这个固定点。

关键公式

$$V^{\pi}(s) = \sum_a \pi(a|s) \sum_{s'} P(s'|s,a) [R(s,a,s') + \gamma V^{\pi}(s')]$$

高频追问

- Bellman operator 为什么是 contraction?
- 函数逼近时还一定收敛吗?

易错点 不要一上来背公式；先说递归结构与 fixed point。

Q006 Bellman Optimality 与 Bellman Expectation 有什么区别？

题型：基础扩展

频率：★★★★☆

难度：★★★★☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 Expectation 固定策略做评价；Optimality 在下一动作上取 max，定义最优价值并导出 value iteration / Q-learning。

深入解析

- Expectation：动作来自当前 π ；Optimality：假设之后总选最优动作。
- V^* 和 Q^* 满足唯一固定点（有限 MDP、 $\gamma < 1$ 等标准条件）。
- Q-learning 的 target 直接把期望动作替换成 max，因此可以 off-policy。

关键公式

$$Q^*(s,a)=E[r+\gamma \max_{a'} Q^*(s',a')]$$

高频追问

- 为什么 max 会带来 overestimation bias？
- soft Bellman backup 是什么？

易错点 “max” 是算法偏差的重要来源，Double DQN、SAC 都在不同方向处理它。

Q007 Dynamic Programming、Monte Carlo、TD 的区别？

题型：公开面经母题

频率：★★★★★

难度：★★★☆☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 DP 要环境模型并 bootstrap；MC 不要模型但等完整 return；TD 不要模型且 bootstrap，可在线更新。

深入解析

- 比较三维：是否需要 model、是否等 episode 结束、是否 bootstrap。
- MC target 更接近真实 return，bias 小但 variance 大；TD target 使用当前 value estimate，引入 bias 换更低 variance 和更快更新。
- 面试时最好把 n-step / TD(λ) 作为二者连续谱补充。

关键公式

$$\text{TD}(0) \text{ target} = r_t + \gamma V(s_{t+1})$$

高频追问

- continuing task 怎么做 MC？
- TD 为什么可能比 MC 更快？

易错点 “TD 一定优于 MC” 错误；不同任务的 bias-variance 与非平稳程度不同。

Q008 MC 与 TD 各有什么优缺点？

题型：公开面经母题

频率：★★★★★

难度：★★★★☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 MC 无 bootstrap、低偏差高方差；TD 可在线、样本利用更快，但 bootstrap 引入偏差并可能与函数逼近产生不稳定。

深入解析

- MC 对 value 初始值不敏感，但必须看到 return；TD 可以在每一步更新。
- TD 的优势在于 credit 可以逐步传播，但错误估计也会 bootstrap 自己。
- 深度 RL 中 replay、target network、GAE 都是在管理 bootstrap 的收益和风险。

高频追问

- 在 deterministic 环境里 MC 方差还大吗？
- TD target bias 来自哪里？

易错点 不要把 MC 说成“完全无偏”而忽略 finite sample、函数拟合与截断。

Q009 TD Error 是什么？为什么重要？

题型：核心母题

频率：★★★★★

难度：★★☆☆☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 TD error 是一步 bootstrap target 与当前估计的残差，既驱动 value 更新，也构成 GAE、优先回放等算法中的核心信号。

深入解析

- 正 δ 表示实际一步结果比预期好，负 δ 表示更差。
- Prioritized Replay 常按 $|\delta|$ 提高“惊讶样本”的采样概率。
- Actor-Critic 中 δ 或其多步加权形式常被用作 advantage estimator。

关键公式

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

高频追问

- δ 能不能直接当 advantage?
- terminal state 怎么处理?

易错点 terminal transition 需要用 done mask 去掉下一状态 bootstrap。

Q010 手推一个 Monte Carlo 估计问题。

题型：公开面经母题

频率：★★★★☆

难度：★★★★☆

岗位：研究/控制

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 从 $p(x)$ 采 N 个独立样本，用样本均值估计 $E[f(X)]$ ；标准误差随 N 以 $1/\sqrt{N}$ 缩小。

深入解析

- 先写 estimator，再写 expectation 与 variance。
- 若目标分布难采样可转向 importance sampling。
- 方差降低手段包括 control variate、stratified sampling、antithetic sampling、baseline 等。

关键公式

$$\hat{\mu} = (1/N) \sum_i f(X_i), \quad \text{Var}(\hat{\mu}) = \text{Var}(f(X))/N$$

高频追问

- 为什么误差不是 $O(1/N)$ ？
- importance sampling 权重怎么设计？

易错点 要区分 estimator 的方差和单个样本 $f(X)$ 的方差。

Q011 n-step Return 为什么连接了 MC 和 TD?

题型：基础扩展

频率：★★★★☆

难度：★★★★☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 n-step return 用前 n 步真实奖励，再在第 n 步 bootstrap；n=1 接近 TD，n 到 episode 末端接近 MC。

深入解析

- n 增大通常降低 bootstrap bias，但环境与策略随机性造成的 variance 增大。
- off-policy 下 n-step 还要考虑行为策略与目标策略的 mismatch。
- GAE/TD(λ) 可视为对不同 n-step return 的指数加权。

关键公式

$$G_t^{(n)} = \sum_{k=0}^{n-1} \gamma^k r_{t+k+1} + \gamma^n V(s_{t+n})$$

高频追问

- 如何选 n?
- Rainbow 为什么使用 multi-step return?

易错点 不要把“n 越大越好”当结论。

Q012 On-policy 与 Off-policy 的本质区别?

题型：公开面经母题

频率：★★★★★

难度：★★☆☆☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 看产生数据的 behavior policy μ 与要学习/评价的 target policy π 是否相同。

深入解析

- On-policy 稳定但新旧数据很快过期；Off-policy 可以 replay，提高样本效率但分布偏移更难处理。
- SARSA、PPO 常作 on-policy；Q-learning、DQN、DDPG、TD3、SAC 是典型 off-policy。
- LLM 中 PPO rollout 也是“近 on-policy”，多 epoch 训练依靠 importance ratio 控制 mismatch。

关键公式

on-policy: $\mu=\pi$; off-policy: $\mu\neq\pi$

高频追问

- PPO 为什么能重复用同一 rollout 多个 epoch?
- SAC 为什么能长期使用 replay buffer?

易错点 不要用“是否有 replay buffer”作为定义；那只是常见实现现象。

Q013 Importance Sampling 是什么？RL 为什么需要它？

题型：公开面经母题

频率：★★★★★

难度：★★★★☆

岗位：PPO/LLM-RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 用 q 分布采样，却想估计 p 下的期望时，用权重 $p(x)/q(x)$ 做分布修正；PPO 的新旧 policy ratio 就是这一思想。

深入解析

- IS 的前提是目标分布支持集被行为分布覆盖，否则权重会发散或无法估计。
- 高方差来自极端权重，因此 practical RL 常做 clipping、truncation、self-normalization。
- PPO 并不是“完全纠正”旧策略数据，而是用 ratio + clip 构造可控的近似更新。

关键公式

$$E_p[f(x)] = E_q[(p(x)/q(x))f(x)]$$

高频追问

- 为什么 IS variance 可能无限大？
- per-decision IS 与 trajectory IS 区别？

易错点 PPO ratio 是 action probability ratio，不是 reward ratio。

Q014 SARSA 与 Q-learning 有什么区别？

题型：经典母题

频率：★★★★☆

难度：★★★★☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 SARSA 用真实下一动作 a' 做 target，是 on-policy；Q-learning 用 $\max_{a'} Q$ 做 target，学习 greedy target policy，因此 off-policy。

深入解析

- SARSA target 反映探索策略本身的风险，所以 Cliff Walking 中常学到更安全路径。
- Q-learning 的 max operator 更激进，同时带来 maximization bias。
- Expected SARSA 用期望替代 sampled a' ，在方差上介于两者之间。

关键公式

SARSA: $y=r+\gamma Q(s',a')$; **Q-learning:** $y=r+\gamma \max_{a'} Q(s',a')$

高频追问

- Expected SARSA 是什么？
- 为什么 Q-learning 能 off-policy？

易错点 不要把“off-policy”解释成“训练时不用 policy”。

Q015 Exploration 与 Exploitation 如何权衡?

题型：公开面经母题

频率：★★★★★

难度：★★★★☆

岗位：游戏/机器人

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 探索用于发现未知高回报区域，利用用于兑现当前知识。选择方法取决于动作空间、稀疏奖励与安全约束。

深入解析

- 离散动作： ϵ -greedy、Boltzmann、NoisyNet；连续控制：action/parameter noise、entropy。
- 稀疏奖励：intrinsic motivation、curriculum、demonstration、HER。
- 探索不是越随机越好；真实机器人还需考虑 unsafe exploration。

关键公式

$$J = E[R] + \alpha H(\pi)$$

高频追问

- NoisyNet 与 ϵ -greedy 差别？
- 为什么 entropy bonus 会导致性能下降？

易错点 “提高 temperature” 只是一个采样手段，不等于解决深层探索。

第二章 Q-learning / DQN 系列

本章主线 DQN 面试的主线是：函数逼近让 Q-learning 可扩展，也引入 moving target、相关样本、overestimation 与 deadly triad。每个改进都要对应一个 failure mode。

Q016 简述 Q-learning：目标、更新式、为什么 model-free？

题型：公开面经母题

频率：★★★★★

难度：★★★★☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 Q-learning 用 Bellman optimality target 做 TD 更新，不需要显式知道环境转移模型 P ，只依靠采样 transition。

深入解析

- 目标值使用 $r + \gamma \max_{a'} Q(s', a')$ ，因此直接逼近 Q^* 。
- tabular 情况在标准条件下收敛；深度函数逼近后不再自动保证。
- Deep Q-learning 的工程重点不是“加一个神经网络”这么简单，而是 replay 与 target network 稳定训练。

关键公式

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

高频追问

- 为什么是 off-policy？
- max 为什么有偏？

易错点 要能解释“model-free $\neq$ 不使用环境数据”。

Q017 写出 DQN Loss，并解释 terminal mask。

题型：公开面经真题

频率：★★★★★

难度：★★★☆☆

岗位：游戏/Agent

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 DQN 用 online Q 预测当前动作价值，用 frozen target network 构造 bootstrap target。terminal 时不能再 bootstrap。

深入解析

- target $y=r+\gamma(1-\text{done})\max_{a'} Q_{\text{target}}(s',a')$ 。
- prediction 只取 $Q_{\text{online}}(s,a)$ 对应执行动作的分量。
- 实际常用 Huber loss，降低大 TD error 对训练的破坏。

关键公式

$$L(\theta)=E[(r+\gamma(1-d)\max_{a'} Q_{\theta-}(s',a')-Q_{\theta}(s,a))^2]$$

高频追问

- 为什么 Huber 常比 MSE 稳？
- truncated 与 terminated 怎么处理？

易错点 Gymnasium 中 terminated 和 truncated 语义不同；时间上限截断并不一定等价于真正终止。

题源注：公开面经：网易雷火强化学习面试曾直接追问 DQN 损失函数。

Q018 DQN 最经典的两个 trick 是什么？

题型：公开面经真题

频率：★★★★★

难度：★★☆☆☆

岗位：游戏/Agent

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 Experience Replay 打破时间相关性并复用数据；Target Network 让 bootstrap target 在一段时间内相对稳定。

深入解析

- Replay 把序列数据转成近似 iid minibatch，同时使算法更明显 off-policy。
- Target network 解决 moving target；可 hard copy 或 Polyak averaging。
- 两者都是在缓解 function approximation + bootstrap 带来的不稳定。

高频追问

- 为什么 CNN 不算这两个核心 trick？
- replay buffer 太小/太大会怎样？

易错点 回答只背名称不够，必须说清各自对应的 failure mode。

题源注：公开面经：英伟达/网易类强化学习面试长期高频出现 DQN 改进与两个核心 trick。

Q019 Experience Replay 为什么有效？有什么代价？

题型：公开面经母题

频率：★★★★★

难度：★★★★☆

岗位：游戏/Agent

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 它通过随机回放 transition 降低 temporal correlation，并让一次昂贵环境交互被多次利用。

深入解析

- 优势：sample efficiency、近 iid、可做 prioritized sampling。
- 代价：数据来自旧策略；环境非平稳时旧数据可能失效；buffer 分布会影响学习目标。
- 机器人/推荐系统中要特别关注 replay 的时间分布与策略版本。

高频追问

- 为什么 on-policy PPO 不常用长 replay？
- 如何做 reservoir replay？

易错点 Replay Buffer 不是越大越好：过旧数据可能增加 mismatch。

Q020 Target Network 为什么能稳定 DQN?

题型：公开面经母题

频率：★★★★★

难度：★★★★☆

岗位：游戏/Agent

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 若 prediction 和 target 同时由快速变化的同一个网络产生，优化对象本身持续移动；target network 将这一变化放慢。

深入解析

- Hard update 每 C 步复制 $\theta^- \leftarrow \theta$ 。
- Soft update $\theta^- \leftarrow \tau\theta + (1-\tau)\theta^-$ 。
- 本质是控制 bootstrap target 的 nonstationarity。

关键公式

$$\theta^- \leftarrow \tau\theta + (1-\tau)\theta^-$$

高频追问

- τ 太大/太小有什么影响？
- 为什么 actor-critic 也常有 target critic？

易错点 不要说 target network “消除 bias”；它主要提高稳定性。

Q021 什么是 Deadly Triad?

题型：核心理论

频率：★★★★☆

难度：★★★★☆

岗位：研究/高级岗

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 Function approximation、bootstrapping、off-policy 同时出现时，TD 学习可能发散；Deep Q-learning 恰好同时具备三者。

深入解析

- 它解释了为什么 DQN 需要大量稳定化技巧。
- 并不是三者任意一个单独就一定不稳定。
- 实际深度 RL 中仍然大量使用 deadly triad，只是靠 target、replay、regularization、conservative objectives 控制风险。

高频追问

- 为什么 tabular Q-learning 不受同样问题影响？
- SAC 也属于 deadly triad 吗？

易错点 面试不要把它当成“一个定理说一定发散”，而是经典不稳定组合。

Q022 Double DQN 解决什么问题？

题型：经典高频

频率：★★★★★

难度：★★★☆☆

岗位：游戏/Agent

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 普通 DQN 用同一估计器做 action selection 与 evaluation, max 会偏好噪声高估项；Double DQN 把选择和评价拆开。

深入解析

- online network 选 $a^* = \arg\max Q_{\text{online}}(s', a)$ 。
- target network 评估 $y = r + \gamma Q_{\text{target}}(s', a^*)$ 。
- 它减少 maximization overestimation, 但不保证完全无偏。

关键公式

$$a^* = \arg\max_a Q_{\theta}(s', a); \quad y = r + \gamma Q_{\theta^-}(s', a^*)$$

高频追问

- 为什么不是取 min?
- Double Q-learning 与 TD3 双 critic 有何联系?

易错点 “两个网络”不是 Double DQN 的本质；DQN 本来就有 online/target, 关键是 selection/evaluation 解耦。

Q023 Dueling DQN 解决什么问题？

题型：经典高频

频率：★★★★☆

难度：★★★★☆

岗位：游戏

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 将 Q 分解为 state value V 与 action advantage A ，使网络能更快学习“这个状态整体好不好”，尤其当许多动作差别不大时更有效。

深入解析

- 直接 $Q=V+A$ 不可辨识，需要减 $\text{mean}(A)$ 或 $\text{max}(A)$ 约束。
- Dueling 不改变 Bellman target，只改变 network architecture。
- 它与 Double DQN 可组合。

关键公式

$$Q(s,a)=V(s)+A(s,a)-\text{mean}_{\{a'\}}A(s,a')$$

高频追问

- 为什么要减 mean?
- Dueling 对连续动作有意义吗?

易错点 不要把 Dueling 与 Double 混淆：一个是结构，一个是 target bias 修正。

Q024 Prioritized Experience Replay 为什么使用 TD error?

题型：经典高频

频率：★★★★☆

难度：★★★★☆

岗位：游戏/Agent

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 $|\delta|$ 大的 transition 表示当前模型预测误差大，通常包含更多学习信息，因此提高其采样概率。

深入解析

- $P(i) \propto p_i^\alpha$, $p_i = |\delta_i| + \epsilon$ 。
- 改变采样分布会引入 bias，因此使用 IS 权重 $w_i = (1/(NP(i)))^\beta$ 修正。
- priority 需要定期更新，否则会基于陈旧误差。

关键公式

$$P(i) = p_i^\alpha / \sum_k p_k^\alpha$$

高频追问

- α 、 β 各控制什么？
- 为什么高 TD error 也可能只是噪声？

易错点 高 TD error 不等于“高价值样本”，可能来自随机奖励或异常点。

Q025 DQN 加 n-step return 为什么有效?

题型：高频扩展

频率：★★★★☆

难度：★★★★☆

岗位：游戏

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 多步真实奖励让 credit 更快传播，减少纯一步 bootstrap 的慢传播问题。

深入解析

- 在 sparse/delayed reward 场景尤其有价值。
- n 增大后 variance 与 off-policy mismatch 增大。
- Rainbow 证明 multi-step 与其他 DQN 改进可以互补。

高频追问

- n -step 与 eligibility trace 的关系？
- replay 中如何存 n -step transition？

易错点 注意 terminal 之前不足 n 步的截断处理。

Q026 什么是 Distributional RL? 为什么不只学期望 Q?

题型：经典高频

频率：★★★★☆

难度：★★★★☆

岗位：研究/游戏

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 传统 Q 只学 return 的均值；Distributional RL 学整个随机 return $Z(s,a)$ 的分布，保留不确定性和分布形状信息。

深入解析

- C51 用固定 atoms 近似 value distribution。
- 即便最终决策仍按期望值，分布学习也可能改善 representation 与优化。
- 它与 risk-sensitive RL 相关但不等价。

关键公式

$$Q(s,a)=E[Z(s,a)]$$

高频追问

- C51 projection 为什么需要？
- quantile regression DQN 与 C51 区别？

易错点 不要说“Distributional RL 就是输出方差”。

Q027 Rainbow DQN 包含哪些组件？每个解决什么？

题型：经典高频

频率：★★★★☆

难度：★★★★☆

岗位：游戏

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 Rainbow 将 Double、Prioritized Replay、Dueling、Multi-step、Distributional RL、NoisyNet 组合，并做系统消融。

深入解析

- Double：减 overestimation。
- PER：重采高误差样本。
- Dueling：分离 state value 与 action advantage。
- n-step：加速 reward propagation。
- Distributional：学 return distribution。
- NoisyNet：参数化探索。

高频追问

- 哪些组件贡献最大？
- 为什么 Rainbow 仍是 off-policy？

易错点 不要只背六个名词；面试官真正看你能否把“问题→修复”一一对应。

Q028 Q-learning / DQN 为什么不需要 PPO 式 Importance Sampling?

题型：公开面经真题

频率：★★★★★

难度：★★★★☆

岗位：游戏/PPO

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 Q-learning 的 Bellman optimality fixed point 允许使用非当前目标策略产生的 transition；它不是直接对当前 policy 的 action probability 做 likelihood-ratio policy gradient。

深入解析

- PPO 的目标函数显式含 $E_{a \sim \pi_{\text{old}}}$ 对 π_{new} 的 surrogate，需要 ratio 修正。
- DQN 的 TD target 对 next action 取 max，本身就是 off-policy control。
- 但 off-policy Q-learning 仍有分布偏移与函数逼近风险，只是不是同一种 IS 修正。

高频追问


- 为什么 off-policy policy gradient 往往需要 IS?
- DQN 的 state distribution mismatch 怎么办?

易错点 不能回答成“DQN 是 off-policy 所以不需要 IS”；PPO 多 epoch 后也会带 off-policy 成分。

第三章 Policy Gradient / Actor-Critic / PPO

本章主线 PPO 是传统 RL 与 LLM RL 的共同核心。务必做到：能手推 objective、能解释 A 正负下的 clip、能写 GAE、能从系统角度解释 policy lag 与 KL。

PPO / GRPO 训练闭环：面试必须能从数据流解释公式



PPO : Critic + GAE 估计 advantage ; GRPO : 同 prompt 多样本组内相对 reward 估计 advantage ; DAPO/GSPO 继续修复长 CoT 训练中的稳定性

Q029 Value-based 与 Policy-based 的本质区别？

题型：公开面经真题

频率：★★★★★

难度：★★☆☆☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 Value-based 先估价值再选动作；Policy-based 直接参数化 $\pi_{\theta}(a|s)$ 并优化期望回报。

深入解析

- Value 方法天然适合离散动作；Policy 方法可自然输出连续/随机策略。
- Policy gradient 可以直接优化 stochastic policy，但通常方差高、样本效率低。
- Actor-Critic 将两者结合：actor 学 policy，critic 提供 value/advantage。

高频追问

- 连续动作为什么更偏 policy method？
- Q 和 policy 能否同时学习？

易错点 不要把“policy-based 一定 on-policy”作为定义，SAC/DDPG 都是 off-policy actor-critic。

Q030 写出 Policy Gradient Theorem，并解释 log-derivative trick。

题型：核心推导

频率：★★★★★

难度：★★★★☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 把 trajectory probability 对参数的梯度写成 log probability 梯度，就能用采样估计不可微环境中的期望回报梯度。

深入解析

- 环境转移 P 通常不依赖 θ ，因此 trajectory log probability 的 θ 梯度只剩 $\sum \log \pi_\theta(a_t|s_t)$ 。
- 用 return/ Q /advantage 作为权重，得到 REINFORCE / actor-critic。
- 这使 reward 无需可微，但代价是高 variance。

关键公式

$$\nabla J(\theta) = E[\nabla_\theta \log \pi_\theta(a|s) \cdot Q^\pi(s,a)]$$

高频追问

- 为什么 reward 不可微也能优化？
- baseline 为什么不改变期望？

易错点 不要把 policy gradient 当成对 action 本身求梯度；stochastic PG 对 log-prob 求梯度。

Q031 REINFORCE 怎么来？最大缺点是什么？

题型：核心母题

频率：★★★★★

难度：★★★★☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 REINFORCE 用完整 Monte Carlo return 加权 log-prob 梯度，估计简单但方差很大。

深入解析

- 公式可从 trajectory likelihood trick 推导。
- reward-to-go 可去掉与当前动作无关的过去奖励，进一步降方差。
- baseline / critic 是从 REINFORCE 走向 Actor-Critic 的关键一步。

关键公式

$$\nabla J \approx \sum_t G_t \nabla \log \pi_{\theta}(a_t | s_t)$$

高频追问

- 为什么使用 reward-to-go?
- normalize return 有何作用?

易错点 “无偏”不代表好用；高方差会让深网训练非常慢。

Q032 为什么加 baseline 不改变 Policy Gradient 的期望？

题型：核心推导

频率：★★★★★

难度：★★★★☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 因为对任意只依赖 state 的 $b(s)$, $E_{a \sim \pi}[\nabla \log \pi(a|s)b(s)] = b(s) \nabla \sum_a \pi(a|s) = 0$ 。

深入解析

- baseline 只改变 estimator variance, 不改变期望方向。
- 最优 baseline 与 Q 的条件结构有关; $V(s)$ 是常用近似。
- 于是 $Q-b(s)$ 变成 advantage。

关键公式

$$E_a[\nabla \log \pi(a|s)b(s)] = 0$$

高频追问

- baseline 能依赖 action 吗?
- 为什么 advantage normalization 仍常见?

易错点 baseline 若依赖 action, 不能直接套同一证明。

Q033 Actor-Critic 为什么比 REINFORCE 更实用?

题型：公开面经真题

频率：★★★★★

难度：★★★★☆

岗位：全方向

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 Critic 用 learned value 提供低方差 advantage/TD signal, Actor 用该信号更新 policy, 实现 policy improvement 与 evaluation 的闭环。

深入解析

- critic 可学 V 或 Q; 常见 on-policy AC 用 V 做 baseline。
- 优点是能在线、多步 bootstrap; 缺点是 critic bias 会传给 actor。
- 现代 PPO、SAC、TD3 本质上都属于 actor-critic 家族。

关键公式

$$\text{actor update} \propto \nabla \log \pi(a|s) \hat{A}(s,a)$$

高频追问

- critic 不准会怎样?
- actor 与 critic 是否共享 backbone?

易错点 不要把 critic 等同 reward model; critic 预测未来回报, reward 定义任务目标。

Q034 A2C 与 A3C 有什么区别？

题型：公开面经母题

频率：★★★★☆

难度：★★★★☆

岗位：游戏/分布式 RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 A3C 多 worker 异步更新 global network；A2C 常同步收集多个环境 rollout 后统一 batch 更新。

深入解析

- A3C 通过异步 actor 打破样本相关性，但会引入 stale gradient / policy lag。
- A2C 更利于 GPU batch，工程上更简单可控。
- 今天大规模 RL 更常把 actor 与 learner 解耦，并显式管理 policy version。

高频追问

- A3C 为什么不需要 replay buffer？
- 同步 barrier 的代价是什么？

易错点 不要把 A2C 理解成“只有一个 worker”。

Q035 A3C 异步训练为什么可能不收敛？

题型：公开面经真题

频率：★★★★☆

难度：★★★★☆

岗位：分布式 RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 worker 用旧 policy 收集并计算梯度，而 global policy 已更新，造成 stale gradient 与 off-policy drift；并发越大，policy lag 可能越严重。

深入解析

- 不同 worker 的梯度方差叠加，环境分布也可能不同。
- 参数服务器写入次序、optimizer state 与异步更新会进一步复杂化。
- 现代系统常限制 lag、版本化 trajectory、使用 V-trace/importance correction。

高频追问

- IMPALA 的 V-trace 解决什么？
- actor/learner throughput 如何平衡？

易错点 “异步=更快”只说 wall-clock，不代表统计效率更高。

Q036 GAE 是什么？ λ 控制什么？

题型：核心高频

频率：★★★★★

难度：★★★★☆

岗位：PPO/机器人/LLM-RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 GAE 将多步 TD residual 按 $(\gamma\lambda)^l$ 指数加权，形成 advantage estimator； λ 在低方差高偏差与低偏差高方差之间调节。

深入解析

- $\delta_t = r_t + \gamma V_{t+1} - V_t$ 。
- $\lambda=0$ 接近一步 TD； $\lambda \rightarrow 1$ 更接近 Monte Carlo。
- PPO 常将 GAE 与 value function、advantage normalization 配套使用。

关键公式

$$\hat{A}_t^{\text{GAE}} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}$$

高频追问

- 为什么同时有 γ 和 λ ？
- terminal mask 怎么进入 GAE？

易错点 GAE 本身并不是 PPO 专属。

Q037 TRPO 为什么需要 Trust Region?

题型：核心演化

频率：★★★★☆

难度：★★★★☆

岗位：PPO/研究

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 旧策略下采到的数据只能局部代表新策略；一步更新过大时 surrogate 不再可靠。TRPO 用 KL 约束限制策略分布移动。

深入解析

- 理论出发点是 performance improvement lower bound。
- 实际求解需要 natural gradient / Hessian-vector product / conjugate gradient / line search，工程复杂。
- PPO 保留 “proximal update” 思想，用 clip/penalty 做更易实现的近似。

关键公式

$$\mathbb{E}_s[\mathcal{D}_{\text{KL}}(\pi_{\text{old}} \parallel \pi_{\text{new}})] \leq \delta$$

高频追问

- KL 方向为什么重要？
- TRPO 单调改进保证有哪些近似条件？

易错点 不要说 TRPO “严格保证深度网络一定单调变好”；实践算法本身做了多项近似。

Q038 为什么提出 PPO? 相比 TRPO 好在哪里?

题型：公开面经真题

频率：★★★★★

难度：★★★☆☆

岗位：PPO/LLM-RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 PPO 用简单可微的 surrogate clipping/penalty 近似 trust region, 允许 minibatch、多 epoch SGD, 保留较好的稳定性同时大幅简化工程。

深入解析

- PPO 不是单一算法, 原论文有 clipped objective 与 adaptive KL penalty 两类。
- 核心是限制新旧 policy 的有效变化, 而不是“把梯度截断”。
- 在机器人与 LLM post-training 中, 它的工程可扩展性是长期流行的重要原因。

关键公式

$$L^{\text{CLIP}} = E[\min(r_t \hat{A}_t, \text{clip}(r_t, 1-\epsilon, 1+\epsilon) \hat{A}_t)]$$

高频追问

- PPO 为什么能多 epoch?
- clip 能严格保证 KL 吗?

易错点 “PPO 比 TRPO sample efficient” 需要限定为原论文经验结果, 不是普适定理。

Q039 写出 PPO Clipped Objective，并解释每一项。

题型：公开面经真题

频率：★★★★★

难度：★★★★☆

岗位：PPO/LLM-RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 r_t 衡量新策略相对旧策略对已采 action 的概率变化； $\hat{A}$ 表示该动作相对 baseline 的好坏；min+clip 构造悲观 surrogate，限制过激改动的收益。

深入解析

- $r_t = \exp(\log \pi_{\text{new}} - \log \pi_{\text{old}})$ 数值更稳定。
- $A > 0$ 时不鼓励 r 超过 $1 + \epsilon$ ； $A < 0$ 时不鼓励 r 低于 $1 - \epsilon$ 。
- clipping 只是 surrogate 层约束，仍需监控 empirical KL 与 clip fraction。

关键公式

$$L^{\text{CLIP}}(\theta) = E[\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t)] ; r_t(\theta) = \pi_{\theta}(a_t|s_t)/\pi_{\text{old}}(a_t|s_t)$$

高频追问

- 为什么是 min 而不是 max?
- clip fraction 过高说明什么?

易错点 PPO clip 的是 probability ratio，不是 reward、advantage 或 gradient。

Q040 PPO 中 ratio 到底表示什么？

题型：公开面经追问

频率：★★★★★

难度：★★★☆☆

岗位：PPO/LLM-RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 ratio 是同一 state-action 在新旧 policy 下概率（或 density）的比值，>1 表示新策略更偏好该 action。

深入解析

- 离散动作直接取 token/action probability；连续 Gaussian policy 用概率密度。
- LLM 中通常从 token log-prob 差得到 token ratio。
- 大 ratio 表示 distribution shift 大，也是 IS variance 与更新不稳定的来源。

关键公式

$$r = \exp(\log \pi_{\text{new}} - \log \pi_{\text{old}})$$

高频追问

- continuous action ratio 怎么算？
- sequence ratio 为什么会数值爆炸？

易错点 probability density 可以大于 1，不要用离散概率直觉误解连续策略。

Q041 为什么 PPO 需要 Importance Sampling，而 DQN 不需要？

题型：公开面经真题

频率：★★★★★

难度：★★★★☆

岗位：PPO/游戏

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 PPO 用 π_{old} 数据估计 π_{new} 的 policy objective，因此需 likelihood ratio；Q-learning 通过 off-policy Bellman optimality backup 学 Q^* ，不是直接对 π_{new} likelihood 做同样估计。

深入解析

- PPO 多 epoch 进一步加大新旧策略差异，所以 ratio/clip 很关键。
- DQN 虽不使用 PPO 式 IS，仍面临 state/action distribution mismatch。
- off-policy actor-critic 若直接做 policy gradient，也常需要 correction 或依赖专门理论结构。

高频追问

- SAC actor update 为什么不需要 behavior policy ratio？
- IMPALA 为什么要 V-trace？

易错点 避免循环回答：“因为 PPO on-policy，DQN off-policy”。要从目标函数解释。

题源注：公开面经：网易互娱曾直接追问“PPO 使用 Importance Sampling，DQN 为什么不需要”。

Q042 PPO clip 到底 clip 什么？分 $A>0$ 与 $A<0$ 解释。

题型：公开面经真题

频率：★★★★★

难度：★★★★☆

岗位：PPO/LLM-RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 clip 的对象是新旧策略 probability ratio。 $A>0$ 时限制“进一步提高好动作概率”的收益； $A<0$ 时限制“进一步降低坏动作概率”的收益。

深入解析

- $A>0$: $r>1+\epsilon$ 后 surrogate 被截住。
- $A<0$: $r<1-\epsilon$ 后 surrogate 被截住。
- min 选择更保守的一支，因此形成 pessimistic bound-like objective。

关键公式

$$\min(rA, \text{clip}(r, 1-\epsilon, 1+\epsilon)A)$$

高频追问

- 为什么 $A<0$ 时逻辑反过来？
- dual-clip PPO 又修什么？

易错点 很多候选人只会画区间却解释不清 A 的符号，这是高频失分点。

题源注：公开面经：网易互娱曾直接追问 PPO Surrogate Clip 具体 clip 什么、为什么。

Q043 PPO 的完整 Loss 有哪几部分？

题型：公开面经真题

频率：★★★★★

难度：★★★★☆☆

岗位：PPO/机器人

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 常见总损失由 policy surrogate、value regression、entropy bonus 组成；RLHF 还可能额外把 KL 作为 reward shaping 或显式 penalty。

深入解析

- policy loss 决定策略方向。
- value loss 训练 critic 估计 return。
- entropy 鼓励探索，防过早确定化。
- 系数 c_v 、 c_e 与各项 scale 会显著影响训练。

关键公式

$$L_{\text{total}} = L_{\text{policy}} + c_v L_{\text{value}} - c_e H(\pi)$$

高频追问

- value clipping 是什么？
- entropy coefficient 如何调？

易错点 不同代码库符号约定不同：有的最大化 objective，有的最小化负 objective。

Q044 Policy loss 和 Value loss 能否一次 backward?

题型：工程高频

频率：★★★★☆

难度：★★★★☆

岗位：PPO/LLM-RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 可以，只要计算图与共享参数设计正确；共享 backbone 时总 loss 一次 backward 很常见。也可独立 optimizer 解耦 actor/critic。

深入解析

- 共享 backbone 节省计算但 gradient interference 更强。
- 独立网络显存更贵但职责清晰。
- LLM RL 中 value head / value model 的架构选择会直接影响显存、通信与优化稳定性。

高频追问

- value loss 是否应回传到 policy head?
- 如何设置不同 learning rate?

易错点 “可以合并 loss” 不等于所有参数都该同时收到两种梯度。

Q045 PPO 已经 clip，为什么还要监控 KL?

题型：工程高频

频率：★★★★★

难度：★★★★☆

岗位：PPO/LLM-RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 clip 只限制已采 action 上的 surrogate ratio，不保证整个 action distribution 的 KL 小；empirical KL 是策略漂移的全局健康指标。

深入解析

- KL 快速上升通常提示 lr 太大、epoch 太多、advantage scale 异常或 policy lag。
- 常见措施：early stop、调 lr、KL penalty/adaptive β 。
- RLHF 还监控 policy-reference KL，含义与 old-new policy KL 不完全相同。

关键公式

$$D_{KL}(\pi_{old} || \pi_{new})$$

高频追问

- old-policy KL 和 reference KL 区别？
- target KL 怎么设？

易错点 不要把所有 KL 混成一个；“信任域 KL”和“对 reference 的正则 KL”角色不同。

Q046 PPO 是 On-policy，为什么 rollout 能训练多个 epoch?

题型：高频追问

频率：★★★★★

难度：★★★★☆

岗位：PPO/LLM-RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 严格说每次参数更新后数据都会逐渐 off-policy；PPO 用 old log-prob 固定行为策略，并用 ratio+clip 控制多 epoch 重用带来的 mismatch。

深入解析

- epoch 增多提高 sample reuse，但也会提高 KL 与 clipfrac。
- 因此 PPO 不是无限重放；通常每批 rollout 用少数 epochs 后丢弃。
- LLM 长序列中，policy lag 与 generation latency 让这一问题更明显。

高频追问

- epoch 太多的可观测症状？
- mini-batch shuffling 为什么有用？

易错点 不要把 PPO 说成“完全 off-policy”。

Q047 PPO 有哪些缺点？

题型：公开面经真题

频率：★★★★★

难度：★★★★☆

岗位：PPO/LLM-RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 主要问题是 on-policy rollout 贵、critic 成本高、超参敏感、长 horizon credit assignment 难，且在 LLM 中序列长度和巨型 action space 放大这些问题。

深入解析

- 样本效率：数据快速过期。
- 系统成本：actor/critic/reference/reward 多模型并存。
- 估计误差：advantage/value bias。
- 稳定性：KL、entropy collapse、clip saturation。
- LLM：rollout 成为主要 wall-clock，长 CoT 带来 straggler。

高频追问

- 什么时候宁愿用 SAC/TD3？
- 为什么 GRPO 能省显存？

易错点 缺点要和应用场景联系，不能泛泛说“训练慢”。

Q048 手撕 PPO/GAE: 代码顺序与最常见 bug?

题型: 公开面经真题

频率: ★★★★★

难度: ★★★★★

岗位: PPO/LLM-RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 先 rollout 保存 reward/done/value/old_logp; 反向扫描算 GAE; $\text{return} = \text{adv} + \text{value}$; 标准化 advantage; 多 epoch 计算 new_logp、ratio、clipped loss、value loss、entropy。

深入解析

- ratio 应由 $\exp(\text{new_logp} - \text{old_logp})$ 得到, 避免直接 prob 除法的数值问题。
- 旧 log-prob 必须 detach/freeze; GAE 要正确处理 terminal mask。
- advantage normalization、gradient clipping、value clipping、KL early stop 都是常见工程项。

关键公式

$$\text{ratio} = \exp(\text{new_logp} - \text{old_logp})$$

高频追问

- old value 是否也要冻结?
- 连续动作 log_prob 要不要 sum action dims?

易错点 最常见的 silent bug 是 log_prob shape、done mask 和 batch/token averaging。

题源注: 公开面经: 近期大模型/强化学习岗位已出现手撕 PPO。

第四章 DDPG / TD3 / SAC 连续控制

本章主线 连续控制不是“把 DQN 换成 actor”这么简单。DDPG→TD3→SAC 的演化，本质是不断修复 critic error、探索和随机性问题。

Q049 为什么 DQN 不适合连续动作空间？

题型：经典母题

频率：★★★★★

难度：★★☆☆☆

岗位：机器人/控制

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 DQN 的 Bellman target 需要对所有动作做 argmax；连续高维动作不可枚举。Actor 直接输出连续动作，因此 DDPG/TD3/SAC 更自然。

深入解析

- 离散化每维 K 档会产生 K^d 组合爆炸。
- 即便能数值优化 $\arg\max Q$ ，训练时每步都做 inner optimization 也很昂贵。
- Actor 把“求 argmax”摊销成一次前向。

关键公式

$$\mathbf{a} = \mu_{\theta}(\mathbf{s})$$

高频追问

- 为什么 SAC 仍然要学 Q？
- 连续动作也可以用 value iteration 吗？

易错点 “DQN 不能连续动作”是工程结论，不是说数学上的 Q function 不能定义在连续动作上。

Q050 DDPG 的 Actor 和 Critic 如何更新?

题型：公开面经母题

频率：★★★★☆

难度：★★★★☆

岗位：机器人/控制

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 Critic 用 off-policy TD target 学 Q ；Actor 通过 deterministic policy gradient 沿着 critic 对 action 的梯度方向提升 Q 。

深入解析

- target action 来自 target actor $\mu^-(s')$ 。
- critic target $y=r+\gamma Q^-(s',\mu^-(s'))$ 。
- actor gradient 通过 $\partial Q/\partial a \cdot \partial \mu/\partial \theta$ 反传。
- 使用 replay + target networks, 继承 DQN 的稳定化思路。

关键公式

$$\nabla_{\theta} J = E[\nabla_a Q(s,a)|_{a=\mu(s)} \nabla_{\theta} \mu_{\theta}(s)]$$

高频追问

- DDPG exploration 怎么做?
- 为什么 deterministic policy 还能 off-policy?

易错点 actor 最大化的是 critic 估计, critic 偏差会直接被 actor exploit。

Q051 DDPG 为什么容易不稳定？

题型：公开面经追问

频率：★★★★☆

难度：★★★★☆

岗位：机器人/控制

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 critic overestimation 与 function approximation error 会被 actor 主动利用；deterministic exploration 也脆弱，导致性能对超参和随机种子敏感。

深入解析

- bootstrapped Q error 会传播。
- actor 每次都朝当前 Q 峰值走，若 Q 峰值是噪声就会被放大。
- TD3 的 twin critic、delayed policy、target smoothing 正是针对这些问题。

高频追问

- 为什么 target network 仍不足？
- OU noise 为什么曾经流行？

易错点 不要只说“DDPG deterministic 所以不稳定”，核心是 actor-critic error coupling。

Q052 TD3 相比 DDPG 的三个关键改进？

题型：公开面经真题

频率：★★★★★

难度：★★★★☆

岗位：机器人/控制

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 Clipped Double Q、Delayed Policy Update、Target Policy Smoothing。三者共同目标是减少 critic estimation error 对 actor 的破坏。

深入解析

- 双 critic 取 min 抑制 overestimation。
- critic 多更新、actor 少更新，让 value 更充分收敛后再推动 policy。
- target action 加载剪噪声，使 Q 对局部 action 扰动更平滑，减少窄尖假峰。

关键公式

$$y = r + \gamma \min(Q_1(s', a'), Q_2(s', a'))$$

高频追问

- 为什么叫 Twin Delayed?
- target noise 与 exploration noise 一样吗?

易错点 target policy smoothing 的噪声只用于 target 计算，不等于环境交互探索噪声。

题源注：公开面经：零跑强化学习岗位从 DDPG 连续追到 TD3、SAC、应用场景与优缺点。

Q053 TD3 为什么取 $\min(Q_1, Q_2)$ ，而不是平均？

题型：高频追问

频率：★★★★☆

难度：★★★★☆

岗位：机器人/控制

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 平均仍可能保留正偏差；min 主动形成悲观估计，针对 actor 会 exploit Q overestimation 的问题。

深入解析

- 若 $Q_i = Q^* + \epsilon_i$ ，policy optimization 会偏好 ϵ 偏大的动作。
- min 会引入一定 underestimation，但实践中比正偏差更可控。
- SAC 的现代实现也常采用双 Q 取 min。

高频追问

- min 会不会太悲观？
- 如何用更多 critic ensemble？

易错点 这不是 Double DQN 的同一机制：Double DQN 解耦 selection/evaluation；TD3 用两个 critic 直接取 min。

Q054 SAC 的核心思想是什么？

题型：公开面经真题

频率：★★★★★

难度：★★★★☆☆

岗位：机器人/控制

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 SAC 在 off-policy actor-critic 中最大化 reward 与 policy entropy，使 agent 在高回报策略中保持尽可能随机，提升探索和稳定性。

深入解析

- soft value/soft Q 含 entropy 项。
- stochastic Gaussian actor 通过 reparameterization trick 低方差反传。
- off-policy replay 提升样本效率。
- 现代 SAC 常自动调 temperature α 。

关键公式

$$J(\pi) = \mathbb{E}[\sum_t \gamma^t r_t + \alpha H(\pi(\cdot|s_t))]$$

高频追问

- 为什么最大熵不等于“乱走”？
- SAC 的 target Q 如何写？

易错点 entropy 是受 reward 约束的优化项，不是无条件越大越好。

Q055 SAC 的 temperature α 是什么？

题型：高频追问

频率：★★★★☆

难度：★★★★☆

岗位：机器人/控制

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 α 控制 reward 与 entropy 的权衡；大 α 更重探索，小 α 更接近纯 reward maximization。

深入解析

- 自动温度调节把 α 作为可学习拉格朗日乘子，使 entropy 接近 target entropy。
- 连续动作 target entropy 常与动作维度相关，但不是万能固定公式。
- α scale 与 reward scale 强相关。

关键公式

$$J(\alpha) = \mathbb{E}[-\alpha(\log \pi(a|s) + H_{\text{target}})]$$

高频追问

- target entropy 如何选？
- reward scaling 会怎样影响 α ？

易错点 不要把 α 与 PPO entropy coefficient 机械等同；SAC 中它嵌入 soft Bellman 结构。

Q056 PPO、TD3、SAC 怎么选？

题型：项目高频

频率：★★★★★

难度：★★★★☆

岗位：机器人/控制

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 仿真便宜、需要简单稳定并行时常选 PPO；真实采样昂贵时 off-policy TD3/SAC 更具样本效率；SAC 比 TD3 更强调 stochastic exploration 与稳健性。

深入解析

- PPO: on-policy、实现稳、数据消耗大。
- TD3: deterministic，连续控制强，但探索与超参更敏感。
- SAC: off-policy + entropy，通常是连续控制强 baseline。
- 最终选择还取决于 reward noise、action constraints、sim2real 和系统吞吐。

高频追问

- 真实机器人为什么不能只看 benchmark return？
- action latency 如何进入设计？

易错点 面试不要给“唯一正确算法”；应给决策条件。

Q057 连续动作为什么不能简单 discretize?

题型：基础扩展

频率：★★★★☆

难度：★★☆☆☆

岗位：机器人/控制

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 动作维数 d 、每维 K 档时组合数 K^d 指数爆炸；分辨率越细，动作空间越不可控。

深入解析

- 离散化还会产生控制抖动和精度瓶颈。
- 某些低维控制仍可离散化，不能绝对化。
- hierarchical/discrete latent action 是折中路线。

关键公式

$$N_{\text{actions}} = K^d$$

高频追问

- hybrid action space 怎么做？
- 离散 skill + 连续参数怎么建模？

易错点 不要只说“连续动作无限多个”而不解释维数灾难。

Q058 LLM top-k sampling 与 SAC stochastic policy 的本质区别？

题型：跨领域追问

频率：★★★★☆

难度：★★★★☆

岗位：LLM/控制

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 top-k 是 inference-time decoding heuristic，裁掉低概率 token 后重归一化；SAC 的随机性来自训练目标中的 entropy regularization，是 policy learning 本身的一部分。

深入解析

- top-k 不改变基础 LM 的训练 objective。
- SAC 在训练中主动塑造更高熵的最优策略。
- 两者都影响随机性，但一个是解码约束，一个是决策目标。

高频追问

- temperature sampling 与 entropy bonus 区别？
- RLHF rollout temperature 会改变训练分布吗？

易错点 避免把 sampling 策略与 RL policy objective 混为一谈。

第五章 Offline RL / Model-based / Multi-Agent / Sim2Real

本章主线 高级岗常用本章区分“只会 benchmark”与“理解真实约束”。Offline、Sim2Real、MARL 都围绕 distribution shift、support 与非平稳性。

Q059 Online RL 与 Offline RL 有什么区别？

题型：高级高频

频率：★★★★☆

难度：★★★★☆

岗位：推荐/机器人/研究

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 Online RL 可持续与环境交互；Offline RL 只有固定 dataset，核心难点是学到的 policy 会访问数据外 OOD action/state。

深入解析

- Offline 的目标不只是 imitation，而是用 reward 实现 policy improvement。
- 无法在线纠错使 value extrapolation error 特别危险。
- 真实医疗、机器人历史日志、推荐日志等场景常受限于 offline setting。

高频追问

- offline-to-online 怎么做？
- off-policy RL 就等于 offline RL 吗？

易错点 off-policy 只描述数据策略与目标策略不同；offline 还意味着训练期间不能获取新数据。

Q060 为什么普通 Q-learning 直接做 Offline RL 容易失败？

题型：核心高级

频率：★★★★☆

难度：★★★★☆

岗位：研究/推荐

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 max/actor 会选择 dataset 未覆盖的动作，而 Q 网络对 OOD action 的值没有可靠监督，容易产生虚高估计并被策略 exploit。

深入解析

- bootstrap 会把 OOD 误差继续传播。
- 这形成 extrapolation error → policy selects OOD → 更大误差的反馈环。
- CQL 用 conservative Q，IQL 则避免显式 query OOD action。

高频追问

- BCQ/BEAR 的思路？
- 为什么更大模型不自动解决 OOD Q？

易错点 这是分布支持集问题，不是简单“数据量少”。

Q061 Behavior Cloning 与 Offline RL 的区别?

题型：高级母题

频率：★★★★☆

难度：★★★★☆

岗位：机器人/推荐

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 BC 只拟合行为策略动作分布，不使用 reward 做真正 policy improvement；Offline RL 试图在固定数据上利用 reward 超过 behavior policy。

深入解析

- BC 稳定、不会主动走向 OOD，但受限于示范质量。
- Offline RL 更有潜力，但必须限制策略偏离 dataset support。
- 很多实用算法采用“value 学习 + advantage weighted BC”的折中。

关键公式

$$L_{BC} = -E_D[\log \pi(a|s)]$$

高频追问

- BC 为什么有 compounding error?
- DAgger 如何缓解?

易错点 不要把 BC 称为 RL；它通常是 supervised imitation learning。

Q062 CQL 的核心思想是什么？

题型：高级经典

频率：★★★★☆

难度：★★★★☆

岗位：Offline RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 CQL 在 Bellman error 外增加 conservative regularizer，压低整体尤其 OOD action 的 Q，同时保持 dataset action 的价值，降低 policy exploit 虚高 Q。

深入解析

- 典型项 $\log\sum_a Q(s,a) - E_{\{a \sim D\}} Q(s,a)$ 。
- 可理解为让 learned Q 对 policy value 更保守。
- 代价是过度 conservative 可能错失真正可泛化的高价值动作。

关键公式

$$L_{\text{CQL}} = L_{\text{TD}} + \alpha [\log \sum_a \exp Q(s,a) - E_{\{a \sim D\}} Q(s,a)]$$

高频追问

- α 太大怎样？
- continuous action 下 $\log\sum \exp$ 怎么近似？

易错点 CQL 不是简单“把所有 Q 减一个常数”。

Q063 IQL 为什么可以避免显式 OOD action evaluation?

题型：高级经典

频率：★★★★☆

难度：★★★★★

岗位：Offline RL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 IQL 从 dataset action 学 Q ，并用 expectile regression 学 V ；policy extraction 再对 dataset action 做 advantage-weighted BC，因此训练中不需要对任意新动作做 max。

深入解析

- V 用 expectile 抓取 Q 分布上侧信息。
- $A=Q-V$ 决定对行为动作的加权。
- policy 仍可能在泛化中产生新动作，但 objective 不显式依赖 $\text{OOD argmax } Q$ 。

关键公式

$$\pi(a|s) \propto \mu(a|s) \exp(\beta A(s,a))$$

高频追问

- expectile 与 quantile 区别？
- β 太大会怎样？

易错点 “不查询 OOD” 是训练目标层面的近似描述，不是部署时保证 policy 绝不离开 dataset。

Q064 Model-based 与 Model-free RL 有何区别?

题型：高级母题

频率：★★★★☆

难度：★★★★☆

岗位：研究/机器人

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 Model-based 显式学习/使用环境动力学再做规划或 imagined rollout；Model-free 直接学 value/policy。

深入解析

- model-based sample efficient, 但 model bias 会随 rollout horizon 累积。
- 短 imagined rollout、uncertainty ensemble、MPC 是控制误差的常见手段。
- 真实系统中 learned model 还能用于安全预测与规划。

高频追问

- world model 为什么重新流行？
- model error 如何估计？

易错点 “Model-based 一定更好” 错误；模型误差可能比样本效率收益更致命。

Q065 Reward Shaping 应遵循什么原则？

题型：公开项目真题

频率：★★★★★

难度：★★★★☆

岗位：游戏/机器人

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 shaping 要帮助探索与 credit assignment，但不能让代理目标替代最终目标。理想情况下使用 potential-based shaping 保持最优策略不变。

深入解析

- 每个 reward 分项都要可监控、可 ablation。
- scale 要统一，否则 agent 只优化最大量级分项。
- 防 shortcut/reward hacking：对关键行为做 counterfactual 测试。
- 终局 reward 应保持足够权重。

关键公式

$$F(s,a,s') = \gamma \Phi(s') - \Phi(s)$$

高频追问

- 为什么 distance-to-goal reward 可能有坑？
- 如何做 reward normalization？

易错点 “奖励越 dense 越好” 是常见误区。

Q066 Sparse Reward 怎么解决？先诊断什么？

题型：公开项目真题

频率：★★★★★

难度：★★★★☆

岗位：游戏/机器人

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 先区分主要瓶颈是 exploration 还是 credit assignment；前者需要更好探索/课程，后者需要更好的 value/return 传播。

深入解析

- exploration: intrinsic reward、self-play、curriculum、demonstrations。
- credit: n-step、GAE、hierarchical decomposition。
- goal-conditioned 任务可用 HER 重标目标。
- 可验证 LLM 任务可通过分解 verifier / process reward 缓解。

高频追问

- HER 为什么只适合某类任务？
- process reward 有什么风险？

易错点 不要把所有 sparse reward 都粗暴改成 dense handcrafted reward。

Q067 Intrinsic Motivation 的基本思想与 noisy-TV 问题？

题型：高级扩展

频率：★★★★☆

难度：★★★★☆

岗位：游戏/研究

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 给 agent 额外内部奖励鼓励 novelty、prediction error 或信息增益，但随机不可预测却无任务价值的状态可能长期吸引 agent，形成 noisy-TV。

深入解析

- count-based / pseudo-count 奖励稀有状态。
- RND 用随机网络预测误差衡量 novelty。
- 信息增益方法试图奖励“可学习的不确定性减少”，更能绕开纯随机噪声。

关键公式

$$r = r_{\text{ext}} + \beta r_{\text{int}}$$

高频追问

- intrinsic reward 何时 anneal?
- episodic novelty 和 lifelong novelty 区别？

易错点 prediction error 高可能只是不可约噪声，不一定意味着值得探索。

Q068 Self-play 为什么能产生 Curriculum?

题型：公开项目真题

频率：★★★★☆

难度：★★★★☆

岗位：游戏/MARL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 对手随自身能力一起提升，任务难度自动匹配当前水平，形成动态课程。

深入解析

- naive self-play 可能循环或遗忘旧策略。
- opponent pool / league training 保留历史策略，增加策略多样性。
- 评估要防 Elo/胜率被非传递关系误导。

高频追问

- AlphaStar league 为什么复杂？
- 如何避免策略坍缩到单一打法？

易错点 Self-play 不保证自动覆盖所有策略空间。

Q069 多智能体 RL 最大难题是什么？QMIX 解决什么？

题型：高级高频

频率：★★★★☆

难度：★★★★☆

岗位：游戏/MARL

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 每个 agent 学习时其他 agent 的 policy 也变，导致环境对单 agent 非平稳；QMIX 通过单调 mixing network 支持 centralized training、decentralized execution。

深入解析

- 各 agent 学局部 Q_i ，mixing network 结合 global state 得到 Q_{tot} 。
- 单调约束 $\partial Q_{tot} / \partial Q_i \geq 0$ 保证联合 argmax 可由局部 greedy 动作组成。
- 代价是可表达的 joint value class 受单调约束限制。

关键公式

$$\partial Q_{tot} / \partial Q_i \geq 0$$

高频追问

- VDN 与 QMIX 区别？
- non-monotonic coordination 怎么办？

易错点 不要把“集中训练”误解成部署时需要全局信息。

Q070 机器人 Sim2Real 怎么做？

题型：公开项目真题

频率：★★★★☆

难度：★★★★☆

岗位：机器人

面试官在考什么

机制理解、公式解释、failure mode 与工程迁移能力。

30 秒回答

核心结论 核心是缩小 simulator 与现实动力学/观测差异：domain randomization、system identification、adaptation、residual policy、真实数据 fine-tune。

深入解析

- 随机 mass、friction、delay、sensor noise、motor strength、terrain 等。
- 若随机范围太窄，覆盖不到现实；太宽则策略过度保守、难学。
- privileged learning 可在训练时用真值状态，部署时蒸馏到观测策略。

高频追问

- latency randomization 为什么重要？
- 安全 sim2real 如何做？

易错点 Sim2Real 不只是视觉 domain shift，动力学与控制时延往往更关键。

第六章 RLHF / DPO / GRPO / DAPO / GSPO

本章主线 2026 的 LLM 算法岗已经把 GRPO/DAPO/GSPO 放到一面。答题时要把算法改动绑定到 critic 成本、zero-signal group、entropy collapse、long-CoT weighting 与 sequence-level ratio。

LLM Post-training 强化学习演化主线



核心演化：PPO 解决“更新太大”→ DPO 绕开在线 RL → GRPO 去 Critic → DAPO 修复 GRPO 长 CoT pathology → GSPO 重新思考 sequence-level 优化粒度。

Q071 完整讲一下 RLHF Pipeline。

题型：LLM 高频

频率：★★★★★

难度：★★★★☆

岗位：LLM Post-training

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 经典流程是 SFT → preference data → Reward Model → PPO/策略优化，并用 reference/KL 控制策略偏离。现代体系还包括 DPO、verifier RL、GRPO 等变体。

深入解析

- SFT 学人类示范行为分布。
- RM 从偏好对学习 sequence-level scalar reward。
- RL 在当前 policy 采样上直接优化 reward。
- reference model 作为语言先验锚点，避免 reward hacking 与过度漂移。

关键公式

$$\max_{\pi} E[r_{\phi}(x,y) - \beta KL(\pi || \pi_{ref})]$$

高频追问

- RLAIIF 与 RLHF 差别？
- 为什么 reasoning RL 常用 verifier 而非 RM？

易错点 不要把“RLHF”只等同 PPO；它是更广的基于人类反馈对齐范式。

Q072 已经有 SFT，为什么还需要 RL?

题型：公开面经真题

频率：★★★★★

难度：★★★★☆☆

岗位：LLM Post-training

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 SFT 是 token-level behavior cloning，无法直接优化 correctness、preference、tool success 等 sequence-level 目标；RL 可以用不可微 verifier/reward 直接优化期望任务收益。

深入解析

- SFT 仍是重要 warm start，保证语言与指令基本能力。
- RL 的价值在于 policy exploration：可以发现示范数据中没有的新解法。
- 对于有可验证答案的数学、代码，RL signal 尤其强。

高频追问

- 为什么 preference pair 不能简单 chosen-only SFT?
- RL 一定比 SFT 好吗?

易错点 RL 不是替代 SFT，而是优化信号与数据生成机制不同。

Q073 Reward Model 怎么训练？

题型：LLM 高频

频率：★★★★★

难度：★★★★☆

岗位：LLM Post-training

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 对同一 prompt 的 preferred/rejected response 学 Bradley-Terry 排序：让 chosen 的 scalar reward 高于 rejected。

深入解析

- RM 学相对偏好，不要求绝对分数有真实物理含义。
- pair 构造质量、长度 bias、annotator disagreement 会直接进入 reward。
- 训练后还必须做 calibration、OOD、adversarial 与 optimizer-facing 测试。

关键公式

$$L_{RM} = -\log \sigma(r(x,y_w) - r(x,y_l))$$

高频追问

- 为什么 RM accuracy 高仍会 reward hack？
- 如何做 listwise preference？

易错点 不要只看 held-out pair accuracy；policy 会主动搜索 RM 的漏洞。

Q074 Reward Model 准确率很高，为什么 RL 还是可能训练坏？

题型：公开面经追问

频率：★★★★★

难度：★★★★☆

岗位：LLM Post-training

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 RM 的离线准确率是在训练/验证分布上测的；policy 优化会把生成分布推向 RM 未见区域，并主动 exploit approximation error，形成 Goodhart/reward hacking。

深入解析

- policy shift 越大，RM OOD 越严重。
- RM 与 policy 同源模型还可能共享盲点。
- 解决：reference KL、reward ensemble、rule verifier、周期性新偏好数据、adversarial eval。

高频追问

- 如何识别 reward hacking？
- RM ensemble 为什么有用？

易错点 优化器面对的 RM 鲁棒性，比普通分类准确率更重要。

Q075 RLHF 为什么需要 Reference Model?

题型：公开面经真题

频率：★★★★★

难度：★★★☆☆

岗位：LLM Post-training

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 Reference 提供“不要离原语言模型太远”的锚，通过 KL 约束保持语言质量、分布支持与行为先验。

深入解析

- 无 KL 时 policy 可能寻找奇怪字符串获得 RM 高分。
- β 太大则学不到 reward，太小则漂移过度。
- 一些方法动态调 β 以维持 target KL。

关键公式

$$R_{\text{total}} = R_{\text{task}} - \beta \text{KL}(\pi_{\theta} \parallel \pi_{\text{ref}})$$

高频追问

- reference 是否更新？
- DeepSeek-R1 中 reference refresh 有什么意义？

易错点 reference 与 PPO 的 π_{old} 不是同一个概念：一个是长期锚，一个是本轮采样行为策略。

Q076 KL 在 RLHF 中出现在哪里？过大和过小意味着什么？

题型：公开面经真题

频率：★★★★★

难度：★★★★☆

岗位：LLM Post-training

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 常见有两类 KL：policy 与 reference 的长期正则，以及 policy 新旧版本的 trust-region/训练稳定指标。过大表示漂移，过小可能更新过于保守。

深入解析

- reference KL 可放到 reward shaping 或 loss penalty。
- token-level KL 的估计方式与方向会影响数值。
- 监控 KL 同时要看 reward、entropy、length、held-out task，否则单一 KL 不能定义好坏。

关键公式

$$D_{KL}(\pi_{\theta} || \pi_{ref}) = E_{\{y \sim \pi_{\theta}\}} [\log \pi_{\theta}(y) - \log \pi_{ref}(y)]$$

高频追问

- reverse KL 与 forward KL 行为差别？
- sampled KL estimator 会为负吗？

易错点 单样本 log-ratio 可以为负，真正 KL 的期望非负。

Q077 为什么经典 RLHF 常用 PPO?

题型：公开面经真题

频率：★★★★★

难度：★★★★☆

岗位：LLM Post-training

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 PPO 能用不可微 sequence reward 更新巨大 stochastic policy，clip/KL 约束又能控制语言模型分布漂移，并且已有成熟的大规模 actor-critic 工程。

深入解析

- token 就是 action，prefix 是 state。
- rollout 产生 response 后得到终局/过程 reward。
- critic 做 credit assignment 与 variance reduction。
- 但 critic 成本和 rollout 开销促成 GRPO 等新方法。

高频追问

- 为什么不用 DQN?
- 为什么不用 SAC?

易错点 回答必须包含“适用性 + 历史工程成熟度”，不能说它理论上是唯一正确选择。

Q078 PPO 里已经有 Critic，为什么还需要 Reward Model?

题型：公开面经真题

频率：★★★★★

难度：★★★★☆

岗位：LLM Post-training

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 RM 定义“什么输出更好”，Critic 预测在当前 prefix 下未来可获得的累计 reward，用于 advantage/credit assignment。

深入解析

- RM 通常对完整 response 给 scalar 或过程分。
- Critic 对每个 token prefix 估 value。
- 即便有准确 RM，仍需 critic 降低 policy gradient variance；反之 critic 不能自己定义偏好目标。

高频追问

- process reward model 与 critic 的区别？
- value head 可以和 RM 共用吗？

易错点 “都是打分模型”是表面相似，训练目标和时间语义完全不同。

Q079 DPO 的核心思想与损失函数？

题型：LLM 高频

频率：★★★★★

难度：★★★★☆

岗位：LLM Post-training

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 DPO 在 KL-regularized preference model 假设下，把隐式 reward 与 optimal policy 关系代入，直接对 chosen/rejected 的 policy-reference log-ratio 做 logistic classification。

深入解析

- 不需要显式 RM、critic、在线 rollout，工程显著简单。
- β 控制相对 reference 的偏好强度。
- DPO 依赖固定 preference data，缺少在线探索与 verifier 搜索能力。

关键公式

$$L_{DPO} = -\log \sigma(\beta[(\log \pi_{\theta}(y_w) - \log \pi_{\text{ref}}(y_w)) - (\log \pi_{\theta}(y_l) - \log \pi_{\text{ref}}(y_l))])$$

高频追问

- β 太大/太小？
- IPO/KTO/ORPO 与 DPO 的关系？

易错点 DPO 不是“没有 reward”；它把 reward 隐式消去了。

Q080 DPO vs PPO，什么时候选哪个？

题型：公开面经真题

频率：★★★★★

难度：★★★★☆

岗位：LLM Post-training

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 有高质量固定偏好对、追求简单稳定时 DPO 很合适；有可验证 reward、希望在线探索新解法时 PPO/GRPO 类 online RL 更有优势。

深入解析

- DPO 训练成本近似普通 fine-tuning，但受数据边界约束。
- 在线 RL 可以持续生成 hard trajectories，但 rollout 与系统复杂度高。
- 实际 pipeline 常 SFT/DPO 做行为塑形，再 verifier RL 做能力探索。

高频追问

- DPO 能否 online 化？
- 为什么 reasoning 模型更偏 verifier RL？

易错点 不要把比较变成“DPO 新所以更好”；要看 reward 是否可在线验证。

Q081 GRPO 为什么被提出？和 PPO 最核心区别？

题型：公开面经真题

频率：★★★★★

难度：★★★★☆

岗位：LLM Reasoning

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 GRPO 对同一 prompt 采一组 responses，用组内相对 reward 标准化得到 advantage，从而不再需要独立 value critic，显著降低 LLM RL 显存与系统复杂度。

深入解析

- 对 prompt q 采 G 个输出，计算各自 reward。
- $A_i = (r_i - \text{mean}(r)) / \text{std}(r)$ 是最直观 group-relative advantage。
- 仍可使用 PPO 风格 ratio、clip、KL。
- 代价是每 prompt 要多 sample，且组内无 reward 差异时没有学习信号。

关键公式

$$A_i = (r_i - \text{mean}_j r_j) / (\text{std}_j r_j + \epsilon)$$

高频追问

- GRPO 真的完全没有 value 吗？
- group size 如何影响方差？

易错点 不要把 GRPO 简化成“PPO 去掉 critic”；group normalization 改变了 advantage 估计机制。

题源注：原始研究：DeepSeekMath 提出 GRPO；DeepSeek-R1 后续在大规模推理 RL 中采用 GRPO。

Q082 PPO vs GRPO 为什么 GRPO 更省显存？

题型：公开面经真题

频率：★★★★★

难度：★★★☆☆

岗位：LLM Reasoning

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 PPO 通常需要大规模 value/critic 模型及 optimizer states；GRPO 用组内 reward 做 baseline，省去 critic 及其梯度、optimizer、通信。

深入解析

- LLM 32B/70B 时少一个同规模模型价值巨大。
- 但 GRPO rollout 数量更高，推理侧算力可能上升。
- 系统瓶颈从 learner memory 更偏向 rollout throughput/straggler。

高频追问

- 省显存是否等于更快？
- reference/RM 还需要吗？

易错点 显存节省与总 FLOPs/端到端 wall-clock 不是同一指标。

Q083 GRPO 一个 group 全对或全错会发生什么？

题型：LLM Reasoning 高频

频率：★★★★★

难度：★★★★☆

岗位：LLM Reasoning

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 所有 reward 相同意味着组内相对 advantage 近 0，几乎没有策略区分信号；大量 zero-variance groups 会浪费昂贵 rollout。

深入解析

- 全对说明题太简单，全错说明题过难或模型尚无成功轨迹。
- Dynamic Sampling 会过滤/重采这些低信息 prompt。
- curriculum 的目标是让任务保持在“有成功也有失败”的学习边界。

关键公式

$$\text{Var_group}(r)=0 \Rightarrow \hat{A}_i \approx 0$$

高频追问

- 如何定义有效 sample efficiency?
- 只看 pass@1 会错过什么?

易错点 std=0 的数值除零可以加 ϵ ，但算法信息仍然是 0，不是数值技巧能解决。

Q084 Rule-based Reward 与 Neural Reward Model 各有什么优缺点？

题型：LLM Reasoning 高频

频率：★★★★★

难度：★★★★☆

岗位：LLM Reasoning

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 rule/verifier 在数学、代码等可验证任务中确定、抗模型偏差；neural RM 覆盖开放文本更广，但存在 reward hacking、OOD 与 judge bias。

深入解析

- 优先级原则：能执行验证就尽量执行验证。
- 规则 reward 也可能被 parser/格式漏洞 exploit，需要 adversarial test。
- 开放任务可用 RM ensemble + reference + human audit。

高频追问

- 答案正确但 reasoning 错怎么办？
- process verifier 如何构造？

易错点 “规则奖励不会被 hack”也是错的，任何代理指标都可能有漏洞。

Q085 DAPO 相比 GRPO 的四个核心改动？

题型：2026 真题

频率：★★★★★

难度：★★★★★

岗位：LLM Reasoning

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 DAPO 重点修复大规模长 CoT RL 的训练 pathology：Clip-Higher、Dynamic Sampling、Token-level Policy Gradient Loss、Overlong Reward Shaping。

深入解析

- Clip-Higher：正向更新上界更宽，改善探索与 entropy collapse。
- Dynamic Sampling：去掉 reward 方差为 0 的 group，提高有效 rollout。
- Token-level loss：调整不同 response 长度的梯度权重。
- Overlong shaping：对过长输出平滑惩罚，避免硬截断带来的噪声。

高频追问

- 为何上界和下界 clip 要解耦？
- Dynamic Sampling 是否改变训练分布？

易错点 DAPO 不是一个单点 trick，而是“算法 + 数据采样 + 长度处理”系统组合。

题源注：2026 面经：字节大模型算法岗公开题目已直接比较 GRPO、DAPO、GSPO。

Q086 GSPO 为什么改用 Sequence-level Importance Ratio?

题型：2026 真题

频率：★★★★★

难度：★★★★★

岗位：LLM Reasoning

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 GSPO 把优化单位从 token-level ratio 提升到 sequence-level ratio，使 importance correction 与 sequence-level reward 的粒度更一致，并改善长序列与 MoE RL 的稳定性。

深入解析

- GSPO 认为 GRPO 的 token-level importance weight 只基于每个位置的一次 token sample，容易把高方差噪声注入长序列梯度。
- 它对整条 response 做 sequence-level clipping，并让同一 response 的 token 在梯度中共享同一 sequence weight。
- 论文使用长度归一化的 sequence likelihood ratio（几何平均比值），避免序列越长 ratio 数值范围越极端。

关键公式

$$s_i(\theta) = \exp\left(\frac{1}{|y_i|} \sum_t [\log \pi_{\theta}(y_{i,t} | x, y_{i,<t}) - \log \pi_{\text{old}}(y_{i,t} | x, y_{i,<t})]\right)$$

高频追问

- 为什么要除以 $|y_i|$?
- sequence-level clip 对 fine-grained credit assignment 有何代价?

易错点 GSPO 的 ratio 不是简单“把 token ratio 相乘后直接 clip”；论文显式做 $1/|y|$ 长度归一化。

题源注：2026 面经：同类岗位直接追问 GSPO 相对 GRPO 的改进。

Q087 PPO、GRPO、DAPO、GSPO 如何形成演化路线？

题型：2026 总结题

频率：★★★★★

难度：★★★★☆

岗位：LLM Reasoning

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 PPO 解决“策略更新不能太大”；GRPO 去 critic 以降低 LLM RL 成本；DAPO 修复 GRPO 在长 CoT 的采样、clip、长度与 loss weighting 问题；GSPO 进一步重审 importance ratio 的 sequence 粒度。

深入解析

- 回答要按 failure mode，不按年份背诵。
- PPO: trust-region approximation。
- GRPO: value-free group baseline。
- DAPO: scalable long-CoT training recipe。
- GSPO: sequence-level policy optimization。

高频追问

- 为什么新算法仍常保留 PPO-style clip？
- 不同算法能否混合？

易错点 面试官要看“为什么改”，不是“改了什么名词”。

Q088 GRPO 中 KL 怎么加？与 PPO reference KL 的关系？

题型：2026 真题

频率：★★★★★

难度：★★★★☆

岗位：LLM Reasoning

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 GRPO 仍可对 policy 与 reference 计算 token/sequence KL 作为正则或 reward penalty；它去掉的是 critic，不是 reference 约束。

深入解析

- 常见实现用 sampled log-ratio 近似 KL penalty。
- β 控制 reward exploitation 与语言先验保持。
- 如果 reference 随训练阶段更新，KL 的“锚”也在移动。

关键公式

$$\tilde{r} = r_{\text{task}} - \beta \cdot \text{KL}(\pi_{\theta} || \pi_{\text{ref}})$$

高频追问

- KL penalty 放 reward 还是 loss 有区别吗？
- reference refresh 会怎样影响探索？

易错点 “GRPO 不需要 KL” 是错误结论。

Q089 Agentic RL 的过程奖励如何设计到 token/step?

题型：2026 真题

频率：★★★★☆

难度：★★★★★

岗位：Agentic RL

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 先把长 trajectory 分成语义 step: thought/tool-call/tool-result/final; reward 可在 step boundary 给, 并通过 return/advantage 向相应 token 段传播, 而不是把同一个终局分数无脑平均到所有 token。

深入解析

- 工具调用可用 schema valid、execution success、cost、state progress 等确定性信号。
- 过程 reward model 可给每一步分数, 但要防 dense reward shortcut。
- credit assignment 可用 token-level GAE、step-level return 或 hierarchical value。

高频追问

- tool result 不可微如何训练?
- 失败工具调用如何归因到参数 token?

易错点 粒度必须和 agent action semantics 对齐, token 只是参数化载体。

Q090 GRPO 长尾 rollout 导致 GPU 利用率低，怎么解决？

题型：2026 工程真题

频率：★★★★★

难度：★★★★★

岗位：LLM RL Infra

面试官在考什么

能否把 LLM 训练现象还原到 policy optimization、reward、采样和系统成本，而不是只背论文名词。

30 秒回答

核心结论 自回归长度差异导致 straggler：短序列 GPU 空等长序列。要从 dynamic batching、length bucketing、async rollout、continuous batching、max-length curriculum 与资源解耦处理。

深入解析

- 按预测长度/历史长度分桶，减少同 batch 长短混杂。
- rollout 服务与 learner 解耦，使用异步队列隐藏长尾。
- continuous batching 让完成序列立刻腾出 KV slot。
- 监控 p50/p95/p99 response length 与 tokens/sec，而非只看 batch latency。

高频追问

- 截断长序列的统计偏差？
- 为什么 speculative decoding 可能帮助？

易错点 不要只说“加 GPU”；straggler 是调度与长度分布问题。

题源注：2026 面经：公开题目已追问 GRPO 长尾 rollout 导致 GPU 利用率低的工程解决方案。

第七章 Debug / RL Infra / 系统设计 / 手撕实现

本章主线 最后 10 题决定你像不像真正训练过 RL。面试官会把算法题变成 Debug、Infra、指标联动和系统设计题。

Q091 RL 训练 reward 全 0 或全 1，怎么排查？

题型：公开面经真题

频率：★★★★★

难度：★★★★☆

岗位：全方向

面试官在考什么

是否真正做过训练：能否从指标、数据流、版本和吞吐定位问题。

30 秒回答

核心结论 先确认 reward pipeline 无 bug，再判断任务难度与探索边界。全 0 常是过难/解析失败；全 1 常是过易/泄漏/reward loophole。

深入解析

- 检查 verifier/parser 单测与人工样本。
- 画 reward 分布按 prompt 难度、长度、版本切片。
- GRPO 中 zero-variance group 直接没有有效相对 advantage。
- 用 curriculum / dynamic sampling 让训练样本保持“可区分”。

高频追问

- reward 只有 0/1 是否一定不好？
- 如何做 binary verifier calibration？

易错点 binary reward 本身没问题，问题是整个 batch/group 无方差。

Q092 什么是 Entropy Collapse? 怎么发现和缓解?

题型：2026 高频

频率：★★★★★

难度：★★★★☆

岗位：PPO/LLM-RL

面试官在考什么

是否真正做过训练：能否从指标、数据流、版本和吞吐定位问题。

30 秒回答

核心结论 policy entropy 持续下降、输出多样性坍缩，导致探索停止；在 reasoning RL 中可能表现为固定模板、固定长度或局部 token 过度确定。

深入解析

- 监控 token entropy、unique response ratio、self-BLEU/semantic diversity、clipfrac。
- 缓解：entropy bonus、减 lr/epoch、调 clip、提高 rollout temperature、DAPO Clip-Higher。
- 要同时看 reward：entropy 降低有时是合理收敛，关键是是否伴随泛化/探索恶化。

关键公式

$$H(\pi) = -E[\log \pi(a|s)]$$

高频追问

- 为什么 reward 上升时也可能 entropy collapse?
- sequence entropy 怎么定义?

易错点 熵下降不是自动等于坏；需要和任务性能、探索需求联动判断。

Q093 什么是 Reward Hacking? 举一个算法层面的例子。

题型：系统高频

频率：★★★★★

难度：★★★★☆

岗位：全方向

面试官在考什么

是否真正做过训练：能否从指标、数据流、版本和吞吐定位问题。

30 秒回答

核心结论 当优化器最大化代理 reward 而不是真实目标时，会寻找代理漏洞；例如格式奖励过强时模型输出冗余模板刷分，或 learned RM 偏爱长回答导致长度膨胀。

深入解析

- 识别：reward 上升但外部评测/人工质量下降。
- 缓解：独立 verifier、对抗测试、reward ensemble、规则 hard constraints、holdout metric。
- 最重要的是 reward 与最终业务指标之间持续做 causal sanity check。

高频追问

- Goodhart 定律如何理解？
- 为什么 stronger optimizer 更容易 hack reward？

易错点 不要只把 reward hacking 理解成“模型作弊”，它是代理目标优化的系统性现象。

Q094 为什么 Long-CoT RL 容易越来越长？

题型：LLM 工程高频

频率：★★★★★

难度：★★★★☆

岗位：LLM Reasoning

面试官在考什么

是否真正做过训练：能否从指标、数据流、版本和吞吐定位问题。

30 秒回答

核心结论 若 reward 只看正确性，长 reasoning 提供更多搜索/自检机会，policy 会学到“延长计算”作为提升成功率的策略；若无成本项就可能过度思考。

深入解析

- 长度与正确率常非线性相关。
- 硬截断 $\text{len} > L \rightarrow 0$ reward 会制造不连续噪声。
- 可用 overlong shaping、token cost、adaptive max length、difficulty-conditioned budget。

关键公式

$$R_{\text{total}} = R_{\text{correct}} - \lambda \cdot \text{cost}(\text{length})$$

高频追问

- 如何避免模型为了短而牺牲正确率？
- test-time compute 与 training reward 怎么匹配？

易错点 不能简单以“越短越好”优化 reasoning model。

Q095 设计一个大规模 PPO/GRPO Rollout 系统。

题型：系统设计

频率：★★★★★

难度：★★★★★

岗位：RL Infra/LLM

面试官在考什么

是否真正做过训练：能否从指标、数据流、版本和吞吐定位问题。

30 秒回答

核心结论 将 prompt sampling、rollout inference、reward/verifier、trajectory storage、advantage、learner、weight broadcast 解耦；核心是让 rollout 和 learner 持续流水而非相互等待。

深入解析

- rollout 侧：vLLM/SGLang 类 continuous batching、KV cache、长短序列调度。
- reward 侧：CPU/GPU verifier 分层，异步并发。
- learner：FSDP/Megatron/ZERO，gradient accumulation。
- 一致性：给 trajectory 记录 policy_version，限制 stale rollout。
- 观测：tokens/s、p95 latency、KL、entropy、reward std、GPU util。

高频追问

- 同步 vs 异步 RL 的权衡？
- 权重广播如何避免停顿？

易错点 只画 “Actor→Learner” 框图不够，要指出端到端瓶颈与一致性协议。

Q096 Actor-Learner 架构中的 Policy Lag 是什么？

题型：系统设计

频率：★★★★☆

难度：★★★★☆

岗位：分布式 RL

面试官在考什么

是否真正做过训练：能否从指标、数据流、版本和吞吐定位问题。

30 秒回答

核心结论 actor 用旧版本 π_k 生成数据时 learner 已到 π_{k+m} ，trajectory 对当前策略越来越 off-policy，导致 importance ratio 极端与训练不稳定。

深入解析

- 用 policy_version 标签测 lag。
- 限制允许最大版本差；及时 weight broadcast。
- 异步系统可用 correction（如 V-trace）或丢弃过旧数据。
- 吞吐调优要让 actor 与 learner 速率匹配。

关键公式

$$\text{lag} = \text{learner_version} - \text{rollout_version}$$

高频追问

- 什么时候宁愿丢数据？
- lag 与 KL 的关系？

易错点 “异步越多越好” 错误；吞吐和统计效率存在 tradeoff。

Q097 给一款 FPS/MOBA 游戏，怎么从零定义 RL 问题？

题型：公开面经真题

频率：★★★★★

难度：★★★★★

岗位：游戏 RL

面试官在考什么

是否真正做过训练：能否从指标、数据流、版本和吞吐定位问题。

30 秒回答

核心结论 按 State→Action→Reward→Environment Interface→Training/Evaluation 的顺序答，并把信息结构、动作层级、终局目标与自博弈说清。

深入解析

- State：自身、队友、敌人、地图、对象、历史；图/集合结构可用 attention。
- Action：移动/瞄准/技能/目标选择，可 hierarchical。
- Reward：终局胜负为锚，damage/resource/objective 仅做 shaping。
- Interface：确定 tick、观测延迟、动作执行与 reset。
- Training：self-play、opponent pool、curriculum、分布式 actor。

高频追问

- 地图怎么表示？
- 瞄准角是连续动作还是离散？
- 如何防 reward farming？

易错点 最危险的是把 reward 设计成几十项却不讲因果与消融。

Q098 System Design: 设计完整 LLM Reasoning RL Pipeline。

题型：终极系统题

频率：★★★★★

难度：★★★★★

岗位：LLM Reasoning/Infra

面试官在考什么

是否真正做过训练：能否从指标、数据流、版本和吞吐定位问题。

30 秒回答

核心结论 从 prompt curriculum 到多样本 rollout、verifier、group statistics、advantage、policy update、KL/entropy、evaluation、hard prompt mining 建立闭环，并对数据版本和 policy 版本全链路可追踪。

深入解析

- Prompt Pool: 按难度、领域、失败簇分层采样。
- Rollout: G responses/prompt, continuous batching。
- Verifier: 数学、代码、格式分层；开放题用 judge/RM。
- Selection: 过滤 zero-signal group, 监控 reward variance。
- Optimization: GRPO/DAPO/GSPO, 记录 ratio/clip/KL/entropy。
- Evaluation: pass@k/cons@k、held-out、长度、成本、安全与回归。
- Data flywheel: 失败簇→新 prompt/新 verifier→下一轮。

关键公式

$$\text{success} = \text{capability gain} - \lambda_1 \cdot \text{drift} - \lambda_2 \cdot \text{cost} - \lambda_3 \cdot \text{regression}$$

高频追问

- reward 上升但 held-out 降低怎么办？
- 如何做 checkpoint selection？

易错点 好的答案一定包含“训练指标不等于真实能力”，并设置独立 held-out 与防污染流程。

Q099 手撕 GRPO: 从 group reward 到 clipped objective 如何实现?

题型: 2026 手撕题

频率: ★★★★★

难度: ★★★★★

岗位: LLM Reasoning

面试官在考什么

是否真正做过训练: 能否从指标、数据流、版本和吞吐定位问题。

30 秒回答

核心结论 对每个 prompt 的 G 个 response 计算 reward, 组内标准化得到 A; 保存 old token log-prob; 训练时算 new-old logp 得 ratio, 用 PPO-style clip 与 A 形成 loss, 再加 KL/entropy 等项。

深入解析

- 实现难点是 batch 结构: prompt×sample×token 的 mask。
- response padding token 不应参与 loss; 按 token 还是按 sequence 聚合要与算法定义一致。
- reward normalization 要按 group 维, 不可跨全 batch 混。
- old logp 必须对应 rollout 时 policy 版本。

关键公式

$$A_{\{i\}} = (r_i - \mu_{\text{group}}) / (\sigma_{\text{group}} + \epsilon); \text{ratio}_t = \exp(\log p_{\text{new},t} - \log p_{\text{old},t})$$

高频追问

- group size=1 会怎样?
- token-average 和 sequence-average 区别?

易错点 最常见 bug 是 group 维度错、mask 错、旧 logp 与 response 对不上。

Q100 训练中应该监控哪些 RL 指标？如何联动诊断？

题型：工程必会

频率：★★★★★

难度：★★★★☆

岗位：全方向

面试官在考什么

是否真正做过训练：能否从指标、数据流、版本和吞吐定位问题。

30 秒回答

核心结论 至少同时监控 reward、task accuracy、KL、entropy、value/advantage stats、clipfrac、gradient norm、response/action length、success rate 与系统吞吐。

深入解析

- reward $\uparrow$ + held-out $\downarrow$ ：疑似 reward hacking/overfit。
- KL $\uparrow$ + clipfrac $\uparrow$ ：更新过大。
- entropy $\downarrow$ + diversity $\downarrow$ ：探索坍缩。
- value loss 爆炸：critic target/scale/done mask 问题。
- reward std ≈ 0 ：训练样本缺少区分信号。
- GPU util 低 + p99 length 高：rollout straggler。

高频追问

- advantage mean/std 应该是什么样？
- gradient norm spike 怎么定位？

易错点 单看 reward 曲线几乎无法判断 RL 是否健康。

附录 A 一页公式总表

公式	表达式
Return	$G_t = \sum_{k \geq 0} \gamma^k r_{t+k+1}$
Bellman V	$V^\pi(s) = E[r + \gamma V^\pi(s')]$
Q-learning	$y = r + \gamma \max_{a'} Q(s', a')$
TD error	$\delta = r + \gamma V(s') - V(s)$
Advantage	$A = Q - V$
Policy Gradient	$\nabla J = E[\nabla \log \pi(a s) A(s, a)]$
GAE	$\hat{A}_t = \sum_l (\gamma \lambda)^l \delta_{t+l}$
PPO ratio	$r_t = \exp(\log \pi_{\text{new}} - \log \pi_{\text{old}})$
PPO clip	$\min(rA, \text{clip}(r, 1-\epsilon, 1+\epsilon)A)$
TD3	$y = r + \gamma \min(Q1-, Q2-)$
SAC	$J = E[\sum r + \alpha H(\pi)]$
CQL	$L_{\text{TD}} + \alpha (\log \text{sumexp } Q - E_D Q)$
DPO	$-\log \sigma(\beta[(\log \pi_w - \log \pi_{\text{ref}}, w) - (\log \pi_l - \log \pi_{\text{ref}}, l)])$
GRPO	$A_i = (r_i - \text{mean } r) / \text{std } r$
RLHF	$R_{\text{total}} = R_{\text{task}} - \beta \text{KL}(\pi \pi_{\text{ref}})$

附录 B 算法选型速查

算法	范式	动作	数据复用	样本效率	适合	主要风险
DQN	Off-policy	离散	Replay	高	Atari/离散控制	连续动作、Q 过估计
PPO	On-policy	离散/连续	否	低-中	稳定并行仿真、LLM RL	rollout 贵、critic 成本
TD3	Off-policy	连续	Replay	高	机器人连续控制	探索与超参敏感
SAC	Off-policy	连续	Replay	高	真实采样昂贵的控制	entropy/scale 调节
CQL/IQL	Offline	离散/连续	固定集	固定数据	日志/历史数据	分布支持与 conservative bias
DPO	Offline preference	文本	固定偏好	高	偏好对齐	缺少在线探索
GRPO	Online RL	文本	短期 rollout	中	可验证 reasoning	group zero-signal、rollout 成本
DAPO	Online RL	文本	短期 rollout	中	长 CoT reasoning	系统复杂、配方依赖
GSPO	Online RL	文本	短期 rollout	中	sequence-level LLM RL	credit 粒度与实现细节

附录 C 参考研究与公开面经来源

1. Mnih et al. Human-level control through deep reinforcement learning. Nature, 2015.

2. Schulman et al. Trust Region Policy Optimization. ICML, 2015.

3. Schulman et al. High-Dimensional Continuous Control Using Generalized Advantage Estimation. 2015.

4. Schulman et al. Proximal Policy Optimization Algorithms. arXiv:1707.06347, 2017.
5. Lillicrap et al. Continuous control with deep reinforcement learning. 2015.
6. Fujimoto et al. Addressing Function Approximation Error in Actor-Critic Methods (TD3). ICML, 2018.
7. Haarnoja et al. Soft Actor-Critic. 2018.
8. Hessel et al. Rainbow: Combining Improvements in Deep Reinforcement Learning. AAAI, 2018.
9. Kumar et al. Conservative Q-Learning for Offline Reinforcement Learning. NeurIPS, 2020.
10. Kostrikov et al. Offline Reinforcement Learning with Implicit Q-Learning. 2021.
11. Rafailov et al. Direct Preference Optimization. NeurIPS, 2023.
12. Shao et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models (GRPO). 2024.
13. Guo et al. DeepSeek-R1 incentivizes reasoning in LLMs through reinforcement learning. Nature, 2025.
14. Yu et al. DAPO: An Open-Source LLM Reinforcement Learning System at Scale. 2025.
15. Zheng et al. GSPO: Group Sequence Policy Optimization. arXiv:2507.18071, 2025.
16. 牛客网公开面经：网易互娱强化学习面经（PPO Importance Sampling / Surrogate Clip / AC / 游戏系统设计）。
17. 牛客网公开面经：网易雷火强化学习面经（Policy Gradient / A3C / KL / DQN Loss）。
18. 牛客网公开面经：零跑强化学习算法工程师（Monte Carlo / DDPG / TD3 / SAC / Self-play）。
19. 牛客网公开面经：2026 字节大模型算法岗（PPO vs GRPO / DAPO / GSPO / Importance Sampling）。
20. 牛客网公开面经：2026 字节大模型算法岗（GRPO KL / Agentic RL 过程打分 / rollout 长尾 / 手撕 PPO、GRPO）。

阅读建议 论文用于验证算法机制，公开面经用于验证“企业会怎么问”。两者结合时，以原论文/官方技术资料解释算法，以面经确定复习优先级。

附录 D 7 天强化学习面试冲刺计划

天数	任务
Day 1	01-15: MDP、Bellman、MC/TD、on/off-policy; 手推 TD error 与 n-step。
Day 2	16-28: DQN 全家桶; 手写 DQN target、Double DQN、Replay Buffer。
Day 3	29-48: Policy Gradient→AC→GAE→TRPO→PPO; 必须手撕 PPO。
Day 4	49-70: DDPG/TD3/SAC + Offline RL + Reward Shaping + Sim2Real。
Day 5	71-82: RLHF、RM、KL、DPO; 把“为什么”讲通。
Day 6	83-90: GRPO、DAPO、GSPO; 手撕 GRPO, 重点看 2026 面经追问。
Day 7	91-100: Debug、指标联动、Rollout Infra、FPS/MOBA、LLM Reasoning RL System Design; 做 2 次完整模拟面试。