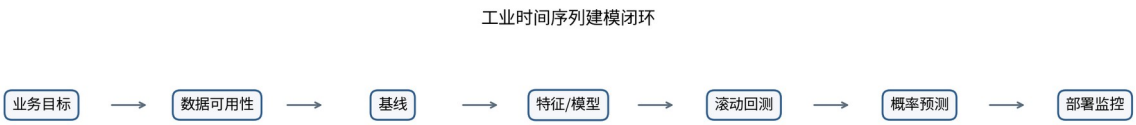
时间序列面试 100 题

从统计建模到 Time-Series Foundation Models

专业面试宝典 · 2026.09 版



原创结构：题目 → 核心考点 → 标准回答 → 原理深挖 → 追问树 → 易错点 → 工程落地

参考经典面试题集“由题入理、层层追问”的学习方式；不复制任何受版权保护的原书文字或版式。

前言：这本 PDF 应该怎么用

这不是一本“背答案”的题库。时间序列面试真正区分候选人的地方，往往不是是否记得 ARIMA 的三个字母，而是能否把统计假设、特征可用性、滚动回测、概率预测和业务成本连成一个闭环。

建议回答结构 先给 20 秒结论；再给公式/直觉；最后补“什么时候失效、怎么验证、线上怎么做”。这样既适合面试官快速判断，也给后续追问留下空间。

难度与频率标记

- 难度 1-2：基础概念，要求准确；难度 3：常规算法岗；难度 4：中高级；难度 5：Research / Senior / Staff 常见深挖。
- 频率以 ★★★★★ 表示相对复习优先级，不意味着某家公司固定题库。
- “公开面经”只作为题型存在性的旁证；答案内容以统计学习与 forecasting 原理为准。

面试答题的四层能力

层级	目标
L1 定义	能准确解释概念与公式。
L2 诊断	知道假设、边界、常见错误。
L3 工程	知道如何构造 point-in-time 数据、回测和上线。
L4 决策	能把概率预测转成库存、容量、风险等业务决策。

目录与知识地图

01 第一章 时间序列基础与统计直觉 · Q01-Q10

把“时间依赖”讲清楚：IID 为什么失效，趋势/季节/周期如何区分，ACF/PACF 与随机过程是什么。

02 第二章 平稳性、差分、分解与预处理 · Q11-Q20

从 unit root 到 ADF/KPSS、差分、Box-Cox、STL、结构突变和缺失值泄漏。

03 第三章 ARIMA、ETS 与状态空间模型 · Q21-Q35

经典统计预测的核心：AR/MA、Box-Jenkins、SARIMA、ARIMAX、残差诊断、ETS 和 Kalman Filter。

04 第四章 机器学习与大规模 Global Forecasting · Q36-Q50

把序列变成监督学习：lag/rolling/calendar、LightGBM、local vs global、冷启动、间歇需求与 ensemble。

05 第五章 深度学习预测模型 · Q51-Q65

从 RNN/LSTM 到 DeepAR、N-BEATS、TFT、PatchTST、iTransformer、TimeMixer；同时保留“简单模型可能更强”的判断力。

06 第六章 回测、指标与概率预测 · Q66-Q78

高级面试分水岭：point-in-time correctness、rolling CV、MASE/RMSSE、quantile loss、CRPS、prediction interval 与非对称业务成本。

07 第七章 多变量、协整、层级与因果 · Q79-Q88

VAR、Granger、cointegration、ECM、spurious regression、hierarchical reconciliation 和 forecasting vs causality。

08 第八章 异常检测、变化点与漂移 · Q89-Q93

从 residual anomaly 到 change point 和 concept drift，强调线上监控如何拆分 horizon/segment。

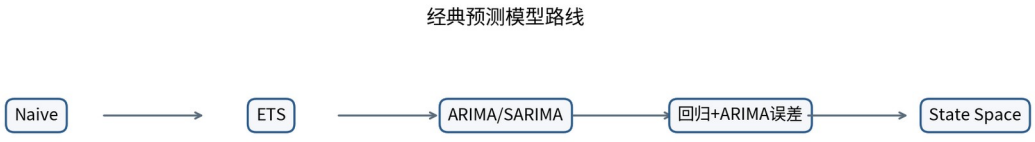
09 第九章 工业系统设计题 · Q94-Q96

销量预测系统、百万 SKU-store、离线好线上差：把建模能力落到系统与业务决策。

10 第十章 Time-Series Foundation Models · Q97-Q100

TimesFM、Chronos、Moirai 等 zero-shot / universal forecasting 体系，以及 2026 年多变量与协变量能力演进。

模型路线速览



现代预测模型路线


Global GBDT
DeepAR/N-BEATS
TFT
PatchTST/iTransformer
TS Foundation Model

第 1 章

时间序列基础与统计直觉

把“时间依赖”讲清楚：IID 为什么失效，趋势/季节/周期如何区分，ACF/PACF 与随机过程是什么。

本章面试目标 掌握 Q01-Q10。优先做到：定义准确、公式会解释、能指出失败模式，并能给出时间正确的验证方案。

Q001 什么是时间序列？它与普通 IID 数据最大的区别是什么？

难度 ★★★☆☆ **频率** ★★★★★ 关键词 时间依赖、IID、顺序、泄漏

一句话标准回答

时间序列的样本由时间索引组织，当前值通常与历史值相关；因此随机打乱会破坏依赖结构。预测问题还具有“信息集随时间增长”的特点：在时点 t 做预测，只能使用 t 当时已经可见的数据。

核心公式 / 结构

$$P(y_t|y_{t-1},\ldots) \neq P(y_t)$$

深挖原理

高级回答要把“非 IID”落到工程后果：切分必须按时间；标准化/编码器只能在训练窗拟合；任何特征都需要 point-in-time correctness；评估要模拟真实部署时的信息边界。

面试官继续追问

- 为什么随机 K-fold 会虚高?
- 什么情况下可以近似 IID?
- 面板时间序列又多了哪些依赖?

易错点 只说“有时间戳”不够；真正区别是依赖、非平稳和信息可用性。

高级加分点 面试中若听到“不能 shuffle”后立即追问“为什么”，应回答到信息集 I_t 和 leakage，而不是只说顺序重要。

Q002 Trend、Seasonality、Cycle 有什么区别?

难度 ★★☆☆☆ **频率** ★★★★☆ 关键词 趋势、季节、周期、分解

一句话标准回答

Trend 是长期方向；Seasonality 是固定或近似固定周期重复结构；Cycle 通常周期长度不固定，例如宏观经济周期。

核心公式 / 结构

$$y_t = T_t + S_t + R_t$$

深挖原理

面试时应进一步指出：季节性周期与业务采样频率相关，同一序列可能同时存在日/周/年多重季节性；趋势也可能是确定性趋势或随机趋势。

面试官继续追问

- 月度数据如何识别年季节?
- cycle 与 seasonality 为什么不能混用?

> **易错点** 把所有波动都叫 seasonality。

Q003 White Noise 和 Random Walk 有什么区别?

难度 ★★★☆☆ **频率** ★★★★★ 关键词 白噪声、随机游走、非平稳

一句话标准回答

白噪声本身不可由过去线性预测；随机游走是白噪声的累积，其方差随时间增长，因此不平稳。随机游走的一阶差分就是白噪声。

核心公式 / 结构

$$\varepsilon_t \sim WN(0,\sigma^2);\ y_t = y_{t-1} + \varepsilon_t$$

深挖原理

随机游走是理解 unit root、naive forecast 与 differencing 的入口。对 random walk，最优一步点预测常常就是最后观测值。

面试官继续追问

- random walk with drift 呢?
- 为什么方差随 t 增长?

> **易错点** 把“白噪声不相关”误说成“独立”；不相关比独立弱。

Q004 什么是 Autocorrelation?

难度 ★★☆☆☆ **频率** ★★★★☆ 关键词 ACF、自相关、lag

一句话标准回答

lag-k 自相关衡量当前值与 k 步之前值的线性相关。它是诊断周期、惯性和 ARMA 结构的重要工具。

核心公式 / 结构

$$\rho_k = Corr(y_t, y_{t-k})$$

深挖原理

高 ACF 可能只是趋势或季节性造成，不能直接解释为“可预测因果关系”。通常应在去趋势/差分后再解释相关结构。

面试官继续追问

- 趋势序列 ACF 为什么很高?
- 负自相关意味着什么?

易错点 用相关性直接推出因果。

Q005 ACF 和 PACF 有什么区别?

难度 ★★★☆☆ **频率** ★★★★★ 关键词 ACF、PACF、AR、MA

一句话标准回答

ACF 包含直接与间接相关；PACF 控制中间 lag 后看 t 与 t-k 的直接线性关系。经典经验：AR(p) 的 PACF 常在 p 阶后截尾，MA(q) 的 ACF 常在 q 阶后截尾。

核心公式 / 结构

$$PACF(k)=Corr(y_t,y_{t-k}|y_{t-1:t-k+1})$$

深挖原理

这只是候选模型识别 heuristic。有限样本、季节项、差分、混合 ARMA 都会让图形不“教科书化”，最终仍应通过信息准则、残差和滚动回测验证。

面试官继续追问

- ARMA 的 ACF/PACF 怎么看?
- 季节 lag 怎么识别?

易错点 把“截尾/拖尾”当成绝对判据。

Q006 什么是 Lag Operator / Backshift Operator?

难度 ★★☆☆☆ **频率** ★★★☆☆ 关键词 B 算子、差分、ARIMA

一句话标准回答

Backshift operator 用代数形式统一表示 lag。AR、MA、差分和季节差分都可以写成关于 B 的多项式。

核心公式 / 结构

$$B\ y_t=y_{t-1};\ (1-B)y_t=\Delta y_t$$

深挖原理

例如 ARIMA 可写为 ϕ(B)(1-B)^d y_t=θ(B)ε_t；季节差分为 (1-B^m)。掌握 B 算子有助于看懂 SARIMA 的乘法结构。

面试官继续追问

- (1-B)^2 展开是什么？
- 季节 AR 多项式怎么写？

易错点 只会符号，不理解它对应的时序操作。

Q007 什么叫平稳？

难度 ★★★☆☆ **频率** ★★★★★ **关键词** 弱平稳、均值、方差、协方差

一句话标准回答

弱平稳要求均值、方差不随时间改变，协方差只依赖 lag 而非绝对时间。许多经典 ARMA 统计推断都建立在这一结构上。

核心公式 / 结构

$$E[y_t]=\mu;\ Var(y_t)=\sigma^2;\ Cov(y_t,y_{t-k})=\gamma_k$$

深挖原理

面试高分点：不是所有预测模型都要求原序列平稳；“为了 ARIMA 做适当差分”和“所有机器学习都必须先差分”是两回事。

面试官继续追问

- 带确定性趋势的序列是否平稳？
- 季节性为什么破坏平稳？

易错点 把“平稳”说成数据完全不变化。

Q008 Strict Stationarity 和 Weak Stationarity 有什么区别？

难度 ★★★☆☆ **频率** ★★★★☆ **关键词** 严格平稳、弱平稳、分布

一句话标准回答

严格平稳要求任意有限维联合分布在时间平移后不变；弱平稳只约束一二阶矩。

核心公式 / 结构

$$(y_{t1},\dots,y_{tk}) \equiv_d (y_{t1+h},\dots,y_{tk+h})$$

深挖原理

若过程高斯，均值与协方差已决定联合分布，因此高斯过程下弱平稳与严格平稳联系更紧。

面试官继续追问

- 为什么 ARMA 常讨论弱平稳？
- 非高斯时有什么差异？

易错点 误以为弱平稳就是“近似严格平稳”。

Q009 为什么采样频率非常重要？

难度 ★★☆☆☆ **频率** ★★★★☆ 关键词 采样、聚合、aliasing、多季节

一句话标准回答

采样频率决定你能看见哪些变化模式。过度聚合会丢失高频季节性；采样过慢还可能造成 aliasing。

核心公式 / 结构

$f_s > 2f_{max}$（Nyquist 条件的理想化表述）

深挖原理

工程上还涉及业务决策频率：库存按天决策，却只建月度模型，统计上可能很好但无法支持决策。

面试官继续追问

- 小时转日数据会丢什么？
- 不同时区如何处理？

易错点 只按模型方便选择粒度，而不看决策粒度。

Q010 不规则时间序列怎么处理？

难度 ★★★☆☆ **频率** ★★★★☆ 关键词 不规则采样、重采样、时间间隔

一句话标准回答

可重采样到规则网格，也可显式加入 time-gap；状态空间/连续时间模型能更自然处理不规则观测。

核心公式 / 结构

$$\Delta t_i = t_i - t_{i-1}$$

深挖原理

插值的风险是制造不存在的信息。用于监督预测时，任何插值都必须遵循当时的信息集；离线用双向插值很容易泄漏。

面试官继续追问

- 传感器断点怎么处理?
- 事件流为何不一定要 resample?

> **易错点** 把所有缺失时间点直接线性插值且用于回测。

第 2 章

平稳性、差分、分解与预处理

从 unit root 到 ADF/KPSS、差分、Box-Cox、STL、结构突变和缺失值泄漏。

本章面试目标 掌握 Q11-Q20。优先做到：定义准确、公式会解释、能指出失败模式，并能给出时间正确的验证方案。

Q011 什么是 Unit Root?

难度 ★★★☆☆ **频率** ★★★★★ 关键词 单位根、随机游走、I(1)

一句话标准回答

AR(1) 在 ϕ=1 时含单位根，退化为随机游走；冲击影响不会衰减，方差随时间增长。

核心公式 / 结构

$$y_t=\varphi y_{t-1}+\varepsilon_t,\ \varphi=1$$

深挖原理

单位根是“随机趋势”而非简单确定性线性趋势。含单位根序列通常通过差分变为平稳，因此称 I(1)。

面试官继续追问

- ϕ≈1 会怎样?
- 为什么单位根检验很难?

易错点 把 unit root 等同“趋势存在”。

Q012 ADF Test 在检验什么?

难度 ★★★☆☆ **频率** ★★★★★ 关键词 ADF、单位根、假设检验

一句话标准回答

ADF 原假设是存在单位根，核心看 γ 是否支持单位根结构。p 值足够小时拒绝 H0，为平稳提供证据。

核心公式 / 结构

$$\Delta y_t=\alpha+\beta t+\gamma y_{t-1}+\Sigma\delta_i\Delta y_{t-i}+\varepsilon_t$$

深挖原理

检验规格必须考虑是否包含截距/趋势以及 lag 数；样本短、结构突变时统计功效会显著下降。

面试官继续追问

- p>0.05 能证明有单位根吗?
- 为何要加 lagged differences?

易错点 把“不拒绝”说成“证明 H0 正确”。

Q013 ADF 和 KPSS 为什么经常一起使用?

难度 ★★★☆☆ **频率** ★★★★★ 关键词 ADF、KPSS、互补检验

一句话标准回答

两种检验把原假设方向反过来，可以减少单一检验造成的误判。

核心公式 / 结构

$$ADF:H0=unit\ root;\ KPSS:H0=stationary$$

深挖原理

若 ADF 与 KPSS 给出冲突，优先检查趋势项、结构突变、样本长度、季节性与非线性；不要机械投票。

面试官继续追问

- 两者都 reject 怎么解释?
- trend-stationary 如何识别?

易错点 只看一个 p 值做自动化差分。

Q014 为什么做 Differencing?

难度 ★★☆☆☆ **频率** ★★★★★ 关键词 差分、随机趋势、季节差分

一句话标准回答

差分通过消除相邻 level 关系来处理随机趋势；季节差分处理 seasonal unit root。

核心公式 / 结构

$$\Delta y_t=y_t-y_{t-1};\ \Delta_m\ y_t=y_t-y_{t-m}$$

深挖原理

差分改变建模目标：模型预测的是变化量，最终要积分还原到 level；误差也会在多步还原中累积。

面试官继续追问

- 何时用 seasonal differencing?
- 差分后如何还原?

易错点 把差分当万能去趋势工具。

Q015 什么是 Over-differencing?

难度 ★★★☆☆	频率 ★★★★★	关键词 过度差分、方差、负相关

一句话标准回答

差分阶数过高会引入额外噪声和不必要的 MA 结构，预测方差可能增大。

核心公式 / 结构

$$\Delta^2 y_t=\Delta y_t-\Delta y_{t-1}$$

深挖原理

一个实用诊断是：若差分后 lag-1 ACF 出现明显强负相关，可能提示过度差分，但仍需结合模型与检验判断。

面试官继续追问

- 怎样确定最低必要 d?
- d=2 常见吗?

易错点 以“越平稳越好”为目标不断差分。

Q016 Log / Box-Cox Transformation 为什么有用?

难度 ★★☆☆☆	频率 ★★★★☆	关键词 方差稳定、Box-Cox、log

一句话标准回答

对数或 Box-Cox 主要用于稳定方差、把乘性关系转为近似加性，并降低极端大值的影响。

核心公式 / 结构

$$w_t=(y_t^{\lambda}-1)/\lambda;\ \lambda\to 0 \text{ 时为 } \log(y_t)$$

深挖原理

变换后预测需要反变换；因为非线性，直接 exp(E[log Y]) 通常不是 E[Y]，若需要均值预测应考虑 bias adjustment。

面试官继续追问

- 为什么 log 后均值回变有偏?
- 含零值怎么办?

易错点 把变换与差分混为一谈。

Q017 Additive Seasonality 和 Multiplicative Seasonality 怎么判断?

难度 ★★☆☆☆ **频率** ★★★★☆ 关键词 加性、乘性、季节振幅

一句话标准回答

若季节振幅大致不随 level 改变，倾向加性；若 level 越高季节波动越大，倾向乘性。

核心公式 / 结构

$$\text{Additive: } y=T+S+R;\ \text{Multiplicative: } y=T\times S\times R$$

深挖原理

log 变换常把乘性结构转为加性结构。实践中不应只肉眼判断，还应通过残差和 out-of-sample 结果选择。

面试官继续追问

- 零值下 multiplicative 怎么办?
- ETS 中 error/trend/seasonal 如何组合?

易错点 以“增长型序列一定乘性”做机械判断。

Q018 STL 是什么?

难度 ★★★☆☆ **频率** ★★★★☆ 关键词 STL、LOESS、分解、robust

一句话标准回答

STL 用局部回归迭代估计趋势与季节，可允许季节模式缓慢变化，并提供 robust 选项降低异常点影响。

核心公式 / 结构

$$y_t=T_t+S_t+R_t$$

深挖原理

STL 是分解方法，不等价于完整预测模型。常见方案是 STL+ETS/ARIMA，或只在 residual 上做异常检测。

面试官继续追问

- STL 与 classical decomposition 区别?
- 多季节如何做 MSTL?

易错点 把 STL 本身说成“深度预测模型”。

Q019 Structural Break 会对模型造成什么影响?

难度 ★★★★☆	频率 ★★★★★	关键词 结构突变、regime、干预

一句话标准回答

结构突变意味着模型参数或数据生成机制改变，使用全历史平均参数可能造成系统性偏差。

核心公式 / 结构

$$P_{before}(Y|X) \neq P_{after}(Y|X)$$

深挖原理

方法包括 intervention dummy、change-point model、rolling window、regime switching、样本重加权。真正关键是先判断突变是一次性异常还是长期 regime change。

面试官继续追问

- 疫情数据该删掉还是保留?
- break 后窗口多长?

易错点 把 break 当普通 outlier 删除。

Q020 处理缺失值为什么会产生时间泄漏?

难度 ★★★★☆	频率 ★★★★★	关键词 缺失值、插值、泄漏、point-in-time

一句话标准回答

若用未来观测插值、用全局均值或全时期统计量拟合 imputer，就把未来信息带进训练或验证。

核心公式 / 结构

$$\text{Imputer}_t \text{ 只能使用 } I_t \text{ 信息集}$$

深挖原理

安全做法是把 imputer 作为 pipeline 的可训练组件，在每个 backtest fold 的训练窗重新拟合；生产环境还要模拟 publication lag 与 late-arriving data。

面试官继续追问

- ffill/bfill 哪个安全?
- 传感器缺失本身是不是特征?

易错点 离线先清洗全数据，再切 train/test。

高级加分点 把缺失值处理封装进每个 backtest fold 的 pipeline，是数据科学与真实生产之间非常关键的一步。

第 3 章

ARIMA、ETS 与状态空间模型

经典统计预测的核心：AR/MA、Box-Jenkins、SARIMA、ARIMAX、残差诊断、ETS 和 Kalman Filter。

本章面试目标 掌握 Q21-Q35。优先做到：定义准确、公式会解释、能指出失败模式，并能给出时间正确的验证方案。

Q021 推导 AR(1) 的均值、方差和 ACF。

难度 ★★★★☆ **频率** ★★★★★ **关键词** AR1、推导、平稳条件

一句话标准回答

对 $y_t=c+\phi y_{t-1}+\varepsilon_t$，在 $|\phi|<1$ 时可用无限展开得到稳定均值与方差，自相关按 ϕ 的幂指数衰减。

核心公式 / 结构

$$\mu=c/(1-\phi);\ Var=\sigma^2/(1-\phi^2);\ \rho_k=\phi^k$$

深挖原理

这是统计岗常见白板题。要说明 $|\phi|<1$ 是协方差平稳条件；$\phi<0$ 时 ACF 正负交替衰减。

面试官继续追问

- $\phi=1/-1$ 分别怎样?
- 如何估计 ϕ?

易错点 只背公式，不会从期望/方差递推推导。

Q022 AR(p) 的平稳条件是什么?

难度 ★★★★☆ **频率** ★★★★☆ **关键词** 特征根、AR 多项式

一句话标准回答

AR(p) 平稳要求 AR characteristic polynomial 的根都位于单位圆外。

核心公式 / 结构

$$\varphi(B)=1-\varphi_1B-\ldots-\varphi_pB^p$$

深挖原理

面试解释时可从 AR(1) 的 $|\phi|<1$ 类比到高阶情形。根靠近单位圆意味着长记忆和接近非平稳，参数估计也更不稳定。

面试官继续追问

- AR(2) 如何判断?
- 复根意味着什么?

易错点 只用“系数绝对值都小于 1”判断 AR(p)。

Q023 MA(q) 为什么需要 invertibility?

难度 ★★★★☆	频率 ★★★★☆	关键词 MA、可逆性、可识别

一句话标准回答

可逆性允许把 MA 写成收敛的无限 AR 形式，也让参数表示唯一可识别。

核心公式 / 结构

θ(B) roots outside unit circle

深挖原理

MA(1) 中不同 θ 可能对应相同二阶结构；约束可逆区间选择规范表示。

面试官继续追问

- MA(1) 可逆条件?
- 为何 MA 天然平稳?

易错点 把平稳条件与可逆条件混淆。

Q024 AR 和 MA 最大的直觉差异是什么?

难度 ★★☆☆☆	频率 ★★★★★	关键词 AR、MA、shock

一句话标准回答

AR 通过过去观测解释惯性，MA 通过过去未预测到的 shock 解释短期冲击传播。

核心公式 / 结构

AR:过去观测；MA:过去创新项

深挖原理

现实模型往往混合二者：AR 捕获持续性，MA 修正 residual autocorrelation。

面试官继续追问

- MA 的 ε 为什么可估计?
- AR∞ 与 MA∞ 的关系?

易错点 把 moving average 误解成普通滑动平均。

Q025 解释 ARIMA(p,d,q)。

难度 ★★★☆☆	频率 ★★★★★	关键词 ARIMA、p d q、Box-Jenkins

一句话标准回答

ARIMA 先通过 d 阶差分把非平稳 level 转为近似平稳序列，再用 AR(p)+MA(q) 建模其线性依赖。

核心公式 / 结构

$$\varphi(B)(1-B)^d y_t=\theta(B)\varepsilon_t$$

深挖原理

高分回答必须补一句：ARIMA 不只是“ACF/PACF 选阶”，还要做残差白噪声诊断和 out-of-sample rolling validation。

面试官继续追问

- ARIMA 与 ARMA 差别?
- drift 怎么加?

易错点 把 I 解释成“interpolation”。

Q026 如何选择 p,d,q?

难度 ★★★★☆	频率 ★★★★★	关键词 Box-Jenkins、AIC、残差

一句话标准回答

先确定最低必要 d，再用 ACF/PACF 给候选 p/q，利用 AICc/BIC 缩小候选，最后用残差白噪声和滚动回测决定。

核心公式 / 结构

识别→估计→诊断→回测

深挖原理

自动 ARIMA 的价值是搜索，但不能替代对异常、外生变量、结构突变和业务 horizon 的理解。

面试官继续追问

- AIC 最小为什么不一定 test 最好?
- 季节项怎么选?

易错点 只凭一张 ACF/PACF 图定最终模型。

高级加分点 最终模型选择应优先服从 out-of-sample 任务，而不是漂亮的 in-sample ACF/PACF。

Q027 SARIMA 是什么?

难度 ★★★☆☆ 频率 ★★★★★ 关键词 SARIMA、季节差分、季节 ARMA

一句话标准回答

SARIMA 在普通 ARIMA 外增加季节 AR、季节差分和季节 MA，周期 m 由采样频率和业务周期决定。

核心公式 / 结构

$$ARIMA(p,d,q)(P,D,Q)_m$$

深挖原理

乘法季节结构意味着普通与季节多项式相乘，可能生成组合 lag，例如 1 与 m 的交互项。

面试官继续追问

- 日数据 m=7 还是 365?
- 多重季节怎么办?

易错点 认为一个 SARIMA 只能有一个“真实周期”且其他周期忽略。

Q028 ARIMAX / SARIMAX 中 X 是什么?

难度 ★★★★☆ 频率 ★★★★★ 关键词 外生变量、未来可用性、动态回归

一句话标准回答

ARIMAX 把结构化协变量通过回归项解释，剩余误差再用 ARIMA 捕获自相关。

核心公式 / 结构

$$y_t=\beta^T x_t+n_t,\ n_t\sim ARIMA$$

深挖原理

关键不是“有哪些 X”，而是 forecast origin 时未来 X 是否可知。known-future（节假日、计划促销）和 unknown-future（真实天气、竞争者销量）必须区分。

面试官继续追问

- 未来 X 不知道怎么办?
- X 本身也有误差如何传播?

易错点 在验证时偷偷使用未来真实 X，线上却只能用预测 X。

高级加分点 业务系统必须为每个协变量维护 availability contract：event_time、available_time、revision_time。

Q029 如何判断 ARIMA 拟合完成?

难度 ★★★★☆ **频率** ★★★★★ 关键词 残差、白噪声、Ljung-Box

一句话标准回答

检查 residual mean、ACF、Ljung-Box、方差稳定性、异常点与分布；最重要的是 residual 是否还存在系统性可预测结构。

核心公式 / 结构

$$e_t=y_t-\hat{y}_t;\ \text{residual should resemble white noise}$$

深挖原理

残差近似正态不是点预测无偏的必要条件，但对基于高斯假设的区间与 likelihood 推断会影响更大。

面试官继续追问

- Ljung-Box H0 是什么?
- 残差非正态能用吗?

易错点 只看训练 RMSE 或 R^2。

Q030 AIC、BIC 和 Forecast Accuracy 有什么区别?

难度 ★★★☆☆ **频率** ★★★★★ 关键词 AIC、BIC、似然、泛化

一句话标准回答

AIC/BIC 是模型内基于 likelihood 与复杂度惩罚的选择准则；forecast accuracy 是未来未见数据上的实际误差。

核心公式 / 结构

$$AIC=-2\log L+2k;\ BIC=-2\log L+k\log n$$

深挖原理

AIC 更偏预测效率，BIC 惩罚更强且有模型选择一致性语境；但任何信息准则都不能替代真实 deployment-like backtest。

面试官继续追问

- AICc 为什么用于小样本?
- 不同数据变换的 AIC 可直接比吗?

易错点 把 AIC 当作“预测误差单位”。

Q031 ETS 是什么?

难度 ★★★☆☆ **频率** ★★★★★ 关键词 ETS、指数平滑、状态空间

一句话标准回答

ETS 把误差、趋势、季节分别指定为 additive/multiplicative/none，并可写成状态空间模型。

核心公式 / 结构

$$ETS(Error,Trend,Seasonality)$$

深挖原理

ARIMA 与 ETS 的建模视角不同：ARIMA 重点是差分后的 autocorrelation；ETS 直接更新 level/trend/seasonal states。两者都应保留为强 baseline。

面试官继续追问

- ETS(A,A,A) 如何解释?
- 什么时候 damped trend?

易错点 认为指数平滑只是“对数据加权平均”。

Q032 Simple Exponential Smoothing 的递推公式是什么?

难度 ★★☆☆☆ **频率** ★★★★☆ 关键词 SES、指数权重、level

一句话标准回答

SES 对最近观测权重大，历史权重指数衰减；适用于无明显趋势和季节的 level 序列。

核心公式 / 结构

$$\ell_t=\alpha y_t+(1-\alpha)\ell_{t-1}$$

深挖原理

展开递推可看到 y_{t-k} 的权重约为 α(1-α)^k。α 越大反应越快，但也更敏感噪声。

面试官继续追问

- α→1/0 分别怎样?
- 初始化怎么做?

易错点 把 SES 用于明显趋势数据且不做比较。

Q033 Holt 方法解决了什么问题?

难度 ★★☆☆☆ 频率 ★★★★☆ 关键词 Holt、level、trend

一句话标准回答

Holt 在 SES 基础上显式维护 level 和 trend，使预测可以外推趋势。

核心公式 / 结构

$$\hat{y}_{t+h|t}=\ell_t+hb_t$$

深挖原理

可加入 damped trend：长期把趋势增量逐步衰减，常比无限线性外推更稳健。

面试官继续追问

- 为什么趋势要 damp?
- Holt 与线性回归 trend 有何不同?

易错点 把短期趋势无限线性外推。

Q034 Holt-Winters 是什么?

难度 ★★★☆☆ 频率 ★★★★★ 关键词 Holt-Winters、季节

一句话标准回答

Holt-Winters 在 Holt level/trend 上加入季节状态，存在加性和乘性季节版本。

核心公式 / 结构

$$\text{level} + \text{trend} + \text{seasonal update}$$

深挖原理

面试要说明：它是一类强大、快速、可解释的 baseline，尤其适合单序列与清晰季节结构，不能因为有深度学习就跳过。

面试官继续追问

- 季节初值怎么给?
- multiplicative 对零值怎么办?

易错点 认为传统模型“不值得做”。

Q035 ARIMA 和 State Space Model 什么关系?

难度 ★★★★☆ **频率** ★★★★☆ 关键词 状态空间、Kalman、隐藏状态

一句话标准回答

很多 ARIMA/ETS 都能转成状态空间表示。状态空间把动态系统写成潜在状态转移和观测方程，Kalman Filter 递归完成 filtering 与 prediction。

核心公式 / 结构

$$x_t=Fx_{t-1}+w_t;\ y_t=Hx_t+v_t$$

深挖原理

状态空间的工程优势是自然处理缺失观测、时间变化状态和不确定性传播；扩展 Kalman/particle filter 还能处理非线性/非高斯。

面试官继续追问

- filtering vs smoothing?
- Kalman 假设?

易错点 把 Kalman Filter 说成“平滑噪声的移动平均”。

第 4 章

机器学习与大规模 Global Forecasting

把序列变成监督学习：lag/rolling/calendar、LightGBM、local vs global、冷启动、间歇需求与 ensemble。

本章面试目标 掌握 Q36-Q50。优先做到：定义准确、公式会解释、能指出失败模式，并能给出时间正确的验证方案。

Q036 如何把时间序列转换成监督学习问题?

难度 ★★☆☆☆	频率 ★★★★★	关键词 lag、窗口、监督学习

一句话标准回答

通过滑动窗口构造特征与标签，每个预测 origin 形成一个监督样本。

核心公式 / 结构

$$X_t=[y_{t-1},\ldots,y_{t-k},x_t],\ Y_t=y_t$$

深挖原理

最重要的是“特征时间戳与可用时间”而不是纯 shift：某些特征在 t 时点产生但 t+2 才发布，也不能用于 t 的预测。

面试官继续追问

- multi-step 标签怎么构造?
- 窗口长度如何选?

易错点 先在全量表上随意 rolling 再切数据。

Q037 Lag Features 怎么选择?

难度 ★★★☆☆	频率 ★★★★★	关键词 lag、季节、特征选择

一句话标准回答

应结合 ACF、业务周期、forecast horizon 和 validation 选择。对于日销量，lag1/7/14/28 往往比机械生成 1…1000 更有意义。

核心公式 / 结构

$$lags=\{1,2,7,14,28,\ldots\}$$

深挖原理

大量相邻 lag 对树模型虽可用，但会增加训练成本和共线；对高维 global data，要平衡表示能力与内存/延迟。

面试官继续追问

- 是否要包含 lag<forecast horizon?
- 缺失历史怎么处理?

易错点 只凭 ACF 选特征而忽略业务周期。

Q038 Rolling Features 最大的 leakage trap 是什么?

难度 ★★★★☆ 频率 ★★★★★ 关键词 rolling、shift、泄漏

一句话标准回答

预测 y_t 的 rolling 均值必须只由 t-1 及更早值计算。最常见错误是 rolling 后没 shift，窗口直接包含 y_t。

核心公式 / 结构

$$feature_t=rolling(y.shift(1),window)$$

深挖原理

安全原则可概括为“shift first, rolling second”；更严格时还要按 horizon shift，例如预测 H 步时根据 deployment pipeline 明确每个 lag 是否可得。

面试官继续追问

- rolling std/min/max 是否一样?
- EWM 如何防泄漏?

易错点 特征工程完成后才切 train/test。

高级加分点 代码审查时优先搜 rolling/expanding/ewm 以及 target aggregation，检查其前面是否正确 shift。

Q039 Calendar Features 有哪些?

难度 ★★☆☆☆ 频率 ★★★★☆ 关键词 日历、节假日、事件

一句话标准回答

常见日历特征包括小时、星期、月份、季度、月初/月末、节假日、工资日、开学季、促销事件等。

核心公式 / 结构

$$hour,\ dow,\ dom,\ month,\ holiday,\ payday\ldots$$

深挖原理

日历特征是 known-future，部署友好；但“weekday=1…7”存在人为序数含义，可用类别编码、sin/cos 或树模型分类处理。

面试官继续追问

- 春节这种移动节日怎么编码?

- 距节日天数有何价值?

易错点 只加 month/dow，不考虑业务事件。

Q040 如何编码周期性时间特征?

难度 ★★☆☆☆ **频率** ★★★★☆ **关键词** sin/cos、周期编码

一句话标准回答

用正余弦把周期变量映射到单位圆，使周期首尾相邻，例如 23:00 与 00:00 距离自然接近。

核心公式 / 结构

$$\sin(2\pi t/m),\ \cos(2\pi t/m)$$

深挖原理

对树模型，直接类别或整数也可能有效；sin/cos 更适合线性/神经模型，但不是唯一正确编码。

面试官继续追问

- 为什么需要两个维度?
- 一年 365/365.25 怎么办?

易错点 只用 sin 导致不同相位不可唯一表示。

Q041 什么是 Known Future Covariate?

难度 ★★★☆☆ **频率** ★★★★★ **关键词** 协变量、未来可用性

一句话标准回答

known-future 是预测时已经确定的未来变量，如日历、既定促销、计划价格；observed-past 只能看到历史。

核心公式 / 结构

$$x_{t+h} \text{ known at forecast origin}$$

深挖原理

这是 TFT、Chronos-2、现代 global forecasting 的核心数据契约。错误标记 covariate availability 会直接导致线上崩溃。

面试官继续追问

- 天气预报算 known future 吗?

- 计划价格临时变更怎么办?

易错点 验证阶段用未来真实值代替当时可获得的预测值。

Q042 Recursive、Direct、MIMO 多步预测有什么区别?

难度 ★★★★☆ **频率** ★★★★★ 关键词 多步、递归、Direct、MIMO

一句话标准回答

Recursive 只训练一步模型但会误差累积；Direct 为每个 horizon 训练独立模型；MIMO 一次输出整个 horizon 并可学习各步关联。

核心公式 / 结构

$$\text{Recursive: one-step repeated; Direct: } f_h\text{; MIMO: vector output}$$

深挖原理

还可以做 direct-recursive hybrid。实际选择取决于 horizon、数据量、推理成本以及未来 covariates 的形式。

面试官继续追问

- 为什么 recursive 训练/推理分布不一致?
- teacher forcing 相关吗?

易错点 只按“模型数量少”选择 recursive。

高级加分点 选择多步策略时同时考虑误差传播、模型数量、联合一致性和推理吞吐。

Q043 Random Forest 和 ARIMA 做趋势外推时有什么区别?

难度 ★★★★☆ **频率** ★★★★★ 关键词 树模型、外推、趋势

一句话标准回答

树模型对训练 target 范围外的线性外推通常弱；带 drift/trend 的 ARIMA 或回归可以显式延伸趋势。

核心公式 / 结构

$$\text{Tree prediction is piecewise constant in target regions}$$

深挖原理

但 RF/GBDT 在非线性、交互、类别和外生变量丰富时可能远强于 ARIMA。正确答案是比较 inductive bias，不是给绝对胜负。

面试官继续追问

- XGBoost 能否外推?
- 怎样给树模型加入趋势能力?

易错点 “树永远不能预测未来”这种错误绝对化。

Q044 LightGBM 做时间序列为什么如此常见?

难度 ★★★☆☆ **频率** ★★★★★ 关键词 LightGBM、global、结构化特征

一句话标准回答

LightGBM 能高效处理大量 lag/rolling/calendar/categorical-like 特征，特别适合成千上万 SKU/store 的 global forecasting。

核心公式 / 结构

$$\hat{y}=f(\text{lags},\text{rolling},\text{calendar},\text{price},\text{promo},\text{IDs})$$

深挖原理

工业优势还包括训练快、解释方便、missing value 友好、CPU inference 快。缺点是需人工设计时间特征，概率输出需 quantile/objective 或后处理。

面试官继续追问

- 为什么 M5 中 GBDT 强?
- 如何做 quantile LightGBM?

易错点 认为 GBDT 只能做 tabular，不能做时序。

Q045 Local Model 和 Global Model 有什么区别?

难度 ★★★★☆ **频率** ★★★★★ 关键词 local、global、cross-learning

一句话标准回答

Local 每条序列独立；Global 在大量相关序列间共享参数，利用 cross-learning 提升低数据量 series 的泛化。

核心公式 / 结构

$$\text{Local: one model per series; Global: shared } f \text{ across series}$$

深挖原理

Global model 尤其适合 retail、traffic、cloud metrics。挑战是不同尺度、异质性与 ID 泄漏，需要 scaling、static features 与合适采样。

面试官继续追问

- 什么时候 local 更好?
- global 如何避免大序列支配 loss?

易错点 简单认为“global 一定更强”。

高级加分点 Global model 的核心不是“一个模型省事”，而是跨序列共享统计强度。

Q046 Global Model 怎么告诉模型“这是哪个商品”?

难度 ★★☆☆☆ **频率** ★★★★☆ **关键词** 静态特征、embedding、ID

一句话标准回答

用 item/store/category/region 等静态特征或 embedding 表达序列身份；还可加入产品文本、图像、价格带等属性。

核心公式 / 结构

$$z_i=\text{Embedding}(\text{item_id})$$

深挖原理

ID embedding 能记住个体，但冷启动商品没有训练过 ID，因此应加入可泛化 metadata，不能只靠 ID。

面试官继续追问

- 新 ID embedding 怎么办?
- embedding 维度怎么选?

易错点 把 ID 当连续整数直接输入线性模型。

Q047 Cold Start 怎么解决?

难度 ★★★★☆ **频率** ★★★★★ **关键词** 冷启动、元数据、相似序列

一句话标准回答

新商品历史不足时，依靠 global model、category/brand/price、相似 SKU、层级先验、文本/图像 embedding、analogue forecasting 等迁移信息。

核心公式 / 结构

$$P(y_{new}|metadata, related\ series)$$

深挖原理

可以做 two-stage：先用 metadata 给初始 prior，随真实销量积累逐渐提高自身 lag 权重。还要区分“真正新品”和“店铺新上架但全网已有历史”。

面试官继续追问

- 新品没有任何 metadata 呢?
- 冷启动评估怎么构造?

易错点 随机划分导致同一商品历史泄漏，从而虚假解决 cold start。

高级加分点 冷启动评估要刻意留出完整未见实体，而不是随机留出该实体的一部分时间点。

Q048 Intermittent Demand 怎么预测?

难度 ★★★★☆ **频率** ★★★★★ 关键词 间歇需求、Croston、零膨胀

一句话标准回答

间歇需求大量为零，经典 Croston 将非零需求大小和需求间隔分别平滑；SBA/TSB 修正其偏差/发生概率。

核心公式 / 结构

$$Demand\ occurrence \times demand\ size$$

深挖原理

现代 global 模型可使用 hurdle/zero-inflated/negative binomial 分布。业务评价不应只用 MAPE，库存成本与 service level 更关键。

面试官继续追问

- Croston 为什么有偏?
- 零太多时 RMSE 有何问题?

易错点 把零销量一律当“无需求”，忽略缺货导致的 censored demand。

高级加分点 如果零销量来自缺货，目标本身被截断，应先解决 censored demand，而不是仅换成 Croston。

Q049 Promotion / Cannibalization 怎么建模?

难度 ★★★★☆ 频率 ★★★★☆ 关键词 促销、价格、替代、交叉效应

一句话标准回答

促销不仅改变自身销量，也会挤压替代品；单序列模型会漏掉 cross-item effects。

核心公式 / 结构

$$sales_i=f(own\ promo, competitor\ promo, category\ state, history)$$

深挖原理

可加入 own/competitor price、promo、category totals、cross-lags、product embeddings；若要回答“促销增量”而不是预测销量，还必须进入因果推断。

面试官继续追问

- 促销是外生的吗?
- 如何处理缺货干扰?

易错点 把促销相关性直接当 uplift。

Q050 为什么 Ensemble 经常有效?

难度 ★★★☆☆ 频率 ★★★★★ 关键词 组合、误差相关、stacking

一句话标准回答

若模型误差不完全相关，组合可降低方差和模型风险。简单平均往往就是很强 baseline。

核心公式 / 结构

$$Var(w\ e1+(1-w)e2)\ depends\ on\ error\ covariance$$

深挖原理

高级做法包括按 horizon/segment 学权重、stacking、动态 ensemble；但权重学习也必须做时间序列 CV，不能用 test。

面试官继续追问

- 如何求最优线性权重?
- 相关性很高还值得组合吗?

易错点 只比较单模型 leaderboard，不做组合。

高级加分点 组合的收益取决于误差协方差；两个几乎同构模型的简单平均收益可能很小。

第 5 章

深度学习预测模型

从 RNN/LSTM 到 DeepAR、N-BEATS、TFT、PatchTST、iTransformer、TimeMixer；同时保留“简单模型可能更强”的判断力。

本章面试目标 掌握 Q51-Q65。优先做到：定义准确、公式会解释、能指出失败模式，并能给出时间正确的验证方案。

Q051 RNN 为什么适合时序?

难度 ★★☆☆☆ 频率 ★★★★☆ 关键词 RNN、隐藏状态、序列

一句话标准回答

RNN 通过隐藏状态递归压缩历史，天然尊重顺序并可处理变长序列。

核心公式 / 结构

$$h_t=f(W_xx_t+W_hh_{t-1})$$

深挖原理

其缺点是长依赖梯度消失/爆炸、训练无法完全并行、长 horizon autoregressive inference 慢。

面试官继续追问

- BPTT 是什么?
- 为什么长序列困难?

易错点 认为 RNN 自动记住任意长历史。

Q052 LSTM 比 RNN 改进了什么?

难度 ★★★☆☆ 频率 ★★★★★ 关键词 LSTM、门控、cell state

一句话标准回答

LSTM 通过 cell state 和输入/遗忘/输出门，让信息与梯度更容易长期传播。

核心公式 / 结构

$$c_t=f_t⊙c_{t-1}+i_t⊙g_t$$

深挖原理

它缓解但不彻底消除长期依赖问题；对大规模 forecasting，global probabilistic objective 和 covariate design 往往比“换成 LSTM”更重要。

面试官继续追问

- GRU 与 LSTM 区别?
- forget gate 为何关键?

易错点 把 LSTM 说成完全没有梯度消失。

Q053 DeepAR 的核心思想是什么?

难度 ★★★★☆	频率 ★★★★★	关键词 DeepAR、global、概率预测

一句话标准回答

DeepAR 在大量相关序列上训练一个 autoregressive RNN，网络输出概率分布参数而不是单点值，再通过采样得到未来轨迹。

核心公式 / 结构

$$p(y_t|\text{history}, \text{covariates}) = p(y_t|\theta_t)$$

深挖原理

它把 global learning 与 probabilistic forecasting 结合。不同数据类型可选择 Gaussian、Student-t、Negative Binomial 等 likelihood。

面试官继续追问

- 为什么零售适合 NB?
- sampling 如何得到 quantile?

易错点 只把 DeepAR 说成“LSTM 预测器”。

Q054 N-BEATS 为什么特殊?

难度 ★★★★☆	频率 ★★★★☆	关键词 N-BEATS、backcast、forecast、残差

一句话标准回答

N-BEATS 用全连接残差 block，不依赖 RNN/attention；每个 block 同时输出 backcast 和 forecast，逐层解释剩余信号。

核心公式 / 结构

$$x \leftarrow x - \text{backcast};\ \hat{y} \leftarrow \hat{y} + \text{forecast}$$

深挖原理

interpretable 版本用趋势/季节 basis 约束输出，使 block 更可解释；generic 版本则完全学习 basis。

面试官继续追问

- 为什么 backcast 有用?
- 与 boosting 有何相似直觉?

易错点 误以为所有 N-BEATS 都有显式季节 basis。

Q055 N-HiTS 相比 N-BEATS 改了什么?

难度 ★★★★☆ 频率 ★★★★☆ 关键词 N-HiTS、多尺度、插值

一句话标准回答

N-HiTS 用多尺度下采样和分层插值，让不同 block 在不同频率上建模，提高长 horizon 的效率。

核心公式 / 结构

multi-rate sampling + hierarchical interpolation

深挖原理

直觉上低频层先捕获宏观趋势，高频层补细节，与多分辨率信号处理相似。

面试官继续追问

- 为什么更适合 long horizon?
- 下采样会丢信息吗?

易错点 只背模型名字，不会解释 multi-scale。

Q056 Temporal Fusion Transformer 为什么适合工业 forecasting?

难度 ★★★★★ 频率 ★★★★★ 关键词 TFT、多视界、协变量、可解释

一句话标准回答

TFT 明确区分静态变量、known-future 与 observed-past，含 variable selection、gating、局部 recurrent processing 和 interpretable attention，并常用 quantile loss。

核心公式 / 结构

static + known future + observed past → multi-horizon quantiles

深挖原理

它的强项不是“用了 Transformer”，而是输入语义设计非常贴近工业多视界预测。代价是结构复杂、调参和训练成本较高。

面试官继续追问

- VSN 如何解释变量重要性?

- attention 是否等于因果解释?

易错点 把 attention 权重直接解释为 causal importance。

高级加分点 TFT 适合工业的原因是数据角色划分，而不仅仅是 attention。

Q057 Transformer 做时间序列一定比简单模型好吗?

难度 ★★★★☆	频率 ★★★★★	关键词 baseline、DLinear、inductive bias

一句话标准回答

不一定。DLinear 等研究显示在部分 long-term benchmark 上，简单线性模型能显著击败当时复杂 Transformer。

核心公式 / 结构

$$\text{Complexity} \neq \text{accuracy}$$

深挖原理

真正高水平回答要强调 benchmark 设计、lookback、normalization、data leakage、模型容量与任务类型都会改变结论。因此所有复杂模型都必须对比 Naive/ETS/Linear/GBDT。

面试官继续追问

- 为何线性模型在周期趋势明显时很强?
- Transformer 何时更有优势?

易错点 “论文 SOTA = 生产更好”。

高级加分点 能主动说“我先跑 seasonal naive / linear / LightGBM”通常比直接说“大模型”更成熟。

Q058 DLinear 的思想是什么?

难度 ★★★☆☆	频率 ★★★★☆	关键词 DLinear、分解、线性

一句话标准回答

DLinear 先做移动平均式分解，再分别用线性层把历史映射到未来。

核心公式 / 结构

x=trend+seasonal; linear projections

深挖原理

它的重要价值是作为 sanity-check baseline：若复杂模型赢不了 DLinear，说明模型复杂度可能没有转化成有效 inductive bias。

面试官继续追问

- Linear/NLinear/DLinear 区别?
- 移动平均窗口怎么影响?

易错点 把 DLinear 当“传统线性回归”而不理解直接多步映射。

Q059 PatchTST 为什么 Patch?

难度 ★★★★☆	频率 ★★★★★	关键词 PatchTST、patch、channel independence

一句话标准回答

PatchTST 将连续子序列 patch 当 token，减少 attention token 数并让每个 token 保留局部上下文；channel-independent 共享权重处理各变量。

核心公式 / 结构

L points → roughly L/P tokens

深挖原理

patching 同时降低 $O(L^2)$ attention 成本并允许更长 lookback。要注意 patch length/stride 是重要超参数。

面试官继续追问

- patch overlap 有何作用?
- channel independence 会损失跨变量关系吗?

易错点 只说“像 ViT”不解释为什么适合时序。

Q060 iTransformer 的 “Inverted” 是什么?

难度 ★★★★☆	频率 ★★★★★	关键词 iTransformer、变量 token、跨变量注意力

一句话标准回答

传统时序 Transformer 把时间点/patch 当 token；iTransformer 把每个变量的整段历史表示成 token，让 attention 直接学习变量间关系。

核心公式 / 结构

$$token_i = embedding(X_{1:T}^{(i)})$$

深挖原理

时间维关系主要在每个 variate token 的前馈/投影中编码，而 attention 聚焦跨变量 correlation，特别适合高维 multivariate forecasting。

面试官继续追问

- 变量数很大时复杂度如何?
- 与 channel-independent 的 PatchTST 相反在哪?

易错点 把 inverted 理解成“时间倒序”。

Q061 Autoformer 解决什么问题?

难度 ★★★★☆	频率 ★★★★☆	关键词 Autoformer、分解、自相关

一句话标准回答

Autoformer 把趋势/季节分解嵌入网络，并用 Auto-Correlation 机制捕获周期子序列依赖，目标是提升长周期预测。

核心公式 / 结构

$$decomposition + auto\text{-}correlation\ mechanism$$

深挖原理

它代表了“为时序设计专门 attention/相关机制”的研究路线；后续工作也促使社区重新审视这些复杂机制是否真正必要。

面试官继续追问

- Auto-Correlation 与 self-attention 差异?
- 分解为何有帮助?

易错点 只记“Transformer 改进版”。

Q062 FEDformer 为什么进入频域?

难度 ★★★★☆ 频率 ★★★★☆ 关键词 FEDformer、Fourier、wavelet

一句话标准回答

FEDformer 假设很多序列在频域存在更稀疏的全局表示，通过 Fourier/Wavelet 增强模块结合分解建模长依赖。

核心公式 / 结构

time signal ↔ sparse frequency components

深挖原理

频域有利于周期信号，但对强非平稳、突变和局部事件，纯频域表示也有局限，因此通常与时域/分解结合。

面试官继续追问

- 傅里叶为何擅长周期?
- wavelet 优势是什么?

易错点 把频域稀疏性当所有数据都成立。

Q063 TSMixer / TiDE 告诉我们什么?

难度 ★★★☆☆ 频率 ★★★★☆ 关键词 MLP、attention 替代、效率

一句话标准回答

TSMixer、TiDE 表明多层感知机通过时间维与特征维 mixing，也能在多步预测中达到强性能，且训练/推理更轻。

核心公式 / 结构

simple mixing can be competitive

深挖原理

它们强化一个面试原则：模型选型应依据数据、延迟和验证，不要将 attention 视作时序任务的必要条件。

面试官继续追问

- 何时 MLP 更适合?
- covariates 如何注入?

易错点 把架构新颖性当性能来源。

Q064 TimeMixer 的核心思想是什么?

难度 ★★★★☆ **频率** ★★★★☆ **关键词** TimeMixer、多尺度、分解

一句话标准回答

TimeMixer 将序列构造成多个尺度，分解并混合不同频率/尺度的信息，使低频趋势和高频细节共同参与预测。

核心公式 / 结构

$$X^{(0)},X^{(1)},\ldots,X^{(K)} \text{ multiscale mixing}$$

深挖原理

本质是 multi-resolution inductive bias：长 horizon 关注宏观、短期波动关注细节。

面试官继续追问

- downsampling ratio 怎么选?
- 多尺度是否增加延迟?

易错点 只会描述“多尺度”，无法说明信息流。

Q065 为什么时序 normalization 比普通 ML 更棘手?

难度 ★★★★☆ **频率** ★★★★★ **关键词** scaling、RevIN、分布漂移

一句话标准回答

不同序列量纲差异巨大，且同一序列随时间 level/variance 也会变化。错误的全数据 normalization 会泄漏未来。

核心公式 / 结构

$$z=(x-\mu_{context})/\sigma_{context}$$

深挖原理

常见方案包括 per-series scale、context normalization、RevIN、robust scaling。模型输出需反变换，概率分布参数也要正确缩放。

面试官继续追问

- global model 如何避免大尺度 series 主导?
- RevIN 解决什么?

易错点 用全数据 mean/std 处理所有 folds。

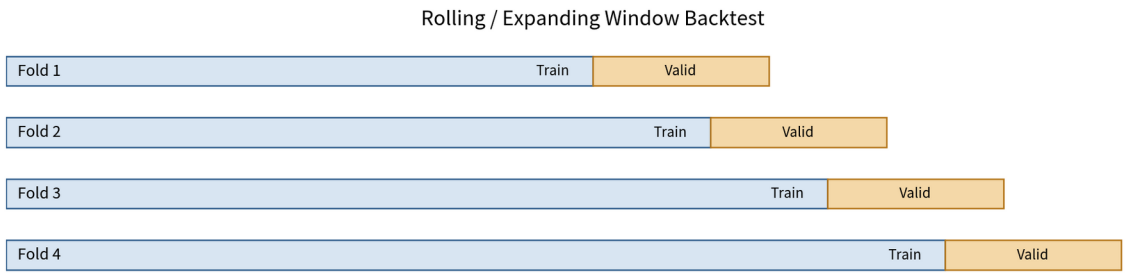
高级加分点 任何 normalization 都要明确统计量来自哪个时间窗，并在推理时能复现。

第 6 章

回测、指标与概率预测

高级面试分水岭：point-in-time correctness、rolling CV、MASE/RMSSE、quantile loss、CRPS、prediction interval 与非对称业务成本。

本章面试目标 掌握 Q66-Q78。优先做到：定义准确、公式会解释、能指出失败模式，并能给出时间正确的验证方案。



Q066 为什么不能 Random K-Fold?

难度 ★★★★☆ **频率** ★★★★★ 关键词 时间交叉验证、未来泄漏

一句话标准回答

随机 K-fold 让未来样本参与训练去预测过去，不符合真实预测的信息流，尤其在趋势与 drift 下会严重虚高。

核心公式 / 结构

$$\text{Train}_i \subset (-\infty, t_i],\ \text{Valid}_i \subset (t_i, \infty)$$

深挖原理

rolling-origin / expanding-window 是标准方案；如果 production 使用固定训练窗口，则 sliding-window backtest 更贴近真实。

面试官继续追问

- 时间序列分类能随机 split 吗?
- group+time 怎么切?

易错点 “只要不 shuffle 就是正确 CV”——还需检查重叠标签和实体泄漏。

高级加分点 回测方案本身就是模型的一部分；错误回测会系统性选择错误模型。

Q067 Expanding Window 和 Sliding Window 的区别?

难度 ★★★☆☆ **频率** ★★★★★ 关键词 expanding、sliding、drift

一句话标准回答

Expanding 持续累积历史，样本利用充分；Sliding 固定最近窗口，更能适应 concept drift。

核心公式 / 结构

$$\text{Expanding}:[1:t];\ \text{Sliding}:[t-W:t]$$

深挖原理

窗口长度是 bias-variance / stability-plasticity trade-off：太短方差高，太长旧 regime 污染。应通过 backtest 与 drift 特性选。

面试官继续追问

- 哪些业务适合 sliding?
- seasonality 要求窗口至少多长?

易错点 默认“历史越多越好”。

Q068 为什么必须按 Forecast Horizon 评估?

难度 ★★★★☆	频率 ★★★★★	关键词 horizon、误差曲线、多视界

一句话标准回答

不同 horizon 难度不同，平均一个指标会掩盖短期好、长期差或反之。

核心公式 / 结构

$$E(h)=\text{Metric}(\{\hat{y}_{t+h|t}\})$$

深挖原理

应输出 per-horizon metric 与加权业务指标；库存可能更重视 lead-time cumulative demand，而运营调度更重视近端 horizon。

面试官继续追问

- 如何加权 horizon?
- direct 模型是否每步都用同一 loss?

易错点 只报整体 RMSE。

Q069 常见 Data Leakage 有哪些?

难度 ★★★★★	频率 ★★★★★	关键词 泄漏、point-in-time、publication lag

一句话标准回答

常见泄漏：random split、rolling 含目标、全数据 scaler/encoder、future actual covariate、全时期聚合、后验修订数据、未来类别统计、publication delay 未模拟。

核心公式 / 结构

$$\text{Feature}(t) \text{ must be computable using data available by } t$$

深挖原理

高级面试要明确“event time ≠ availability time”。金融、宏观、供应链数据经常晚到或修订，必须维护 point-in-time feature store。

面试官继续追问

- target encoding 怎么防泄漏?
- revised macro data 怎么回测?

易错点 只把“用了未来 target”才叫泄漏。

高级加分点 point-in-time correctness 是高级时序工程面试最高频的隐性考点之一。

Q070 RMSE 和 MAE 有什么区别?

难度 ★★★☆☆ **频率** ★★★★★ 关键词 RMSE、MAE、异常值

一句话标准回答

MAE 线性惩罚，对异常误差更稳健；RMSE 平方惩罚，大误差权重更高。

核心公式 / 结构

$$MAE=mean|e|;\ RMSE=sqrt(mean\ e^2)$$

深挖原理

二者还对应不同统计目标：在理想条件下，最小化 MSE 对应条件均值，最小化 MAE 对应条件中位数。

面试官继续追问

- 业务成本非对称时怎么办?
- RMSE 可跨 series 比吗?

易错点 “RMSE 单位平方”——RMSE 开根后与原变量同单位。

Q071 MAPE 有什么致命问题?

难度 ★★★☆☆ **频率** ★★★★★ 关键词 MAPE、零值、偏置

一句话标准回答

真实值为 0 时不可定义，接近 0 时会爆炸；还会对低量级样本给予过高权重，并存在不对称偏好。

核心公式 / 结构

$$MAPE=mean\ |e/y|$$

深挖原理

零销量/间歇需求中应考虑 MASE/RMSSE、WAPE、quantile/business loss；WAPE 也有自身聚合偏好，不能万能。

面试官继续追问

- sMAPE 是否解决全部问题?
- MAPE 对 over/under forecast 是否对称?

易错点 为了指标稳定给 y 加 epsilon，却不解释指标含义已改变。

Q072 sMAPE 真的是完全 symmetric 吗?

难度 ★★★☆☆	频率 ★★★★☆	关键词 sMAPE、边界

一句话标准回答

sMAPE 让分母同时含真实值和预测值，缓解 MAPE 的部分不对称和尺度问题。

核心公式 / 结构

$$2|y-\hat{y}|/(|y|+|\hat{y}|)$$

深挖原理

但在接近零、符号变化、解释性方面仍有问题，“symmetric”不是说统计性质完美对称。

面试官继续追问

- $y=\hat{y}=0$ 怎么定义?
- 为什么竞赛常用 sMAPE?

易错点 把名称当性质证明。

Q073 为什么 MASE 很重要?

难度 ★★★★☆	频率 ★★★★★	关键词 MASE、scale-free、naive baseline

一句话标准回答

MASE 用 naive/seasonal naive 的历史误差作尺度，使不同量纲序列可比较，且避免 MAPE 的零值问题。

核心公式 / 结构

$$MASE=MAE_{model} / MAE_{naive_in\text{-}sample}$$

深挖原理

MASE<1 意味着优于所选 naive benchmark。季节序列应使用 seasonal naive denominator，否则基准不公平。

面试官继续追问

- 分母为 0 怎么办?
- 多序列如何聚合 MASE?

易错点 忘记说明 denominator 的 lag m。

高级加分点 跨 SKU 比较时 scale-free metric 很重要，但最终还要叠加业务权重。

Q074 RMSSE 是什么?

难度 ★★★☆☆ **频率** ★★★★☆ 关键词 RMSSE、M5、scaled error

一句话标准回答

RMSSE 是 squared-error 版本的 scaled metric，保持跨序列可比性并对大误差更敏感。

核心公式 / 结构

$$RMSSE=sqrt(MSE_{model} / MSE_{naive_scale})$$

深挖原理

M5 使用 WRMSSE 将层级不同节点按业务销售权重聚合，体现“metric 要反映业务价值”。

面试官继续追问

- WRMSSE 权重来自什么?
- 为什么不是 MAPE?

易错点 只记缩写，不理解 scaling denominator。

Q075 Quantile Loss 如何实现概率预测?

难度 ★★★★☆ **频率** ★★★★★ 关键词 quantile、pinball、P90

一句话标准回答

pinball loss 对低估和高估施加不同权重，使模型直接学习条件分位数 $q_\tau(x)$。

核心公式 / 结构

$$L_\tau=(\tau-1\{y<q\})(y-q)$$

深挖原理

τ=0.5 等价于 absolute loss 的中位数；τ 高时低估惩罚更大，适合缺货成本高的业务。多 quantile 时还需处理 quantile crossing。

面试官继续追问

- 如何避免 crossing?
- quantile 与 prediction interval 关系?

易错点 把 P90 解释成“90% 概率等于这个值”。

高级加分点 quantile loss 连接“概率预测”与“非对称业务成本”，是非常值得手推的题。

Q076 CRPS 是什么?

难度 ★★★★★ **频率** ★★★★☆ 关键词 CRPS、概率分布、proper score

一句话标准回答

CRPS 比较完整预测 CDF 与真实观测，兼顾 calibration 与 sharpness，是概率预测重要 proper scoring rule。

核心公式 / 结构

$$CRPS(F,y)=\int(F(z)-1\{z\geq y\})^2dz$$

深挖原理

对于退化点预测，CRPS 与 absolute error 有联系；样本型分布可通过经验公式估计。

面试官继续追问

- CRPS 与 NLL 区别?
- 为什么 proper scoring rule 重要?

易错点 只用 coverage 评价概率预测。

Q077 Prediction Interval 怎么评价?

难度 ★★★★☆ **频率** ★★★★★ 关键词 coverage、sharpness、校准

一句话标准回答

先看 90/95% interval 的 empirical coverage 是否接近 nominal，再看 interval width / sharpness；还应按 horizon 和 segment 检查。

核心公式 / 结构

$$\text{Coverage} \approx \text{nominal};\ \text{width should be small conditional on calibration}$$

深挖原理

区间过宽可轻易获得高 coverage，因此“校准 + 尽可能尖锐”才是目标。可用 interval score、Winkler score 或 CRPS 综合。

面试官继续追问

- 为什么远期区间应更宽?
- conformal prediction 如何用?

易错点 只报平均区间宽度或只报 coverage。

高级加分点 概率模型应同时检查 calibration 与 sharpness，任何单一维度都可能被投机。

Q078 如果缺货成本比库存成本高 5 倍，该用什么 loss?

难度 ★★★★★	频率 ★★★★★	关键词 非对称成本、newsvendor、quantile

一句话标准回答

当 under-forecast 成本远高于 over-forecast，应优化非对称损失，而不是 MSE。newsvendor 下最优订货点对应特定需求 quantile。

核心公式 / 结构

$$q^* = C_{under}/(C_{under}+C_{over})$$

深挖原理

若 $C_{under}=5C_{over}$，则临界分位约 $5/6 \approx 0.833$。真正生产还要加入 lead time、holding cost、service level、capacity constraints。

面试官继续追问

- 为什么条件均值不再最优?
- 如何把 forecast 连接库存优化?

易错点 模型指标与业务成本完全脱节。

高级加分点 预测不是决策终点；newsvendor 把需求分布映射成最优库存分位。

第 7 章

多变量、协整、层级与因果

VAR、Granger、cointegration、ECM、spurious regression、hierarchical reconciliation 和 forecasting vs causality。

本章面试目标 掌握 Q79-Q88。优先做到：定义准确、公式会解释、能指出失败模式，并能给出时间正确的验证方案。

Q079 VAR 是什么?

难度 ★★★★☆ 频率 ★★★★★ 关键词 VAR、多变量、参数爆炸

一句话标准回答

VAR 让每个变量由所有变量的历史共同解释，适合中低维相互作用序列。

核心公式 / 结构

$$Y_t=c+\Sigma A_iY_{t-i}+\varepsilon_t$$

深挖原理

参数约 $O(d^2p)$，维度上升迅速过拟合，因此常需 regularized VAR、Bayesian VAR 或降维。

面试官继续追问

- VAR 的平稳条件?
- 如何选 lag p?

易错点 高维数据直接套 VAR。

Q080 什么是 Granger Causality?

难度 ★★★★☆ 频率 ★★★★★ 关键词 Granger、预测因果、滞后

一句话标准回答

若加入 X 的历史显著提高对 Y 的预测，则称 X Granger-causes Y。它是预测性概念，不等价于干预因果。

核心公式 / 结构

X Granger-causes Y if X past improves prediction of Y beyond Y past

深挖原理

common cause、遗漏变量、同时性、错误 lag 都会造成误导。做检验前通常还需处理 stationarity/cointegration。

面试官继续追问

- 双向 Granger 怎么解释?
- 多变量下如何控制?

易错点 把“Granger causality”直接翻译成“X 导致 Y”。

Q081 什么是 Cointegration?

难度 ★★★★★	频率 ★★★★★	关键词 协整、I(1)、长期均衡

一句话标准回答

多个非平稳序列若存在某线性组合平稳，说明它们共享长期 equilibrium relationship。

核心公式 / 结构

$$x_t,y_t\sim I(1),\ y_t-\beta x_t\sim I(0)$$

深挖原理

协整允许“level 非平稳但组合有长期约束”，因此不能简单对所有变量一阶差分后丢掉长期信息。

面试官继续追问

- Engle-Granger 与 Johansen 区别?
- 协整秩是什么?

易错点 看高相关系数就说协整。

Q082 什么是 Spurious Regression?

难度 ★★★★☆	频率 ★★★★★	关键词 伪回归、非平稳、高 R^2

一句话标准回答

两个无关随机游走回归可能得到高 R^2、显著 t 值，原因是共同非平稳趋势破坏经典渐近推断。

核心公式 / 结构

independent random walks can produce significant OLS

深挖原理

解决思路是先检验平稳/协整，必要时差分或使用 ECM/VECM，而不是盲目 OLS levels。

面试官继续追问

- 为什么 Durbin-Watson 异常?
- 趋势回归是否都伪?

易错点 高 R^2 就认为关系真实。

Q083 Error Correction Model 为什么重要?

难度 ★★★★★	频率 ★★★★☆	关键词 ECM、短期、长期

一句话标准回答

ECM 同时建模短期变化与偏离长期均衡后的纠偏速度。

核心公式 / 结构

$$\Delta y_t=\alpha(y_{t-1}-\beta x_{t-1})+\gamma\Delta x_t+\varepsilon_t$$

深挖原理

α 通常应具有把系统拉回 equilibrium 的符号；VECM 是多变量协整系统的推广。

面试官继续追问

- α=0 表示什么?
- ECM 与差分回归相比多了什么?

易错点 只做差分导致长期关系完全丢失。

Q084 Cross-correlation 有什么坑?

难度 ★★★★☆	频率 ★★★★☆	关键词 互相关、趋势、lag

一句话标准回答

高 cross-correlation 可能由共同趋势、季节或自相关造成，不代表 X 真正领先 Y。

核心公式 / 结构

$$CCF(k)=Corr(x_t,y_{t+k})$$

深挖原理

常用 prewhitening 思路先移除自身 autocorrelation，再检查 cross-correlation；更稳健仍需多变量模型与业务时序逻辑。

面试官继续追问

- lead-lag 如何验证?
- sampling mismatch 怎么办?

易错点 直接在原始 trending series 上扫 lag。

Q085 什么是 Hierarchical Forecasting?

难度 ★★★★☆	频率 ★★★★★	关键词 层级、coherence、聚合

一句话标准回答

层级/分组时序要求不同聚合层预测一致，例如总销量必须等于地区/商品之和。

核心公式 / 结构

$$y_t = S\, b_t$$

深挖原理

独立预测每个节点通常不 coherent。reconciliation 用 summing matrix 把 base forecasts 投影到满足约束的空间。

面试官继续追问

- temporal hierarchy 是什么?
- cross-sectional hierarchy 呢?

易错点 只在最后简单归一化而不考虑误差结构。

高级加分点 hierarchy 的本质是线性约束空间，reconciliation 是对 base forecasts 的投影/校正。

Q086 Bottom-up、Top-down 和 MinT 有什么区别?

难度 ★★★★★	频率 ★★★★★	关键词 reconciliation、MinT

一句话标准回答

Bottom-up 只预测底层再聚合；Top-down 从总量按比例分配；MinT 根据 base forecast error covariance 寻找低方差的 coherent reconciliation。

核心公式 / 结构

$$\text{reconciled } \hat{y} = S\, G\, \hat{y}_{base}$$

深挖原理

MinT 的难点是 covariance estimation，节点多时需 shrinkage。它往往能利用各层 base forecast 的信息，而不是丢弃某层。

面试官继续追问

- 为何 top-down 可能损失底层信号?

- MinT-shrink 是什么?

易错点 认为 reconciliation 会自动提升每个节点准确率。

高级加分点 MinT 的优势来自利用所有层级 base forecasts 与误差协方差，而非只信某一层。

Q087 一个序列同时有日、周、年周期怎么办?

难度 ★★★★☆	频率 ★★★★★	关键词 多重季节、MSTL、TBATS、Fourier

一句话标准回答

单季节 SARIMA 很难表示多重周期，可用 Fourier terms + dynamic regression、TBATS、MSTL、calendar features 或现代 global/deep models。

核心公式 / 结构

$$m=\{24,168,8766...\}$$

深挖原理

选择方法时要考虑周期是否整数、是否随时间变化以及历史长度是否足以识别长周期。年周期至少需要多个完整年度才可靠。

面试官继续追问

- 小时电力数据如何建?
- 节假日算季节吗?

易错点 只有一年历史却强行拟合年季节。

Q088 Forecasting 与 Causal Inference 有什么区别?

难度 ★★★★★	频率 ★★★★★	关键词 预测、因果、do-operator

一句话标准回答

预测回答“会发生什么”，因果回答“如果主动改变 X 会怎样”。高预测相关不代表干预有效。

核心公式 / 结构

$$\text{Forecast:}E[Y_{future}|history];\ \text{Causal:}E[Y|do(X=1)]-E[Y|do(X=0)]$$

深挖原理

例如促销常在高需求时安排，模型会学到 promo 与 sales 高度相关，但这不等于促销造成全部增量。uplift/政策决策需要因果设计。

面试官继续追问

- 预测模型能用于决策吗?
- 什么时候结构模型结合 forecast?

易错点 把 feature importance 当 causal effect。

高级加分点 如果问题从“预测销量”变成“促销是否值得做”，任务已经从 forecasting 转向 causal decision。

第 8 章

异常检测、变化点与漂移

从 residual anomaly 到 change point 和 concept drift，强调线上监控如何拆分 horizon/segment。

本章面试目标 掌握 Q89-Q93。优先做到：定义准确、公式会解释、能指出失败模式，并能给出时间正确的验证方案。

Q089 Point、Contextual 和 Collective Anomaly 有何区别?

难度 ★★★☆☆	频率 ★★★★☆	关键词 异常类型、上下文

一句话标准回答

Point anomaly 是单点异常；contextual anomaly 只在特定季节/上下文异常；collective anomaly 是一段模式整体异常。

核心公式 / 结构

point vs contextual vs collective

深挖原理

时间序列异常检测必须把季节与趋势剥离，否则每周高峰可能被错误报警。

面试官继续追问

- 35°C 什么时候异常?
- collective anomaly 举例?

易错点 只用全局 z-score。

Q090 如何利用 STL 做异常检测?

难度 ★★★☆☆	频率 ★★★★☆	关键词 STL、残差、MAD

一句话标准回答

先用 STL 提取趋势与季节，再对 remainder 做 robust threshold，可减少季节性导致的误报。

核心公式 / 结构

r_t=y_t-T_t-S_t; z_robust=(r-med)/1.4826MAD

深挖原理

生产上要防 STL 使用未来信息：在线异常检测应使用 causal/rolling decomposition 或只在已发生历史上更新。

面试官继续追问

- 为什么 MAD 比 std 稳健?
- 异常会污染 trend 吗?

易错点 用双向平滑分解做实时告警评估。

Q091 Change Point Detection 和 Anomaly Detection 有何不同?

难度 ★★★★☆ 频率 ★★★★★ 关键词 变化点、regime、CUSUM

一句话标准回答

异常通常是短暂偏离；change point 表示均值、方差或整个生成机制在某时点后持续改变。

核心公式 / 结构

$$\text{distribution parameter } \theta \text{ changes at } \tau$$

深挖原理

检测到 change point 后通常需要重估模型或切换 regime，而不是简单删除该点。

面试官继续追问

- PELT/CUSUM 区别?
- 渐变 drift 与 abrupt break?

易错点 把长期 level shift 当成一串 outliers。

Q092 Concept Drift 怎么处理?

难度 ★★★★☆ 频率 ★★★★★ 关键词 drift、retraining、window

一句话标准回答

监控 feature/target/residual/calibration drift，并通过滑动窗口、重训练、样本加权、regime model 或 ensemble switching 适应。

核心公式 / 结构

$$P_t(Y|X) \text{ changes over time}$$

深挖原理

drift detection 不应只看输入分布；如果 X drift 但条件关系稳定，模型未必坏。真正关心的是 forecast error 与 business impact。

面试官继续追问

- 多久重训?
- data drift 与 concept drift 区别?

易错点 “PSI 大就立刻重训”这种机械规则。

高级加分点 监控 drift 最终要落到 residual / business loss，而不是仅比较输入分布。

Q093 生产环境为什么只监控 RMSE 不够?

难度 ★★★★☆	频率 ★★★★★	关键词 监控、分群、bias、coverage

一句话标准回答

整体 RMSE 会掩盖局部失败。应按 horizon、地区、SKU 类别、业务权重看 MAE/bias/coverage，同时监控数据新鲜度、缺失率、延迟和 feature drift。

核心公式 / 结构

$$\text{Monitor metric} \times \text{horizon} \times \text{segment} \times \text{time}$$

深挖原理

对概率预测还要监控 quantile coverage；对库存预测要看 underforecast rate 和 service level，而非仅预测误差。

面试官继续追问

- 如何设置告警阈值?
- 真实 target 延迟到账怎么办?

易错点 一个全局 dashboard 数值代表全部健康。

第 9 章

工业系统设计题

销量预测系统、百万 SKU-store、离线好线上差：把建模能力落到系统与业务决策。

本章面试目标 掌握 Q94-Q96。优先做到：定义准确、公式会解释、能指出失败模式，并能给出时间正确的验证方案。

Q094 设计一个完整的销量预测系统。

难度 ★★★★★ 频率 ★★★★★ 关键词 系统设计、销量、回测、部署

一句话标准回答

先澄清预测粒度、horizon、更新频率、库存/补货决策和成本；再定义 point-in-time 数据集，建立 seasonal naive/ETS/GBDT baseline，做 rolling backtest，输出 quantiles，最后接入库存策略和监控。

核心公式 / 结构

Objective→Data→Baseline→Backtest→Model→Uncertainty→Decision→Monitoring

深挖原理

高级答案会区分 demand 与 observed sales（缺货会 censor demand）、known-future promo、价格计划、商品层级，并设计 champion/challenger 与重训练机制。

面试官继续追问

- 目标是销量还是真实需求?
- 新品怎么办?
- 促销未来可知吗?
- 库存约束怎么结合?

易错点 一上来选 LSTM/TFT，没有业务定义和基线。

高级加分点 系统设计题的第一句话应是“先确认预测对象、horizon、粒度和决策成本”。

Q095 你有 100 万个 SKU-store series，怎么建模?

难度 ★★★★★ 频率 ★★★★★ 关键词 大规模、global、分层、特征存储

一句话标准回答

优先考虑 global GBDT/深度模型而非百万个独立模型；统一构造 lag/rolling/calendar/price/promo/static features，按系列 scaling，分布式训练与批推理。

核心公式 / 结构

shared global model + batch inference + reconciliation

深挖原理

系统层面需要 point-in-time feature store、缺失与冷启动策略、层级 reconciliation、quantile 输出、分批调度、模型版本与数据版本追踪。

面试官继续追问

- 如何采样避免大店主导?
- 百万 series 的 backtest 成本?
- 模型如何分片?

易错点 “一个模型吃全部”但没有处理异质尺度/数据倾斜。

高级加分点 百万序列问题首先是 data/compute/system problem，其次才是单个模型结构问题。

Q096 如何 Debug 一个“离线 RMSE 极好，上线完全失效”的 forecasting pipeline?

难度 ★★★★★	频率 ★★★★★	关键词 debug、train-serving skew、泄漏

一句话标准回答

按顺序排查：时间泄漏；特征 availability/publication lag；离线与线上计算不一致；模型输入分布漂移；标签延迟/修订；评估 horizon 与业务目标不匹配。

核心公式 / 结构

$$\text{Leakage} \rightarrow \text{availability} \rightarrow \text{skew} \rightarrow \text{drift} \rightarrow \text{objective mismatch}$$

深挖原理

建议做“time-travel replay”：选历史预测时点，用当时可见快照完整重放 pipeline，并逐特征比对 offline/online values。

面试官继续追问

- 如果线上只有某些 SKU 失效?
- 如何自动化数据契约检查?

易错点 直接重训更大模型，而不查数据。

高级加分点 历史时点重放（time-travel replay）是定位 offline-online 差异非常有效的方法。

第 10 章

Time-Series Foundation Models

TimesFM、Chronos、Moirai 等 zero-shot / universal forecasting 体系，以及 2026 年多变量与协变量能力演进。

本章面试目标 掌握 Q97-Q100。优先做到：定义准确、公式会解释、能指出失败模式，并能给出时间正确的验证方案。

Q097 什么叫 Time-Series Foundation Model?

难度 ★★★★★	频率 ★★★★★	关键词 TSFM、zero-shot、预训练

一句话标准回答

时序基础模型在跨领域、跨频率的大规模序列上预训练一个共享模型，目标是在未见数据上 zero-shot/few-shot forecasting。

核心公式 / 结构

$$D_1+\ldots+D_N \rightarrow \text{pretrain } M \rightarrow \text{zero/few-shot forecast}$$

深挖原理

核心难点是尺度、频率、变量数、horizon、covariates 和预训练/评测污染。与语言模型不同，连续值 tokenization/patching 和概率输出设计尤其关键。

面试官继续追问

- zero-shot 为什么可能赢 task-specific?
- 如何检查 benchmark leakage?

易错点 把“foundation model”理解成“参数很大”。

高级加分点 TSFM 的核心价值是跨数据集预训练后产生迁移能力，而不是参数规模本身。

Q098 TimesFM、Chronos、Moirai 的思想有什么不同?

难度 ★★★★★	频率 ★★★★★	关键词 TimesFM、Chronos、Moirai、tokenization

一句话标准回答

TimesFM 路线强调 patch-based decoder/大规模预训练；原始 Chronos 将数值缩放量化成 token 并借鉴语言模型，Chronos-2 进一步统一单/多变量与协变量 quantile forecasting；Moirai 面向跨频率、可变变量数和概率分布的 universal forecasting。

核心公式 / 结构

$$\text{TimesFM: patches; Chronos: TS tokenization/encoder variants; Moirai: universal multivariate design}$$

深挖原理

比较时不要只看参数量：输入表示、是否支持 covariates/multivariate、输出分布、上下文长度、推理吞吐与训练数据覆盖更关键。

面试官继续追问

- Chronos-2 与原始 Chronos 的结构变化?
- Moirai 2.0 为何 decoder-only?

易错点 用旧版模型能力描述 2026 新版。

高级加分点 2026 年比较 TSFM 必须核对版本；Chronos-2 与原始 Chronos、Moirai 2.0 与早期 Moirai 架构能力都已变化。

Q099 Foundation Model 会不会淘汰 ARIMA / LightGBM?

难度 ★★★★★ **频率** ★★★★★ **关键词** 模型选择、基线、成本

一句话标准回答

不会。清晰单序列季节模式下 ETS/ARIMA 便宜稳定；百万结构化 series 的 LightGBM 仍有强工程优势；TSFM 在 zero-shot、跨域和冷启动上很有吸引力。

核心公式 / 结构

$$\text{Choose by accuracy + calibration + latency + cost + robustness}$$

深挖原理

成熟团队会构建 model ladder：SeasonalNaive→Classical→Global ML→Deep→TSFM，在同一 point-in-time backtest 上比较，并考虑推理成本和可解释性。

面试官继续追问

- 何时 foundation model 最有价值?
- 如何做 fallback?

易错点 “最新模型必须替换传统模型”。

高级加分点 模型体系应设计 fallback 与 champion/challenger，不应“一次性迁移”到单一 foundation model。

Q100 2026 前沿：TimesFM-3 相比 TimesFM-2.5 真正解决了什么?

难度 ★★★★★ **频率** ★★★★★ **关键词** TimesFM-3、多变量、协变量、

non-autoregressive

一句话标准回答

Google Research 2026-08-31 发布的 TimesFM-3 将 TimesFM 从此前严格的 univariate 体系推进到 multivariate forecasting，支持多 target、past covariates、known past/future covariates，并在单次 forward 中进行多视界预测。

核心公式 / 结构

multivariate targets + covariates + single-forward multi-horizon

深挖原理

关键架构直觉是同时处理 temporal 与 variate interactions，并避免逐 patch autoregressive decode 带来的误差累积和延迟。面试应同时指出：最新模型仍需与强 baseline 做 point-in-time backtest，并警惕预训练数据与 benchmark overlap。

面试官继续追问

- single-forward decode 的利弊?
- 多变量 attention 复杂度?
- 协变量未来可用性如何保证?

易错点 只背“330M/1T points”等数字，不解释能力边界与评估。

高级加分点 TimesFM-3 的真正面试价值在“multivariate + covariates + single-forward”能力跃迁，而不只是最新发布日期。

附录 A：30 道最高优先级题目

01. Q001 什么是时间序列？它与普通 IID 数据最大的区别是什么？
02. Q003 White Noise 和 Random Walk 有什么区别？
03. Q005 ACF 和 PACF 有什么区别？
04. Q007 什么叫平稳？
05. Q011 什么是 Unit Root？
06. Q012 ADF Test 在检验什么？
07. Q014 为什么做 Differencing？
08. Q021 推导 AR(1) 的均值、方差和 ACF。
09. Q025 解释 ARIMA(p,d,q)。
10. Q026 如何选择 p,d,q？
11. Q027 SARIMA 是什么？
12. Q028 ARIMAX / SARIMAX 中 X 是什么？
13. Q029 如何判断 ARIMA 拟合完成？
14. Q031 ETS 是什么？
15. Q036 如何把时间序列转换成监督学习问题？
16. Q037 Lag Features 怎么选择？
17. Q038 Rolling Features 最大的 leakage trap 是什么？
18. Q042 Recursive、Direct、MIMO 多步预测有什么区别？
19. Q043 Random Forest 和 ARIMA 做趋势外推时有什么区别？
20. Q045 Local Model 和 Global Model 有什么区别？
21. Q050 为什么 Ensemble 经常有效？
22. Q066 为什么不能 Random K-Fold？
23. Q069 常见 Data Leakage 有哪些？
24. Q070 RMSE 和 MAE 有什么区别？
25. Q071 MAPE 有什么致命问题？
26. Q073 为什么 MASE 很重要？
27. Q077 Prediction Interval 怎么评价？
28. Q078 如果缺货成本比库存成本高 5 倍，该用什么 loss？
29. Q094 设计一个完整的销量预测系统。
30. Q096 如何 Debug 一个“离线 RMSE 极好，上线完全失效”的 forecasting pipeline？

冲刺方法 第一遍只练 20 秒口答；第二遍补公式；第三遍让自己回答每题的“易错点”和“追问”。如果 30 题能稳定回答到第三层，已覆盖大多数核心时序面试框架。

附录 B：Python 时间正确性代码模板

1. 防泄漏 rolling 特征

```
# 预测 y_t：窗口必须截止到 t-1
df['lag_1'] = df.groupby('series_id')['y'].shift(1)
df['roll_mean_7'] = (
    df.groupby('series_id')['y']
      .shift(1)
      .rolling(7)
      .mean()
      .reset_index(level=0, drop=True)
)
```

2. Expanding-window backtest 伪代码

```
for cutoff in cutoffs:
    train = data[data.time <= cutoff]
    valid = data[(data.time > cutoff) &
                 (data.time <= cutoff + horizon)]
    pipeline.fit(train)        # scaler/imputer/model 全部只 fit train
    pred = pipeline.predict(valid)
    evaluate(valid.y, pred, by_horizon=True)
```

3. Quantile loss

```
def pinball(y, q, tau):
    e = y - q
    return max(tau * e, (tau - 1) * e)
```

4. Point-in-time feature contract

```
feature_row = {
    'event_time': ...,         # 事件发生时间
    'available_time': ...,     # 系统实际可使用时间
    'revision_time': ...,      # 后续修订时间
    'value': ...
}
# 回：只允 available_time <= forecast_origin
```

参考资料与延伸阅读

[1] Hyndman, R. J. & Athanasopoulos, G.. Forecasting: Principles and Practice (3rd ed.). OTexts. https://otexts.com/fpp3/

[2] Salinas et al.. DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks. International Journal of Forecasting, 2020. https://www.sciencedirect.com/science/article/pii/S0169207019301888

[3] Lim et al.. Temporal Fusion Transformers for Interpretable Multi-horizon Time Series Forecasting.
https://arxiv.org/abs/1912.09363

[4] Oreshkin et al.. N-BEATS: Neural Basis Expansion Analysis for Interpretable Time Series Forecasting.
https://arxiv.org/abs/1905.10437

[5] Nie et al.. A Time Series is Worth 64 Words: Long-term Forecasting with Transformers (PatchTST).
https://arxiv.org/abs/2211.14730

[6] Zeng et al.. Are Transformers Effective for Time Series Forecasting? AAAI 2023.
https://ojs.aaai.org/index.php/AAAI/article/view/26317

[7] Liu et al.. iTransformer: Inverted Transformers Are Effective for Time Series Forecasting. ICLR 2024.
https://openreview.net/forum?id=JePfAI8fah

[8] Amazon. Chronos-2 model card (2026): univariate, multivariate and covariate-informed zero-shot forecasting.
https://huggingface.co/amazon/chronos-2

[9] Salesforce. Moirai 2.0 (2025): decoder-only universal time-series forecasting update.
https://www.salesforce.com/blog/moirai-2-0/

[10] Google Research. TimesFM-3: A zero-shot foundation model for multivariate forecasting, Aug 31 2026.
https://www.research.google/blog/timesfm-3-a-zero-shot-foundation-model-for-multivariate-forecasting/

关于“真题”来源

公开面经用于确认某些题型确实出现在真实招聘流程中，例如 ARIMA / unit root、RMSE vs MAE、随机森林与 ARIMA 比较、时间序列系统设计、数据泄漏与冷启动等。公开面经可能存在记忆偏差或页面变更，因此本书不把未经官方确认的逐字描述标成“某公司原题”，而把它们作为题型证据；标准答案来自可验证的统计与 forecasting 原理。